



云南民族大学学报(自然科学版)

Journal of Yunnan Minzu University(Natural Sciences Edition)

ISSN 1672-8513,CN 53-1192/N

《云南民族大学学报(自然科学版)》网络首发论文

题目：低秩矩阵分解与时序建模融合的无人机执行器故障诊断方法
作者：许兆宋，刘久富，汪超，杨欣，周大可，范胜林
网络首发日期：2025-09-01
引用格式：许兆宋，刘久富，汪超，杨欣，周大可，范胜林. 低秩矩阵分解与时序建模融合的无人机执行器故障诊断方法[J/OL]. 云南民族大学学报(自然科学版). <https://link.cnki.net/urlid/53.1192.n.20250829.1428.010>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

低秩矩阵分解与时序建模融合的无人机执行器故障诊断方法

许兆宋, 刘久富*, 汪超, 杨欣, 周大可, 范胜林

(南京航空航天大学 自动化学院, 江苏 南京 211100)

摘要: 针对飞行数据冗余和高维特性导致数据驱动的无人机执行器故障诊断准确率低、效率低等问题, 提出一种基于贝叶斯概率矩阵分解和长短期记忆网络模型的故障诊断方法 (BMF-LSTM), 旨在提高执行器故障检测准确性和效率。首先最大化以低秩矩阵向量为隐变量的变分下界, 并通过变分推断求解隐变量的近似后验分布, 从而估计飞行数据矩阵的低秩分解值; 其次, 引入后验一阶矩和二阶矩, 将高维矩阵的贝叶斯参数估计转化为矩的代数运算, 并自适应稀疏估计隐变量; 最后, 在估计隐变量后验后以低秩负载矩阵作为故障特征数据集, 并利用 LSTM 网络构建无人机执行器故障诊断模型。在 ALFA 无人机飞行数据集上对所提方法和其他方法进行对比, 结果表明, 基于 BMF-LSTM 模型的故障诊断方法准确率高, 响应速度快。

关键词: 模式识别; 故障诊断; 贝叶斯统计推断; 矩阵分解; 长短期记忆网络; 后验矩

中图分类号: TP181

UAV actuator fault diagnosis method based on low rank matrix factorization and time series modeling

XU Zhao-song, LIU Jiu-fu*, WANG Chao, YANG Xin, ZHOU Da-ke, FAN Sheng-lin

(College of Automation, Nanjing University of Aeronautics and Astronautics, Nanjing Jiangsu 211100, China)

Abstract: To address the issues of low accuracy and efficiency in data-driven fault diagnosis for UAV actuators, which are caused by the redundancy and high-dimensional characteristics of flight data, a fault diagnosis method based on Bayesian probabilistic matrix factorization and long short-term memory network model (BMF-LSTM) is proposed. This method aims to improve the accuracy and efficiency of actuator fault detection. First, the variational lower bound with low-rank matrix vectors as hidden variables is maximized, and the approximate posterior distribution of hidden variables is solved through variational inference to estimate the low-rank factorization values of the flight data matrix. Second, the first and second moments of the posterior are introduced to transform the Bayesian parameter estimation of high-dimensional matrices into algebraic operations of moments, and the hidden variables are adaptively and sparsely estimated. Finally, after estimating the posterior of hidden variables, the low-rank load matrix is used as the fault feature dataset, and an LSTM network is employed to construct the UAV actuator fault diagnosis model. The proposed method is compared with other methods on the ALFA UAV flight dataset. The results show that the BMF-LSTM model-based fault diagnosis method features high accuracy and fast response speed.

Key words: pattern recognition; fault diagnosis; Bayesian statistical inference; matrix factorization; long short-term memory network; posterior moment

0 引言

近年来无人机在各领域发挥着越来越重要的作用, 作为保障无人机安全运行的核心环节, 无人机故障诊断^[1-3]不仅是避免事故的“防火墙”, 更是推动无人机产业可持续发展的关键技术。当前, 故障诊断方法主要分为三类: 基于专家经验的先验推理方法^{[4][5]}、基于机理建模的仿真分析方法^{[6][7]}以及基于数据驱动

的挖掘分析方法^[8]。先验推理方法需建立过往经验形成的故障知识库, 但是无人机系统故障形式多样, 专家知识难以考虑到所有潜在故障模式, 因此漏检、错检; 仿真分析方法要求准确建立无人机系统模型, 模型可移植性差而且容易受到外界环境因素干扰; 相较而言, 数据驱动方法不需要专家知识也不用明确无人机系统内部机理模型, 而是直接挖掘传感器数据, 通过数据与故障的关联特性分析系统故障模式。

基金项目: 国家自然科学基金资助项目 (61473144)

作者简介: 第一作者: 许兆宋 (1998-), 男, 河南南阳人, 硕士研究生, 主要研究方向为机器学习、大数据分析等; 通信作者: 刘久富 (1970-), 男, 江苏淮安人, 硕导, 博士, 主要研究方向为机器学习、贝叶斯网络建模等, liujiufu4@126.com.

随着高性能计算机和人工智能的快速发展, 数据驱动故障诊断方法得到越来越广泛的应用。文献[9]提出了一种基于隐半马尔可夫模型的异常事件检测算法, 算法引入持续时间变量, 能够捕捉飞行员动作的时间间隔特性, 并通过计算序列的联合似然与条件概率实现故障诊断, 进而预防航空安全事件的发生。文献[10]提出了一种基于主动学习和改进半监督支持向量机的无人机故障诊断方法, 调整分类边界至样本低密度区域, 并结合聚类假设优化边界置信度, 显著提高了故障诊断的准确率。文献[11]提出了一种基于多变量状态估计和DBSCAN聚类算法的群组无人机故障诊断方法, 利用多变量状态估计技术构建正常飞行状态的记忆矩阵, 通过相似性度量计算观测值与估计值的残差, 实现无监督故障诊断。文献[12]提出一种用于无人机飞行数据的STC-LSTM故障诊断框架, 将全连接神经网络相关性分析方法作为参数选择基础, 利用历史数据建立多参数间的时空映射关系, 并结合 3σ 原则判定故障。

然而伴随智能飞控系统的发展, 机载传感网络规模越来越大, 高维传感数据包含大量冗余特征和噪声导致故障诊断准确率降低, 故障漏报、错报; 依赖于距离度量、聚类或最近邻搜索的故障诊断算法在高维空间中也变得更加耗时; 高维数据通常包含更多的潜在特征, 现有故障诊断方法捕捉故障数据潜在特征结构和提取关键特征的能力有限。为了克服上述挑战, 本文提出一种融合贝叶斯矩阵分解^{[13][14]} (Bayesian Matrix Factorization, BMF) 和长短期记忆网络 (Long Short-Term Memory, LSTM) 的故障诊断方法。

1 相关理论

1.1 贝叶斯矩阵分解

矩阵分解乘法模型^[17]为:

$$Y = LF + E \quad (1)$$

其中 Y 表示 $n \times p$ 的观测数据矩阵; L 表示 $n \times K$ 的负载矩阵; F 表示 $K \times p$ 的因子矩阵; E 表示 $n \times p$ 的随机误差项。

将负载矩阵和因子矩阵秩为 K 情况下的贝叶斯矩阵分解模型定义如下:

$$Y = \sum_{k=1}^K l_k f_k + E \quad (2)$$

$$l_{k1}, \dots, l_{kn} \sim \text{iid } g_{l_k}, \quad g_{l_k} \in \mathcal{G}_l \quad (3)$$

$$f_{k1}, \dots, f_{kp} \sim \text{iid } g_{f_k}, \quad g_{f_k} \in \mathcal{G}_f \quad (4)$$

$$E_{ij} \sim N(0, 1/\tau_{ij}), \quad \tau := (\tau_{ij}) \in \mathcal{T} \quad (5)$$

其中 l_k 是 L 的第 k 组 n 维列向量, 服从独立同分布的待估计先验分布 g_{l_k} ; f_k 是 F 的第 k 组 p 维行向量, 服从独立同分布的待估计先验分布 g_{f_k} ; $\mathcal{G}_l$ 和 $\mathcal{G}_f$ 是 g_{l_k} 和 g_{f_k} 所属的分布族; $\mathcal{T}$ 是 $n \times p$ 的精度矩阵。

贝叶斯矩阵分解将 l_k 和 f_k 看作隐变量, 基于观测到数据之前对参数的不确定性的认识指定隐变量的先验分布形式 g_{l_k} 和 g_{f_k} , 通过后验分布对隐变量 l_k 和 f_k 进行推断^[18]。

1.2 长短期记忆网络

LSTM网络引入门控机制和记忆单元, 用以解决循环神经网络中的梯度消失问题。假设在 t 时刻, d 维数据 $x_t \in \mathbf{R}^{d \times 1}$ 输入

LSTM网络, 并通过记忆单元和输出门结果更新隐藏状态 $h_t \in \mathbf{R}^{k \times 1}$ 。 $t-1$ 时刻网络的隐藏状态和记忆单元状态分别为 $h_{t-1} \in \mathbf{R}^{k \times 1}$ 与 $C_{t-1} \in \mathbf{R}^{k \times 1}$, k 是LSTM网络隐藏状态的数量。在LSTM网络中, 遗忘门负责调控历史记忆单元信息的保留比例, 其计算公式如下:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (6)$$

式中, $W_f \in \mathbf{R}^{k \times (k+d)}$ 是遗忘门的权重矩阵, $b_f \in \mathbf{R}^{k \times 1}$ 是遗忘门的偏置项, σ 是Sigmoid激活函数。

输入门负责判定当前输入里需存储至记忆单元的信息内容, 控制候选记忆单元 $\tilde{C}_t$ 的更新权重, 其计算公式如下:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (7)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (8)$$

式中, W_i 是输入门的权重矩阵, W_C 是候选记忆单元的权重矩阵, b_i 、 b_C 是偏置项。

记忆单元的作用是存储数据中的长期依赖关系信息, 其计算公式如下:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (9)$$

式中, $\odot$ 表示逐元素乘法。

输出门根据当前记忆单元生成隐藏状态 h_t , 作为下一时刻的输入, 其计算公式如下:

$$h_t = o_t \odot \tanh(C_t) \quad (10)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (11)$$

式中, W_o 是输出门的权重矩阵, b_o 是偏置项。

2 BMF-LSTM 无人机执行器故障诊断方法

本文提出一种BMF-LSTM无人机执行器故障诊断方法, 诊断模型如图1所示。通过贝叶斯矩阵分解将飞行数据分解为两个低秩矩阵, 捕捉无人机多维度飞行数据中的潜在结构。其次, 利用LSTM提取无人机飞行时间序列数据中的长期依赖关系, 更准确地捕捉无人机执行器故障潜在特征, 提高BMF-LSTM方法的故障诊断精度。

2.1 无人机飞行数据分解

2.1.1 经验贝叶斯矩阵分解

对于式(2)~式(5)的BMF模型, 将负载矩阵和因子矩阵秩为1 (即 $K=1$)时的 g_{l_1} , g_{f_1} , l_1 , f_1 简记为 g_l , g_f , l , f , 并假设 $\mathcal{G}_l$ 和 $\mathcal{G}_f$ 是相同的先验族, 记为 $\mathcal{G}_l = \mathcal{G}_f = \mathcal{G}$ 。

设定正态分布作为模型的先验分布参数 g_l 和 g_f , 将观测变量的边际似然函数定义为:

$$L(g_l, g_f, \tau) := \iint [p(Y|l, f, \tau) g_l(dl_1) \dots g_l(dl_n) g_f(df_1) \dots g_f(df_p)] \quad (12)$$

其中 $p(Y|l, f, \tau)$ 代表似然函数。

通过最大似然估计对参数 g_l , g_f 和 τ 进行最优求解, 最终得到后验概率分布如下:

$$p(l, f | Y, \hat{g}_l, \hat{g}_f, \tau) = \frac{p(Y|l, f, \tau) g_l g_f}{L(g_l, g_f, \tau)} \quad (13)$$

然而有些情况下, 后验概率难以求解, 式(13)的分母 $L(g_l, g_f, \tau)$ 通常是复杂的积分, 引入变分推断 (Variational Inference, VI) 技术可以有效地避免求解复杂积分的问题^{[19][20]}。




图1 无人机执行器故障诊断流程图

Fig. 1 UAV actuator fault diagnosis flow chart

首先给隐变量设定一个分布族 Q ，每个变分分布 $q(\mathbf{l}, \mathbf{f}) \in Q$ 近似于实际分布 $p(\mathbf{l}, \mathbf{f} | Y, \mathbf{g}_l, \mathbf{g}_f, \boldsymbol{\tau})$ 。于是求解后验概率这一目标转变为找到最优的变分分布 $q(\mathbf{l}, \mathbf{f}) \in Q$ ，相当于求解以下优化问题：

$$q^*(\mathbf{l}, \mathbf{f}) = \arg \min_{q(\mathbf{z}) \in Q} \text{KL}(q(\mathbf{l}, \mathbf{f}) \| p(\mathbf{l}, \mathbf{f} | Y, \mathbf{g}_l, \mathbf{g}_f, \boldsymbol{\tau})) \quad (14)$$

对式(12)取对数似然函数^[21]：

$$\begin{aligned} \mathcal{L}(\mathbf{g}_l, \mathbf{g}_f, \boldsymbol{\tau}) &:= \log L(\mathbf{g}_l, \mathbf{g}_f, \boldsymbol{\tau}) \\ &= F(q, \mathbf{g}_l, \mathbf{g}_f, \boldsymbol{\tau}) + D_{\text{KL}}(q \| p) \end{aligned} \quad (15)$$

其中

$$D_{\text{KL}}(q \| p) = - \int q(\mathbf{l}, \mathbf{f}) \log \frac{p(\mathbf{l}, \mathbf{f} | Y, \mathbf{g}_l, \mathbf{g}_f, \boldsymbol{\tau})}{q(\mathbf{l}, \mathbf{f})} d\mathbf{l} d\mathbf{f} \quad (16)$$

$$F(q, \mathbf{g}_l, \mathbf{g}_f, \boldsymbol{\tau}) = \int q(\mathbf{l}, \mathbf{f}) \log \frac{p(Y, \mathbf{l}, \mathbf{f} | \mathbf{g}_l, \mathbf{g}_f, \boldsymbol{\tau})}{q(\mathbf{l}, \mathbf{f})} d\mathbf{l} d\mathbf{f} \quad (17)$$

式(16)被称作 KL 散度 (Kullback-Leibler divergence)，它是两个概率密度之间接近程度的信息论度量，当 $q(\cdot) = p(\cdot)$ 时 KL 散度达到最小。然而，KL 散度通常也是难以计算的，因为它同样需要计算复杂积分 $L(\mathbf{g}_l, \mathbf{g}_f, \boldsymbol{\tau})$ ^[22]。因此，可通过最大化式(17)中的证据下界 (Evidence Lower Bound, ELBO) 从而间接最小化 KL 散度^[23]，于是有

$$\mathcal{L}(\mathbf{g}_l, \mathbf{g}_f, \boldsymbol{\tau}) = \max_q F(q, \mathbf{g}_l, \mathbf{g}_f, \boldsymbol{\tau}) \quad (18)$$

变分推断方法的思想是在 $q(\mathbf{l}, \mathbf{f}) \in Q$ 的约束条件下优化与 $q_l, q_f, g_l, g_f, \boldsymbol{\tau}$ 相关的变分下界 $F(q_l, q_f, g_l, g_f, \boldsymbol{\tau})$ 。

根据平均场理论，假设在概率推断模型中所有隐变量都是相互独立的，且每个变量的概率分布都由对应的参数独立控制，于是 $q(\mathbf{l}, \mathbf{f})$ 定义为：

$$q(\mathbf{l}, \mathbf{f}) = \prod_{i=1}^n q_{l_i}(l_i) \prod_{j=1}^p q_{f_j}(f_j) \quad (19)$$

由此可以得到

$$q(\mathbf{l}) = \prod_{i=1}^n q_{l_i}(l_i) \quad (20)$$

$$q(\mathbf{f}) = \prod_{j=1}^p q_{f_j}(f_j) \quad (21)$$

通过交替优化算法优化目标函数 F ，下面通过伪代码描述优化过程，其中假设负载和因子矩阵的秩 K 为 1。

算法 1 交替优化算法

输入：初始值 $q_l^{(0)}, q_f^{(0)}, g_l^{(0)}, g_f^{(0)}$ 。

输出： $q_l^{(t)}, q_f^{(t)}, g_l^{(t)}, g_f^{(t)}, \boldsymbol{\tau}^{(t)}$ 。

a) $t \leftarrow 0$ 。

b) 重复以下步骤直至目标函数 F 收敛：

$t \leftarrow t + 1$ ；

更新参数 $\boldsymbol{\tau}^{(t)}$ ：保持 $q_l^{(t-1)}, q_f^{(t-1)}, g_l^{(t-1)}, g_f^{(t-1)}$ 不变，最大化目标函数 F 来更新 $\boldsymbol{\tau}^{(t)}$ ；

更新 $q_l^{(t)}, g_l^{(t)}$ ：融合步骤 a 更新好的参数 $\boldsymbol{\tau}^{(t)}$ ，保持上一刻 $q_f^{(t-1)}, g_f^{(t-1)}$ 不变，最大化目标函数 F 来更新 $q_l^{(t)}, g_l^{(t)}$ ；

更新 $q_f^{(t)}, g_f^{(t)}$ ：融合步骤 a 与步骤 b 更新好的参数 $\boldsymbol{\tau}^{(t)}, q_l^{(t)}, g_l^{(t)}$ ，最大化目标函数 F 来更新 $q_f^{(t)}, g_f^{(t)}$ 。

c) 返回 $q_l^{(t)}, q_f^{(t)}, g_l^{(t)}, g_f^{(t)}, \boldsymbol{\tau}^{(t)}$ 。

对于负载和因子矩阵的秩为 K 的情况，假设 q_l, q_f 表示 K 个负载和因子的变分分布：

$$q_l(l_1, \dots, l_K) = \prod_k q_{l_k}(l_k) \quad (22)$$

$$q_f(f_1, \dots, f_K) = \prod_k q_{f_k}(f_k) \quad (23)$$

因此式 (17) 的目标函数是关于 $q_l = (q_{l_1}, \dots, q_{l_K})$ 、 $q_f = (q_{f_1}, \dots, q_{f_K})$ 、 $g_l = (g_{l_1}, \dots, g_{l_K})$ 、 $g_f = (g_{f_1}, \dots, g_{f_K})$ 以及精度 $\boldsymbol{\tau}$ 的函数，具体如下：

$$\begin{aligned} F(q_l, q_f, g_l, g_f, \boldsymbol{\tau}) &= \\ &= \int \prod_k q_{l_k}(l_k) q_{f_k}(f_k) \log \frac{p(Y, \mathbf{l}, \mathbf{f}; g_{l_1}, g_{f_1}, \dots, g_{l_K}, g_{f_K}, \boldsymbol{\tau})}{\prod_k q_{l_k}(l_k) q_{f_k}(f_k)} dl_k df_k = \end{aligned} \quad (24)$$

$$E_{q_l, q_f} \log p(Y | \mathbf{l}, \mathbf{f}; \boldsymbol{\tau}) + \sum_k E_{q_{l_k}} \log \frac{g_{l_k}(l_k)}{q_{l_k}(l_k)} + \sum_k E_{q_{f_k}} \log \frac{g_{f_k}(f_k)}{q_{f_k}(f_k)}$$

2.1.2 引入后验一阶矩和二阶矩实现稀疏贝叶斯矩阵分解

Johnstone 等人^[24]将后验中位数和后验均值作为阈值规则，通过混合先验分布结合边际极大似然估计实现对稀疏参数的自适应阈值选择。受此启发，本文引入后验分布 q_{l_k} 和 q_{f_k} 的一阶矩和二阶矩 $\bar{l}_k \in R^n$ ， $\bar{l}_k^2 \in R^n$ ， $\bar{f}_k \in R^p$ ， $\bar{f}_k^2 \in R^p$ 实现对 $\mathbf{l}$ 和 $\mathbf{f}$ 的稀疏估计^[25-27]，其中二阶矩用以调整参数估计的不确定性。一阶矩和二阶矩的计算公式如下：

$$\bar{l}_k := (\mathbb{E}_{q_{l_k}}(l_{ki})) \quad (25)$$

$$\bar{l}_k^2 := (\mathbb{E}_{q_{l_k}}(l_{ki}^2)) \quad (26)$$

$$\bar{f}_k := (\mathbb{E}_{q_{f_k}}(f_{kj})) \quad (27)$$

$$\bar{f}_k^2 := (\mathbb{E}_{q_{f_k}}(f_{kj}^2)) \quad (28)$$

在维持其他参数恒定的前提下，借助迭代更新优化目标函数，以下为各参数基于一阶矩与二阶矩的更新规则

1) 精度参数 $\boldsymbol{\tau}$ 的更新

$$\hat{\tau} = \arg \max_{\tau \in T} \sum_{ij} [\log(\tau_{ij}) - \tau_{ij} \overline{R^2_{ij}}] \quad (29)$$

其中

$$\begin{aligned} \overline{R^2_{ij}} &:= E_{q_l, q_f} [(Y_{ij} - \sum_{k=1}^K l_{ki} f_{kj})^2] \\ &= (Y_{ij} - \sum_k \bar{l}_{ki} \bar{f}_{kj})^2 - \sum_k (\bar{l}_{ki})^2 (\bar{f}_{kj})^2 + \sum_k \bar{l}_{ki}^2 \bar{f}_{kj}^2 \end{aligned} \quad (30)$$

2) 负载和因子的更新

以更新负载为例, 将式(24)的目标函数写成关于分布 q_l, g_l 的形式:

$$\begin{aligned} F(q_l, q_f, g_l, g_f, \tau) &= E_{q_{l_k}} \left[-\frac{1}{2} \sum_i (A_{ik} l_{ki}^2 - 2B_{ik} l_{ki}) \right] \\ &\quad + E_{q_{l_k}} \log \frac{g_{l_k}(l_k)}{q_{l_k}(l_k)} + C_1 \end{aligned} \quad (31)$$

其中 C_1 是关于 q_{l_k} 和 g_{l_k} 的常数, 并且

$$A_{ik} = \sum_j \tau_{ij} E_{q_f} (f_{kj}^2) \quad (32)$$

$$B_{ik} = \sum_j \tau_{ij} (R_{ij}^k E_{q_f} f_{kj}) \quad (33)$$

$$g_{l_k}(l_k) := \prod_j g(l_{kj}) \quad (34)$$

$$q_{l_k}(l_k) := \prod_i q(l_{ki}) \quad (35)$$

其中

$$R_{ij}^k := Y_{ij} - \sum_{k' \neq k} \bar{l}_{ki'} \bar{f}_{kj'} \quad (36)$$

表示残差矩阵。

根据式(18), 当 $q_{l_k}(l_k) = p(l_k | Y, g_{l_k})$ 时, 目标函数最大化, 可以得到负载的近似后验分布为:

$$q_l = \arg \max_{q_l} F(q_l, q_f, g_l, g_f, \tau) \quad (37)$$

通过最大似然估计(Maximum Likelihood Estimation, MLE)

可以求得先验分布:

$$\hat{g}_l = \arg \max_{g_l} \max_{q_l} F(q_l, q_f, g_l, g_f, \tau) \quad (38)$$

同理, 可以得到因子的近似后验分布 q_f 和先验估计 $\hat{g}_f$, 最后从近似后验分布中计算隐变量的均值作为 l 和 f 的估计值。

3) 后验矩的算法实现

通过迭代更新 K 个负载与因子矩阵, 每次更新时固定其余参数, 实现参数的逐步优化。以下是相应的伪代码:

算法 2 反拟合交替优化

输入: $n \times p$ 的数据矩阵 Y 。

输出: $\bar{l}, \bar{l}^2, \bar{f}, \bar{f}^2, \tau$ 。

a) 创建函数 $\text{moment}(\mathbf{x}, \mathbf{s}) \rightarrow (\bar{\theta}, \bar{\theta}^2)$ 。 // 返回一阶矩和二阶矩

b) 创建函数 $\text{init}(Y) \rightarrow (l; f)$ 。 // 提供负载和因子初值

c) 创建函数 $\text{update}(Y, \bar{l}, \bar{f}, \bar{l}^2, \bar{f}^2, k) \rightarrow (\bar{l}_k, \bar{l}_k^2, \bar{f}_k, \bar{f}_k^2, \tau)$ 。 /* 更新单个负载和因子 */

d) $(\bar{l}_1, \dots, \bar{l}_K; \bar{f}_1, \dots, \bar{f}_K) \leftarrow \text{init}(Y)$ 。 // 初始化一阶矩

e) $\bar{l}_k^2 \leftarrow \bar{l}_k^2; \bar{f}_k^2 \leftarrow \bar{f}_k^2$ 。 // 初始化二阶矩

f) 重复以下步骤直至目标函数 F 收敛:

for $k=1, \dots, K$ do:

$(\bar{l}_k, \bar{l}_k^2, \bar{f}_k, \bar{f}_k^2, \tau) \leftarrow \text{update}(Y, \bar{l}, \bar{f}, \bar{l}^2, \bar{f}^2, k)$ 。

g) 返回 $\bar{l}, \bar{l}^2, \bar{f}, \bar{f}^2, \tau$ 。

2.2 LSTM 训练和故障分类

将飞行数据集记作观测数据矩阵 Y , 使用 BMF 方法分解得到负载矩阵 $L = (l_1, l_2, \dots, l_k)^T$ 和因子矩阵 $F = (f_1, f_2, \dots, f_k)$ 。 F 反映飞行特征之间的相关性或飞行行为的内在特性, L 反映飞行行为随时间变化的趋势或周期性模式。考虑负载矩阵 L 隐含了无人机分别在故障和正常工作模式下的丰富信息, 选择负载矩阵 L 作为低秩特征矩阵构建新的特征数据集。

采用滑动窗口方法将特征数据集切分成多个子序列, 若特征数据集的时间步 (即负载矩阵 L 的行数) 为 n , 滑动窗口长度为 l , 则生成的窗口数量为:

$$\text{num} = n - l + 1 \quad (39)$$

t 时刻的窗口数据为:

$$w_t = [x_t, \dots, x_{t+l-1}] \quad (40)$$

采用 One-Hot 编码处理窗口数据的类别标签, 将编码后的窗口数据输入 LSTM 网络。经全连接层特征映射后, 通过 Softmax 函数由最终隐藏状态生成故障概率分布:

$$p(y_i) = \text{Softmax}(W_y \cdot h_t + b_y) \quad (41)$$

式中, $W_y \in \mathbf{R}^{C \times k}$ 是全连接层的权重矩阵, C 为类别数, $i = (1, 2, \dots, C)$, b_y 是偏置项。

采用交叉熵损失衡量预测概率与真实标签的差异:

$$\text{Loss} = -\frac{1}{N} \sum_{i=1}^N p(y_i^*) \log(p(y_i)) \quad (42)$$

其中 N 为训练批次大小, $p(y_i^*)$ 是第 i 个样本的真实概率分布, 对于真实类别 C , $p(y_C^*) = 1$, 其余类别的值为 0。

LSTM 网络通过反向传播机制进行训练, 设置输入层结点数 K 个, LSTM 层结点数 128 个, 输出层节点数为 3 个。选择 Adam 优化器动态调整学习率, 根据当前批次的损失计算所有模型参数的梯度, 通过最小化损失更新模型权重和偏置等参数。

3 实验结果与分析

3.1 无人机飞行数据预处理

3.1.1 数据说明

Air Lab Fault and Anomaly (ALFA)数据集^[28]通过 Pixhawk 自动驾驶仪禁用无人机各类执行器模拟突发故障。该数据集汇集了 47 组无人机飞行状态记录数据, 包含多种无人机执行器在正常飞行中突发失效的场景。具体故障类型包括: 电动发动机完全失去动力、方向舵卡死在某一侧或零位、单副翼或双副翼锁定在零位、升降舵卡死在最低位置或零位等突发故障案例。数据集包含大量的数据字段, 比如 GPS、操纵面状态、轨迹偏差、空速、风速、线速度、角速度、时间参考、电池状态等, 选择 13 个典型数据字段作为飞行特征, 如表 1 所示。

表 1 飞行特征

序号	特征	描述
1	field.pose.position.x	x 轴位置
2	field.pose.position.y	y 轴位置

3	field.pose.position.z	z 轴位置
4	field.pose.orientation.x	x 轴姿态分量
5	field.pose.orientation.y	y 轴姿态分量
6	field.pose.orientation.z	z 轴姿态分量
7	field.pose.orientation.w	旋转标量
8	field.twist.linear.x	沿 x 轴的线速度
9	field.twist.linear.y	沿 y 轴的线速度
10	field.twist.linear.z	沿 z 轴的线速度
11	field.twist.angular.x	绕 x 轴的角速度
12	field.twist.angular.y	绕 y 轴的角速度
13	field.twist.angular.z	绕 z 轴的角速度

本文选择 ALFA 数据集中 26 次故障飞行数据样本作为 BMF-LSTM 模型验证对象。实验通过滑动窗口方法扩展训练数据的多样性和数量，窗口长度 $l=200$ ，数据类别 $C=3$ ，采用 One-Hot 方式将标签为 y_0 的正常数据样本（Class0）编码为 $[1,0,0]$ ，标签为 y_1 的发动机全动力损失故障样本（Class1）编码为 $[0,1,0]$ ，标签为 y_2 的右副翼 0 位卡阻故障样本（Class2）编码为 $[0,0,1]$ 。数据集共 4105 个样本，按 70%、15%、15% 的比例划分为训练集、验证集和测试集，具体组成见表 2。

表 2 数据集组成

Table 2 Dataset composition

数据集	Class0	Class1	Class2
训练集	1539	1039	295
验证集	330	223	64
测试集	330	222	63

3.1.2 数据标准化

对无人机传感参数量纲差异问题，采用 z-score 归一化对原始数据进行无量纲处理：

$$x^* = \frac{x - \mu}{\sigma} \quad (43)$$

式中， x^* 是归一化值， x 是无人机实测飞行数据， μ 、 σ 分别是实测数据的均值和方差。

3.2 飞行数据贝叶斯矩阵分解结果

以含发动机全动力损失故障的飞行数据作为分解实例，实验将观测数据矩阵 Y 分解秩为 7（ $K=7$ ）的负载矩阵 L 和因子矩阵 F 。在推断 L 和 F 的后验分布的过程中，本文将复杂的多参数优化问题转化为简单的子问题，并交替优化这些子问题，从而找到 ELBO 的局部最优解来近似真实后验分布，因子矩阵的 ELBO 优化过程如图 2 所示。经过 7 次迭代优化，ELBO 的数值由 -9607.75 增加至 -8462.124，直至因子没有显著提高目标值，结束迭代过程。在迭代开始阶段，ELBO 值增大速度较快，可能是因为 BMF 模型参数与真实后验分布差异较大，优化空间较大。随着迭代的进行，ELBO 值的增大速度逐渐减慢，这表明 BMF 模型正在接近一个稳定的状态，即模型参数的调整对 ELBO 值的影响越来越小。

图 3 为 F 对应的因子向量 f_k 可视化直方图，可以看到 BMF 方法分解得到的因子普遍具有稀疏性，许多因子收缩至接

近于 0，部分因子只在几个关键飞行特征上显示较高数值，BMF 自动从数据中提取出潜在关联性，使得模型能够分离和识别不同状态下的飞行特征。例如，在 f_4 中，无人机的 x 轴位置、x 轴姿态分量、x 轴线速度和 z 轴对应的角速度对应的因子值接近于 0，表明某些时刻发动机全动力损失对这些飞行特征的影响作用比其他时刻要小；在 f_5 中，无人机的 z 轴线速度和 x 轴位置对应的绝对因子值远高于其他飞行特征，表明某些时刻发动机全动力损失对这些飞行特征的影响作用比其他时刻要大。




图 2 ELBO 交替优化

Fig. 2 ELBO alternate optimization

3.3 无人机执行器故障诊断结果

3.3.1 评估指标

本文将准确率（Accuracy）、精确率（Precision）和召回率（Recall）作为评估无人机执行器故障诊断效果的关键指标，计算公式如式(44)~(46)所示：

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + TN + FN} \quad (44)$$

$$\text{Precision} = \frac{TP}{TP + FP} \quad (45)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (46)$$

在分类模型中， TP 是真实类别与预测结果均为正类的样本， FP 是预测为正类但实际为负类的样本， TN 是真实类别与预测结果均为负类的样本， FN 是预测为负类但实际为正类的样本。准确率为正确分类样本占比，精确率是正类判定中真实正类的比例，召回率为实际正类中被正确识别的比例，三者值越高表明模型分类性能越优。

3.3.2 不同模型的故障诊断实验结果及分析

为了验证所提方法的有效性，本文对比了基于主成分分析（PCA）^{[29][30]}、t-分布随机邻域嵌入（t-SNE）^{[31][32]}、广义不相关回归（GURM）^[33]以及 BMF 等特征提取方法的 LSTM 模型在相同数据集以及算力情况下的无人机发动机及副翼等执行器故障诊断准确率，对比的结果如图 4 所示。诊断模型分别记作 PCA-LSTM、t-SNE-LSTM、GURM-LSTM 和 BMF-LSTM（所提模型）。随着训练轮数的增加，准确率在第 40-第 50 轮的检测准确率趋于稳定，分别为 83.7%、86.8%、92.0%、97.4%，BMF-LSTM 模型表现出最高的平均准确率。通过分析可将结果归结为以下原因，PCA-LSTM 模型通过线性分析降维和提取特




图3 因子向量可视化直方图

Fig. 3 Histogram of factor vector visualization

征,对于无人机飞行数据这类非线性故障特征的表征能力有限,导致诊断准确率相对较低;t-SNE-LSTM 模型虽适用于非线性数据降维,但它只保留了无人机飞行数据中局部特征的相似性,所以可能丢失关键信息,其故障诊断准确率略高于 PCA-LSTM 但低于 NMF-LSTM 和 BMF-LSTM;GURM-LSTM 模型在提取特征时引入自适应图正则化,也能够捕捉故障信号的非线性关系,但依赖数据分布假设,故障类型多样时可能无法完全适应,其故障诊断准确率为 92%,比 BMF-LSTM 模型低 5.4%。总体而言,本文提出的 BMF-LSTM 模型的准确率最高,验证了它在无人机执行器故障诊断任务中的有效性,因此该模型具有一定的应用和参考价值。

BMF-LSTM 在诊断各类无人机执行器故障数据时具有较强的准确性。此外, BMF-LSTM 的假阳率和假阴率较低,表明该模型较少出现误判和漏判。




图4 不同模型的故障诊断准确度随训练轮数变化的对比图

Fig. 4 Comparative chart of fault diagnosis accuracy of different models with varying epochs

图 5 给出的是各模型在测试数据集中的故障分类混淆矩阵, BMF-LSTM 的大部分预测结果集中在真阳性区域,且集中度高高于 PCA-LSTM、t-SNE-LSTM 和 GURM-LSTM 模型,表明




图5 不同模型的无人机飞行执行器故障分类混淆矩阵

Fig. 5 Confusion matrix for fault classification of UAV flight actuators in different models

表 3 详细给出了 4 种模型在无人机发动机和副翼故障数据集中的故障诊断对比结果,表中以黑体加粗格式标明各类别的最高平均精确率和召回率。本文提出的 BMF-LSTM 模型融合概率建模与时空特征,综合性能具有显著优势,平均精确率为 96.9%、平均召回率为 97.1%。相比之下, PCA-LSTM 模型和

t-SNE-LSTM 模型对于正常数据的分类表现较好，但它们的整体分类性能仍低于 GURM-LSTM 和 BMF-LSTM，这点在故障数据的分类精确率上表现明显，BMF-LSTM 模型在无人机发动机故障数据中的分类精准率分别比 PCA-LSTM、t-SNE-LSTM 高 17.6%、14.4%，在副翼卡组故障数据中的分类精准率比 PCA-LSTM、t-SNE-LSTM 分别高 15.3%、10.7%。GURM-LSTM 模型的整体性能略低于 BMF-LSTM 模型，其平均精确率和平均召回率分别比 BMF-LSTM 低 5.7%、5.8%。对比诊断指标可以发现，无论在何种故障模式下本文所提方法的精确率、召回率数值上都优于其他模型。这表明，BMF-LSTM 模型在处理无人机复杂时序数据和故障情况时，能够更好地捕捉到数据中的时空特征和潜在结构，从而提高故障诊断性能。

表 3 故障诊断结果对比

Table 3 Comparison of fault diagnosis results			
模型	类别	精确率	召回率
PCA-LSTM	Class0	87.0%	85.5%
	Class1	80.1%	81.5%
	Class2	80.0%	82.5%
t-SNE-LSTM	Class0	89.8%	87.9%
	Class1	83.3%	85.1%
	Class2	84.6%	87.3%
GURM-LSTM	Class0	92.8%	94.2%
	Class1	91.7%	89.2%
	Class2	89.1%	90.5%
BMF-LSTM	Class0	97.6%	98.2%
	Class1	97.7%	96.4%
	Class2	95.3%	96.8%

3.3.3 BMF-LSTM 模型消融实验结果及分析

为进一步验证 BMF 方法的快速响应特性，本小节对比 LSTM 模型及其 2 种扩展模型：（1）LSTM 模型。传统的长短期记忆网络模型，能够捕捉时间序列的长期依赖，并用于无人机执行器故障数据分类，从而达到故障诊断的目的。（2）LSTM1 模型。该模型在 LSTM 模型基础上引入贝叶斯矩阵分解，先一步对无人机执行器故障飞行数据进行潜在特征提取，消除数据冗余并降低数据维度。（3）LSTM2 模型，即 BMF-LSTM 模型。在 LSTM1 模型变分近似负载和因子矩阵时引入后验矩，将高维矩阵的贝叶斯推断转化为矩的代数运算，从而降低变分推断计算成本。

3 种模型的响应时间对比结果如表 4 所示。传统 LSTM 的响应时间为 1.746s，经过贝叶斯矩阵分解特征提取并降维处理后，LSTM1 的响应时间变小，较传统 LSTM 模型减少了 0.091s。进一步地，在引入后验矩后 LSTM2 的响应时间再一次得到改善，较 LSTM1 模型减少了 0.192s。总体来说，在本文实验条件下，BMF 方法使传统 LSTM 模型在无人机执行器故障诊断任务中的响应速度提升了 16.2%，验证了所提方法的有效性。

表 4 响应时间

Table 4 Response time			
模型	LSTM	LSTM1	LSTM2
响应时间/s	1.746	1.655	1.463

4 结束语

本文提出了一个无人机执行器故障诊断模型 BMF-LSTM，用以应对高维数据环境下传统故障诊断方法面临的冗余特征干扰、计算效率低下等挑战。首先通过变分贝叶斯矩阵分解建模数据的潜在低维结构，引入后验矩以简化变分近似复杂度，并使得估计的参数具有稀疏性；保留对故障诊断具有判别性的低秩隐藏特征，并利用分解后的低维特征构建特征训练集，通过 LSTM 网络进一步学习低维特征中的长期依赖关系；最后经全连接层特征映射后，通过 Softmax 函数计算无人机执行器正常与故障的概率。

最后在 ALFA 无人机执行器故障数据集集中进行方法有效性验证，与另外三种特征提取方法相比，基于 BMF 的 LSTM 模型表现出最优性能。实验结果表明，所提 BMF-LSTM 模型通过贝叶斯矩阵分解降维、概率建模与 LSTM 判别学习的协同设计，能够有效提取高维、冗余无人机飞行数据的关键数据特征，提高无人机执行器故障诊断的准确率和响应速度。

由于 VI 迭代推断和 LSTM 时序计算导致在线推理延迟较高，难以满足毫秒级响应的实时监测需求。未来本文将进一步探索非参数先验与在线学习机制的结合，以应对动态高维数据的实时检测需求。

5 参考文献

[1] Zhang Y, Li S, Zhang A, et al. FW-UAV fault diagnosis based on knowledge complementary network under small sample[J]. Mechanical Systems and Signal Processing, 2024, 215: 111418.

[2] Altınors A, Yol F, Yaman O. A sound based method for fault detection with statistical feature extraction in UAV motors[J]. Applied Acoustics, 2021, 183: 108325.

[3] Li R, Jiang B, Zong Y, et al. Event-Triggered Collaborative Fault Diagnosis for UAV-UGV Systems[J]. Drones, 2024, 8(7): 324.

[4] 彭喜元, 庞景月, 彭宇, 等. 航天器遥测数据异常检测综述 [J]. 仪器仪表学报, 2016, 37(9): 1929-1945.

PENG X Y, PANG J Y, PENG Y, et al. Review on anomaly detection of spacecraft telemetry data[J]. Chinese Journal of Scientific Instrument, 2016, 37(9): 1929-1945.

[5] Tsai D M, Jen P H. Autoencoder-based anomaly detection for surface defect inspection[J]. Advanced Engineering Informatics, 2021, 48: 101272.

[6] BRONZ M, BASKAYA E, DELAHAYE D, et al. Real-time fault detection on small fixed-wing UAVs using machine learning[C] // Proceedings of the IEEE/AIAA 39th Digital Avionics Systems Conference. Piscataway: IEEE, 2020: 1-10.

-
- [7] Çelik Ü., Eren H. Classification of Manifold Learning Based Flight Fingerprints of UAVs in Air Traffic[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(5): 5229-5238.
- [8] Wang B, Wang Z, Liu L, et al. Data-Driven Anomaly Detection for UAV Sensor Data Based on Deep Learning Prediction Model[C] // 2019 Prognostics and System Health Management Conference (PHM-Paris), Paris, France, 2019: 286-290
- [9] MELNYK I, YADAV P, STEINBACH M, et al. Detection of precursors to aviation safety incidents due to human factors [C] // Proceedings of the IEEE 13th International Conference on Data Mining Workshops. Piscataway: IEEE, 2013: 407-412.
- [10] PAN D W, NIE L Q, KANG W X, et al. UAV anomaly detection using active learning and improved S3VM model [C] // Proceedings of the 2020 International Conference on Sensing, Measurement and Data Analytics in the era of Artificial Intelligence. Piscataway: IEEE, 2020: 253-258.
- [11] Geng C, Xiang S, Wang N, Wang Y. UAV Anomaly Detection Using Fleet Data Based on DBSCAN-MSET Method[C]// 2023 IEEE 16th International Conference on Electronic Measurement & Instruments (ICEMI). Harbin, China, 2023: 395-400.
- [12] Zhong J, Zhang Y J, Wang J Y, et al. Unmanned aerial vehicle flight data anomaly detection and recovery prediction based on spatio-temporal correlation[J]. IEEE Transactions on Reliability, 2021, 71(1), 457-468.
- [13] Dalhoumi O, Bouguila N, Amayri M, Fan W. Bayesian matrix factorization for semibounded data[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 34(6): 3111-3123.
- [14] Wu P, Pei M, Wang T, Liu Y, Liu Z, Zhong L. A Low-Rank Bayesian Temporal Matrix Factorization for the Transfer Time Prediction Between Metro and Bus Systems[J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(7): 7206-7222.
- [15] Shang R, Liu H, Li W, Zhang W, Ma T, Jiao L. An efficient evolutionary architecture search for variational autoencoder with alternating optimization and adaptive crossover[J]. Swarm and Evolutionary Computation, 2024, 86: 101520.
- [16] Xu J, Liu B, Xiao Y. A variational inference method for few-shot learning[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2022, 33(1): 269-282.
- [17] Srivastava S, Engelhardt B E and Dunson D B. Expandable factor analysis[J]. Biometrika, 2017, 104(3): 649-663.
- [18] Dunson D B. Bayesian latent variable models for clustered mixed outcomes[J]. Journal of the Royal Statistical Society. Series B (Statistical Methodology), 2000, 62(2): 355-366.
- [19] Zhang C, Büttepage J, Kjellström H, et al. Advances in variational inference[J]. IEEE transactions on pattern analysis and machine intelligence, 2019, 41(8): 2008-2026.
- [20] Blei D M, Kucukelbir A, McAuliffe J D. Variational Inference: A review for statisticians[J]. Journal of the American Statistical Association, 2017, 112(518): 859-877.
- [21] Hoffman M D, Blei D M, Wang C, et al. Stochastic variational inference[J]. Journal of Machine Learning Research, 2013, 14(1): 1303-1347.
- [22] Fox C W, Roberts S J. A tutorial on variational bayesian inference[J]. Artificial Intelligence Review, 2012, 38(2): 85-95.
- [23] Kucukelbir A, Tran D, Ranganath R, et al. Automatic differentiation variational inference[J]. Journal of machine learning research, 2017, 18(14): 1-45.
- [24] Johnstone I M, Silverman B W. Needles and straw in haystacks: Empirical Bayes estimates of possibly sparse sequences[J]. The Annals of Statistics, 2004, 32(4): 1594-1649.
- [25] Piironen J, Paasiniemi M, Vehtari A. Projective inference in high - dimensional problems: Prediction and feature selection[J]. Electronic Journal of Statistics, 2020, 14: 2155 - 2197.
- [26] Ge T, Chen C Y, Ni Y, et al. Polygenic prediction via Bayesian regression and continuous shrinkage priors[J]. Nature communications, 2019, 10: 1776.
- [27] Castillo I, Schmidt-Hieber J, Van der Vaart A. Bayesian linear regression with sparse priors[J]. The Annals of Statistics, 2015, 43(5): 1986-2018.
- [28] Keipour A, Mousaei M, Scherer S. Alfa: A dataset for uav fault and anomaly detection[J]. The International Journal of Robotics Research, 2021, 40(2-3): 515-520.
- [29] Greenacre M, Groenen P J F, Hastie T, et al. Principal component analysis[J]. Nature Reviews Methods Primers, 2022, 2(1): 100.
- [30] Vidal R, Ma Y, Sastry S. Generalized principal component analysis (GPCA)[J]. IEEE transactions on pattern analysis and machine intelligence, 2005, 27(12): 1945-1959.
- [31] Anowar F, Sadaoui S, Selim B. Conceptual and empirical comparison of dimensionality reduction algorithms (pca, kpca, lda, mds, svd, lle, isomap, le, ica, t-sne)[J]. Computer Science Review, 2021, 40: 100378.
- [32] Meyer B H, Ramirez Pozo A T, Zola W M N. Global and local structure preserving GPU t-SNE methods for large-scale applications[J]. Expert Systems with Applications, 2022, 201: 116918.
- [33] LI X, ZHANG H, ZHANG R, et al. Generalized uncorrelated regression with adaptive graph for unsupervised feature selection[J]. IEEE transactions on neural networks and learning systems, 2019, 30(5): 1587-1595.