



单位代码 10635

学 号 112015314000988

西南大学

硕士学位论文

基于低秩和光滑先验的图像修补算法研究

论 文 作 者: 邱一芳
指 导 教 师: 王建军 教授
学 科 专 业: 统计学
研 究 方 向: 海量数据分析
提交论文日期: 2018 年 6 月 5 日
论文答辩日期: 2018 年 5 月 21 日
学位授予单位: 西南大学

中 国 • 重 庆

2018 年 6 月

目 录

摘要	I
ABSTRACT	III
第 1 章 绪论	1
1.1 研究背景及意义	1
1.2 研究现状	2
1.3 本文主要工作及结构安排	4
第 2 章 相关理论及基础	5
2.1 引言	5
2.2 矩阵相关理论知识	5
2.3 张量相关理论知识	6
2.4 ADMM 算法简介	8
2.5 小结	9
第 3 章 基于矩阵 Schatten-p 范数与光滑性的图像修补	10
3.1 引言	10
3.2 相关工作	10
3.3 所提模型	12
3.4 数值实验	15
3.5 小结	16
第 4 章 基于张量修补与光滑先验的图像修补	21
4.1 相关工作	21
4.2 基于二阶 TV 的改进 SPC 算法	22
4.3 数值实验	24
4.4 小结	25
第 5 章 总结与展望	27
5.1 本文工作总结	27
5.2 后续工作展望	27
参考文献	33
已完成文章目录	34
致谢	35

基于低秩和光滑先验的图像 修补算法研究

统计学 专业 硕士研究生 邱一芳

指导教师 王建军 教授

摘要

随着多媒体技术、现代传感器、计算机通信及网络技术等的飞速发展和广泛应用,人们经常需要存储、处理与分析规模更大、结构更复杂的图像数据。作为图像处理领域的一个研究热点问题,图像修补问题在最近几年引起了学者和产业界的广泛关注。本文针对图像修补这一应用问题,分别从矩阵和张量视角进行了深入研究。不同于以往基于图像单一低秩先验的修补方法,本文将图像的低秩和光滑先验加以联合,并将其引入到图像修补问题的算法研究。在与以往经典修补算法的对比中,所提算法取得了更为理想的修补结果。全文结构以及内容安排如下:

第1章为绪论,简述了图像修补的研究背景和意义,并给出了与图像修补相关的研究现状,最后总结了本文的主要工作和全文的组织结构。

第2章是相关理论及基础,简要介绍了与本文相关的矩阵和张量基础知识,最后对本文涉及的交替方向乘子法做了简单介绍。

第3章在矩阵视角下研究了图像修补问题,提出了同时考虑图像矩阵低秩和光滑先验的新修补算法。该算法通过最小化图像矩阵的 Schatten- p 范数与一类改进的二阶全变差来实现图像的修补。所作数值实验结果表明:当缺失率越大时, p 越小效果越好;而当缺失率越小时, p 越大效果越好。通过选择适当的 p 值,本节所提算法优于当前许多算法。

第4章通过张量视角研究了图像修补问题,改良了一类新近提出的 SPC (Smooth PARAFAC tensor Completion) 算法。具体地,我们将基于一类改进的二阶全变差约束引入到 SPC 算法,用以替换 SPC 算法中的一阶全变差约束。与 SPC 算法相比,相应数值实验结果表明:与 SPC 算法相比 ssim 和 psnr 两项指标上均优于原 SPC 算法。

第5章总结了本文的工作,并对后续潜在研究工作进行了展望。

关键字: 低秩, Schatten- p 范数, 光滑性, 张量分解, 算法设计

Research on Image completion algorithms based on low Rank and smooth prior information

Yifang Qiu

Directed by Prof. Jianjun Wang

ABSTRACT

With the rapid development and wide application of multimedia technology, modern sensor, computer communication and network technology, people often need to store, deal with and analyze image data with larger scale and more complex structure. As a hot research topic in the field of image processing, image completion has attracted wide attention from scholars and industry in recent years. Aiming at the application problem of image inpainting, we have studied deeply from the perspective of matrix and tensor respectively. Unlike the previous repair method based on single low rank prior to image, this paper combines the low rank of the image and the smooth prior, and introduces it to the algorithm of image completion. Compared with previous classical patching algorithm, the proposed algorithm achieves better repair results. The full text structure and content are arranged as follows:

The first chapter is an introduction, which describes the background and significance of the research of image completion, and gives the current research status related to image completion. Finally, the main work and the organization structure of the full text are summarized.

The second chapter is the related theory and the foundation, and briefly introduces the matrix and tensor basic knowledge related to this article. Finally, a brief introduction to the popular alternating direction multiplier is introduced in this paper.

In the third chapter, we study the problem of image inpainting from the perspective of matrix, and propose a new algorithm of joint image matrix, which is low rank and smooth prior. The algorithm achieves perfect image completion by minimizing the Schatten-p norm of image matrix and a class of improved two order total variation. The numerical experiment results show that when the missing rate is bigger, the smaller the p is, the better the effect is. When the missing rate is smaller, the bigger the p is, the better the effect will be. By choosing the appropriate p value, the algorithm proposed in this section is better

than many algorithms.

The fourth chapter studies the problem of image inpainting through tensor perspective, and improves a recently proposed SPC (Smooth PARAFAC tensor Completion) algorithm. Specifically, we will introduce SPC algorithm based on a modified two order total variation constraint to replace the first order total variation constraint in SPC algorithm. Compared with the SPC algorithm, the numerical experiment results show that compared with the SPC algorithm, SSIM and PSNR are better than the original SPC algorithm on the two indexes.

The fifth chapter summarizes the work of this paper, and prospects for future potential research.

Keywords: Low rank, Schatten-p norm, smoothness, tensor decomposition, algorithm design

第1章 绪论

据不完全统计,人类至少有 80% 以上的外界信息是经视觉获得的。作为场景信息记录和传递的载体,自胶片相机诞生以来,图像便成为人们获取和解码外界客观世界最重要的途径之一。特别是近年来,随着数码成像技术、电子通信、移动互联网以及社交网络的快速发展,图像越发成为人们进行信息交流的主要媒介。本章首先简要介绍了图像修补的研究背景和意义,其次介绍了图像修补的研究现状,最后给出了本文的结构安排。

1.1 研究背景及意义


数字图像的质量在人们进行信息传递和解码的过程中起着至关重要的作用。高质量的图像,因其携带更为丰富的场景信息,可以极大提升信息传递的准确性和有效性,甚至给受众以美的享受;质量差的图像,由于大量细节信息的丢失,容易造成信息解码和传输的歧义性和低效性。有时还会给受众带来不适。因此,无论是数字图像的采集者还是解码者,都希望得到理想的高质量图像。然而,在数字图像处理的诸多环节(如采集、存储、传输和解码等)中,图像不可避免地会受到来自外部环境、硬件设备和人为等因素的影响,导致图像质量的下降,引起图像失真或图像缺损等问题。比如,人为对图像中数据信息(如文本和障碍物等)进行增删会导致图像修补问题的产生。本文研究的重点就是图像修补问题。

图像修补又被称为图像补全,或图像修复。其目标是借助一定技术手段,通过部分已知图像数据来修补或补全其他未知图像数据。目前在图像修补领域,一个较为流行的技术手段是矩阵修补技术 [1, 2, 3, 4, 5, 6, 7]。即,首先将待修补图像视作(单个或多个)矩阵,同时利用图像矩阵潜在的(近似)低秩结构(见图 1.1),构建相应的低秩重构模型,进而实现其完美的修补。事实上,从数字图像的离散存储方式来看,黑白图像等价于一个矩阵,而彩色 RGB 图像则可以视作三个(来自不同通道)尺寸相同的矩阵的叠加。Candès 等人 [8] 较早地开展了低秩秩矩阵修补理论和应用方面的研究。其后有大量学者进行了后续研究,获得了许多漂亮的结果。基于矩阵视角的图像修补研究为图像修补问题的深入研究开辟了新的通途。然而,随着研究的深入,人们发现:当图像以张量形式存储时,现有矩阵修补技术,不仅破坏了图像数据的内部结构,而且并不能保证从尽可能少的已知数据中实现图像的完美修补。为此,一些学者提出了基于张量数据的修补方案。例如在 [9, 10, 11, 12, 13, 14, 15, 16] 中,提出了基于张量低秩约束的建模方法。

矩阵和张量型图像的低秩先验在图像修补的应用研究中取得了极大的成功,若干算法模型也在图像之外的许多领域得到了大量应用。然而从从先验信息的角



(a) 图 1 原始图像



(b) 图 2 奇异值排序

图 1.1: 图像的低秩结构

度, 低秩性结构仅仅刻画了图像的全局信息。然而在实际中, 图像数据除了具有(近似)低秩结构外, 还往往具有其他一些局部光滑的特征。面对这类图像数据, 如果仅考虑其低秩性, 其重构表现往往难以让人满意。另外, 从实际的图像修补问题来看, 当图像的已知数据很少的时候, 仅仅利用单一的低秩先验, 往往并不能有效地实现图像的完美重构。自然, 如何整合更多的先验信息特别是(局部)光滑先验信息来提升图像修补质量成了一个值得研究的课题, 具有重要理论和现实意义。

1.2 研究现状

稀疏表示(Sparse Representation)[17]和压缩传感(Compressed Sensing)[18, 19]是信号处理和机器学习领域的重要研究课题。所谓稀疏性, 指的是有意义的信号在适当选取的一组完备基下可以只用其中少数几个基来表达。但在实际应用中, 我们将面临着各种各样的数据, 如图像、视频和基因微阵列(Microarray), 数据自身就是矩阵或张量的形态。如果强行展开向量再套用向量的稀疏性的处理方法, 那么必然会破坏数据内在的结构特征。那么如何来度量高维数据的“稀疏性”就成为了研究的起点, 充分利用矩阵型数据的图像行及列的相关性。自然想到秩是矩阵稀疏性的合理度量。矩阵修补(matrix completion)问题应运而生, 并应用于诸多领域, 如图像修复[20]、推荐系统[21]、图像分类[22]、图像分割[23]等领域。由于秩函数的非凸性和非光滑性, 标准矩阵修补问题求解成为了一个 NP 难问题, 其求解复杂度均随着矩阵维数的增加呈平方倍指数增长。为此, 众多研究者对此展开了广泛研究, 取得了大量的研究成果[1, 2, 3, 4, 5, 6, 7]。一些学者考虑秩函数的凸松弛, 即矩阵的核范数。如 Cai 等[1]中, 提出了一种矩阵补全的奇异值阈值算法, Lin 等人[2]将不精确增广拉格朗日乘子法应用于核范数极小化。该方法用零填充缺失的项, 并假定填充的矩阵等于真正完整的矩阵加上一个误差矩阵。Chen 等人[3]将交

替方向乘子法 [24] 用于核范数最小化。该方法与文献 [2] 相似, 但误差矩阵并不明确的出现。Hu 等人 [4] 提出将截断核范数应用于矩阵修补。截断核范数等于部分最小奇异值之和, 比核范数最小化效果要好。Lu 等人 [25] 将广义奇异值阈值方法应用于低秩矩阵修补。实际上, 截断核范数极小化可以看作是广义奇异值阈值法的一种特例, 其中最大的几个奇异值用零点加权。虽然基于核范数极小化的矩阵修补问题是一个具有全局最优解的凸问题, 但松弛会使解偏离原解。为了能在不增大计算量的情况下, 更好地逼近秩极小化问题。Nie 等人 [5] 将 Schatten-p 范数替换了核范数用于矩阵修补。另一方面核范数松弛的求解方法涉及较为复杂的矩阵奇异值分解, 从而影响了模型的求解效率。于是一些研究者 Srebro[26]、Wen[6]、Shen[7] 等提出了基于矩阵分解的方法。即给定一个秩为 $r(\leq \min(m, n))$, 大小为 $m \times n$ 的部分观测矩阵, 通过优化大小分别为 $m \times r$ 和 $r \times n$ 的且乘积为目标矩阵两个矩阵, 可以恢复出缺失项。基于矩阵分解的矩阵修补是非凸的, 该方法要求事先知道秩 r 。在文献 [6] 中, Wen 提出通过动态调整 r 的矩阵因式分解来恢复缺失项。该方法基于分块坐标下降算法, 它只需要求解一个线性最小二乘问题, 而不是一个奇异值分解。

张量是一个多维数组, 向量和矩阵可以被分别看作是一阶和二阶张量。例如, 彩色图像的数据是三阶张量, 由红、绿和蓝三种通道叠加而成。这类张量数据可以将其按三个通道分别处理, 即对应三个矩阵修补问题, 但这种处理方式严重破坏了张量数据的结构信息, 不利于张量问题的有效求解, 为此, 如何在张量框架下实现(张量形式)图像数据的修补是一个迫切的研究任务。张量修补作为矩阵修补的高阶推广, 能够比矩阵修补更有效地利用数据的结构信息, 得到了广泛关注。目前张量修补中有三类常见的方法。第一类方法称为核范数极小化。在这类方法中将张量的核范数定义为张量的每个模式展开矩阵的核范数之和。一些文献 [9, 10, 11] 建议最小化张量矩阵展开的核范数之和。然而, 在 [27] 中已经表明, 为了确保恢复, 这种方法需要高度非最优的测量数。如在 [10] 中, Liu 等人提出 HaLRTC (high accuracy low rank tensor completio) 算法考虑把张量在每个模式下的展开 (mode unfolding) 矩阵的核范数作为目标函数。思路直接, 易于实现。核张量范数极小化的理论结果已在 [12] 中得到, 但正如刚才提到的, 这种方法并不能产生一种易于处理的算法。文献 [13] 中的理论结果只适用于一类特殊的可分离测量系统, 并且需要一个非最优的测量次数。其他文献 [9, 10, 14] 只对一些通常有希望但缺乏理论分析的算法进行了数值实验。不难看出, 有关张量的早期算法并未能充分的利用张量的高维结构信息。为更好的利用张量结构信息, 第二类使用低秩张量分解, 张量分解是一种将 n 阶张量分解为另一个较小尺寸的 n 阶张量的方法, 称为“核心张量”和 n 个因子矩阵。有两种常用的分解模型: Tucker 分解 [28] 以及 CP (CANDE

COMP/PARAFAC) 分解 [29]。第三类利用张量的代数结构包括基于低秩张量流形上的黎曼优化的方法 [15, 30, 31]。文献 [16, 14] 中的方法是基于实代数几何的工具, 给出了张量核范数的平方和松弛。在图像修补中通常假定数据是光滑的。对于灰度图像, 相邻像素之间的差异通常应该较小。在 [32] 中, 将全变差 (TV) 的极小化作为光滑性约束。此外, 在 [33] 中结合了低秩逼近和光滑约束并采用类似 ADMM 的优化框架来解决。通常, 自然图像兼具这两种结构特征, 所以这种结合是相当有效的

1.3 本文主要工作及结构安排

第1章为绪论, 简述了图像修补的研究背景和意义, 并给出了与图像修补相关的研究现状, 最后总结了本文的主要工作和全文的组织结构。

第2章是相关理论及基础, 简要介绍了与本文相关的矩阵和张量基础知识, 最后对本文涉及的一类流行的交替方向乘子法做了简单介绍。

第3章在矩阵视角下研究了图像修补问题, 提出了联合图像矩阵低秩和光滑先验的新修补算法。该算法通过最小化图像矩阵的 Schatten- p 范数与一类改进的二阶全变差实现图像的完美修补。所获数值实验结果表明: 当缺失率越大时, p 越小效果越好; 而当缺失率越小时, p 越大效果越好。通过选择适当的 p 值, 本节所提算法优于当前许多算法。

第4章通过张量视角研究了图像修补问题, 改良了一类新近提出的 SPC (Smooth PARAFAC tensor Completion) 算法。具体地, 我们将基于一类改进的二阶全变差约束引入到 SPC 算法, 用以替换 SPC 算法中的一阶全变差约束。与 SPC 算法相比, 所获数值实验结果表明: 与 SPC 算法相比 ssim 和 psnr 两项指标上均优于原 SPC 算法。

第5章总结了本文的工作, 并对后续潜在研究工作进行了展望。

第2章 相关理论及基础

2.1 引言

本章主要针对图像修补问题中所涉及到矩阵和张量中若干理论基础和算法工具进行介绍。同时对交替方向乘子法进行了简单介绍。在本文中标量用小写希腊字母 $\alpha, \beta, \gamma, \dots$ 表示, 向量、矩阵和张量分别用小写加粗的英文字母 $\mathbf{a}, \mathbf{b}, \mathbf{c}$, 大写加粗的英文字母 $\mathbf{X}, \mathbf{Y}, \mathbf{Z}$ 和大写的 calligraphic 字母 $\mathcal{X}, \mathcal{Y}, \mathcal{Z}$ 表示。

2.2 矩阵相关理论知识

奇异值分解 (singular value decomposition) 是线性代数中一种重要的矩阵分解, 在信号处理、统计学等领域有重要应用。

定义 1 矩阵的奇异值分解 对于矩阵 $\mathbf{X} \in \mathbb{R}^{m \times n}$ 存在正交矩阵 $\mathbf{U} \in \mathbb{R}^{m \times m}$ 和 $\mathbf{V} \in \mathbb{R}^{n \times n}$ 使得

$$\mathbf{X} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$$

其中 $\mathbf{\Sigma} = \begin{bmatrix} \mathbf{\Sigma}_1 & \mathbf{O} \\ \mathbf{O} & \mathbf{O} \end{bmatrix}$, 且 $\mathbf{\Sigma}_1 = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$, 其对角元素按照以下顺序排列

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0, \quad r = \text{rank}(\mathbf{X})$$

$\sigma_1, \sigma_2, \dots, \sigma_r$ 称为矩阵的奇异值

定义 2 矩阵的核范数 对于矩阵 $\mathbf{X} \in \mathbb{R}^{m \times n}$ 定义其所有奇异值之和为核范数, 即

$$\|\mathbf{X}\|_* = \sum_{i=1}^{\min\{n, m\}} \sigma_i$$

定义 3 矩阵的 Schatten-p 范数 矩阵 $\mathbf{X} \in \mathbb{R}^{n \times m}$ 的 Schatten p 范数定义为

$$\|\mathbf{X}\|_{S_p} = \left(\sum_{i=1}^{\min\{n, m\}} \sigma_i^p \right)^{\frac{1}{p}}$$

其中 σ_i 为矩阵的第 i 个奇异值。容易看出当 $p = 1$ 时 Schatten-p 即为核范数

2.3 张量相关理论知识

对于张量 $\mathcal{X} \in \mathbb{R}^{n_1 \times n_2 \times \cdots \times n_N}$ ， N 称为阶数或 **mode**，第 $i_1, i_2, \dots, i_N$ 个元素记为 $\mathcal{X}_{i_1, i_2, \dots, i_N}$ 。与矩阵中行和列的概念类似，在张量中，改变一个下标，固定其他下标不变所得的一组向量称为纤维。矩阵的列和行可以看做 **mode-1** 和 **mode-2** 的纤维，三阶张量有列纤维 (**mode-1**)、行纤维 (**mode-2**)、管纤维 (**mode-3**) 三种，可分别记为 $\mathcal{X}_{:jk}$, $\mathcal{X}_{i:k}$, $\mathcal{X}_{ij:}$ 。如图 2.1 所示，其中冒号：表示取遍所有的 **mode** 的元素。更进一步，张量也可以看作是矩阵排列的，即改变两个下标，固定其他下标不变，我们称为张量的切片。对于三阶张量有着水平切片、横向切片和正向切片三种，分别记为 $\mathcal{X}_{i::}$, $\mathcal{X}_{:j:}$, $\mathcal{X}_{::k}$ ，如图 2.2 所示。




图 2.1: mode-1 纤维 mode-2 纤维 mode-3 纤维




图 2.2: 水平切片 侧向切片 正向切片

定义 4 张量的 mode 矩阵展开 将张量 $\mathcal{X} \in \mathbb{X}_{n_1 \times n_2 \times \cdots \times n_N}$ 元素通过以下方式映射到矩阵的元素

$$\mathcal{X}_{i_1, i_2, \dots, i_N} \longrightarrow \mathbf{X}_{i_n, j} \quad j = 1 + \sum_{k=1, k \neq n}^N (i_k - 1)J_k, J_k = \prod_{m=1, m \neq n}^{k-1} I_m$$

张量 $\mathcal{X}$ 的 **mode-n** 矩阵展开记为 $\mathbf{X}_{(n)}$ 。所有 **mode-n** 展开矩阵秩所组成的向量称为张量的 **n-rank**，即 $n - \text{rank}(\mathcal{X}) = (\text{rank}(\mathbf{X}_{(1)}), \text{rank}(\mathbf{X}_{(2)}), \dots, \text{rank}(\mathbf{X}_{(N)}))$ 。

定义 5 mode 乘积 对于张量 $\mathcal{X} \in \mathbb{R}^{n_1 \times n_2 \times \cdots \times n_N}$ 与矩阵 $U \in \mathbb{R}^{j \times n_m}$ ，定义：

$$(\mathcal{X} \times_m U)_{i_1 \cdots i_{m-1} j i_{m+1} \cdots i_N} = \sum_{i_m=1}^{n_m} x_{i_1 i_2 \cdots i_N} u_{j i_m}$$

称为张量 $\mathcal{X}$ 和矩阵 U 的 m -mode 乘积, 易知 $\mathcal{X} \times_m U \in \mathbb{R}^{n_1 \times \cdots \times n_{m-1} \times j \times n_{m+1} \times \cdots \times n_N}$ 。

定义 6 CP 分解 对于一个三阶张量 $\mathcal{X} \in \mathbb{R}^{I \times J \times K}$ ，定义其 CP 分解为 [34]

$$\mathcal{X} = \sum_{r=1}^R \lambda_r u_r^{(1)} \circ \cdots \circ u_r^{(N)} \quad (*)$$

其中 $\circ$ 代表向量的外积, 单位向量 $u_r^{(i)}$, $i = 1, 2, \cdots, N$ 在本文称为因子向量, λ_r 为权重。张量的 CP 秩定义为满足 (*) 式最小的 R 。如图 2.3 所示




图 2.3: 张量 CP 分解

定义 7 Tucker 分解 对于一个三阶张量 $\mathcal{X} \in \mathbb{R}^{I \times J \times K}$ ，定义其 Tucker 分解为

$$\mathcal{X} = \mathcal{G} \times_1 U^{(1)} \times_2 \cdots \times_N U^{(N)}$$

其中 $\mathcal{G}$ 称为核心张量, $U^{(i)}$, $i = 1, 2, \cdots, N$ 称为因子矩阵。如图 2.4 所示




图 2.4: 张量 Tucker 分解

2.4 ADMM 算法简介

由于本文第3章中算法的求解基于交替方向乘子法(Alternating Direction Method of Multipliers, ADMM)法,故本节对其进行简要介绍。交替方向乘子法(Alternating Direction Method of Multipliers, ADMM)是一种求解优化问题的计算框架,适用于求解分布式凸优化问题,特别是统计学习问题。ADMM通过分解协调(Decomposition-Coordination)过程,将大的全局问题分解为多个较小、较容易求解的局部子问题,并通过协调子问题的解而得到大的全局问题的解。

ADMM最初是由 Glowinski 和 Marrocco[35] 和 Gabay 和 Mercier[36] 在 1970 年代中期提出的。许多作者,包括 Gabay[37] 和 Eckstein 和 Bertsekas[38],对 ADMM 算法的收敛性进行了研究。由于 admm 算法的提出要早于大规模分布式计算系统和大规模优化问题,所以在 2011 多年前,这种方法还没有广为人知。直到 Boyd 等人于 2011 年重新综述并证明了其适用于大规模的分布式优化问题,从而得到了广泛的应用。

ADMM 计算框架一般问题若优化问题可表示为

$$\min f(x) + g(z) \quad \text{s.t.} \quad \mathbf{A}x + \mathbf{B}z = c$$

其中 $x \in \mathbb{R}^s, z \in \mathbb{R}^n, \mathbf{A} \in \mathbb{R}^{p \times s}, \mathbf{B} \in \mathbb{R}^{p \times n}, c \in \mathbb{R}^p, f: \mathbb{R}^s \rightarrow \mathbb{R}, g: \mathbb{R}^n \rightarrow \mathbb{R}$ 。 x 与 z 是优化变量; $f(x) + g(z)$ 是待最小化的目标函数(Objective Function),它由与变量 x 相关的 $f(x)$ 和与变量 z 相关的 $g(z)$ 这两部分构成,这种结构可以很容易地处理优化目标中的正则化项; $\mathbf{A}x + \mathbf{B}z = c$ 是 p 个等式约束条件(Equality Constraints)的合写。其增广拉格朗日函数(Augmented Lagrangian)为

$$\mathcal{L}_\rho(x, z, y) = f(x) + g(z) + y^T(\mathbf{A}x + \mathbf{B}z - c) + \frac{\rho}{2} \|\mathbf{A}x + \mathbf{B}z - c\|_2^2$$

其中 y 是对偶变量(或称为拉格朗日乘子), $\rho > 0$ 是惩罚参数。 $\mathcal{L}_\rho$ 名称中的“增广”是指其中加入了二次惩罚项 $(\rho/2) \|\mathbf{A}x + \mathbf{B}z - c\|_2^2$ 。

则该优化问题的 ADMM 迭代求解方法为

$$\begin{cases} x^{k+1} := \arg \min_x \mathcal{L}_\rho(x, z^k, y^k) \\ z^{k+1} := \arg \min_z \mathcal{L}_\rho(x^{k+1}, z, y^k) \\ y^{k+1} := y^k + \rho(\mathbf{A}x^{k+1} + \mathbf{B}z^{k+1} - c) \end{cases}$$

可以看出,每次迭代分为三步:

1. 求解与 x 相关的最小化问题，更新变量 x
2. 求解与 z 相关的最小化问题，更新变量 z
3. 更新对偶变量 u

ADMM 名称中的“乘子法”是指这是一种使用增广拉格朗日函数（带有二次惩罚项）的对偶上升（Dual Ascent）方法，而“交替方向”是指变量 x 和 z 是交替更新的。两变量的交替更新是在 $f(x)$ 或 $g(z)$ 可分时可以将优化问题分解的关键原因。

收敛性可以证明，当满足以下条件 [24] 时，

1. 函数 f, g 具有闭的、适当的、凸的性质
2. 非拉格朗日函数 $\mathcal{L}_0$ 有鞍点

ADMM 的迭代收敛（当 $k \rightarrow \infty$ 时， $r^k \rightarrow 0, f(x^k) + g(z^k) \rightarrow p^*, y^k \rightarrow y^*$ ）。这样的收敛条件比没有使用增广拉格朗日函数的对偶上升法的收敛条件宽松了不少。在高精度要求下，ADMM 的收敛很慢；但在中等精度要求下，ADMM 的收敛速度可以接受（几十次迭代）。

2.5 小结

本章介绍了后续章节所涉及到的理论知识，以及相关的算法工具。主要包括：矩阵相关理论基础，包括奇异值分解，核范数以及 Schatten-p 范数的定义；张量相关理论基础，包括张量的基本概念、表示方法以及常见的分解方式以及 ADMM 算法，包括算法的历史，适用范围以及收敛性条件。

第3章 基于矩阵 Schatten-p 范数与光滑性的图像修补

3.1 引言

本章着眼于矩阵类数据的图像修补问题。为此，本章首先回顾了当前矩阵修补领域的相关工作，随后提出了一类联合矩阵低秩与光滑先验的新颖矩阵修补算法。随后借助于流行的 ADMM 算法框架完成了所提模型的数值求解，并将其与若干最新的一些矩阵修补算法进行了对比实验，实验结果表明所提算法具有一定竞争力的。

3.2 相关工作

从模型上讲，矩阵修补是矩阵恢复模型的一类特殊形式。在给出矩阵修补模型之前，我们对矩阵恢复做简单介绍。矩阵恢复广泛地存在于许多工程和科学应用问题 [39, 40, 41, 42] 中，比如，控制理论中的低阶控制元设计，最小实现理论和维数化简，机器学习理论中的多任务学习和流形学习等。在这些问题中，人们往往关心如何从少量线性测量 $\mathbf{b} = \mathcal{A}(\mathbf{X})$ 中成功恢复未知矩阵 $\mathbf{X} \in \mathbb{R}^{n_1 \times n_2}$ 。此处， $\mathbf{b} \in \mathbb{R}^M$ 是线性测量算子 $\mathcal{A}: \mathbb{R}^{n_1 \times n_2} \rightarrow \mathbb{R}^M$ 作用于 $\mathbf{X}$ 上产生的观测数据， M 是测量次数，而 $\mathcal{A}$ 的具体定义如下

$$\mathcal{A}(\mathbf{X}) := [\langle \mathbf{A}^{(1)}, \mathbf{X} \rangle, \langle \mathbf{A}^{(2)}, \mathbf{X} \rangle, \dots, \langle \mathbf{A}^{(M)}, \mathbf{X} \rangle]^T,$$

其中 $\mathbf{A}^{(i)} \in \mathbb{R}^{n_1 \times n_2}$ ，而 $\langle \mathbf{X}, \mathbf{Y} \rangle \triangleq \sum_{i,j} \mathbf{X}_{ij} \mathbf{Y}_{ij}$ 为矩阵内积。

不失一般性，可假定 $n_1 \leq n_2$ 。从数学的角度讲，当 M 较小时，从线性测量 $\mathbf{b} = \mathcal{A}(\mathbf{X})$ 中反解 $\mathbf{X}$ 是一个欠定问题。为此，我们必须要对待恢复矩阵提出一些必要的额外条件。当前一个被广大学者普遍接受的假设是：待恢复矩阵是低秩的或者可由一个低秩矩阵很好地逼近。最自然的想法是最小化矩阵的秩，即考虑以下问题

$$\min_{\mathbf{X}} \text{rank}(\mathbf{X}) \quad \text{s.t. } \mathbf{b} = \mathcal{A}(\mathbf{X}) \quad (3.1)$$

在这当中通常考虑一种简单的情形，即当 $\mathcal{A}(\mathbf{X}) = \mathbf{X}_\Omega$ 时，

$$\min_{\mathbf{X}} \text{rank}(\mathbf{X}) \quad \text{s.t. } \mathbf{X}_\Omega = \mathbf{T}_\Omega \quad (3.2)$$

Ω 表示 $\mathbf{T}$ 中已知元素的索引，即 $\mathbf{X}_\Omega = \mathbf{T}_\Omega$ 意味着 $\mathbf{X}(i, j) = \mathbf{T}(i, j), \forall (i, j) \in \Omega$ 。这

个思路虽然自然,但在计算上遇到了障碍。由于秩不是关于 $\mathbf{X}$ 的凸函数,秩最小化一般是 NP 难的 [43]。因此,往往求解以下核范数极小化问题

$$\min_{\mathbf{X}} \|\mathbf{X}\|_* \quad \text{s.t. } \mathbf{X}_\Omega = \mathbf{T}_\Omega \quad (3.3)$$

其中 $\|\mathbf{X}\|_* = \sum_i \sigma_i(\mathbf{X})$ 表示核范数, $\sigma_i(\mathbf{X})$ 表示矩阵 $\mathbf{X}$ 的第 i 大的奇异值。

矩阵的核范数是矩阵秩的凸松弛。这种处理方式得到了广泛的应用。延续 Candès 和 Recht 的开创性的工作,有许多学者进一步对核范数最小化问题进行了研究。例如, Cai 等人 [44] 在原始核范数最小化问题基础上添加 Frobenius 项,并提出了一个基于梯度下降理论的算法; Hu 等人 [4] 提出了基于矩阵截断核范数最小化算法。虽然基于迹范数极小化的矩阵补全目标是一个具有全局解的凸问题,但松弛会使解严重偏离原解。期望在不引入大量计算量的情况下,能较好地解决秩极小化问题的逼近问题。一些研究人员 [45] 研究了如下的 Schatten- p 极小化问题,利用 Schatten p -范数重新刻画了矩阵的低秩性。当 $p \rightarrow 0$ 时,新的目标函数能比迹范数更好地逼近秩函数。

$$\begin{aligned} \min_{\mathbf{X}} \|\mathbf{X}\|_{S_p}^p \\ \text{s.t. } \mathbf{X}_\Omega = \mathbf{M}_\Omega. \end{aligned} \quad (3.4)$$

关于 Schatten- p 极小化问题的研究表明:选择适当的 $p \in (0, 1)$ 可以产生远优于 $p = 1$ (即核范数最小化问题) 的低秩解。事实上,除了上述提及的一些算法外,还有很多其他形式的矩阵修补算法,

总的来看,当前几乎所有的矩阵修补算法都旨在逼近秩最小化问题(3.2),进而秩的凸松弛。从先验信息的角度,低秩性结构仅仅刻画了矩阵的全局信息。然而在实际中,矩阵除了具有低秩结构外,还往往具有其他一些局部光滑的特征。面对这类矩阵,如果仅考虑其低秩性,其重构表现往往难以让人满意。自然,如何整合更多的先验信息 (特别是矩阵的局部光滑先验信息) 来提升矩阵修补质量成了一个非常重要的研究内容。Han 等人 [33] 从低秩和光滑性角度研究了这类问题,并提出了相应的 LTVNN (Linear total variation approximate regularized nuclear norm) 算法。该算法模型如下

$$\begin{aligned} \min_{\mathbf{X}} \gamma \|\mathbf{X}\|_* + (1 - \gamma) \|\mathbf{X}\|_{\text{LTV}} \\ \text{s.t. } \mathbf{X}_\Omega = \mathbf{M}_\Omega, \end{aligned} \quad (3.5)$$

其中 $0 \leq \gamma \leq 1$ 是一个惩罚参数，而

$$\|\mathbf{X}\|_{\text{LTVA}} \triangleq \sum_{i=1}^m \sum_{j=1}^n ((D_{i,j}^v(\mathbf{X}))^2 + (D_{i,j}^h(\mathbf{X}))^2) \quad (3.6)$$

定义为矩阵的近似线性全变差 (Linear total variation approximate, LTVA)，即

$$D_{i,j}^v(\mathbf{X}) = \begin{cases} \mathbf{X}_{i,j} - \mathbf{X}_{i+1,j}, & 1 \leq i < m \\ 0, & i = m \end{cases}, \quad D_{i,j}^h(\mathbf{X}) = \begin{cases} \mathbf{X}_{i,j} - \mathbf{X}_{i,j+1}, & 1 \leq j < n \\ 0, & j = n. \end{cases}$$

实验结果表明，LTVNN 算法要远优于仅考虑低秩特性的其他矩阵修补算法。然而令人遗憾的是，他们在求解问题(3.5)时，并不是对其进行直接求解，而是将其转化为两个相对独立的子问题进行求解，最后对它们的结果进行整合 (取均值) 显然这种求解方法所得结果与原问题并不完全一致。

3.3 所提模型

光滑是一个重要的属性, 它出现在许多真实世界数据的例子中, 如自然图像/视频、一些光谱信号和生物医学数据, 结合前一小节中所提相关工作算法的优劣, 我们在本节中使用 Schatten-p 范数来刻画矩阵的低秩性, 并利用如下改进的二阶全变差来刻画矩阵数据间的光滑性。




图 3.1: LTVA 和 MSTV 分别是一阶全变差和二阶全变差。灰色的点表示因子向量非首尾的任一元素，红点表示相邻项，灰色点表示其他元素，容易看出，MSTV 一次考虑到了更多相邻元素的信息，因而产生了更好的性能。

对于任意的 $v = m, n$, 我们定义

$$\mathbf{R}_v := \begin{bmatrix} -1 & 1 & & & \\ & 1 & -2 & \ddots & \\ & & 1 & \ddots & 1 \\ & & & \ddots & -2 & -1 \\ & & & & 1 & 1 \end{bmatrix} \in \mathbb{R}^{v \times v}. \quad (3.7)$$

$$\|\mathbf{X}\|_{\text{MSTV}} = \|\mathbf{X}^T \mathbf{R}_m\|_F^2 + \|\mathbf{X} \mathbf{R}_n\|_F^2, \quad (3.8)$$

于是我们考虑一下优化问题:

$$\begin{aligned} \min_{\mathbf{X}} \quad & \|\mathbf{X}\|_{S_p}^p + \lambda(\|\mathbf{X}^T \mathbf{R}_m\|_F^2 + \|\mathbf{X} \mathbf{R}_n\|_F^2) \\ \text{s.t.} \quad & \mathbf{X}_\Omega = \mathbf{M}_\Omega, \end{aligned} \quad (3.9)$$

其中 $\lambda > 0$ 是一个惩罚参数。为能使用 ADMM 框架求解问题(3.9), 所以将问题形式改写为问题(3.10)

$$\begin{aligned} \min_{\mathbf{X}} \quad & \|\mathbf{X}\|_{S_p}^p + \lambda(\|\mathbf{Y}^T \mathbf{R}_m\|_F^2 + \|\mathbf{Y} \mathbf{R}_n\|_F^2) \\ \text{s.t.} \quad & \mathbf{X} - \mathbf{Y}, \mathbf{Y}_\Omega = \mathbf{M}_\Omega \end{aligned} \quad (3.10)$$

(3.10)式所对应的增广拉格朗日函数为

$$\mathcal{L}_\rho(\mathbf{X}, \mathbf{Y}, \mathbf{Z}) = \|\mathbf{X}\|_{S_p}^p + \lambda(\|\mathbf{Y}^T \mathbf{R}_m\|_F^2 + \|\mathbf{Y} \mathbf{R}_n\|_F^2) + \text{Tr}(\mathbf{Z}^T(\mathbf{X} - \mathbf{Y})) + \frac{\rho}{2} \|\mathbf{X} - \mathbf{Y}\|_F^2$$

其中 Tr 为矩阵的迹函数, 即矩阵主对角线元素之和。 $\mathbf{Z} \in \mathbb{R}^{m \times n}$ 是平衡参数, $\rho > 0$ 是惩罚参数, 由 ADMM 算法框架 [24], 只需按以下步骤迭代求解

$$\begin{cases} \mathbf{X}^{(k+1)} = \arg \min_{\mathbf{X}} \|\mathbf{X}\|_{S_p}^p + \text{Tr}((\mathbf{Z}^{(k)})^T(\mathbf{X} - \mathbf{Y}^{(k)})) + \frac{\rho}{2} \|\mathbf{X} - \mathbf{Y}^{(k)}\|_F^2 \\ \mathbf{Y}^{(k+1)} = \arg \min_{\mathbf{Y}} \lambda(\|\mathbf{Y}^T \mathbf{R}_m\|_F^2 + \|\mathbf{Y} \mathbf{R}_n\|_F^2) + \text{Tr}((\mathbf{Z}^{(k)})^T(\mathbf{X}^{(k+1)} - \mathbf{Y})) \\ \quad + \frac{\rho}{2} \|\mathbf{X}^{(k+1)} - \mathbf{Y}\|_F^2 \\ \mathbf{Z}^{(k+1)} = \mathbf{Z}^{(k)} + \rho(\mathbf{X}^{(k+1)} - \mathbf{Y}^{(k+1)}) \end{cases} \quad (3.11)$$

1. 固定 $\mathbf{Y}^{(k)}$ 和 $\mathbf{Z}^{(k)}$, 更新 $\mathbf{X}^{(k+1)}$

$$\mathbf{X}^{(k+1)} = \arg \min_{\mathbf{X}} \|\mathbf{X}\|_{s_p}^p + \text{Tr}((\mathbf{Z}^{(k)})^T (\mathbf{X} - \mathbf{Y}^{(k)})) + \frac{\rho}{2} \|\mathbf{X} - \mathbf{Y}^{(k)}\|_F^2$$

在上式中对 $\mathbf{X}$ 进行配方, 即得

$$\mathbf{X}^{(k+1)} = \arg \min_{\mathbf{X}} \|\mathbf{X}\|_{s_p}^p + \frac{\rho}{2} \|\mathbf{X} - \mathbf{G}\|_F^2, \quad (3.12)$$

其中 $\mathbf{G} = \mathbf{Y}^{(k)} - \mathbf{Z}^{(k)}/\rho$, 对于这个子问题的求解, 在文献 [46] 中已经给出, 可以归结于求解一下问题

$$\min_{\delta_i \geq 0} (\delta_i - \sigma_i)^2 + \frac{1}{2\rho} \delta_i^p$$

更多具体细节可查阅 [46]

2. 固定 $\mathbf{X}^{(k+1)}$ 和 $\mathbf{Z}^{(k)}$, 通过下式求解 $\mathbf{Y}^{(k+1)}$

$$\begin{aligned} \mathbf{Y}^{(k+1)} &= \arg \min_{\mathbf{Y}} \mathcal{L}_\rho(\mathbf{X}^{(k+1)}, \mathbf{Y}, \mathbf{Z}^{(k)}), \\ \text{s.t. } \mathbf{Y}_\Omega &= M_\Omega, \end{aligned}$$

即

$$\begin{aligned} \mathbf{Y}^{(k+1)} &= \arg \min_{\mathbf{Y}} \mathcal{J}(\mathbf{Y}) := \lambda(\|\mathbf{Y}^T \mathbf{R}_m\|_F^2 + \|\mathbf{Y} \mathbf{R}_n\|_F^2) + \frac{\rho}{2} \|\mathbf{Y} - H\|_F^2, \\ \text{s.t. } \mathbf{Y}_\Omega &= M_\Omega, \end{aligned}$$

其中 $H := \mathbf{X}^{(k+1)} + \mathbf{Z}^{(k)}/\rho$ 。令 $\mathcal{J}(\mathbf{Y})$ 关于 $\mathbf{Y}$ 的导函数为 0, 可得

$$2\lambda \mathbf{R}_m \mathbf{R}_m^T \mathbf{Y} + \mathbf{Y} (2\lambda \mathbf{R}_n \mathbf{R}_n^T + \rho I_n) = \rho H, \quad (3.13)$$

其中 I_n 是一个 $n \times n$ 的单位矩阵。上述方程可以利用 Matlab 命令 *lyap* 来求解它, 即

$$\mathbf{Y} = \text{lyap}(2\lambda \mathbf{R}_m \mathbf{R}_m^T, 2\lambda \mathbf{R}_n \mathbf{R}_n^T + \rho I_n, -\rho H).$$

在求得 $\mathbf{Y}$ ，即方程(3.13)的解之后，可以利用下式求得 $\mathbf{Y}^{(k+1)}$

$$\mathbf{Y}^{(k+1)} = M_{\Omega} + \mathbf{Y}_{\Omega^c}. \quad (3.14)$$

3. 按下式更新 $\mathbf{Z}^{(k+1)}$

$$\mathbf{Z}^{(k+1)} = \mathbf{Z}^{(k)} + \rho(\mathbf{X}^{(k+1)} - \mathbf{Y}^{(k+1)}). \quad (3.15)$$

上述过程总结为算法 1

算法 1: 基于 ADMM 框架求解问题(3.9)

输入: $\lambda, \Omega, M_{\Omega}, \mathbf{X}^{(0)} = \mathbf{Y}^{(0)} = M_{\Omega}, \mathbf{Z}^{(0)} = 0, \rho, \mathbf{R}_m, \mathbf{R}_n$

输出: $\mathbf{X}$

- 1 初始化 $k = 1$;
 - 2 **repeat**
 - 3 按(3.12)更新 $\mathbf{X}$;
 - 4 按(3.14)更新 $\mathbf{Y}$;
 - 5 按(3.15)更新 $\mathbf{Z}$;
 - 6 更新 $k = k + 1$;
 - 7 **until** 收敛;
-

3.4 数值实验

在本节中，将本文所提出的矩阵修补算法应用于黑白图片的随机缺失修补问题，并与 IRLS 算法 [45]、PSSV 算法 [47]、LTVNN 算法 [33] 进行对比，算法实验运行在个人电脑（Intel(R) Core(TM) i7-6700HQ CPU 2.60GHz Windows 8.1）上的 MATLAB R2017a 中，每个修补程序重复十次，取平均值为最终结果。测试图片选用了十张图像处理领域常用图片，每张图片大小为 256×256 ，png 格式，如图 3.1 所示

我们使用峰值信噪比 (PSNR) 和结构相似度 (SSIM) 作为评价图片恢复质量的指标。PSNR 通过下式定义

$$\text{PSNR} = 10 \log_{10} \left(\frac{255^2}{\text{MSE}} \right)$$

其中 MSE 为输入与输出张量的均方误差。SSIM 是通过使用图像中局部小块的平均值和方差参数来定义的，更多细节可以参考 [48]。容易看出，SSIM 是对 PSNR 的改进，因为其更好的度量了局部光滑性。



图 3.2: 测试图片

其中 baboon 的恢复结果如表 3.1 所示, 其余图片实验结果见表 3.2-3.10。其中 $p = 0, 0.2, \dots, 1$ 表示 Schatten-p 范数中 p 的取值, 为更好的展示实验结果, 分别将 PSNR 值与 SSIM 值的变化绘制在图 3.2 与 3.3 中。从图中, 我们不难看出, 当缺失比率下降时, 所有算法效果都得到了提升, 并且当缺失率越大时, p 越小效果越好; 而当缺失率越大时, p 越大效果越好。通过选择适当的 p 值, 本节所提算法优于 IRLS 算法、PSSV 算法和 LTVNN 算法。

表 3.1: Baboon 在不同缺失比例与不同算法下的实验结果

缺失百分比 指标	60		50		40		30	
	psnr	ssim	psnr	ssim	psnr	ssim	psnr	ssim
IRLS	21.1646	0.615	21.5698	0.7052	21.7463	0.7716	21.9676	0.8351
PSSV	20.9464	0.5981	21.4313	0.6846	21.8391	0.765	22.3894	0.8389
LTVNN	22.6474	0.7308	23.0399	0.7991	23.3398	0.8537	23.6228	0.8983
P=0.2	23.3549	0.79	23.9352	0.8472	24.2541	0.8878	24.659	0.9241
P=0.4	23.3872	0.7847	23.9365	0.8417	24.2541	0.8878	24.6591	0.9241
P=0.6	23.2604	0.759	23.7553	0.8202	24.258	0.8879	24.6594	0.9241
P=0.8	22.5279	0.701	22.9485	0.7691	24.2666	0.888	24.6607	0.9241




图 3.3: 几种算法在不同缺失率下恢复图像的 PSNR




图 3.4: 几种算法在不同缺失率下恢复图像的 SSIM

3.5 小结

本章主要包括三个部分，首先简要回顾了矩阵修补方面相关的算法工作，然后提出了联合图像矩阵低秩和光滑先验的新修补算法。该算法通过最小化图像矩阵的 Schatten-p 范数与一类改进的二阶全变差实现图像的完美修补。最后我们通过数值实验对所提算法的有效性进行了验证，实验结果表明当缺失比率下降时，所有算法效果都得到了提升，并且当缺失率越大时， p 越小效果越好；而当缺失率越大时， p 越大效果越好。通过选择适当的 p 值，本节所提算法优于 IRLS 算法、PSSV 算法和 LTVNN 算法。

表 3.2: F16 在不同缺失比例与不同算法下的实验结果

缺失百分比 指标	60		50		40		30	
	psnr	ssim	psnr	ssim	psnr	ssim	psnr	ssim
IRLS	21.9156	0.7016	22.425	0.7713	22.7746	0.822	22.8689	0.8654
PSSV	22.0734	0.6935	23.4118	0.7826	24.8638	0.8551	26.2031	0.906
LTVNN	23.5741	0.8657	24.3626	0.9048	24.9329	0.9345	25.5752	0.9569
IRLS	21.9156	0.7016	22.425	0.7713	22.7746	0.822	22.8689	0.8654
PSSV	22.0734	0.6935	23.4118	0.7826	24.8638	0.8551	26.2031	0.906
LTVNN	23.5741	0.8657	24.3626	0.9048	24.9329	0.9345	25.5752	0.9569
p=0.2	26.4956	0.9236	27.4542	0.9483	28.2166	0.9631	29.1393	0.9796
p=0.4	26.6026	0.9125	27.4806	0.936	28.2579	0.9534	29.138	0.9795
p=0.6	26.362	0.8769	27.2138	0.9065	28.1842	0.9686	29.1392	0.9796
p=0.8	24.8174	0.8079	25.7822	0.8587	26.8855	0.9017	29.1422	0.9796

表 3.3: house 在不同缺失比例与不同算法下的实验结果

缺失百分比 指标	60		50		40		30	
	psnr	ssim	psnr	ssim	psnr	ssim	psnr	ssim
IRLS	25.525	0.777	26.0672	0.8253	26.087	0.8649	26.4841	0.8997
PSSV	26.0654	0.7718	28.0929	0.8512	29.448	0.9008	30.5053	0.9401
LTVNN	26.4274	0.8756	27.653	0.9155	28.1243	0.9405	28.7024	0.959
p=0.2	29.0417	0.9026	29.982	0.927	30.1693	0.9447	30.9132	0.9645
p=0.4	29.2966	0.897	30.2222	0.9199	30.4329	0.9418	30.9132	0.9644
p=0.6	29.2566	0.8731	30.3407	0.9044	30.7658	0.931	30.9162	0.9645
p=0.8	28.1938	0.835	29.6067	0.8816	30.5106	0.9172	30.9249	0.9646

表 3.4: barbara 在不同缺失比例与不同算法下的实验结果

缺失百分比 指标	60		50		40		30	
	psnr	ssim	psnr	ssim	psnr	ssim	psnr	ssim
IRLS	22.2608	0.6931	22.6503	0.7619	22.7835	0.8095	22.9808	0.8554
PSSV	22.7399	0.7014	23.9725	0.7935	25.0033	0.8552	26.0949	0.9098
LTVNN	23.4323	0.8143	24.1528	0.8688	24.6326	0.9059	25.129	0.9371
p=0.2	25.6028	0.8864	26.2047	0.9169	26.6761	0.9423	27.1313	0.9598
p=0.4	25.7359	0.8787	26.3215	0.91	26.6746	0.9422	27.1316	0.9598
p=0.6	25.6547	0.8515	26.3149	0.8891	26.679	0.9422	27.1327	0.9598
p=0.8	24.6807	0.797	25.557	0.8529	26.27	0.8947	27.1354	0.9598

表 3.5: cornfield 在不同缺失比例与不同算法下的实验结果

缺失百分比 指标	60		50		40		30	
	psnr	ssim	psnr	ssim	psnr	ssim	psnr	ssim
IRLS	18.769	0.7037	19.2192	0.766	19.407	0.8238	19.7192	0.8675
PSSV	18.7731	0.7094	19.5071	0.7819	20.189	0.8494	21.236	0.904
LTVNN	20.5215	0.8078	21.0574	0.8584	21.3398	0.8987	21.8986	0.9314
p=0.2	22.2104	0.861	23.0372	0.9017	23.5556	0.9296	24.2519	0.9558
p=0.4	22.2527	0.859	23.0808	0.8988	23.583	0.9272	24.2517	0.9557
p=0.6	22.1974	0.8481	23	0.8889	23.4798	0.9209	24.2518	0.9557
p=0.8	21.3171	0.8096	22.1075	0.8608	22.6174	0.9033	24.2524	0.9557

表 3.6: girl 在不同缺失比例与不同算法下的实验结果

缺失百分比 指标	60		50		40		30	
	psnr	ssim	psnr	ssim	psnr	ssim	psnr	ssim
IRLS	26.1295	0.7821	26.6328	0.8372	27.0322	0.8722	27.2116	0.9022
PSSV	26.5676	0.7916	27.6022	0.8523	28.698	0.8986	29.8129	0.934
LTVNN	28.0578	0.8898	28.8705	0.9218	29.7235	0.9454	30.1266	0.9627
p=0.2	31.4153	0.9317	31.9006	0.9454	32.8897	0.9592	33.5731	0.9773
p=0.4	31.0681	0.9168	31.5325	0.9322	32.519	0.9514	33.5741	0.9774
p=0.6	30.0381	0.8859	30.6176	0.9097	33.2117	0.968	33.5755	0.9774
p=0.8	28.2546	0.8413	29.0213	0.8817	30.0945	0.9177	33.5771	0.9774

表 3.7: goldhill 在不同缺失比例与不同算法下的实验结果

缺失百分比 指标	60		50		40		30	
	psnr	ssim	psnr	ssim	psnr	ssim	psnr	ssim
IRLS	25.0033	0.7471	25.4885	0.8053	25.6196	0.8461	25.8311	0.8847
PSSV	25.1268	0.743	26.3287	0.8187	27.2399	0.8759	28.3229	0.9221
LTVNN	26.0358	0.8315	26.7639	0.8797	27.3014	0.9143	27.9531	0.9421
p=0.2	28.686	0.8894	29.4504	0.9209	30.0405	0.9457	30.881	0.9643
p=0.4	28.7515	0.8836	29.4898	0.9152	30.0339	0.9455	30.8816	0.9643
p=0.6	28.2903	0.858	28.9672	0.8937	30.0425	0.9456	30.883	0.9643
p=0.8	26.874	0.8081	27.6234	0.8584	30.059	0.9458	30.8867	0.9643

表 3.8: lena 在不同缺失比例与不同算法下的实验结果

缺失百分比 指标	60		50		40		30	
	psnr	ssim	psnr	ssim	psnr	ssim	psnr	ssim
IRLS	22.6178	0.709	23.0189	0.7729	23.1146	0.8203	23.3984	0.8606
PSSV	22.8427	0.6901	24.1271	0.78	25.0895	0.8503	26.3955	0.9043
LTVNN	24.6131	0.8505	25.4181	0.8958	26.0652	0.9278	26.8669	0.9524
p=0.2	28.4222	0.9271	29.1652	0.9479	29.9665	0.9626	30.7549	0.978
p=0.4	28.269	0.9137	28.8746	0.9348	29.6882	0.9536	30.7551	0.9781
p=0.6	27.3452	0.871	27.9462	0.9014	30.0014	0.967	30.7555	0.9781
p=0.8	25.4329	0.802	26.2536	0.8519	26.9904	0.8964	30.7559	0.9781

表 3.9: peppers 在不同缺失比例与不同算法下的实验结果

缺失百分比 指标	60		50		40		30	
	psnr	ssim	psnr	ssim	psnr	ssim	psnr	ssim
IRLS	22.7389	0.7077	23.2279	0.7763	23.3152	0.8194	23.4774	0.8592
PSSV	23.4487	0.7103	25.1617	0.8062	26.3859	0.8752	28.0038	0.922
LTVNN	24.8018	0.8699	25.9723	0.9159	26.5706	0.9414	27.4152	0.9629
p=0.2	29.2093	0.9468	29.927	0.9614	30.6594	0.9758	31.198	0.9844
p=0.4	29.1491	0.9334	29.8583	0.9488	30.4493	0.9608	31.2015	0.9844
p=0.6	28.3992	0.896	29.18	0.9189	29.8205	0.9415	31.2031	0.9844
p=0.8	26.3067	0.8274	27.3477	0.8741	28.1904	0.9119	31.2068	0.9844

表 3.10: yacht 在不同缺失比例与不同算法下的实验结果

缺失百分比 指标	60		50		40		30	
	psnr	ssim	psnr	ssim	psnr	ssim	psnr	ssim
IRLS	21.3956	0.6989	21.8853	0.763	22.2513	0.8182	22.3835	0.8641
PSSV	21.5942	0.693	22.7855	0.7848	23.9639	0.8562	25.3182	0.9124
LTVNN	22.8397	0.8246	23.4688	0.8737	24.1846	0.9142	24.6703	0.9431
p=0.2	24.1877	0.8707	24.9742	0.9082	25.7981	0.9396	26.5473	0.962
p=0.4	24.3952	0.8672	25.1995	0.9033	25.801	0.9397	26.5479	0.962
p=0.6	24.5275	0.8479	25.3691	0.8883	25.8109	0.9399	26.5496	0.962
p=0.8	23.6895	0.7953	24.6289	0.8502	25.4966	0.8972	26.5526	0.962

第4章 基于张量修补与光滑先验的图像修补

4.1 相关工作

低秩张量修补中最核心的问题是定义与矩阵中秩相类似的概念。与矩阵的情形类似，最直接的想法是

$$\min_{\mathcal{X}} \text{rank}(\mathcal{X}) \quad \text{s.t. } \mathcal{X}_{\Omega} = \mathcal{T}_{\Omega} \quad (4.1)$$

其中的 $\text{rank}(\mathcal{X})$ 代表张量某种秩的定义。

如果使用 n-rank 及其相关的定义，那么问题是非凸的，如果使用 CP 秩，由于在目前也没有一个直接的算法给出任意张量的 CP 秩，所以问题也同样难以求解。对于使用 n-rank 的解决方法是考虑其中每一个的凸松弛，得到如下问题

$$\min_{\mathcal{X}} \sum_{i=1}^N \|\mathcal{X}_{(i)}\|_* \quad \text{s.t. } \mathcal{X}_{\Omega} = \mathcal{T}_{\Omega} \quad (4.2)$$

其中 $\|\mathcal{X}_{(i)}\|_*$ 表示张量 $\mathcal{X}$ mode-i 展开矩阵的核范数。

这类问题可以通过交替方向乘子法 (ADMM) 法来求解。与直接把张量展开为矩阵来研究不同，越来越多的研究人员提出了基于张量分解的修补算法。如基于 Tucker 分解的 STDC[12] 研究以下问题

$$\begin{aligned} \min_{\mathcal{G}, \mathbf{U}^{(1)}, \dots, \mathbf{U}^{(N)}} & \sum_{i=1}^N \alpha_i \|\mathbf{U}^{(i)}\|_* + \delta \text{tr}(\mathbf{\Phi} \mathbf{L} \mathbf{\Phi}^T) + \gamma \|\mathcal{G}\|_F^2 \\ \text{s.t. } & \mathcal{X} = \mathcal{G} \times \{\mathbf{U}^{(i)}\}_{i=1}^N, \mathcal{X}_{\Omega} = \mathcal{T}_{\Omega} \end{aligned} \quad (4.3)$$

其中 $\mathbf{\Phi} = \mathbf{U}^{(1)} \otimes \dots \otimes \mathbf{U}^{(N)}$, $\otimes$ 是克罗内克积。

该优化问题同样可以采用基于 ADMM 的方法来求解,值得注意的是 $\delta \text{tr}(\mathbf{\Phi} \mathbf{L} \mathbf{\Phi}^T)$ 可以看做是用来约束因子矩阵间的相似性,即利用了数据间的光滑先验信息。

最近在文献 [10] 中作者将光滑先验引入张量的 CP 分解中,对因子向量进行

光滑约束。先假定张量的 CP 秩是固定的, 考虑以下优化问题

$$\begin{aligned} \min_{\Lambda, A, B, C} & \frac{1}{2} \|\mathcal{X} - \mathcal{Y}\|_F^2 + \sum_{r=1}^R \frac{\lambda_r^2}{2} (\rho_m \|L^m \mathbf{a}_r\|_p^p + \rho_n \|L^n \mathbf{b}_r\|_p^p + \rho_l \|L^l \mathbf{c}_r\|_p^p) \\ \text{s.t. } & \mathcal{Y} = \sum_{r=1}^R \lambda_r \mathbf{a}_r \circ \mathbf{b}_r \circ \mathbf{c}_r, \mathcal{X}_\Omega = \mathcal{T}_\Omega, \mathcal{X}_{\bar{\Omega}} = \mathcal{Y}_{\bar{\Omega}} \\ & \mathbf{a}_r, \mathbf{b}_r, \mathbf{c}_r \text{ 为单位向量} \end{aligned} \quad (4.4)$$

其中 $\mathcal{X} \in \mathbb{R}^{m \times n \times l}$ 是一个完整的输出张量, 缺失项用光滑的 CP 近似 $\mathcal{Y}$ 填充。约束 $\mathcal{X}_\Omega = \mathcal{T}_\Omega$ 和 $\mathcal{X}_{\bar{\Omega}} = \mathcal{Y}_{\bar{\Omega}}$ 意味着以下关系成立

$$\mathcal{X}_{i_1, i_2, \dots, i_N} = \begin{cases} \mathcal{T}_{i_1, i_2, \dots, i_N} & (i_1, i_2, \dots, i_N) \in \Omega \\ \mathcal{Y}_{i_1, i_2, \dots, i_N} & (i_1, i_2, \dots, i_N) \notin \Omega \end{cases}$$

ρ_m, ρ_n, ρ_l 为权重参数, $p \in \{1, 2\}$ 参数代表了两种不同的范数约束, 矩阵 $L^n \in \mathbb{R}^{(n-1) \times n}$ 是一个光滑约束矩阵, L 为一阶 TV 算子, $\|L^m \mathbf{a}_r\|_p^p, \|L^n \mathbf{b}_r\|_p^p, \|L^l \mathbf{c}_r\|_p^p$ 作为约束项, 约束了 CP 分解中因子向量的光滑性。

4.2 基于二阶 TV 的改进 SPC 算法

当数据更为复杂的时候, 仅仅用矩阵 (如图 4.1, 对于一个彩色图像分别考虑每个颜色通道的图像矩阵恢复效果, 再将分别计算的结果组合起来。) 或转化为矩阵 (比如张量的矩阵展开) 来表示这些数据往往会丢失一些数据本身的结构信息, 这时我们就需要借助张量来表示这种多目标之间的关系。在高维的情形中很多问题可以转化为求解一个可以很好的描述原始数据的低秩张量, 而这一类问题就叫做低秩张量修补问题。



图 4.1:

上述 SPC 算法刻画光滑性是基于张量 CP 分解中因子向量的一阶 TV 范数, 它

与前一章中介绍的 LTVA 是类似的, 可以写作

$$\|\mathbf{X}\|_{\text{LTVA}} = \|\mathbf{X}^T L_m\|_F^2 + \|\mathbf{X}^T L_n\|_F^2$$

其中 L^n 在文献 [10] 中定义为

$$L^n := \begin{pmatrix} 1 & -1 & & & \\ & 1 & -1 & & \\ & & \ddots & \ddots & \\ & & & 1 & -1 \end{pmatrix} \quad (4.5)$$

线性全变差易引起的阶梯效应, 且由前一章我们知道它并不是光滑性的最佳度量。所以本文考虑以下前一章所使用的二次全变差矩阵 $W^n \in \mathbb{R}^{n \times n}$ 来约束因子向量

$$R^n := \begin{pmatrix} -1 & 1 & & & \\ 1 & -2 & 1 & & \\ & & \ddots & \ddots & \\ & & & 1 & -2 & 1 \\ & & & & 1 & -1 \end{pmatrix} \quad (4.6)$$

矩阵 (2) 和 (3) 对于因子向量的约束在几何上的不同如图 4.1 所示



图 4.2: (2) 和 (3) 分别是一阶全变差和二阶全变差。灰色的点表示因子向量非首尾的任一元素, 红点表示对应与 (2) 和 (3) 的相邻项

针对优化问题 (1) 使用分层交替最小二乘法 (HALS)[49, 50] 求解。首先固定 r 考虑以下局部函数的最小化:

$$\begin{aligned} \min_{\lambda_r, a, b, c} & \frac{1}{2} \|\mathcal{Z}_r - \mathcal{Y}_r\|_F^2 + \frac{\lambda_r^2}{2} (\rho_m \|\mathbf{R}^m \mathbf{a}_r\|_p^p + \rho_n \|\mathbf{R}^n \mathbf{b}_r\|_p^p + \rho_l \|\mathbf{R}^l \mathbf{c}_r\|_p^p) \\ \text{s.t. } & \mathcal{Y}_r = \lambda_r \mathbf{a}_r \circ \mathbf{b}_r \circ \mathbf{c}_r \quad [\mathcal{Z}_r]_\Omega = \mathcal{T}_\Omega^{(r)}, [\mathcal{Z}_r]_{\bar{\Omega}} = \mathcal{Y}_{\bar{\Omega}} \quad (4) \\ & \mathbf{a}_r, \mathbf{b}_r, \mathbf{c}_r \end{aligned}$$

其中 $\mathcal{Z}_r = \mathcal{X} - \sum_{i \neq r} \lambda_i \mathbf{a}_i \circ \mathbf{b}_i \circ \mathbf{c}_i$ 且 $\mathcal{T}_\Omega^{(r)} = \mathcal{T}_\Omega - [\sum_{i \neq r} \lambda_i \mathbf{a}_i \circ \mathbf{b}_i \circ \mathbf{c}_i]_\Omega$,

注 1: 由图 1 可知本文所使用的二阶全变分相比于一阶全变分利用了更多的相邻元素, 同时避免一阶全变分所带来的阶梯效应, 因此能产生更好的性能。

注2: 从光滑约束的形式来看, 还可以考虑更为复杂的高阶光滑以及根据图片局部形式自适应的调整光滑约束形式, 以及考虑更多可用的矩阵先验信息以提高现有矩阵修补方法的性能。

模型基于文献 [51] 中 SPC 的算法框架进行求解, 现将算法流程介绍如下:

- 1) 更新因子向量 $\mathbf{a}_r, \mathbf{b}_r, \mathbf{c}_r$: 以 $\mathbf{a}_r$ 为例研究目标函数的梯度 (或次梯度)。目标函数可以简化为

$$\frac{\lambda_r^2}{2} \rho^m \|\mathbf{R}^m \mathbf{a}_r\|_p^p - \lambda_r \mathbf{a}_r^T \mathbf{z}_r^{(n)} + \frac{1}{2} \lambda_r^2 \mathbf{a}_r^T \mathbf{a}_r$$

其中 $\mathbf{z}_r^{(n)} := \text{vec}(\mathcal{Z}_r \times_1 \mathbf{a}_r^T \times_2 \mathbf{b}_r^T \times_3 \mathbf{c}_r^T)$, 那么目标函数的梯度 (或次梯度) 由下式给出

$$\nabla_k = \begin{cases} \frac{\lambda_r^2}{2} \rho^m (\mathbf{R}^m)^T \text{SGN}(\mathbf{R}^m \mathbf{a}_r) - \lambda_r \mathbf{z}_r^{(n)} + \lambda_r^2 \mathbf{a}_r & (p = 1) \\ \lambda_r^2 \rho^m (\mathbf{R}^m)^T \mathbf{L}^m \mathbf{a}_r - \lambda_r \mathbf{z}_r^{(n)} + \lambda_r^2 \mathbf{a}_r & (p = 2) \end{cases}$$

其中的 SGN 为向量化的符号函数, 即 $\text{SGN}(\mathbf{x}) = (\text{sgn}(x_1), \text{sgn}(x_2), \dots, \text{sgn}(x_n))$ 利用所求得的梯度 (或次梯度) 考虑基于梯度 (或次梯度) 的系数归一化更新方法 [52, 53]。为简化符号, 把在迭代算法中第 k 次更新时目标函数的梯度记为 ∇_k 。则

$$\mathbf{a}_{k+1} = \frac{\mathbf{a}_k - \alpha \nabla_k}{\sqrt{1 - 2\alpha \mathbf{a}_k^T \nabla_k + \alpha^2 \nabla_k^T \nabla_k}}$$

$\mathbf{b}_r, \mathbf{c}_r$ 的更新与之类似, 其中 α 为步长参数, 作用在于确保目标函数减小。迭代上式直到收敛。

- 2) 更新 λ_r : 目标函数可以化简为

$$\frac{1}{2} \lambda_r^2 - \lambda_r \langle \mathcal{Z}_r, \mathbf{a}_r \circ \mathbf{b}_r \circ \mathbf{c}_r \rangle + \frac{1}{2} \lambda_r^2 (\rho_m \|\mathbf{R}^m \mathbf{a}_r\|_p^p + \rho_n \|\mathbf{R}^n \mathbf{b}_r\|_p^p + \rho_l \|\mathbf{R}^l \mathbf{c}_r\|_p^p)$$

所以

$$\lambda_r = \frac{\langle \mathcal{Z}_r, \mathbf{a}_r \circ \mathbf{b}_r \circ \mathbf{c}_r \rangle}{(1 + \rho_m \|\mathbf{R}^m \mathbf{a}_r\|_p^p + \rho_n \|\mathbf{R}^n \mathbf{b}_r\|_p^p + \rho_l \|\mathbf{R}^l \mathbf{c}_r\|_p^p)}$$

关于 R 的估计与 [51] 中一致。

4.3 数值实验

在本节中, 将本文所提出的算法应用于随机缺失彩色图片的修补问题, 并与 SPC (由于在文献 [51] 中 SPC 已经与 LTVNN, HaLRTC, STDC 和 FBCP-MP 进行对

比, 且结果优于这些方法, 故此处只和 SPC 进行对比) 进行对比, 以此来进行算法的评估。算法实验运行在个人电脑 (Intel(R) Xeon(R) CPU 3.50GHz Windows 7) 上的 MATLAB R2015b 中, 每个修补程序重复十次, 取平均值为最终结果。测试图片选用了十张图像处理领域常用彩色图片, 每张图片大小为 256×256 , png 格式, 如图 4.2 所示



图 4.3: 测试图片

与在矩阵修补的算法中一样, 这里也使用峰值信噪比 (PSNR) 和结构相似度 (SSIM) 作为评价图片恢复质量的指标。为了说明本文所提出算法的有效性, 将算法在约束项 $\|L^{(n)}u_r^{(n)}\|_p^p$ 中 $p = 1, p = 2$ 两种情况下分别与 spc-TV 和 spc-QV 进行比较。在实验中, 当 $p = 1$ 和 $p = 2$ 时光滑参数向量 ρ 分别设置为 $\rho = [0.01, 0.01, 0]$, $\rho = [0.5, 0.5, 0]$ 。最大迭代数均设置为 1000。每张图片以不同缺失比例 60%, 70%, 80% 进行测试。实验结果如表 1 与表 2 所示, 从结果中我们可以看出本文所提出的算法在 $P=1$ 时 ssim 和 psnr 两项指标上均优于原 SPC 算法, $p=2$ 时, 在过半数的测试图片上也表现优异。

4.4 小结

本章主要内容包括三个部分, 首先简要回顾了张量修补领域的进展, 然后提出了一种改良的 SPC (Smooth PARAFAC tensor Completion) 算法。具体地, 我们将基于一类改进的二阶全变差约束引入到 SPC 算法, 用以替换 SPC 算法中的一阶全变差约束。最后我们通过数值实验对所提算法的效果进行了验证, 实验结果表明在 $P=1$ 时 ssim 和 psnr 两项指标上均优于原 SPC 算法, $p=2$ 时, 在过半数的测试图片上也表现优异。

表 4.1: $p=1$

图片 (缺失率%)	SPC-TV		ours		图片 (缺失率%)	SPC-TV		ours	
	ssim	psnr	ssim	psnr		ssim	psnr	ssim	psnr
Baboon_60	0.88	25.52	0.89	25.95	girl_60	0.91	31.05	0.92	31.82
Baboon_70	0.83	23.91	0.84	24.39	girl_70	0.88	29.34	0.9	30.18
Baboon_80	0.75	22.33	0.77	22.76	girl_80	0.84	27.4	0.86	28.25
F16_60	0.88	27.94	0.88	28.28	goldhill_60	0.91	30.56	0.92	30.99
F16_70	0.85	26.81	0.86	27.29	goldhill_70	0.88	29.12	0.89	29.62
F16_80	0.8	25.09	0.82	25.7	goldhill_80	0.82	27.14	0.84	27.72
House_60	0.95	30.11	0.96	30.42	lena_60	0.98	29.19	0.98	29.84
House_70	0.94	28.58	0.94	29.04	lena_70	0.97	27.67	0.97	28.45
House_80	0.92	27.06	0.93	27.6	lena_80	0.95	25.68	0.96	26.6
barbara_60	0.92	28.36	0.94	29.02	peppers_60	0.97	28.15	0.98	29.17
barbara_70	0.89	26.46	0.91	27.2	peppers_70	0.96	26.34	0.97	27.43
barbara_80	0.83	24.27	0.85	25.01	peppers_80	0.94	24.22	0.95	25.27
cornfield_60	0.93	25.62	0.94	26.02	yacht_60	0.92	27.86	0.93	28.41
cornfield_70	0.89	23.57	0.9	24.16	yacht_70	0.88	25.9	0.89	26.51
cornfield_80	0.82	21.44	0.84	21.98	yacht_80	0.8	23.54	0.83	24.18

表 4.2: $p=2$

图片 (缺失率%)	SPC-QV		ours		图片 (缺失率%)	SPC-QV		ours	
	ssim	psnr	ssim	psnr		ssim	psnr	ssim	psnr
Baboon_60	0.9	26.34	0.9	26.36	girl_60	0.94	32.41	0.94	32.81
Baboon_70	0.86	24.96	0.86	24.9	girl_70	0.92	31.07	0.93	31.37
Baboon_80	0.8	23.59	0.8	23.45	girl_80	0.9	29.57	0.9	29.85
F16_60	0.91	28.31	0.91	28.53	goldhill_60	0.93	31.21	0.93	31.32
F16_70	0.89	27.31	0.89	27.51	goldhill_70	0.91	29.96	0.91	30
F16_80	0.85	25.89	0.85	26	goldhill_80	0.87	28.44	0.87	28.41
House_60	0.96	30.25	0.96	30.37	lena_60	0.98	29.85	0.98	30.21
House_70	0.95	29.04	0.95	29.06	lena_70	0.97	28.62	0.97	29
House_80	0.93	28.04	0.94	28.05	lena_80	0.96	27.18	0.96	27.47
barbara_60	0.94	29.24	0.94	29.38	peppers_60	0.98	29.65	0.98	30.12
barbara_70	0.92	27.62	0.92	27.66	peppers_70	0.97	28.13	0.98	28.61
barbara_80	0.88	25.8	0.88	25.74	peppers_80	0.96	26.45	0.97	26.88
cornfield_60	0.94	26.33	0.94	26.38	yacht_60	0.94	28.6	0.94	28.66
cornfield_70	0.91	24.48	0.91	24.41	yacht_70	0.91	27.03	0.92	26.96
cornfield_80	0.86	22.66	0.86	22.52	yacht_80	0.87	24.92	0.87	24.69

第5章 总结与展望

5.1 本文工作总结

随着现代传感器、多媒体技术、计算机通信和网络技术的迅速发展和广泛应用,人们往往需要存储、处理和分析规模更大、维数更高、结构更为复杂的数据。如人脸图像数据、视频监控数据、网络社交数据等。如何从观测到的矩阵或张量数据中恢复出原始数据,已成为机器学习、数据挖掘、模式识别和计算机视觉等领域的研究热点。本文着眼于观测数据的低秩与光滑结构对低秩矩阵与低秩张量数据恢复与补全问题进行了深入的研究,并在黑白与彩色图片的模拟实验中展示了本文所提出方法的有效性及其可行性。并且与现有算法进行比较,结果表明本文所提算法具有一定的竞争力。

本文的工作主要有以下两点:

1. 为了更好的度量矩阵的低秩结构特性使用 Schatten- p 范数代替常用的核范数,并且约束改进的二阶全变差来刻画数据的光滑性结构特征。据此提出了一种新的矩阵修补算法。将该算法应用于随机缺失的黑白图片修补问题中,与现有算法对比,优于现有算法,并发现当缺失率越大时, p 越小效果越好;而当缺失率越大时, p 越大效果越好。
2. 针对更为高阶张量修补问题,在前人的研究基础上,在张量 CP 分解的基础上引入了改进的二阶全变差,并将改进的张量修补算法应用于随机缺失的彩色图片恢复问题中,与原算法相比提升了恢复效果,验证了所提算法的有效性。

5.2 后续工作展望

低秩矩阵和张量的恢复应用前景非常广泛,本文虽然涉及了矩阵和张量数据的低秩特性与数据的光滑性,但是对于低秩矩阵与张量恢复的研究还处在起步阶段,其延伸的相应的研究是没有尽头的,仍然有很多想法可以让我们去尝试,不管是理论还是算法上依旧存在很多值得深入探究和讨论的问题,有理由相信一些新的理论与算法将会不断地涌现。本文提出以下几个后续的研究方向,希望能为感兴趣的读者提供一些有意义的启示:

1. 挖掘探索更多类型的结构先验信息。低秩矩阵和张量恢复模型在机器学习、计算机视觉、信号和图像处理等领域有着广泛的应用。然而,在实际应用中,

观测数据往往具有一些特殊的结构或属性。除了本文提到的光滑性外，必然还有其他结构信息，充分挖掘这些数据的结构信息，并将这些结构信息与低秩矩阵和低秩张量模型相结合，从而更好地描述数据结构，更有效地解决更为具体的某一类问题。

2. 噪声的干扰。本文的算法中只考虑了缺失值没有涉及噪声的影响，而在实际采集的数据中，噪声的出现是无法避免的，并且噪声所服从的分布也是各不一样。这方面工作的开展更符合于实际，所以有着很好的研究价值。
3. 张量分解。本文的研究是基于张量的 CP 分解，但最近的一种张量分解方法 tsvd[54] 在相关问题上显示出更为优异的性能，tsvd 从形式上更为接近矩阵的 svd 分解。下一步可以考虑将光滑性约束引入 tsvd 分解模型中。
4. 张量的秩。虽然现在关于张量的秩已经有了 Tucker 秩、CP 秩 [34], tubal-秩 [54] 等，但是均各有优劣，比如 CP 秩只能通过迭代的方式逼近，没有一般简易的求解方法。没有完全与矩阵的秩相对应的定义，这就限制了深入研究张量修补时的理论基础以及相关算法的性能。寻找更为实用、更为本质的张量秩的定义同样是研究的方向之一。

参考文献

- [1] Cai J F, Candès S E J, et al. A singular value thresholding algorithm for matrix completion[J]. Siam Journal on Optimization, 2008, 20(4): 1956–1982.
- [2] Lin Z, Chen M, Ma Y. The augmented lagrange multiplier method for exact recovery of corrupted low-rank matrices[J], arXiv preprint arXiv: 1009.5055. 2010.
- [3] Chen C, He B, Yuan X. Matrix completion via an alternating direction method[J]. Ima Journal of Numerical Analysis, 2012, 32(1): 227–245.
- [4] Hu Y, Zhang D, Ye J, et al. Fast and accurate matrix completion via truncated nuclear norm regularization[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2013, 35(9): 2117–2130.
- [5] Nie F, Huang H, Ding C. Low-rank matrix recovery via efficient Schatten p-norm minimization[C]. 26th American Association for Artificial Intelligence, 2012: 655-661.
- [6] Wen Z, Yin W, Zhang Y. Solving a low-rank factorization model for matrix completion by a nonlinear successive over-relaxation algorithm[J]. Mathematical Programming Computation, 2012, 4(4): 333–361.
- [7] Shen Y, Wen Z, Zhang Y. Augmented Lagrangian alternating direction method for matrix separation based on low-rank factorization[J]. Optimization Methods and Software, 2014, 29(2): 239–263.
- [8] Candès E J, Recht B. Exact matrix completion via convex optimization[J]. Foundations of Computational Mathematics, 2008, 9(6): 717.
- [9] Gandy S, Recht B, Yamada I. Tensor completion and low-rank tensor recovery via convex optimization[J]. Inverse Problems, 2011, 27(2): 025010.
- [10] Liu J, Musialski P, Wonka P, et al. Tensor completion for estimating missing values in visual data[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2013, 35(1): 208–220.
- [11] Mu C, Huang B, Wright J, et al. Square deal: lower bounds and improved relaxations for tensor recovery[C]. International Conference on Machine Learning, 2014: 73–81.

- [12] Yuan M, Zhang C H. On tensor completion via nuclear norm minimization[J]. Foundations of Computational Mathematics, 2016, 16(4): 1031–1068.
- [13] Shah P, Rao N, Tang G. Optimal low-rank tensor recovery from separable measurements: four contractions suffice[J]. arXiv preprint arXiv:1505.04085. 2015.
- [14] Rauhut H, Stojanac Ž. Tensor theta norms and low rank recovery[J]. arXiv preprint arXiv: 1505.05175. 2015.
- [15] Absil P A, Mahony R, Sepulchre R. Optimization algorithms on matrix manifolds[M]. Princeton University Press, 2009.
- [16] Barak B, Moitra A. Tensor prediction, rademacher complexity and random 3-xor[J]. CoRR, abs/1501.06521, 2015.
- [17] Elad M. From exact to approximate solutions[M]. Springer New York, 2010.
- [18] Eldar Y C, Kutyniok G. Compressed sensing: theory and applications[M]. Cambridge University Press, 2012.
- [19] Foucart S, Rauhut H. A mathematical introduction to compressive Sensing[M]. Birkhäuser Basel, 2013.
- [20] Li W, Zhao L, Lin Z, et al. Non-local image inpainting using low-rank matrix completion[C] Computer Graphics Forum, 2015, 34(6): 111–122.
- [21] Gogna A, Majumdar A. Matrix completion incorporating auxiliary information for recommender system design[J]. Expert Systems with Applications. 2015, 42(14): 5789–5799.
- [22] Cabral R, De la Torre F, Costeira J P, et al. Matrix completion for weakly-supervised multi-label image classification[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(1): 121–135.
- [23] Otazo R, Candès E, Sodickson D K. Low-rank plus sparse matrix decomposition for accelerated dynamic MRI with separation of background and dynamic components[J]. Magnetic Resonance in Medicine, 2015, 73(3): 1125–1136.

- [24] Boyd S, Parikh N, Chu E, et al. Distributed optimization and statistical learning via the alternating direction method of multipliers[J]. Foundations and Trends in Machine Learning, 2011, 3(1): 1–122.
- [25] Lu C, Zhu C, Xu C, et al. Generalized singular value thresholding[C]. American Association for Artificial Intelligence, 2015: 1805-1811.
- [26] Srebro N. Learning with matrix factorizations[D]. Massachusetts Institute of Technology. 2004.
- [27] Recht B, Fazel M, Parrilo P A. Guaranteed minimum-rank solutions of linear matrix equations via nuclear norm minimization[J]. Siam Review, 2010, 52(3): 471–501.
- [28] Tucker L R. Implications of factor analysis of three-way matrices for measurement of change[J]. Problems in Measuring Change, 1963, 15: 122–137.
- [29] Hitchcock F L. The expression of a tensor or a polyadic as a sum of products[J]. Studies in Applied Mathematics, 1927, 6(1-4): 164–189.
- [30] Kressner D, Steinlechner M, Vandereycken B. Low-rank tensor completion by riemannian optimization[J]. BIT Numerical Mathematics, 2014, 54(2): 447–468.
- [31] Vandereycken B. Low-rank matrix completion by riemannian optimization[J]. Siam Journal on Optimization, 2013, 23(2): 1214–1236.
- [32] Rudin L I, Osher S, Fatemi E. Nonlinear total variation based noise removal algorithms[J]. Physica D: nonlinear phenomena, 1992, 60(4): 259–268.
- [33] Han X, Wu J, Wang L, et al. Linear total variation approximate regularized nuclear norm optimization for matrix completion[J]. Abstract and Applied Analysis, 2014, 5(28): 189–221.
- [34] Kolda T G, Bader B W. Tensor decompositions and applications[J]. Siam Review, 2009, 51(3): 455–500.
- [35] Glowinski R, Marrocco A. Sur l'approximation, par éléments finis d'ordre 1, et la résolution, par pénalisation-dualité, d'une classe de problèmes de dirichlet non linéaires.[J]. Journal of Equine Veterinary Science, 1975, 2(2): 41–76.

- [36] Gabay D, Mercier B. A dual algorithm for the solution of nonlinear variational problems via finite element approximation[J]. Computers and Mathematics with Applications, 1976, 2(1): 17–40.
- [37] Fortin M, Glowinski R. Augmented lagrangian methods: application to the numerical solution of boundary-value problems[J]. Studies in Mathematics and Its Applications, 1983, 15(3): 165–193.
- [38] Eckstein J, Bertsekas D P. On the douglas—rachford splitting method and the proximal point algorithm for maximal monotone operators[J]. Mathematical Programming, 1992, 55(1-3): 293–318.
- [39] Fazel M, Hindi H, Boyd S P. Log-det heuristic for matrix rank minimization with applications to hankel and euclidean distance matrices[C]. American Control Conference, Proceedings of the IEEE, 2003, 3: 2156-2162.
- [40] Gleich D F, Lim L H. Rank aggregation via nuclear norm minimization[C]. Proceedings of the 17th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2011: 60-68.
- [41] Mohan K, Fazel M. Reweighted nuclear norm minimization with application to system identification[C]. American Control Conference (ACC), IEEE, 2010, 58(8): 2953-2959.
- [42] Meka R, Jain P, Caramanis C, et al. Rank minimization via online learning[C]. Proceedings of the 25th International Conference on Machine learning. ACM, 2008: 656–663.
- [43] Gillis N, Glineur F. Low-rank matrix approximation with weights or missing data is np-hard[J]. Siam Journal on Matrix Analysis and Applications, 2011, 32(4): 1149–1165.
- [44] Cai J F, Candès E J, Shen Z. A singular value thresholding algorithm for matrix completion[J]. Siam Journal on Optimization, 2010, 20(4): 1956–1982.
- [45] Lai M J, Xu Y, Yin W. Improved iteratively reweighted least squares for unconstrained smoothed l_q minimization[J]. Siam Journal on Numerical Analysis, 2013, 51(2): 927–957.

- [46] Nie F, Wang H, Huang H, et al. Joint Schatten p -norm and ℓ_p -norm robust matrix completion for missing value recovery[J]. Knowledge and Information Systems, 2015, 42(3): 525–544.
- [47] Oh T H, Tai Y W, Bazin J C, et al. Partial sum minimization of singular values in robust PCA: algorithm and applications[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 38(4): 744–758.
- [48] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE Trans Image Process, 2004, 13(4): 600–612.
- [49] Cichocki A, Zdunek R, Amari S. Hierarchical ALS algorithms for nonnegative matrix and 3d tensor factorization[C]. International Conference on Independent Component Analysis and Signal Separation, 2007: 169-176.
- [50] Cichocki A, Zdunek R, Phan A H, et al. Nonnegative matrix and tensor factorizations: applications to exploratory multi-way data analysis and blind source separation[M]. John Wiley and Sons, 2009.
- [51] Yokota T, Zhao Q, Cichocki A. Smooth parafac decomposition for tensor completion[J]. IEEE Transactions on Signal Processing, 2015, 64(20): 5423–5436.
- [52] Owsley N L. Adaptive data orthogonalization[C]. IEEE International Conference on ICASSP, 1978: 109-112.
- [53] Douglas S C, Amari S i, Kung S Y. On gradient adaptation with unit-norm constraints[J]. IEEE Transactions on Signal Processing, 2000, 48(6): 1843–1847.
- [54] Kilmer M E, Braman K, Hao N, et al. Third-order tensors as operators on matrices: a theoretical and computational framework with applications in imaging[J]. Siam Journal on Matrix Analysis and Applications, 2013, 34(1): 148–172.

已完成文章目录

邱一芳, 王文东, 王建军. 改进的平滑约束低秩张量修补算法 [J]. 西南大学学报 (已接收)

致 谢

时光荏苒，仿佛本科刚刚毕业。这是在西南大学的第7年，硕士生涯也行将结束，此刻我的内心中充满了对老师同学的感激以及对于大学校园的依依不舍。

首先，我要感谢我的导师王建军教授！感谢王老师三年来的敦敦教诲，特别是在写论文期间对我严格要求，悉心指导，才有了我的今天。王老师一丝不苟的作风，严谨求实的态度，踏踏实实的精神，不仅授我以文，而且教我做人，对王老师感激之情无法用言语表达。另外，王老师对学术的追求，对时间的珍惜，对生活的认真态度也必将影响我一生。

感谢师母景佳老师，感谢她对我生活上的关心。感谢师兄王文东、张枫，没有他们的帮助我的论文将难以付梓。特别是王文东师兄，对我学习生活上给予了极大的帮助。感谢同门李文昊、冯念慈、张小康，同窗好友蔡宗鹏、鲁吟盈，室友肖江、卢鑫等所有的同学在三年来对我生活和学习上的关心和照顾。

感谢我的母校西南大学，这是我人生重要的中转站，我很感谢在这里学到的一切，收获的一切，这将是我人生中无法忘却的回忆，我不会忘记在这里的点点滴滴。

感谢我的家人！他们一直是我的精神支柱，每当遇到坎坷总能得到他们的支持和鼓励，这样才能使我能够走到今天。

最后，向在百忙中抽出时间来对参加本文评议、评阅和答辩的所有专家表示最真诚的感谢！

邱一芳
西南大学