

分类号: TN911.23

单位代码: 10300

密 级: 公开

学 号: 20211249228

南京信息工程大学

硕士专业学位论文



论文题目: 基于低秩矩阵/张量分解的失效阵元
缺失数据恢复方法

申请人姓名: 蒋志军

指导教师: 陈金立

类别名称: 电子信息

领域名称: 通信工程

培养学院: 电子与信息工程学院

提交时间: 2024年6月6号

二〇二四年五月

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 基于矩阵分解的缺失数据恢复研究现状	2
1.2.2 基于张量分解的缺失数据恢复研究现状	5
1.2.3 阵列缺失数据恢复研究现状.....	6
1.3 本文主要内容及工作安排	8
第二章 矩阵/张量理论基础	10
2.1 引言.....	10
2.2 矩阵分解和矩阵填充基础理论	10
2.2.1 矩阵基础知识.....	10
2.2.2 矩阵分解方法.....	11
2.2.3 矩阵填充方法.....	11
2.3 张量分解和张量填充基础理论	15
2.3.1 张量基础知识.....	16
2.3.2 张量分解方法.....	17
2.3.3 张量填充方法.....	19
2.4 本章小结.....	20
第三章 基于低秩 Hankel 矩阵分解的失效阵元缺失数据恢复方法	22
3.1 引言.....	22
3.2 双基地 MIMO 雷达信号模型	23
3.3 基于低秩 Hankel 矩阵分解的协方差矩阵重构方法.....	25
3.3.1 MIMO 雷达协方差矩阵重构模型	25
3.3.2 重构模型的优化求解算法.....	28
3.3.3 复杂度分析.....	30
3.4 仿真结果与分析.....	31
3.4.1 算法估计目标角度星座图.....	32
3.4.2 各算法 RMSE 随 SNR 变化关系	33
3.4.3 各算法 RMSE 随快拍数变化关系.....	33
3.4.4 各算法 RMSE 随失效阵元数变化关系.....	34
3.4.5 各算法的运行时间.....	35
3.5 基于 AWR1843 毫米波雷达实测数据验证	35
3.5.1 FMCW MIMO 雷达平台简介	35
3.5.2 基于雷达实测数据的算法验证.....	39

3.6 本章小结.....	42
第四章 基于因子矩阵先验信息的失效阵元缺失数据恢复方法	43
4.1 引言.....	43
4.2 基于因子矩阵先验信息的协方差张量重构方法	43
4.2.1 MIMO 雷达协方差张量重构模型	44
4.2.2 重构模型的优化求解算法.....	48
4.2.3 收敛性与复杂度分析.....	51
4.3 仿真与分析.....	52
4.3.1 各算法目标角度估计星座图.....	52
4.3.2 算法收敛性曲线图.....	53
4.3.3 各算法 RMSE 随 SNR 变化关系.....	54
4.3.4 各算法 RMSE 随快拍数变化关系.....	55
4.3.5 各算法 RMSE 随失效阵元数变化关系.....	56
4.3.6 各算法的运行时间.....	56
4.4 本章小结.....	57
第五章 总结与展望	58
5.1 本文总结.....	58
5.2 未来展望.....	59
参考文献.....	60
附录 算法 2 收敛性证明	69
1 第四章定理 1 证明.....	69
2 第四章定理 2 证明.....	72

摘 要

在阵列信号处理领域,受到诸多类似于人为因素、恶劣环境和元器件老化等不可测因素的影响,阵列中传感器阵元损坏的问题不容忽视。当阵列中出现失效阵元时,多输入多输出(Multiple-Input Multiple-Output, MIMO)雷达虚拟阵列协方差矩阵中出现整行和整列的数据丢失,由协方差矩阵排列而成四阶协方差张量中某些切片数据也全部丢失,导致现有角度估计方法的性能不可避免地出现下降。围绕如何利用 MIMO 雷达虚拟阵列协方差数据特性进行失效阵元缺失数据恢复,本文主要工作可分为如下两部分:

(1) 针对阵元失效时 MIMO 雷达虚拟阵列协方差矩阵中整行和整列缺失数据恢复问题,本文提出一种基于低秩 Hankel 矩阵分解的失效阵元缺失数据恢复方法。首先,对协方差矩阵可分解性进行了分析,并应用奇异值分解(Singular Value Decomposition, SVD)提取维度较低的矩阵因子;接着本文将具有整行缺失数据的矩阵因子重新排列为低秩块 Hankel 矩阵,建立了核范数约束下的不完整矩阵因子重构模型;此外,由于结构化低秩 Hankel 矩阵具有较好的分解特性,采用低秩矩阵拟合方法将低秩块 Hankel 矩阵分解为两个维度较低的矩阵,重新定义了核范数约束问题,从而避免了传统核范数最小化模型计算复杂度高的问题;最后,基于交替方向乘子法(Alternating Direction Method of Multipliers, ADMM)对优化的矩阵因子重构模型进行求解。实验结果表明,该方法能有效地重构出矩阵因子中的缺失元素,实现 MIMO 雷达协方差矩阵中丢失数据的补全。

(2) 为利用双基地 MIMO 雷达接收信号的多维张量结构特征,本文基于均匀线性阵列(Uniform Linear Array, ULA)的 MIMO 雷达协方差张量模型,建立阵元故障下虚拟阵列四阶协方差张量 CANDECOMP/PARAFAC(CP)分解模型,并分析阵元失效导致部分切片数据完全丢失的问题;然后,将协方差张量中完整切片缺失数据重建问题表述为低秩张量填充问题。因此,本文基于协方差张量 CP 分解模型,探索了因子矩阵 Vandermonde 结构以及因子矩阵之间的潜在比例关系;此外,对由因子矩阵排列而成的块 Hankel 矩阵施加核范数惩罚项,并将重建张量与原始观测张量之间的线性约束表述为凸松弛约束;最后,本文提出一种张量填充算法用于恢复 MIMO 雷达失效阵元缺失数据,并证明了所提算法的收敛性。仿真结果验证了该方法在重建协方差张量中缺失数据的有效性。

关键词: MIMO 雷达, 角度估计, 阵元失效, 低秩分解, Hankel 矩阵

Abstract

In array signal processing, the problem of sensor element failure in array is non-negligible due to the various unpredictable factors such as human-related factors, harsh environmental conditions and aging components. The occurrence of antenna failure in the array will result in the complete loss of entire rows and columns of data in the virtual array covariance matrix of Multiple-Input Multiple-Output (MIMO) radar. Moreover, the fourth-order covariance tensor, formed by arranging array covariance matrix, exhibits substantial entirely-missing slices, which inevitably causes the angle estimation methods severe performance degradation. By leveraging the properties of MIMO radar virtual array covariance data, this paper can be divided into the following two aspects to recover the missing data of failed array.

(1) To address missing data recovery from entire rows and columns in the virtual array covariance matrix of MIMO radar under element failure, a method which can recover missing data resulting from failed elements is proposed based on low-rank Hankel matrix decomposition. This method firstly analyzes the decomposability property of the covariance matrix and then performs the Singular Value Decomposition (SVD) on the covariance matrix to extract the low-dimensional matrix factor. Subsequently, by rearranging the matrix factor with the entire-rows missing data into a low-rank block Hankel matrix, an incomplete matrix factor reconstruction model is thereby established under nuclear norm constraint. Moreover, a low-rank matrix fitting method is employed to decompose the low-rank block Hankel matrix into two lower-dimensional matrices due to the decomposability of structured low-rank Hankel matrix. This realizes an equivalent representation of the nuclear norm constraint and avoids the high computational complexity in traditional nuclear norm minimization. Finally, alternating direction method of multipliers is used to solve the optimized matrix factor reconstruction model. Experimental results indicate that the proposed method effectively reconstruct the missing elements in the matrix factors and thereby completing of missing data in the covariance matrix of MIMO radar.

(2) To exploit the tensor multidimensional structure of received signals for bistatic MIMO

radar, a CANDECOMP/PARAFAC (CP) decomposition model of fourth-order covariance tensor of virtual array is established under element failure, which is based on MIMO radar covariance tensor representation of a uniform linear array (ULA). Afterwards, the problem of partial slices data loss induced by elements failure is analyzed. Then, reconstructing the complete slice missing data of covariance tensor can be modified as a low-rank tensor completion problem. Therefore, based on the covariance tensor CP decomposition model, this paper explores the Vandermonde structure of factor matrix and potential proportional relationship between the factor matrices. Additionally, this paper imposes the nuclear norm penalty on the block Hankel matrix formed by factor matrix and utilizes a convex relaxation constraint to express the linear relationship between the reconstructed tensor and the original observed tensor. Finally, a tensor completion algorithm is proposed to recover the missing data of failure array of MIMO radar. The convergence of the proposed algorithm has been proven. Simulation results verify the effectiveness of the proposed method for completing missing data in the covariance tensor.

Keywords: MIMO radar, Angle estimation, Array antenna failure, Low rank decomposition, Hankel matrix

第一章 绪论

1.1 研究背景及意义

20 世纪初,多输入多输出(Multiple-Input Multiple-Output, MIMO)雷达体制提出后引起了大量学者的广泛关注^[1-4]。基于收发阵列的配置方式, MIMO 雷达可分为分布式 MIMO 雷达和集中式 MIMO 雷达。分布式 MIMO 雷达发射/接收阵列的阵元间距满足空间分集条件,可以从不同的角度同时观测目标,以提高雷达检测性能^[5-7];集中式 MIMO 雷达通过多个发射天线同时传输相互正交的波形,然后利用多个接收天线收集目标回波信号,并在接收端进行匹配滤波对发射信号进行分离,形成大孔径虚拟阵列,进而提高角度分辨率以及增强抗干扰能力^[8-10]。此外,根据收发阵列之间的间距,集中式 MIMO 雷达可分为单基地 MIMO 雷达和双基地 MIMO 雷达。受益于集中式 MIMO 雷达结构上的易实现性,目前许多研究仍是关注于集中式 MIMO 雷达。本文主要研究双基地 MIMO 雷达失效阵元缺失数据恢复问题。

目标角度估计一直是 MIMO 雷达系统探测目标信息的核心内容之一,众多学者针对双基地 MIMO 的目标发射角(Direction of Departure, DOD)和接收角(Direction of Arrival, DOA)估计问题,先后提出矩阵分解类算法和张量分解类算法,主要为以下几种:

(1) 矩阵分解类算法:指基于协方差矩阵进行特征值分解或奇异值分解提取出信号子空间、分离噪声子空间的算法,主要包括多重信号分类(Multiple Signal Classification, MUSIC 算法^[11])和基于旋转不变技术的参数估计(Estimation of Signal Parameters via Rotational Invariance Technique, ESPRIT 算法^[12,13]),其中 MUSIC 算法涉及二维空间谱搜索问题,导致计算复杂度极高,在实际应用中实时性不佳;而 ESPRIT 算法则利用发射和接收阵列本身所具备的旋转不变性实现对目标角度的估计,避免了二维谱峰搜索,具有较高的算法效率。

(2) 张量分解类算法:近些年来,随着计算机的发展,计算机处理数据的能力大大提升,众多学者开始关注多维数据复杂结构的张量算法。张量类分解算法旨在利用信号本身的多维结构,提高目标参数估计性能,更好地抑制噪声影响,但一般均具有较高的计算复杂度。主要包括平行因子分解(Parallel Factor Analysis, PARAFAC^[14,15])和高阶奇异

值分解(Higher Order Singular Value Decomposition, HOSVD^[16])两大类。

随着人们对雷达的抗干扰性、实时性和最大可探测目标等技术的深入研究,如今 MIMO 雷达阵列的规模不断增大,导致整个天线阵列系统需处理的数据量在不断增加,冗长的数据处理时间造成了算法实时性较差的影响。当回波数较少且目标信息较为稀疏时,对整个阵列进行全采样可能会存在冗余信息,此时合理地进行降采样阵元数目,可以降低采样时间,但此举会造成阵元数据丢失^[17];另一方面,在实际大规模雷达阵列系统中,由于工作环境恶劣、元器件老化等因素的影响,增加了 MIMO 雷达系统中阵元受损的概率^[18-20]。一旦部分阵列天线出现损坏,会导致 MIMO 雷达阵列的几何结构遭到破坏,造成虚拟阵列中出现大量虚拟阵元缺失,致使阵列采样数据出现丢失,将会影响整体阵列系统性能^[21-23]。此外,愈发复杂的雷达系统中,每个发射、接收天线均具有专用的发射、接收驱动模块,该模块包括功率放大器、上/下变频器和天线馈线系统等器件,实际阵列系统在长时间连续运行后硬件受损的可能性亦会增加^[24]。以上皆可看作是 MIMO 雷达失效阵元丢失数据的问题,在此情况下,目标角度估计算法的准确性会显著降低。当诊断出故障阵元位置时,直接对故障阵元以及相关的收发模块进行更换是一种直接且有效的方案,但这可能会为时已晚,且在大规模 MIMO 雷达阵列中,复杂的阵列结构也会降低对损坏天线阵元的修复效率^[25]。而且,对于一些特殊场合,如深海、战场、深空等恶劣的环境下,维修或替换故障阵元并非易事^[25]。因此,有效地降低 MIMO 雷达故障阵元缺失数据对目标角度估计性能造成的不利影响具有重要的意义。

1.2 国内外研究现状

近些年,一些学者对天线阵列中存在受损阵元缺失数据问题的研究中,提出利用矩阵填充(Matrix Completion, MC)理论对失效阵元缺失数据进行恢复,并在此基础上进行高精度目标角度估计^[26,27]。受此启发,本文主要针对双基地 MIMO 雷达失效阵元缺失数据恢复问题,基于矩阵/张量填充理论对失效阵元缺失数据重构问题展开研究。

1.2.1 基于矩阵分解的缺失数据恢复研究现状

随着信息技术的迅速发展,现代社会产生的数据呈指数级上升趋势,对大规模数据的分析与处理是当前研究热点之一。例如,在信号处理、推荐系统、高维数据分析、图

像处理等多个研究领域经常会面临大规模数据的情况。在大规模数据中，一方面可以挖掘并利用其潜在的丰富信息；另一方面，庞大的数据量给分析与处理带来了巨大的麻烦。更具挑战的问题是，在许多实际情况下，受到诸多不可测因素的影响，实际中获得的数据普遍存在不完整的问题，以生物医学为例，磁共振波谱信号通常可以建模成一系列指数信号的叠加，但是由于时间成本、实验成本、硬件设备等因素限制，实际应用中往往无法按照奈奎斯特准则对波谱信号进行完整采样，导致采样数据出现丢失，造成信号失真问题^[28]。类似地，在雷达阵列^[29]、模拟数字转换^[30]、谐波分析^[31]、成像^[32]等应用中，采样的信号通常以电磁波的形式存在，同样可以建模为复指数信号，上述采样数据丢失问题也时有发生。此外，在人脸识别系统中，人脸图像中含有的阴影、高光、遮挡、变形等因素也会降低数据质量。值得注意的是，当信号没有以奈奎斯特频率收集时，亦会发生数据丢失的情况，此时就需要新的理论和实用算法为实际应用提供相应的理论支撑。因此，如何从仅具有部分观测项的采样数据中准确且高效地重建出完整的原始数据，成为当前非常前沿的问题。

近年来，压缩感知理论在信号处理和图像处理领域备受关注^[33]，此理论通过利用信号映射的向量或矩阵的稀疏性，即向量或矩阵中大部分元素为零，实现了对信号的采样与重建。为实际应用中处理数据不完整性问题提供了一种新的手段。同时，香农采样定理为信号的无失真重建提供了充分条件，即采样频率超过信号带宽的两倍，此临界频率被称为奈奎斯特频率，但不是信号重建的必要条件。在实际情况中，因信号频带过宽、高实验成本等固有限制，采样频率往往难以达到奈奎斯特速率，尤其在无线电系统中，由于硬件采样频率限制，实现奈奎斯特采样率通常具有挑战性^[34]。

压缩感知突破了奈奎斯特采样速率的限制，指出对于可压缩的信号，可以从远低于奈奎斯特频率的采样数据中无失真地重构出完整信号。低秩矩阵恢复问题作为压缩感知技术的延伸，本质上两者具有紧密的联系。矩阵的低秩性是指矩阵的秩相对于行数或列数而言相对较小，若对一个矩阵进行奇异值分解，并将其奇异值排列为向量形式，那么此向量的稀疏性便对应于该矩阵的低秩性。低秩概念可以视为矩阵稀疏性的扩展，通过利用此特性，矩阵秩最小化可以有效重构矩阵中缺失元素。

文献[35]提出当矩阵满足低秩性且观测矩阵满足一定采样数时，从少量观测元素中精确地重构出完整矩阵成为可能，并证明了大多数矩阵在具备低秩性的情况下，通过求解秩最小化问题可以成功恢复出缺失元素。为从不完整观测矩阵 $\mathbf{M}$ 重建出完整低秩矩

阵 $\mathbf{X}$ ，其秩最小化模型可描述为

$$\begin{aligned} \min_{\mathbf{X}} \quad & \text{rank}(\mathbf{X}) \\ \text{s.t.} \quad & \mathbf{X}_{\Omega} = \mathbf{M}_{\Omega} \end{aligned} \quad (1-1)$$

式中， $\text{rank}(\cdot)$ 为秩函数， Ω 为已观测元素索引集合。

由于秩函数是非凸且非连续的，式(1-1)模型的求解是 NP-hard 问题，且随着矩阵维度的增加，此问题的求解复杂度呈指数级增长。因此，众多学者研究利用核范数替代秩函数^[36]，此时秩最小化模型将变为凸优化模型，当满足一定的非相干条件时，核范数最小化模型可以准确地重建矩阵。核范数最小化模型为^[35]

$$\begin{aligned} \min_{\mathbf{X}} \quad & \|\mathbf{X}\|_* \\ \text{s.t.} \quad & \mathbf{X}_{\Omega} = \mathbf{M}_{\Omega} \end{aligned} \quad (1-2)$$

式中， $\|\mathbf{X}\|_*$ 表示矩阵 $\mathbf{X}$ 的核范数，即 $\|\mathbf{X}\|_* = \sum_{i=1}^r \sigma_i$ ， σ_i 表示矩阵 $\mathbf{X}$ 的第 i 个奇异值。在式(1-2)所描述模型中，矩阵分解作为有效的数学工具而被广泛运用，例如矩阵的奇异值分解常常被运用于求解此模型，以提高对缺失数据恢复的准确度。此外，为降低计算复杂度，矩阵的 Qatar Riyal(QR)分解也常被用于替代矩阵奇异值分解，以提高缺失数据的重构效率。

在诸多应用中，式(1-2)所描述的矩阵填充模型在重建缺失元素时，其有效性是源于对数据矩阵中固有的低秩特性，此特性描绘了矩阵元素之间的总体相关性，利用此低秩特性，式(1-2)也可以表示为另一种凸优化问题

$$\min_{\mathbf{X}} \quad \mu \|\mathbf{X}\|_* + \frac{1}{2} \|\mathbf{X}_{\Omega} - \mathbf{M}_{\Omega}\|_F^2 \quad (1-3)$$

式中， $\|\mathbf{X}\|_F$ 为矩阵 $\mathbf{X}$ 的 Frobenius 范数，且该式可以通过半正定规划(Semi-Definite Programming, SDP)求解。

文献[37]提出了一个经典奇异值阈值(Singular Value Thresholding, SVT)算法求解(1-3)的一个近似问题

$$\begin{aligned} \min_{\mathbf{X}} \quad & \mu \|\mathbf{X}\|_* + \frac{1}{2} \|\mathbf{X}\|_F^2 \\ \text{s.t.} \quad & \mathbf{X}_{\Omega} = \mathbf{M}_{\Omega} \end{aligned} \quad (1-4)$$

此优化模型的具体求解在第二章中详细介绍。

最近，得益于低秩矩阵填充理论的发展，低秩 Hankel 矩阵填充(Low Rank Hankel

Matrix Completion, LRHMC)模型被提出用于重建复指数信号^[38-46]。

对于一维复指数观测信号 $\mathbf{y} = [y(1), y(2) \cdots y(2N-1)]^T \in \mathbb{C}^{2N-1}$ 重建问题, 文献[47]提出 LRHMC 模型依赖于由信号 $\mathbf{y}$ 构造的 Hankel 矩阵 $\mathcal{H}(\mathbf{y}) \in \mathbb{C}^{N \times N}$ 是低秩的, 进而可将信号 $\mathbf{y}$ 的重建问题转变为 $\mathcal{H}(\mathbf{y})$ 的低秩 Hankel 矩阵重建问题

$$\begin{aligned} \min_{\mathbf{x}} \quad & \text{rank}(\mathcal{H}(\mathbf{x})) \\ \text{s.t.} \quad & \mathcal{P}_{\Omega}(\mathbf{x}) = \mathcal{P}_{\Omega}(\mathbf{y}) \end{aligned} \quad (1-5)$$

式中, $\mathbf{x}$ 为待重建信号, $\mathcal{P}_{\Omega}(\cdot)$ 表示在集合 Ω 上的正交投影算子。

类似地, 优化问题(1-5)也可以凸松弛为核范数最小化问题

$$\begin{aligned} \min_{\mathbf{x}} \quad & \|\mathcal{H}(\mathbf{x})\|_* \\ \text{s.t.} \quad & \mathcal{P}_{\Omega}(\mathbf{x}) = \mathcal{P}_{\Omega}(\mathbf{y}) \end{aligned} \quad (1-6)$$

1.2.2 基于张量分解的缺失数据恢复研究现状

近些年来, 随着低秩矩阵填充问题的不断深入研究, 愈来愈多的学者将矩阵填充问题向更高维的数据填充问题扩展, 即张量填充(Tensor Completion, TC)问题。不同于矩阵秩的唯一性, 张量因其更高的阶数以及复杂的结构, 不同的张量分解方式导致张量秩存在多种定义, 进而衍生了不同的张量填充算法。文献[48]首先提出张量的 CANDECOMP/PARAFAC(CP)秩定义, 指秩-1 张量分解的最小数量。文献[49]将张量的 CP 秩引入不完整彩色图像重建问题上, 采用分层概率模型以及完全贝叶斯推理算法自适应确定张量的潜在 CP 秩, 并结合稀疏诱导先验提出了完全贝叶斯 CP 分解算法。文献[50]基于张量 CP 秩提出迹范数正则化 CP 分解算法, 通过利用一种易处理的凸松弛方法建立因子矩阵秩最小化模型, 将低 CP 秩张量填充算法成功应用到计算机视觉数据处理领域中。最近, Tucker 秩被提出并应用到张量填充问题中^[51], 文献[52]自然地将矩阵中秩的凸松弛形式扩展到张量中, 将张量沿着各个模方向展开得到的矩阵核范数的加权平均值作为张量 Tucker 秩的凸松弛定义, 并建立了张量填充优化模型

$$\begin{aligned} \min_{\mathcal{X}} \quad & \sum_{i=1}^n \alpha_i \|\mathcal{X}_{(i)}\|_* \\ \text{s.t.} \quad & \mathcal{P}_{\Omega}(\mathcal{X}) = \mathcal{P}_{\Omega}(\mathcal{Y}) \end{aligned} \quad (1-7)$$

式中, $\alpha_i \geq 0$, $\sum_{i=1}^n \alpha_i = 1$, 当 $n=2$ 时, 此模型退化为矩阵填充形式。为求解式(1-7), 文献[52]分别设计了三种优化算法: SiLRTC(Simple Low Rank Tensor Completion)算法、FaLRTC(Fast Low Rank Tensor Completion)算法和 HaLRTC(High Accuracy Low Rank Tensor Completion)算法。在图像处理领域, 文献[53]以张量火车(Tensor Train, TT)秩作为式(1-7)中张量 Tucker 秩的有效替代, 考虑更加平衡的张量矩阵化排列方式, 旨在捕获张量中潜在的信息, 并提出了两种新的求解算法, 一种是基于 TT 秩的 SiLRTC 算法(SiLRTC-TT), 另一种是利用多线性矩阵分解模型逼近张量 TT 秩, 称为基于 TT 秩的并行矩阵分解算法(TMac-TT)。文献[54]为增强张量低 TT 秩属性, 在张量填充框架中联合利用全变分(Total Variation, TV)和 Tikhonov 正则项, 提出了一种专用于图像和视频缺失数据的张量补全算法。文献[55]针对 Gaussian Mixture Model(GMM)噪声处理以及不完整张量缺失数据恢复问题, 提出一种鲁棒的张量填充算法, 该算法利用张量环(Tensor Ring, TR)秩和改进 ℓ_p 范数, 将优化问题分解为若干鲁棒线性回归(Robust Linear Regression)子问题, 并基于梯度下降法和交替方向乘子法设计了两种优化算法, 以应对复杂的噪声和数据缺失问题。另一方面, 文献[56]针对张量核范数^[57]因需要计算张量奇异值分解而带来的高计算复杂度问题, 基于张量管秩的性质, 通过将维度较大的张量分解为两个维度较小的张量并借此维持张量低秩结构, 提出一种避免张量奇异值分解计算的低秩张量分解优化算法, 且在算法迭代过程中利用特征值分解和 PCA 实现张量秩的自适应估计。此外, 针对传统基于张量奇异值分解和张量核范数最小化的低秩张量填充算法存在计算成本局限性问题, 文献[58]提出一种快速张量填充方法, 通过利用 QR 分解^[59]减少核范数正则化中张量的维度大小, 并采用近似张量奇异值分解方法, 成功降低了计算复杂度。

1.2.3 阵列缺失数据恢复研究现状

近些年来, 众多学者将矩阵填充理论运用到阵列信号处理领域, 在雷达成像^[60]、MIMO 雷达^[61]以及目标角度估计^[62]等方向取得了显著的成果。文献[21]为解决均匀线性天线阵列中出现部分受损阵元时目标信息估计问题。首先, 采取基于列结构的检测策略对接收信号矩阵的每一列进行扫描以定位部分受损天线位置, 然后将接收信号缺失数据恢复问题表述为低秩矩阵填充问题, 并采用递归最小二乘法(Recursive Least Squar, RLS)进行 DOA 估计。文献[62]提出一种均匀线性阵列中存在部分失效阵元时的 DOA 估计方

法, 首先利用 SVT 算法对不完整数据矩阵中缺失数据进行重建, 再采用矩阵束(Matrix Pencil)从重建出的完整数据矩阵中估计出目标 DOA 值。此外, 文中提出一种失效阵元检测方法, 通过利用不同时间采样信号之间的差异性定位失效阵元位置, 以形成观测元素定位矩阵, 这是 MC 算法的必要初始条件。另一方面, 文献[63]提出利用较低的采样率和简化的硬件进行目标 DOA 估计的方法, 文中也提出一种 Uniform Spatial Sampling(USS)模型, 以确保降采样下的数据矩阵中每一行及每一列均具有一个或多个采样元素, 即数据矩阵中缺失元素位置是随机分布的。上述一些方法均假设阵列中接收数据缺失情况为随机缺失, 然后利用 MC 算法有效恢复出缺失元素。但人为降低采样率会导致信号矩阵存在整行或整列数据缺失, 即结构性数据缺失^[64]。但在传统矩阵填充理论中, 秩最小化模型在重建结构性数据缺失时可能会失效, 这是因为对矩阵中整列或整行缺失元素直接填充零元素仍然将使得矩阵的秩最小^[65]。

文献[62]和文献[63]均属于主动降采样导致的阵列数据丢失问题^[66], 实际中, 阵元失效在许多情况下是由于阵元直接损坏所致, 从而造成阵列采样数据缺失, 影响角度估计性能。为此, 文献[67]将深度神经网络(Deep Neural Network, DNN)应用于阵元缺损时的 DOA 估计问题, 通过联合利用去噪自动编码器(Denoising Autoencoder, DAE)和并行网络实现受损数据的分类和重建, 然而, 此方法需要大量的训练样本来提高 DNN 的 DOA 估计性能。文献[68]对阵元失效时的协方差矩阵进行差分处理, 利用正常的冗余虚拟阵元数据来填充失效阵元缺失数据, 进而获得完整的协方差矩阵, 估计出目标 DOA。文献[69]将该方法拓展应用于阵元故障下单基地 MIMO 雷达 DOA 估计问题中, 为了保证 MIMO 雷达的协方差矩阵具有 Toeplitz 结构, 要求发射阵元间距为接收阵元间距的 N 倍, 其中 N 为接收阵元数, 因此该方法的应用具有较大的局限性。文献[70]提出一种结构化的 MC 算法, 通过构造虚拟阵列协方差矩阵为不存在整行整列元素缺失的四重 Hankel 矩阵, 然后利用低秩 MC 算法恢复出缺失数据, 然而, 该方法在进行角度估计时需利用 Vandermonde 分解等方法, 且四重 Hankel 矩阵操作造成了巨大的矩阵维度扩张问题, 导致该算法运算时间仍然存在很大的优化空间。

相较于传统均匀线阵, 稀疏互质阵列^[71,72]因其两个阵元数量互质的均匀线性子阵的配置方式, 具有阵列孔径大、自由度高、空间分辨率好等优点。在差联合阵列中, 存在含有空洞的非连续虚拟阵列, 这些空洞会造成虚拟阵列孔径变小, 降低了阵列分辨率性能。现有的一些方法通过将虚拟阵列的非连续性视作一种非理想情况, 将非连续部分舍

弃并提取出虚拟均匀阵列，但是此举会降低虚拟阵元利用率，损失了部分阵列孔径，导致互质阵列整体性能下降。若可以对空洞进行重构以形成完整连续的虚拟均匀阵列，即补偿因空洞造成的缺失数据，则可以实现无信息缺损的目标 DOA 估计。文献[73]针对现有方法无法充分利用互质阵列所接收到的全部信息，设计了一种基于虚拟阵列内插算法的互质阵列 DOA 估计方法，此方法利用阵列插值构造虚拟均匀线性阵列，可以利用非均匀虚拟阵列中所有虚拟阵元，再以矩阵 Toeplitz 特性作为先验信息，通过原子范数重构虚拟阵列协方差矩阵。但此方法仅适用于随机缺失数据恢复，并不适用于具有完整切片缺失的数据重建。文献[74]提出一种基于张量模型的稀疏互质阵列 DOA 估计方法，利用移维增广和张量重塑方法以分散协方差张量中的切片缺失数据，然后对具有整个切片缺失的虚拟阵列协方差张量施加低秩正则化约束，设计了一种张量核范数最小化问题以重构结构化协方差张量，进而充分利用虚拟阵列中非连续虚拟阵列。

在处理互质阵列中的非连续虚拟阵列问题的同时，对于 MIMO 雷达领域，众多学者也积极探索新的方法以解决失效阵元引起的数据缺失问题。受益于矩阵填充理论在失效阵元缺失数据恢复中的广泛应用，研究人员将张量填充算法引入 MIMO 雷达缺失数据恢复问题，并在此领域展开了深入研究^[75-77]。文献[20]首先建立阵元缺损下双基地 MIMO 雷达三维观测信号张量模型，然后利用 PARAFAC 算法分解不完整张量数据以移除不含目标信息的缺失数据，结合原子范数最小化(Atomic Norm Minimization, ANM)算法以恢复缺失数据，提高角度估计性能。文献[78]对双基地 MIMO 雷达三维阵列观测张量进行随机采样，然后基于加速近端梯度线搜索(Accelerated Proximal Gradient Line-search, APGL)算法实现自适应秩估计，并结合张量填充算法恢复三维观测张量中随机缺失元素值，实现目标角度估计。

综上所述，国内外基于矩阵框架对阵列失效阵元缺失数据恢复的方法已经取得了一些研究成果，但在张量框架下基于 MIMO 雷达多维结构特征以恢复张量结构性缺失数据的研究尚在探索阶段。

1.3 本文主要内容及工作安排

本文主要工作是基于低秩矩阵/张量分解理论，分析 MIMO 雷达虚拟阵列协方差矩阵/张量的结构特性，设计 MIMO 雷达失效阵元缺失数据重建的算法，以补偿失效阵元

对角度估计性能的影响。主要工作可分为以下三个部分：第一部分分析了矩阵/张量基础理论；第二部分研究基于低秩 **Hankel** 矩阵分解的失效阵元缺失数据恢复方法；第三部分研究基于因子矩阵先验信息的失效阵元缺失数据恢复方法。

第一章为绪论，首先介绍了本文的研究背景与意义，然后阐述了基于矩阵/张量分解的缺失数据恢复研究现状以及阵列中缺失数据恢复的研究发展与现状，最后对本文的内容安排进行说明。

第二章介绍了矩阵/张量相关的基础理论，并对常见矩阵分解/矩阵填充方法和张量分解/张量填充方法进行了简要的介绍。

第三章首先介绍了双基地 **MIMO** 雷达信号模型，分析了阵元失效下 **MIMO** 雷达虚拟阵列数据矩阵的结构特性，提出一种基于低秩 **Hankel** 矩阵分解的失效阵元缺失数据恢复方法。该方法利用 **SVD** 从协方差矩阵中提取出矩阵因子，为利用矩阵因子中数据的相关性，对不完整矩阵因子建立核范数约束下的低秩 **Hankel** 矩阵重构模型，且通过低秩矩阵拟合方法将 **Hankel** 矩阵分解为两个维度较低的矩阵，避免求解核范数时计算复杂度高的问题，最后采用 **ADMM** 算法对该矩阵重构模型进行求解，重构出矩阵因子中缺失元素，进而实现协方差矩阵中丢失数据的补全。实验结果表明，所提方法可以有效重构失效阵元缺失数据。

第四章分析了协方差张量中因子矩阵的先验信息，并提出了一种基于因子矩阵先验信息的失效阵元缺失数据恢复方法。该方法基于张量 **CP** 分解模型，推导了协方差张量中因子矩阵之间的潜在关联信息，同时为利用因子矩阵的 **Vandermonde** 结构，将因子矩阵重新排列为块 **Hankel** 矩阵并施加核范数惩罚约束，建立用于重建协方差张量中结构性缺失数据的张量填充模型，并采用 **ADMM** 算法对该模型进行求解，分析并证明了优化求解算法的收敛性。仿真结果表明该方法可以有效重建协方差张量中缺失数据，改善阵元失效时的角度估计性能。

第五章对本文的主要研究内容和贡献进行归纳总结，并对未来的研究方向进行展望。

第二章 矩阵/张量理论基础

2.1 引言

矩阵/张量填充问题是现代信号处理和数据分析领域中备受关注的关键议题之一。在现实生活中，由于诸多原因的影响，如人为降采样和阵元故障，观测的数据往往是不完整的，此时如何从有限观测信号中重建完整信号是一个研究热点。在这一背景下，矩阵和张量填充技术通过利用观测信号的潜在先验信息，可实现对观测信号中缺失数据的重建。

作为本文后续章节的理论基础，本章将对矩阵/张量填充的基础理论进行阐述，并使用一些示例对常见的矩阵/张量运算、矩阵/张量分解进行说明。此外，本章还简要介绍一些常见的矩阵/张量填充算法，为后续本文算法推导过程奠定基础。

2.2 矩阵分解和矩阵填充基础理论

矩阵填充源于压缩感知理论，旨在利用有限数量的已知观测数据重建一个完整的矩阵。经典矩阵补全理论中，低秩性源于奇异值的稀疏性，即对矩阵进行奇异值分解得到极少个数的奇异值^[36]，此时该矩阵的秩非常小，利用这种低秩先验信息可以精确恢复缺失数据。但秩最小化模型为非凸的，所以众多算法求解其凸松弛形式的核范数最小化问题以重建矩阵中的随机缺失数据，常见的包括奇异值阈值算法(Singular Value Thresholding Algorithm, SVT)、不定增广拉格朗日算法(Inexact Augmented Lagrange Multipliers, IALM)等。

2.2.1 矩阵基础知识

定义 2.2.1 矩阵的内积：对于两个矩阵 $\mathbf{X}_1 \in \mathbb{C}^{n_1 \times n_2}$ 和 $\mathbf{X}_2 \in \mathbb{C}^{n_1 \times n_2}$ ，其内积定义为

$$\langle \mathbf{X}_1, \mathbf{X}_2 \rangle = (\text{vec}(\mathbf{X}_1))^H (\text{vec}(\mathbf{X}_2)) \quad (2-1)$$

式中， $\text{vec}(\cdot)$ 表示向量化处理。

定义 2.2.2 矩阵的 Kronecker 积：对于矩阵 $\mathbf{A} \in \mathbb{C}^{I \times J}$ 和 $\mathbf{B} \in \mathbb{C}^{K \times L}$ ，其 Kronecker 积为 $\mathbf{A} \otimes \mathbf{B} \in \mathbb{C}^{(I \times K) \times (J \times L)}$ ，表示为

$$\mathbf{A} \otimes \mathbf{B} = \begin{bmatrix} a_{11}\mathbf{B} & a_{12}\mathbf{B} & \cdots & a_{1J}\mathbf{B} \\ a_{21}\mathbf{B} & a_{22}\mathbf{B} & \cdots & a_{2J}\mathbf{B} \\ \vdots & \vdots & \ddots & \vdots \\ a_{I1}\mathbf{B} & a_{I2}\mathbf{B} & \cdots & a_{IJ}\mathbf{B} \end{bmatrix} \quad (2-2)$$

式中， a_{ij} 为矩阵 $\mathbf{A}$ 的第 (i, j) 个元素。

定义 2.2.3 矩阵的 Khatri-Rao 积：对于矩阵 $\mathbf{A} \in \mathbb{C}^{I \times L}$ 和 $\mathbf{B} \in \mathbb{C}^{K \times L}$ ，其 Khatri-Rao 积为 $\mathbf{A} \odot \mathbf{B} = [\mathbf{a}_1 \otimes \mathbf{b}_1, \dots, \mathbf{a}_L \otimes \mathbf{b}_L] \in \mathbb{C}^{(I \times K) \times L}$ ，其中 $\mathbf{a}_l$ 和 $\mathbf{b}_l$ 分别为矩阵 $\mathbf{A}$ 和 $\mathbf{B}$ 的第 l 列。

2.2.2 矩阵分解方法

定义 2.2.4 复矩阵的奇异值分解：对复矩阵 $\mathbf{X} \in \mathbb{C}^{n_1 \times n_2}$ 进行 SVD，始终会生成酉不变矩阵 $\mathbf{U}$ 和 $\mathbf{V}$ ，且存在如下形式

$$\mathbf{X} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^H \quad (2-3)$$

式中， $\mathbf{\Sigma} = \text{diag}\{\sigma_i\}_{1 \leq i \leq r}$ 为由奇异值构成的对角矩阵， σ_i 为矩阵 $\mathbf{X}$ 的奇异值且 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r$ ，其中 r 为矩阵 $\mathbf{X}$ 的秩，矩阵 $\mathbf{U}$ 和 $\mathbf{V}$ 为矩阵 $\mathbf{X}$ 的左奇异值矩阵和右奇异值矩阵，且满足 $\mathbf{U}^H \mathbf{U} = \mathbf{I}$ ， $\mathbf{V}^H \mathbf{V} = \mathbf{I}$ 。

定义 2.2.5 矩阵的 QR 分解：对复矩阵 $\mathbf{X} \in \mathbb{C}^{M \times N}$ 进行 QR 分解，其形式为

$$\mathbf{X} = \mathbf{Q}_r \mathbf{R}_r \quad (2-4)$$

式中， $\mathbf{Q}_r \in \mathbb{C}^{M \times N}$ 且满足 $\mathbf{Q}_r^H \mathbf{Q}_r = \mathbf{I}_N$ ； $\mathbf{R}_r \in \mathbb{C}^{N \times N}$ 为上三角矩阵，其主对角线元素均非负。

2.2.3 矩阵填充方法

(1) 可行性分析

在第一章中，本文介绍了大多数矩阵缺失数据恢复问题可以被建模为核范数最小化模型，但是否对任意低秩矩阵皆可以通过这种方式实现缺失数据的恢复？若无额外先验

信息的条件下，答案显然是否定的。例如以下矩阵 $\mathbf{M}$

$$\mathbf{M} = \begin{bmatrix} 0 & 0 & \cdots & 0 & 1 \\ 0 & 0 & \cdots & 0 & 0 \\ \vdots & \vdots & & \vdots & \vdots \\ 0 & 0 & \cdots & 0 & 0 \end{bmatrix} \quad (2-5)$$

显然，矩阵 $\mathbf{M}$ 的秩为 1。然而，该矩阵仅在右上角上有一个数据，其余元素为 0，若对该矩阵进行采样，有极大概率采样矩阵是全零矩阵。此时，矩阵填充算法无法从全零采样矩阵中重建出非零矩阵，因此，对于类似于式(2-5)的矩阵形式，无法利用 MC 算法进行重建，这是因为该类型的矩阵结构导致采样时信息的丢失，使得在恢复过程中无法有效推测未知数据。

对于另外一种情形，矩阵 $\mathbf{M}$ 具有如下形式

$$\mathbf{M} = \begin{bmatrix} m_1 & m_2 & \cdots & m_{n-1} & m_n \\ 0 & 0 & \cdots & 0 & 0 \\ \vdots & \vdots & & \vdots & \vdots \\ 0 & 0 & \cdots & 0 & 0 \end{bmatrix} \quad (2-6)$$

尽管矩阵 $\mathbf{M}$ 仍具备低秩性，但同样无法通过已知的采样元素来重构缺失的数据。这是因为即使采样率非常高，仍然存在第一行元素缺失的情况，使得无法通过矩阵填充算法对这些未被采样的元素进行重建。

在上述两种情况下，矩阵 $\mathbf{M}$ 中存在一大部分零元素。对此类矩阵进一步进行 SVD 分解可以发现，由上述低秩矩阵 $\mathbf{M}$ 奇异值组成向量中的元素大多为零，只含有极少数非零元素，即对矩阵 $\mathbf{M}$ 采样得到的矩阵极有可能位于采样算子的零空间中。此情况下，矩阵填充算法在重建缺失数据时会失效。理论表明，实际中若想要成功地应用矩阵填充算法，低秩矩阵的奇异值向量必须具备充分扩散的特征^[79]，即其奇异值向量包含部分非零的奇异值元素。

除此之外，不同的采样方式也会带来不同的矩阵填充效果，若采样方式不合理，在重建缺失数据时低秩 MC 算法也会失效。若存在秩 1 矩阵 $\mathbf{M}$ 为

$$\mathbf{M} = \mathbf{xy} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_{n_1} \end{bmatrix} \begin{bmatrix} y_1 & y_2 & \cdots & y_{n_2} \end{bmatrix} \quad (2-7)$$

在对矩阵 $\mathbf{M}$ 采样时，若第 i 行采样元素完全为零时，而任何元素与零相乘结果均为

零。因此，矩阵填充算法无法计算得出列向量 $\mathbf{x}$ 中第 i 个元素 x_i ；类似地，若第 j 列采样元素完全为零，利用 MC 算法无法得到行向量 $\mathbf{y}$ 中第 j 个元素 y_j 。本质上来讲，仅用 0 元素填充缺失的行或列可以得到最小秩。因此，传统的低秩 MC 算法要求采样矩阵的每一行和每一列均具有非零元素。也就是说，MC 算法对待重建的缺失数据位置存在一定要求，必须随机分布在采样矩阵中，从而确保算法的成功应用。

此外，文献[36]指出想要从少量的采样数据中成功地重建出完整矩阵，不仅对采样矩阵中已知元素的数目、位置分布有所要求，待重建矩阵本身也必须满足非相关性条件。对低秩矩阵 $\mathbf{M}$ 进行 SVD 分解

$$\mathbf{M} = \sum_{i=1}^r \mathbf{u}_i \sigma_i \mathbf{v}_i^H = \mathbf{U} \Sigma \mathbf{V}^H \quad (2-8)$$

式中， $\mathbf{U}$ 和 $\mathbf{V}$ 分别为左右奇异值矩阵。定义到 r 维子空间 $\mathbf{U}$ 和 $\mathbf{V}$ 的正交投影 $\mathbf{P}_U$ 和 $\mathbf{P}_V$ 可分别表示为

$$\mathbf{P}_U = \sum_{i=1}^r \mathbf{u}_i \mathbf{u}_i^H \quad (2-9)$$

$$\mathbf{P}_V = \sum_{i=1}^r \mathbf{v}_i \mathbf{v}_i^H \quad (2-10)$$

可通过 $\mathbf{u}_i$ 和 $\mathbf{v}_i$ 定义矩阵 $\mathbf{E}$

$$\mathbf{E} = \sum_{i=1}^r \mathbf{u}_i \mathbf{v}_i^H \quad (2-11)$$

定理 2.1^[36]：非相关条件： $\mathbf{P}_U$ 为 r 维子空间 $\mathbf{U}$ 的正交投影， $\{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n\}$ 表示 n 维空间的一组标准正交基，则 $\mathbf{U}$ 的相关性定义为

$$\mu(\mathbf{U}) = \frac{n}{r} \max_{1 \leq i \leq n} \|\mathbf{P}_U \mathbf{e}_i\|^2 \quad (2-12)$$

同理易得子空间 $\mathbf{V}$ 的相关性 $\mu(\mathbf{V})$ 。若存在常数 $\mu_0 \geq 0$ ，使

$$\max(\mu(\mathbf{U}), \mu(\mathbf{V})) < \mu_0 \quad (2-13)$$

且存在常数 μ_1 ，使

$$|\mathbf{E}| \leq \mu_1 \sqrt{\frac{r}{n_1 n_2}} \quad (2-14)$$

定理 2.2^[36]: 一维度为 $n_1 \times n_2$ 的矩阵 $\mathbf{M}$, $r = \text{rank}(\mathbf{M})$, $n = \max(n_1, n_2)$ 。若存在常数 C 、 c 与 β , 且 $\beta > 2$, 使得对矩阵 $\mathbf{M}$ 进行随机采样得到的元素的数目 m 满足

$$m \geq C \max(\mu_1^2, \mu_0^{1/2} \mu_1, \mu_0 n^{1/4}) nr (\beta \log n) \quad (2-15)$$

此时式(1-2)所示的核范数最小化模型存在唯一解, 该唯一解逼近矩阵 $\mathbf{M}$ 的概率至少为 $1 - cn^{-\beta}$ 。若 $\mathbf{M}$ 的秩满足 $r \leq \mu_0^{-1} n^{1/5}$, 则采样元素数目 m 只需满足

$$m \geq C \mu_0 n^{6/5} r (\beta \log n) \quad (2-16)$$

当低秩矩阵满足定理 2.1 的非相关性条件时, 且从该矩阵中采样元素的元素数目满足定理 2.2 时, 通过求解核范数最小化模型可以精确地重建出矩阵 $\mathbf{M}$ 中的缺失元素。

(2) SVT 算法

本小节以 SVT 算法介绍矩阵填充问题求解, 第一章中所提及的矩阵填充模型(1-4)为

$$\begin{aligned} \min_{\mathbf{X}} \quad & \mu \|\mathbf{X}\|_* + \frac{1}{2} \|\mathbf{X}\|_F^2 \\ \text{s.t.} \quad & \mathbf{X}_\Omega = \mathbf{M}_\Omega \end{aligned} \quad (2-17)$$

式中, $\mu \geq 0$ 为正则化参数, 当 $\mu \rightarrow \infty$ 时, 优化问题(2-17)与(1-2)是等价的。 $\mathbf{M} \in \mathbb{C}^{n_1 \times n_2}$ 为观测矩阵, n_1 和 n_2 分别表示矩阵 $\mathbf{M}$ 的行数与列数, 为待重建的低秩矩阵, Ω 为部分已知元素的索引。

对式(2-17)构造拉格朗日函数

$$\mathcal{L}(\mathbf{X}, \mathbf{Y}) = \mu \|\mathbf{X}\|_* + \frac{1}{2} \|\mathbf{X}\|_F^2 + \langle \mathbf{Y}, \mathbf{X}_\Omega - \mathbf{M}_\Omega \rangle \quad (2-18)$$

式中, $\mathbf{Y}$ 为拉格朗日乘子矩阵, $\langle \cdot \rangle$ 表示矩阵的内积, 基于 ADMM 框架, 通过固定多个变量的值, 依次迭代更新 $\mathbf{X}$ 和 $\mathbf{Y}$ 以最小化函数(2-18), 直至该函数收敛。

SVT 算法的具体步骤总结于表 2-1, 表中 $\text{soft}(\cdot)$ 表示软阈值算子, 对于任意数值 x 和阈值 μ , 其定义为

$$\text{soft}(x, \mu) = \begin{cases} x - \mu, & x > \mu \\ x + \mu, & x < \mu \\ 0, & \text{otherwise} \end{cases} \quad (2-19)$$

表2-1 SVT算法

SVT 算法求解式(2-17)

输入: 矩阵 $\mathbf{M}$ 的观测值 $\mathbf{M}(i, j), (i, j) \in \Omega, \mathbf{Y}^1 = 0$, 步长参数 ρ_k , 迭代次数 $k = 1$ 1: **while not converged do**2: $\mathbf{U}^k \Sigma^k (\mathbf{V}^k)^H = \text{svd}(\mathbf{Y}^k)$ 3: $\mathbf{X}^{k+1} = \mathbf{U}^k \times \text{soft}(\Sigma^k, \mu) \times (\mathbf{V}^k)^H$ 4: $\mathbf{Y}^{k+1} = \mathbf{Y}^k + \rho_k (\mathbf{M}_\Omega - \mathbf{X}_\Omega^{k+1})$

5: 重复步骤2至4直至式(2-18)收敛

(3) IALM 算法

IALM 算法将式(1-2)转换为如下形式

$$\begin{aligned} \min_{\mathbf{X}} \quad & \|\mathbf{X}\|_* \\ \text{s.t.} \quad & \mathbf{X} + \mathbf{E} = \mathbf{M}, \quad \mathcal{P}_\Omega(\mathbf{E}) = 0 \end{aligned} \quad (2-20)$$

上述问题的增广拉格朗日函数为

$$\mathcal{L}(\mathbf{X}, \mathbf{E}, \mathbf{Y}, \mu) = \|\mathbf{X}\|_* + \langle \mathbf{Y}, \mathbf{M} - \mathbf{X} - \mathbf{E} \rangle + \frac{\mu}{2} \|\mathbf{M} - \mathbf{X} - \mathbf{E}\|_F^2 \quad (2-21)$$

式中, $\mathbf{Y}$ 为拉格朗日乘子矩阵, μ 为正则化参数。IALM 算法交替更新变量以最小化目标函数(2-21), 具体步骤总结于表 2-2。

表 2-2 IALM 算法

IALM 算法求解式(2-20)

输入: 矩阵 $\mathbf{M}$ 的观测值 $\mathbf{M}(i, j), (i, j) \in \Omega, \mathbf{Y}^1 = \mathbf{E}^1 = 0, \mu^1 > 0, \rho \in (1, 1.1]$, 迭代次数 $k = 1$ 1: **while not converged do**2: $\mathbf{U}^k \Sigma^k (\mathbf{V}^k)^H = \text{svd}(\mathbf{M} - \mathbf{E}^k + \mathbf{Y}^k / \mu^k)$ 3: $\mathbf{X}^{k+1} = \mathbf{U}^k \times \text{soft}(\Sigma^k, \mu) \times (\mathbf{V}^k)^H$ 4: $\mathbf{E}^{k+1} = \mathcal{P}_\Omega(\mathbf{M} - \mathbf{X}^{k+1} + \mathbf{Y}^k / \mu^k)$ 5: $\mu^{k+1} = \rho \mu^k$ 6: $k = k + 1$ 7: **end while****输出:** 完整矩阵 $\mathbf{X}$

2.3 张量分解和张量填充基础理论

不同于矩阵的秩具有明确的定义, 张量的秩主要取决于张量分解的方式, 众多学者采取不同的方式定义张量的秩, 例如张量的 CP 秩、Tucker 秩和 TT 秩等, 基于不同的

张量秩定义也就产生了诸多的张量填充算法。在介绍张量填充算法前，首先介绍一些张量的基础知识及张量分解方法以便读者后续的阅读。

2.3.1 张量基础知识

定义 2.3.1 张量的切片：特殊地，对于三阶张量 $\mathcal{X} \in \mathbb{C}^{I \times J \times K}$ ，固定第一个坐标不变，改变其余两个坐标，可以得到 $\mathcal{X}$ 的水平切片，如图 2-1(a)所示；类似地，通过固定另外两个维度的坐标，可分别获得 $\mathcal{X}$ 的侧面切片和正面切片。




图 2-1 三阶张量切片示意图


定义 2.3.2 张量的模式- n 展开：对于 N 阶张量 $\mathcal{X} \in \mathbb{C}^{I_1 \times I_2 \times \cdots \times I_N}$ ，其模式- n 展开矩阵为 $\mathcal{X}_{(n)} \in \mathbb{C}^{I_n \times (I_1 \times I_2 \times \cdots \times I_{n-1} \times \cdots \times I_{n+1} \times \cdots \times I_N)}$ ， $\mathcal{X}$ 中位于 $(i_1, i_2, \dots, i_n)$ 处的元素对应于 $\mathcal{X}_{(n)}$ 中位于 (i_n, j) 处的元素，其中 $j = 1 + \sum_{k=1, k \neq n}^N (i_k - 1) J_k$ ， $J_k = \prod_{m=1, m \neq n}^{k-1} I_m$ 。

对于三阶张量 $\mathcal{X} \in \mathbb{C}^{I \times J \times K}$ ，其模式- n 展开示意图为图 2-2 所示。

定义 2.3.3 张量的模式- n 矩阵乘积：张量 $\mathcal{X} \in \mathbb{C}^{I_1 \times I_2 \times \cdots \times I_N}$ 与矩阵 $\mathbf{U} \in \mathbb{C}^{J \times I_n}$ 的模式- n ($n=1, 2, \dots, N$) 乘积表示为 $\mathcal{Y} = \mathcal{X} \times_n \mathbf{U}$ ，其中 $\mathcal{Y} \in \mathbb{C}^{I_1 \times I_2 \times \cdots \times I_{n-1} \times J \times I_{n+1} \times \cdots \times I_N}$ ，且满足如下元素对应关系

$$\mathcal{Y}(i_1, \dots, i_{n-1}, j, i_{n+1}, \dots, i_N) = \sum_{i_n=1}^{I_n} \mathcal{X}(i_1, i_2, \dots, i_N) \mathbf{U}(j, i_n) \quad (2-22)$$

定义 2.3.4 张量模式- n canonical 展开^[80-82]：对于 N 阶张量 $\mathcal{X} \in \mathbb{C}^{I_1 \times I_2 \times \cdots \times I_N}$ ，其模式- n canonical 展开矩阵表示为 $\mathcal{X}_{[k]} \in \mathbb{C}^{m \times n}$ ，其中 $m = \prod_{d=1}^k I_d$ ， $n = \prod_{d=k+1}^N I_d$ 。

图 2-2 三阶张量模式- n 展开形式

定义 2.3.5 秩-1 张量：若一个 N 阶张量 $\mathcal{X} \in \mathbb{C}^{I_1 \times I_2 \times \dots \times I_N}$ 秩为 1，则其可表示为如下向量外积的形式

$$\mathcal{X} = \mathbf{u}^{(1)} \circ \mathbf{u}^{(2)} \circ \dots \circ \mathbf{u}^{(N)} \quad (2-23)$$

式中， $\circ$ 表示外积， $\{\mathbf{u}^{(n)} \in \mathbb{C}^{I_n \times 1}\}_{n=1}^N$ 。

2.3.2 张量分解方法

定义 2.3.6 张量 CP 分解：对于一个 N 阶张量 $\mathcal{X} \in \mathbb{C}^{I_1 \times I_2 \times \dots \times I_N}$ ，其 CP 分解形式为

$$\mathcal{X} = \sum_{r=1}^R g_r \mathbf{u}_r^{(1)} \circ \mathbf{u}_r^{(2)} \circ \dots \circ \mathbf{u}_r^{(N)} \quad (2-24)$$

式中， R 为正整数， $g_r \in \mathbb{C}$ 且不为 0。 $\mathbf{u}_r^{(n)}$ 表示因子矩阵 $\mathbf{U}^{(n)}$ 中第 r 列。张量的 CP 秩定义为构成(2-24)中张量 $\mathcal{X}$ 所用的秩-1 张量的最少个数。图 2-3 所示为一个三阶张量的 CP 分解示意图。结合因子矩阵 $\mathbf{U}^{(n)}$ 的表示形式

$$\mathbf{U}^{(n)} = [\mathbf{u}_1^{(n)}, \mathbf{u}_2^{(n)}, \dots, \mathbf{u}_R^{(n)}] \in \mathbb{C}^{I_n \times R}, 1 \leq n \leq N \quad (2-25)$$

式(2-24)可简写为

$$\mathcal{X} = \llbracket \mathbf{g}; \mathbf{U}^{(1)}, \mathbf{U}^{(2)}, \dots, \mathbf{U}^{(N)} \rrbracket \quad (2-26)$$

式中, $\mathbf{g} = [g_1, g_2, \dots, g_R]^T \in \mathbb{C}^R$ 。根据定义 2.3.2, 张量 $\mathcal{X} = \sum_{r=1}^R g_r \mathbf{u}_r^{(1)} \circ \mathbf{u}_r^{(2)} \circ \dots \circ \mathbf{u}_r^{(N)}$ 的模式- n 展开形式为

$$\mathcal{X}_{(n)} = \mathbf{U}^{(n)} \cdot \mathbf{G} \cdot [\mathbf{U}^{(N)} \odot \dots \odot \mathbf{U}^{(n+1)} \odot \mathbf{U}^{(n-1)} \odot \dots \odot \mathbf{U}^{(1)}]^T \quad (2-27)$$

式中, $\mathbf{G} = \text{diag}([g_1, g_2, \dots, g_R]^T)$ 。




图 2-3 三阶张量的 CP 分解形式

定义 2.3.7 张量 Tucker 分解: 对于一个 N 阶张量 $\mathcal{X} \in \mathbb{C}^{I_1 \times I_2 \times \dots \times I_N}$, 其 Tucker 分解形式为

$$\mathcal{X} = \mathcal{G} \times_1 \mathbf{A}^{(1)} \times_2 \mathbf{A}^{(2)} \times_3 \dots \times_N \mathbf{A}^{(N)} \quad (2-28)$$

式中, $\mathcal{G} \in \mathbb{C}^{R_1 \times R_2 \times \dots \times R_N}$ 为对角核心张量, $\{\mathbf{A}^{(n)} \in \mathbb{C}^{I_n \times R_n}\}_{n=1}^N$ 为因子矩阵。张量 Tucker 秩定义为

$\text{rank}_{\text{Tucker}}(\mathcal{X}) = [R_1, R_2, \dots, R_N]$ 。图 2-4 所示为一个三阶张量的 Tucker 分解示意图。




图 2-4 三阶张量的 Tucker 分解形式

定义 2.3.8 张量 TT 积: 对于给定 M 阶张量 $\mathcal{A} \in \mathbb{C}^{I_1 \times I_2 \times \dots \times I_M}$ 和 N 阶张量 $\mathcal{B} \in \mathbb{C}^{J_1 \times J_2 \times \dots \times J_N}$, 其中 $I_M = J_N$, $\mathcal{A}$ 和 $\mathcal{B}$ 的张量 TT 积表示为 $\mathcal{Z} = \mathcal{A} \times_n^m \mathcal{B}$, $\mathcal{Z} \in \mathbb{C}^{I_1 \times \dots \times I_{m-1} \times I_{m+1} \times \dots \times I_M \times J_1 \times \dots \times J_{n-1} \times J_{n+1} \times \dots \times J_N}$

且满足如下元素对应关系

$$\mathcal{Z}(i_1, \dots, i_{m-1}, i_{m+1}, \dots, i_M, j_1, \dots, j_{n-1}, j_{n+1}, \dots, j_N) = \sum_k^{I_Q} \mathcal{A}(i_1, \dots, i_{m-1}, k, i_{m+1}, \dots, i_M) \mathcal{B}(j_1, \dots, j_{n-1}, k, j_{n+1}, \dots, j_N) \quad (2-29)$$

定义 2.3.9 张量 TT 分解和 TT 秩^[82]: 对于一个 N 阶张量 $\mathcal{X} \in \mathbb{C}^{I_1 \times I_2 \times \dots \times I_N}$, 其 TT 分解形式为

$$\mathcal{X} = \mathcal{V}_1 \times_2^1 \mathcal{V}_2 \times_3^1 \mathcal{V}_3 \times_5^1 \dots \times_{N-1}^1 \mathcal{V}_{N-1} \times_N^1 \mathcal{V}_N \quad (2-30)$$

式中, $\{\mathcal{V}_n \in \mathbb{C}^{R_n \times I_n \times R_{n+1}}\}_{n=1}^N$ 为核心因子张量, TT 秩定义为 $\text{rank}_{\text{TT}}(\mathcal{X}) = [R_1, R_2, \dots, R_N]$, 且

$R_1 = R_N = 1$ 。图 2-5 为三阶张量的 TT 分解示意图。




图 2-5 三阶张量的 TT 分解形式

2.3.3 张量填充方法

类似于经典矩阵填充算法, 张量填充算法亦旨在从不完整观测张量中重建出完整张量。基于秩最小化模型可以建立张量填充模型

$$\begin{aligned} \min_{\mathcal{X}} \quad & \text{rank}(\mathcal{X}) \\ \text{s.t.} \quad & \mathcal{X}_{\Omega} = \mathcal{M}_{\Omega} \end{aligned} \quad (2-31)$$

式中, Ω 表示已知观测数据索引集, $\mathcal{M}$ 为观测张量, $\mathcal{X}$ 为待重建张量。张量的秩具有多重定义, 因此派生了诸多低秩张量填充模型。考虑到秩函数的非凸非连续性, 直接求解式(2-31)是一个 NP-Hard 问题^[83], 因此衍生出诸多不同形式的张量填充模型, 本文主要介绍一些经典张量填充模型。

(1) 低 Tucker 秩张量填充算法

文献[52]基于张量 Tucker 秩所提出的张量填充模型, 即式(1-7)

$$\begin{aligned} \min_{\mathcal{X}} \quad & \sum_{n=1}^N \alpha_n \|\mathcal{X}_{(n)}\|_* \\ \text{s.t.} \quad & \mathcal{X}_{\Omega} = \mathcal{M}_{\Omega} \end{aligned} \quad (2-32)$$

式中, $\mathcal{X}_{(n)}$ 为张量模式- n 展开, α_n 为 $\mathcal{X}_{(n)}$ 的非负权重因子。HaLRTC 算法^[52]在求解式(2-32)时, 辅助变量 $\mathcal{T}_n$ 被引入到模型(2-32)中, 其等价形式为

$$\begin{aligned} \min_{\mathcal{X}, \mathcal{T}_1, \dots, \mathcal{T}_N} \quad & \sum_{n=1}^N \alpha_n \|\mathcal{T}_{n(n)}\|_* \\ \text{s.t.} \quad & \mathcal{X}_\Omega = \mathcal{M}_\Omega, \mathcal{X} = \mathcal{T}_n, n=1, 2, \dots, N \end{aligned} \quad (2-33)$$

然后, 定义式(2-33)的拉格朗日函数为

$$\begin{aligned} \mathcal{L}_\beta(\mathcal{X}, \mathcal{T}_1, \dots, \mathcal{T}_N, \mathcal{Y}_1, \dots, \mathcal{Y}_N) \\ = \sum_{n=1}^N \alpha_n \|\mathcal{T}_{n(n)}\|_* + \langle \mathcal{X} - \mathcal{T}_n, \mathcal{Y}_n \rangle + \frac{\beta}{2} \|\mathcal{T}_n - \mathcal{X}\|_F^2 \end{aligned} \quad (2-34)$$

式中, $\mathcal{Y}_n$ 和 β 分别为拉格朗日乘子和正则化参数, 其完整算法在文献[52]有详细描述。

(2) 低 CP 秩张量填充算法

文献[84]基于低 CP 秩和 CP 分解提出对应的张量填充模型

$$\begin{aligned} \min_{\mathcal{X}, \mathbf{U}^{(n)}} \quad & \frac{1}{2} \|\mathcal{X}_\Omega - \mathcal{M}_\Omega\|_F^2 \\ \text{s.t.} \quad & \mathcal{X} = \sum_{r=1}^R \mathbf{g}_r \mathbf{u}_r^{(1)} \circ \mathbf{u}_r^{(2)} \circ \dots \circ \mathbf{u}_r^{(N)} \end{aligned} \quad (2-35)$$

再利用 Alternating Least Squares(ALS)对(2-35)进行求解, 但此模型是非凸的, 可能会得到局部最优解, 产生较差的优化效果。

文献[50]基于 CP 分解, 提出并证明了因子矩阵的秩可作为张量秩的替代, 建立了如下凸优化低秩张量填充模型

$$\begin{aligned} \min_{\mathcal{X}, \mathbf{U}^{(n)}} \quad & \sum_{n=1}^N \alpha_n \|\mathbf{U}^{(n)}\|_* + \frac{\lambda}{2} \|\mathcal{X} - \mathbf{U}^{(1)} \circ \mathbf{U}^{(2)} \circ \dots \circ \mathbf{U}^{(N)}\|_F^2 \\ \text{s.t.} \quad & \mathcal{X}_\Omega = \mathcal{M}_\Omega \end{aligned} \quad (2-36)$$

式中, α_n 为预定义的权重因子, λ 为正则化参数, $\mathcal{X}$ 为待重建张量, $\mathcal{M}$ 为观测张量。式(2-36)的完整求解算法在文献[50]有详细描述, 因此不再讨论。

2.4 本章小结

本章简要概述了矩阵框架和张量框架下的常见矩阵/张量分解方法和矩阵/张量填充方法, 首先介绍了本文所用的一些常用符号及其定义; 接着对矩阵分解和矩阵填充基础

理论进行了简要介绍，并介绍了两种经典矩阵填充算法 SVT 和 IALM 的求解过程；最后介绍了张量基础知识和常见的张量 CP 分解、Tucker 分解和 TT 分解方法，以及基于低 CP 秩和低 Tucker 秩的两种张量填充算法，为后续章节奠定理论基础。

第三章 基于低秩 Hankel 矩阵分解的失效阵元缺失数据恢复方法

3.1 引言

在实际应用中,由于人为、环境以及硬件本身限制等因素的影响,增加了 MIMO 雷达阵列中阵元受损的概率,此时,经匹配滤波形成的虚拟阵列中存在大量阵元缺失,而造成阵列采样数据丢失,产生较差的目标角度估计性能。因此,如何有效地解决失效阵元缺失数据恢复问题是本章及后续重点讨论对象。

低秩矩阵填充算法在恢复矩阵中缺失数据时,大多数假设数据缺失位置是随机分布的。然而,双基地 MIMO 雷达因失效阵元产生的缺失数据情况为结构性缺失,此时仅利用低秩约束无法重建结构性缺失数据。对于结构性缺失数据重建问题,在逆合成孔径雷达(Inverse Synthetic Aperture Radar, ISAR)成像^[88]、图像处理^[92]等诸多领域中已展开类似的研究。文献[70]提出一种结构化 Hankel 矩阵构造的协方差矩阵缺失数据恢复方法,该方法需利用 Vandermonde 分解等方法精确估计角度,但四重 Hankel 矩阵操作造成了巨大的矩阵维度扩张问题,使得此方法具有很高的计算复杂度。

为更好地解决因失效阵元而导致的缺失数据恢复问题,改善阵元失效时角度估计性能,本文提出一种基于低秩 Hankel 矩阵分解的失效阵元缺失数据恢复方法。首先,采用奇异值分解从不完整的协方差矩阵中提取出维度较低的矩阵因子,并将协方差矩阵缺失数据恢复问题转换为不完整矩阵因子重构问题;然而,传统低秩矩阵填充算法要求矩阵中缺失元素位置具有一定的随机性,在重构矩阵因子中整行缺失元素时可能失效,为此,通过利用矩阵因子行和列间的结构特性,将不完整矩阵因子重新排列为块 Hankel 矩阵,并对其施加核范数约束从而建立不完整矩阵因子重构模型;然后,为避免核范数求解中运算量较大的奇异值分解运算,利用 Hankel 矩阵可分解性质,重新表征了核范数约束问题;最后,采用 ADMM 算法求解优化的矩阵因子重构模型。仿真实验表明本章方法可以有效地恢复失效阵元缺失数据,具有较优的角度估计性能,同时基于毫米波雷达实测数据验证本章方法的有效性。

3.2 双基地 MIMO 雷达信号模型

双基地 MIMO 雷达系统具有 M 个发射阵元和 N 个接收阵元，发射和接收阵元间隔分别为 d_t 和 d_r ，且收发阵列均为半波长间距的均匀线阵。发射阵列发射 M 个正交窄带信号为 $\mathbf{W} = [\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_M]^T \in \mathbb{C}^{M \times K}$ ，且该信号满足 $(1/K)\mathbf{W}\mathbf{W}^H = \mathbf{I}_{M \times M}$ ，其中 K 为每个脉冲周期内的采样个数， $(\cdot)^T$ 为转置运算， $(\cdot)^H$ 为共轭转置运算。在空间远场内若存在 P 个非相干目标，第 $p(p=1, 2, \dots, P)$ 个目标位于 (θ_p, φ_p) ，其中 θ_p 为波离方向角， φ_p 为波达方向角，则接收阵列在第 $q(q=1, 2, \dots, Q)$ 个脉冲周期的接收信号 $\mathbf{X}_q$ 表示为

$$\mathbf{X}_q = \mathbf{A}_r \text{diag}(\mathbf{s}_q) \mathbf{A}_t^T \mathbf{W} + \mathbf{Z}_q \quad (3-1)$$

式中， $\mathbf{A}_r = [\mathbf{a}_r(\varphi_1), \mathbf{a}_r(\varphi_2), \dots, \mathbf{a}_r(\varphi_P)] \in \mathbb{C}^{N \times P}$ 为接收阵列导向矩阵，其中 $\mathbf{a}_r(\varphi_p) = [1, e^{-j2\pi d_r \sin(\varphi_p)/\lambda}, \dots, e^{-j2(N-1)\pi d_r \sin(\varphi_p)/\lambda}]^T \in \mathbb{C}^{N \times 1}$ ； $\mathbf{A}_t = [\mathbf{a}_t(\theta_1), \mathbf{a}_t(\theta_2), \dots, \mathbf{a}_t(\theta_P)] \in \mathbb{C}^{M \times P}$ 为发射阵列导向矩阵，其中 $\mathbf{a}_t(\theta_p) = [1, e^{-j2\pi d_t \sin(\theta_p)/\lambda}, \dots, e^{-j2(M-1)\pi d_t \sin(\theta_p)/\lambda}]^T \in \mathbb{C}^{M \times 1}$ ； $\text{diag}(\mathbf{s}_q)$ 表示由向量 $\mathbf{s}_q$ 构成的对角矩阵，其中 $\mathbf{s}_q = [\beta_1 e^{j2\pi q f_{d1}/f_s}, \beta_2 e^{j2\pi q f_{d2}/f_s}, \dots, \beta_P e^{j2\pi q f_{dP}/f_s}]^T \in \mathbb{C}^{P \times 1}$ ， β_p 和 f_{dp} 分别为第 p 个目标的反射系数和多普勒频率， f_s 为脉冲重复频率； $\mathbf{Z}_q \in \mathbb{C}^{M \times K}$ 为高斯白噪声矩阵。利用发射信号之间的正交特性，用 $(1/K)\mathbf{W}^H$ 右乘式(3-1)，则经匹配滤波后的输出为

$$\mathbf{Y}_q = \mathbf{A}_r \text{diag}(\mathbf{s}_q) \mathbf{A}_t^T + \tilde{\mathbf{Z}}_q, \quad q=1, 2, \dots, Q \quad (3-2)$$

式中， $\mathbf{Y}_q = \mathbf{X}_q \mathbf{W}^H / K$ 表示经匹配滤波后的接收信号矩阵； $\tilde{\mathbf{Z}}_q = \mathbf{Z}_q \mathbf{W}^H / K$ 为匹配滤波后的噪声矩阵。将按列排列为 $MN \times 1$ 维列矢量，即

$$\mathbf{y}_q = (\mathbf{A}_r \odot \mathbf{A}_t) \mathbf{s}_q + \mathbf{z}_q \quad (3-3)$$

式中， $\mathbf{y}_q = \text{vec}(\mathbf{Y}_q)$ ； $\mathbf{z}_q = \text{vec}(\tilde{\mathbf{Z}}_q)$ ； $\odot$ 表示 Khatri-Rao 积。Q 个脉冲周期下的虚拟阵列输出矩阵 $\mathbf{Y}$ 为

$$\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_Q] = (\mathbf{A}_r \odot \mathbf{A}_t) \mathbf{S} + \mathbf{Z} \quad (3-4)$$

式中, $\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_Q] \in \mathbb{C}^{MN \times Q}$, $\mathbf{S} = [\mathbf{s}_1, \mathbf{s}_2, \dots, \mathbf{s}_Q] \in \mathbb{C}^{P \times Q}$, $\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_Q] \in \mathbb{C}^{MN \times Q}$ 。

则 Q 个脉冲周期下的协方差矩阵 $\mathbf{R}$ 可估计为

$$\mathbf{R} = \mathbf{Y}\mathbf{Y}^H / Q = (\mathbf{A}_t \odot \mathbf{A}_t) \mathbf{R}_s (\mathbf{A}_t \odot \mathbf{A}_t)^H + \mathbf{R}_z \quad (3-5)$$

式中, $\mathbf{R}_s = \mathbf{S}\mathbf{S}^H / Q \in \mathbb{C}^{P \times P}$ 为信号协方差矩阵, $\mathbf{R}_z = \mathbf{Z}\mathbf{Z}^H / Q \in \mathbb{C}^{MN \times MN}$ 为噪声协方差矩阵。

对于非相干目标, $\mathbf{R}_s = \text{diag}([\rho_1, \rho_2, \dots, \rho_P]^T)$ 。

在实际应用中, 由于恶劣的外界环境和日益复杂的雷达系统等因素影响, 天线阵列中部分阵元失效的概率增加, 阵列信号因此也会丢失。令 Ω_T 和 Ω_R 分别为发射和接收阵列中故障阵元的位置集合, 由于失效阵元的存在, 因此发射和接收导向矩阵中的一些行元素全为零, 可表示为

$$\tilde{\mathbf{A}}_t(m,:) = \begin{cases} \mathbf{A}_t(m,:), m \notin \Omega_T \\ \mathbf{0} \in \mathbb{R}^{1 \times P}, m \in \Omega_T \end{cases} \text{ 且 } \tilde{\mathbf{A}}_t = \text{diag}(\mathbf{c}_t) \mathbf{A}_t \quad (3-6)$$

$$\tilde{\mathbf{A}}_r(n,:) = \begin{cases} \mathbf{A}_r(n,:), n \notin \Omega_R \\ \mathbf{0} \in \mathbb{R}^{1 \times P}, n \in \Omega_R \end{cases} \text{ 且 } \tilde{\mathbf{A}}_r = \text{diag}(\mathbf{c}_r) \mathbf{A}_r \quad (3-7)$$

式中, $\mathbf{c}_t \in \mathbb{R}^{M \times 1}$ 和 $\mathbf{c}_r \in \mathbb{R}^{N \times 1}$ 均为由 0 和 1 构成的向量。若第 $m(m \in \Omega_T)$ 个发射阵元故障, 则 $[\mathbf{c}_t]_m = 0$, 其中 $[\mathbf{c}_t]_m$ 表示向量 $\mathbf{c}_t$ 中第 m 个元素; 若第 $n(n \in \Omega_R)$ 个接收阵元故障, 则 $[\mathbf{c}_r]_n = 0$, $[\mathbf{c}_r]_n$ 表示向量 $\mathbf{c}_r$ 中第 n 个元素。阵元正常时, 向量 $\mathbf{c}_t$ 和 $\mathbf{c}_r$ 中所有元素都为 1。

阵元失效下虚拟阵列输出信号矩阵 $\tilde{\mathbf{Y}}$ 及其协方差矩阵 $\tilde{\mathbf{R}}$ 分别表示为

$$\tilde{\mathbf{Y}} = (\tilde{\mathbf{A}}_r \odot \tilde{\mathbf{A}}_t) \mathbf{S} + \tilde{\mathbf{Z}} \quad (3-8)$$

$$\tilde{\mathbf{R}} = \tilde{\mathbf{Y}}\tilde{\mathbf{Y}}^H / Q = (\tilde{\mathbf{A}}_r \odot \tilde{\mathbf{A}}_t) \mathbf{R}_s (\tilde{\mathbf{A}}_r \odot \tilde{\mathbf{A}}_t)^H + \tilde{\mathbf{R}}_z \quad (3-9)$$

式中, $\tilde{\mathbf{Z}}$ 为阵元失效下的噪声矩阵; $\tilde{\mathbf{R}}_z = [(\mathbf{c}_t \otimes \mathbf{c}_r)(\mathbf{c}_t \otimes \mathbf{c}_r)^H] \oplus \mathbf{R}_z$ 为阵元失效下的噪声协方差矩阵, 其中 $\oplus$ 为 Hadamard 积运算。

假设 MIMO 雷达具有 $M=3$ 个发射阵元和 $N=3$ 个接收阵元, 且收发阵列中均为第二个阵元受损, 其虚拟阵列输出信号矩阵 $\tilde{\mathbf{Y}}$ 及其协方差矩阵 $\tilde{\mathbf{R}}$ 示意图如图 3.1 所示, 可以看出协方差矩阵中存在大量整行和整列数据缺失。




图 3.1 阵元受损时虚拟阵列信号示意图

3.3 基于低秩 Hankel 矩阵分解的协方差矩阵重构方法

传统矩阵填充方法是依据矩阵的低秩特性来约束待重建矩阵，当缺失项随机分布在待重建矩阵内，可以精确地重建出完整矩阵^[64]。然而，在双基地 MIMO 雷达中，由于失效阵元的存在，协方差矩阵中存在一些整行和整列中无观测数据的情况，这些缺失数据的位置不符合随机分布，被称为结构性缺失^[64]。此时，传统矩阵填充方法中的秩最小化不足以在恢复结构性缺失数据时产生足够的约束，例如对矩阵中整列缺失的元素直接填充零元素仍然将使得矩阵的秩最小，因此导致现有的矩阵填充算法无法恢复结构性缺失数据^[64]。

3.3.1 MIMO 雷达协方差矩阵重构模型

为解决协方差矩阵中结构性缺失数据重建问题，首先分析协方差矩阵的分解特性，根据式(3-5)，阵元正常情况下完整的协方差矩阵 $\mathbf{R}$ 可表示为

$$\begin{aligned}
 \mathbf{R} &= (\mathbf{A}_r \odot \mathbf{A}_t) \mathbf{R}_s (\mathbf{A}_r \odot \mathbf{A}_t)^H + \mathbf{R}_z \\
 &= \left[(\mathbf{A}_r \odot \mathbf{A}_t) \frac{\mathbf{S}}{\sqrt{Q}} \right] \left[(\mathbf{A}_r \odot \mathbf{A}_t) \frac{\mathbf{S}}{\sqrt{Q}} \right]^H + \mathbf{R}_z \\
 &= \mathbf{B} \mathbf{B}^H + \mathbf{R}_z
 \end{aligned} \tag{3-10}$$

式中， $\mathbf{B} = (\mathbf{A}_r \odot \mathbf{A}_t) \mathbf{S} / \sqrt{Q}$ 为矩阵因子。当阵元出现故障时，协方差矩阵分解出的矩阵因子 $\tilde{\mathbf{B}} = (\tilde{\mathbf{A}}_r \odot \tilde{\mathbf{A}}_t) \mathbf{S} / \sqrt{Q}$ 中会出现整行的缺失数据，此时无法直接通过 MC 算法恢复这些

结构性的缺失数据。本章引入块 Hankel 矩阵操作对矩阵因子 $\tilde{\mathbf{B}}$ 进行变换，建立如下矩阵因子重构模型

$$\begin{aligned} \min_{\mathbf{B}, \mathbf{R}} \quad & \text{rank}(\mathcal{H}(\mathbf{B})) \\ \text{s.t.} \quad & P_{\Omega}(\mathbf{R}) = P_{\Omega}(\tilde{\mathbf{R}}), \mathbf{R} = \mathbf{B}\mathbf{B}^H \end{aligned} \quad (3-11)$$

式中， $\mathbf{R}$ 为待恢复的完整协方差矩阵； $\tilde{\mathbf{R}}$ 为阵元故障下的协方差矩阵； $\mathbf{B} \in \mathbb{C}^{MN \times P}$ 为待重建矩阵因子； Ω 为 $\tilde{\mathbf{R}}$ 中已知非零元素的索引集； $P_{\Omega}(\cdot)$ 表示矩阵在索引集 Ω 上的投影； $\mathcal{H}(\cdot)$ 为块 Hankel 矩阵操作。

矩阵 $\mathbf{B} \in \mathbb{C}^{MN \times P}$ 可由 P 个列向量 $\{\mathbf{b}_p \in \mathbb{C}^{MN \times 1}\}_{p=1}^P$ 构成，即 $\mathbf{B} = [\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_p] \in \mathbb{C}^{MN \times P}$ ，其中， $\mathbf{b}_p$ 表示矩阵 $\mathbf{B}$ 的第 p 列元素组成的向量。列向量 $\mathbf{b}_p$ 可由 N 个子列向量 $\{\mathbf{b}_p^n \in \mathbb{C}^{M \times 1}\}_{n=1}^N$ 构成，即 $\mathbf{b}_p = [\mathbf{b}_p^{1T}, \mathbf{b}_p^{2T}, \dots, \mathbf{b}_p^{NT}]^T \in \mathbb{C}^{MN \times 1}$ ，其中，子列向量 $\mathbf{b}_p^n = [b_p^{1,n}, b_p^{2,n}, \dots, b_p^{M,n}]^T \in \mathbb{C}^{M \times 1}$ ， $\{b_p^{m,n}\}_{m=1}^M$ 表示 $\mathbf{b}_p^n$ 中第 m 个元素。

将向量映射到 Hankel 矩阵的变换操作 $\mathcal{F}(\cdot)$ 定义为

$$\mathcal{F}(\cdot): \mathbf{b}_p^n \in \mathbb{C}^{M \times 1} \rightarrow \mathcal{F}(\mathbf{b}_p^n) \in \mathbb{C}^{\gamma \times M - \gamma + 1} \quad (3-12)$$

式中， $\gamma = \left\lfloor \frac{M+1}{2} \right\rfloor$ ，其中 $\lfloor \cdot \rfloor$ 为向下取整运算。以子列向量 $\mathbf{b}_p^n$ 中的元素构造 Hankel 矩阵

$$\mathcal{F}(\mathbf{b}_p^n) = \begin{bmatrix} b_p^{1,n} & b_p^{2,n} & \dots & b_p^{M-\gamma+1,n} \\ b_p^{2,n} & b_p^{3,n} & \dots & b_p^{M-\gamma+2,n} \\ \vdots & \vdots & \ddots & \vdots \\ b_p^{\gamma,n} & b_p^{\gamma+1,n} & \dots & b_p^{M,n} \end{bmatrix} \quad (3-13)$$

以 Hankel 矩阵 $\mathcal{F}(\mathbf{b}_p^n)$ 为子块矩阵，将 N 个子块矩阵 $\{\mathcal{F}(\mathbf{b}_p^n)\}_{n=1}^N$ 排列为矩阵

$$\mathbf{H}_p = \left[\left(\mathcal{F}(\mathbf{b}_p^1) \right)^T, \left(\mathcal{F}(\mathbf{b}_p^2) \right)^T, \dots, \left(\mathcal{F}(\mathbf{b}_p^N) \right)^T \right]^T \in \mathbb{C}^{N\gamma \times M - \gamma + 1}。$$

定义矩阵映射到块 Hankel 矩阵的操作 $\mathcal{Q}(\cdot)$ 为

$$\mathcal{Q}(\cdot): \mathbf{H}_p \in \mathbb{C}^{N\gamma \times M - \gamma + 1} \rightarrow \mathcal{Q}(\mathbf{H}_p) \in \mathbb{C}^{\gamma\eta \times (M - \gamma + 1)(N - \eta + 1)} \quad (3-14)$$

式中, $\eta = \left\lfloor \frac{N+1}{2} \right\rfloor$ 。以矩阵 $\mathbf{H}_p$ 构造的块 Hankel 矩阵 $\mathcal{Q}(\mathbf{H}_p) \in \mathbb{C}^{\eta \times (M-\gamma+1)(N-\eta+1)}$ 可表示为

$$\mathcal{Q}(\mathbf{H}_p) = \begin{bmatrix} \mathcal{F}(\mathbf{b}_p^1) & \mathcal{F}(\mathbf{b}_p^2) & \cdots & \mathcal{F}(\mathbf{b}_p^{N-\eta+1}) \\ \mathcal{F}(\mathbf{b}_p^2) & \mathcal{F}(\mathbf{b}_p^3) & \cdots & \mathcal{F}(\mathbf{b}_p^{N-\eta+2}) \\ \vdots & \vdots & \ddots & \vdots \\ \mathcal{F}(\mathbf{b}_p^\eta) & \mathcal{F}(\mathbf{b}_p^{\eta+1}) & \cdots & \mathcal{F}(\mathbf{b}_p^N) \end{bmatrix} \quad (3-15)$$

以块 Hankel 矩阵 $\mathcal{Q}(\mathbf{H}_p)$ ($p=1, 2, \dots, P$) 为子块, 将 P 个子块 $\{\mathcal{Q}(\mathbf{H}_p)\}_{p=1}^P$ 构造为矩阵 $\mathbf{D} = [\mathcal{Q}(\mathbf{H}_1), \mathcal{Q}(\mathbf{H}_2), \dots, \mathcal{Q}(\mathbf{H}_P)] \in \mathbb{C}^{\eta \times (M-\gamma+1)(N-\eta+1)P}$ 。为了分析方便, 本文用块 Hankel 矩阵操作 $\mathcal{H}(\cdot)$ 表示由矩阵因子 $\mathbf{B}$ 经过变换获得块 Hankel 矩阵 $\mathbf{D}$ 的操作, 即 $\mathbf{D} = \mathcal{H}(\mathbf{B})$ 。

若收发阵元数分别为 $M=5$, $N=3$, 目标个数为 $P=3$, 对虚拟阵列协方差矩阵分解后可得到矩阵因子 $\mathbf{B} \in \mathbb{C}^{15 \times 3}$, 由矩阵因子 $\mathbf{B}$ 构造块 Hankel 矩阵的操作过程如图 3.2 所示。




图 3.2 块 Hankel 矩阵的操作过程示意图

由于式(3-11)中秩的求解为非凸问题, 常用核范数 $\|\cdot\|_*$ 替代矩阵的秩函数, 因此将式(3-11)转换为如下核范数最小化模型

$$\begin{aligned} & \min_{\mathbf{B}, \mathbf{R}} \|\mathcal{H}(\mathbf{B})\|_* \\ \text{s.t. } & P_{\Omega}(\mathbf{R}) = P_{\Omega}(\tilde{\mathbf{R}}), \mathbf{R} = \mathbf{B}\mathbf{B}^H \end{aligned} \quad (3-16)$$

3.3.2 重构模型的优化求解算法

在求解式(3-16)时, 需引入矩阵的 SVD 运算^[86]。对一个维度为 $M \times N$ 的矩阵进行 SVD 运算时, 其计算复杂度约为 $\mathcal{O}(\min(M^2N, MN^2))$ 。由于本文引入了块 Hankel 矩阵操作, 使得矩阵因子 $\mathbf{B}$ 的维度从 $MN \times P$ 扩大为 $\gamma\eta \times (M - \gamma + 1)(N - \eta + 1)P$, 会导致采用 SVD 运算时产生较高的计算复杂度。

为有效降低计算复杂度, 将块 Hankel 矩阵等价表达为两个矩阵的乘积形式^[87], 表示如下

$$\mathcal{H}(\mathbf{B}) = \mathbf{U}\mathbf{V}^H \quad (3-17)$$

式中, $\mathbf{U} \in \mathbb{C}^{\gamma\eta \times P}$, $\mathbf{V} \in \mathbb{C}^{(M - \gamma + 1)(N - \eta + 1)P \times P}$ 。 $\mathcal{H}(\mathbf{B}) = \mathbf{U}\mathbf{V}^H$ 也称为结构化的 Hankel 矩阵分解^[88], 因此核范数可等价表示为如下形式

$$\|\mathcal{H}(\mathbf{B})\|_* = \min_{\mathbf{U}, \mathbf{V}: \mathcal{H}(\mathbf{U}) = \mathbf{U}\mathbf{V}^H} \|\mathbf{U}\|_F^2 + \|\mathbf{V}\|_F^2 \quad (3-18)$$

根据式(3-18), 将式(3-16)转换为如下所示的不完整矩阵因子的重构模型

$$\begin{aligned} & \min_{\mathbf{U}, \mathbf{V}, \mathbf{B}} \|\mathbf{U}\|_F^2 + \|\mathbf{V}\|_F^2 \\ \text{s.t. } & P_{\Omega}(\mathbf{B}) = P_{\Omega}(\tilde{\mathbf{B}}), \mathcal{H}(\mathbf{B}) = \mathbf{U}\mathbf{V}^H \end{aligned} \quad (3-19)$$

式中, $\tilde{\mathbf{B}}$ 为不完整矩阵因子, 由阵元失效下协方差矩阵 $\tilde{\mathbf{R}}$ 分解所得。可以根据式 $\mathbf{R} = \mathbf{B}\mathbf{B}^H$ 从恢复出的完整矩阵因子 $\mathbf{B}$ 估计出完整的协方差矩阵 $\mathbf{R}$ 。

由于噪声的影响, 完整矩阵 $\mathbf{B}$ 与不完整 $\tilde{\mathbf{B}}$ 之间会存在误差, 在式(3-19)模型中加入噪声约束项。此外, 式(3-19)中的等式约束项 $\mathcal{H}(\mathbf{B}) = \mathbf{U}\mathbf{V}^H$ 在实际情况中也为近似相等, 因此引入 $\|\mathcal{H}(\mathbf{B}) - \mathbf{U}\mathbf{V}^H\|_F^2$ 最小二乘约束项使得 $\mathcal{H}(\mathbf{B})$ 逼近 $\mathbf{U}\mathbf{V}^H$ 。最终建立以下不完整矩阵因子填充的模型

$$\begin{aligned} \min_{\mathbf{U}, \mathbf{V}, \mathbf{B}} \quad & \|\mathbf{U}\|_{\text{F}}^2 + \|\mathbf{V}\|_{\text{F}}^2 + \frac{\lambda}{2} \|\mathcal{H}(\mathbf{B}) - \mathbf{U}\mathbf{V}^{\text{H}}\|_{\text{F}}^2 + \mu \|\mathbf{E}\|_{\text{F}}^2 \\ \text{s.t.} \quad & P_{\Omega}(\mathbf{B} + \mathbf{E}) = P_{\Omega}(\tilde{\mathbf{B}}) \end{aligned} \quad (3-20)$$

式中, λ 为正则化参数; μ 为权重参数; $\mathbf{E}$ 为高斯白噪声矩阵, $\|\mathbf{E}\|_{\text{F}}^2$ 为 Frobenius 范数约束的噪声项。将式(3-20)转化为无约束项的优化问题, 则其增广拉格朗日函数可定义为

$$\begin{aligned} \mathcal{L}_{\beta}(\mathbf{U}, \mathbf{V}, \mathbf{E}, \mathbf{B}, \mathbf{M}) = & \frac{1}{2} (\|\mathbf{U}\|_{\text{F}}^2 + \|\mathbf{V}\|_{\text{F}}^2) + \mu \|\mathbf{E}\|_{\text{F}}^2 + \\ & \frac{\lambda}{2} \|\mathcal{H}(\mathbf{B}) - \mathbf{U}\mathbf{V}^{\text{H}}\|_{\text{F}}^2 + \frac{\beta}{2} \left\| \mathbf{B} + \mathbf{E} - \tilde{\mathbf{B}} + \frac{\mathbf{M}}{\beta} \right\|_{\text{F}}^2 \end{aligned} \quad (3-21)$$

式中, $\mathbf{M}$ 为拉格朗日乘子矩阵, β 为惩罚系数。在 ADMM 的框架下, 通过固定多个变量的值, 迭代更新一个变量的值来依次更新变量 $\mathbf{U}$ 、 $\mathbf{V}$ 、 $\mathbf{E}$ 、 $\mathbf{B}$ 和 $\mathbf{M}$ 。第 k 次迭代时, 各个变量的更新函数为

$$\mathbf{E}^{(k+1)} = \arg \min_{\mathbf{E}} \mu \|\mathbf{E}\|_{\text{F}}^2 + \frac{\beta}{2} \left\| \mathbf{B}^{(k)} + \mathbf{E} - \tilde{\mathbf{B}} + \frac{\mathbf{M}^{(k)}}{\beta} \right\|_{\text{F}}^2 \quad (3-22)$$

$$\mathbf{B}^{(k+1)} = \arg \min_{\mathbf{B}} \frac{\lambda}{2} \|\mathcal{H}(\mathbf{B}) - \mathbf{U}^{(k)} \mathbf{V}^{(k)\text{H}}\|_{\text{F}}^2 + \frac{\beta}{2} \left\| \mathbf{B} + \mathbf{E}^{(k+1)} - \tilde{\mathbf{B}} + \frac{\mathbf{M}^{(k)}}{\beta} \right\|_{\text{F}}^2 \quad (3-23)$$

$$\mathbf{U}^{(k+1)} = \arg \min_{\mathbf{U}} \frac{1}{2} \|\mathbf{U}\|_{\text{F}}^2 + \frac{\lambda}{2} \|\mathcal{H}(\mathbf{B}^{(k+1)}) - \mathbf{U} \mathbf{V}^{(k)\text{H}}\|_{\text{F}}^2 \quad (3-24)$$

$$\mathbf{V}^{(k+1)} = \arg \min_{\mathbf{V}} \frac{1}{2} \|\mathbf{V}\|_{\text{F}}^2 + \frac{\lambda}{2} \|\mathcal{H}(\mathbf{B}^{(k+1)}) - \mathbf{U}^{(k+1)} \mathbf{V}^{\text{H}}\|_{\text{F}}^2 \quad (3-25)$$

$$\mathbf{M}^{(k+1)} = \mathbf{M}^{(k)} + \beta (\mathbf{B}^{(k+1)} + \mathbf{E}^{(k+1)} - \tilde{\mathbf{B}}) \quad (3-26)$$

通过求解式(3-22), 更新 $\mathbf{E}$ 的迭代解为

$$\mathbf{E}^{(k+1)} = \frac{\beta}{2\mu + \beta} \left(\tilde{\mathbf{B}} - \mathbf{B}^{(k)} - \frac{\mathbf{M}^{(k)}}{\beta} \right) \quad (3-27)$$

利用最小二乘法求解式(3-23), 可得到更新 $\mathbf{B}$ 的迭代解为

$$\mathbf{B}^{(k+1)} = \frac{1}{\lambda + \beta} \left[\lambda \mathcal{H}^{-1} \{ \mathbf{U}^{(k)} \mathbf{V}^{(k)\text{H}} \} - \beta \left(\mathbf{E}^{(k+1)} - \tilde{\mathbf{B}} + \frac{\mathbf{M}^{(k)}}{\beta} \right) \right] \quad (3-28)$$

式中, $\mathcal{H}^{-1}(\cdot)$ 为块 Hankel 矩阵操作 $\mathcal{H}(\cdot)$ 的逆变换, 对于任意矩阵 $\mathbf{X}$, 均有 $\mathcal{H}^{-1}(\mathcal{H}(\mathbf{X})) = \mathbf{X}$ 。

在变量 $\mathbf{U}$ 和 $\mathbf{V}$ 的子问题求解时，对(3-24)中的矩阵 $\mathbf{U}$ 求偏导得

$$\begin{aligned}\frac{\partial L}{\partial \mathbf{U}} &= \frac{\partial}{\partial \mathbf{U}} \left(\frac{1}{2} \|\mathbf{U}\|_{\text{F}}^2 + \frac{\lambda}{2} \left\| \mathcal{H}(\mathbf{B}^{(k+1)}) - \mathbf{U} \mathbf{V}^{(k)\text{H}} \right\|_{\text{F}}^2 \right) \\ &= \mathbf{U} - \lambda \left(\mathcal{H}(\mathbf{B}^{(k+1)}) - \mathbf{U} \mathbf{V}^{(k)\text{H}} \right) \mathbf{V} \\ &= \mathbf{U} \left(\mathbf{I} + \lambda \mathbf{V}^{(k)\text{H}} \mathbf{V}^{(k)} \right) - \lambda \mathcal{H}(\mathbf{B}^{(k+1)}) \mathbf{V}\end{aligned}\quad (3-29)$$

显然，使 $\frac{\partial L}{\partial \mathbf{U}} = 0$ ，可得到子问题 $\mathbf{U}$ 的最优迭代解。类似地，子问题 $\mathbf{V}$ 的闭式解也可以通过类似方式得到，因此变量 $\mathbf{U}$ 和 $\mathbf{V}$ 的更新迭代解分别为

$$\mathbf{U}^{(k+1)} = \lambda \mathcal{H}(\mathbf{B}^{(k+1)}) \mathbf{V} \left(\mathbf{I} + \lambda \mathbf{V}^{(k)\text{H}} \mathbf{V}^{(k)} \right)^{-1} \quad (3-30)$$

$$\mathbf{V}^{(k+1)} = \lambda \left(\mathcal{H}(\mathbf{B}^{(k+1)}) \right)^{\text{H}} \mathbf{U}^{(k+1)} \left(\mathbf{I} + \lambda \mathbf{U}^{(k+1)\text{H}} \mathbf{U}^{(k+1)} \right)^{-1} \quad (3-31)$$

拉格朗日乘子矩阵 $\mathbf{M}$ 的更新迭代解为

$$\mathbf{M}^{(k+1)} = \mathbf{M}^{(k)} + \beta \left(\mathbf{B}^{(k+1)} + \mathbf{E}^{(k+1)} - \tilde{\mathbf{B}} \right) \quad (3-32)$$

综上所述，式(3-20)所表示的优化模型求解如算法 1 所示。

表 3-1 本章算法模型的求解步骤

算法 1: ADMM 算法求解式(3-20)的优化模型

输入: 不完整协方差矩阵 $\tilde{\mathbf{R}} \in \mathbb{C}^{MN \times MN}$, 采样索引集 Ω , 迭代次数 K , $\rho \in (1.0, 1.1]$

1: 对 $\tilde{\mathbf{R}}$ 进行奇异值分解获得不完整的矩阵因子初始值 $\tilde{\mathbf{B}} \in \mathbb{C}^{MN \times P}$, $k = \Delta \mathbf{B} = 1$

2: 初始化 $\mathbf{U} \in \mathbb{C}^{\gamma \eta \times P}$, $\mathbf{V} \in \mathbb{C}^{(M-\gamma+1)(N-\eta+1)P \times P}$

while $k < K$ **and** $\Delta \mathbf{B} < 10^{-4}$ **do**

3: 通过求解式(3-27)更新 $\mathbf{E}$

4: 通过求解式(3-28)更新 $\mathbf{B}$

5: 通过求解式(3-30)更新 $\mathbf{U}$

6: 通过求解式(3-31)更新 $\mathbf{V}$

7: 通过求解式(3-32)更新 $\mathbf{M}$

8: $\beta^{k+1} = \rho \beta^k$

9: $\Delta \mathbf{B} = \|\mathbf{B} - \mathbf{B}_{\text{last}}\|_{\text{F}} / \|\mathbf{B}_{\text{last}}\|_{\text{F}}$

10: $\mathbf{B}_{\text{last}} \leftarrow \mathbf{B}$

end while

输出: 完整的矩阵因子 $\mathbf{B}$

在算法1中，当迭代条件被满足时迭代停止，可得到完整的矩阵因子 $\mathbf{B}$ ，利用ESPRIT算法从完整矩阵因子 $\mathbf{B}$ 中估计出目标角度。

3.3.3 复杂度分析

文献[69]方法(记为MIMO structure and Difference Co-array, MIMO-DC)的计算复杂度集中在构造完整协方差矩阵上，需对 MN 个子矩阵进行取平均操作，其计算复杂度约为

$\mathcal{O}((MN)^2)$ ；若直接通过CVX等凸优化工具箱求解所提模型式(3-20)，得益于CVX的内点法求解策略，可以取得较好的数据恢复精度，但会产生冗长的计算时间，因此本文采用ADMM算法进行求解模型(3-20)，所提完整求解算法记为(Incomplete Matrix Factor Reconstruction based on Matrix Completion, IMFR-MC)，其计算复杂度主要集中在式(3-30)和式(3-31)中的矩阵相乘和求逆运算，其计算复杂度约为 $\mathcal{O}\left(K_1\left(\gamma(M-\gamma+1)(N-\eta+1)(P^3+P^2)+P^3\right)\right)$ ，其中 K_1 为迭代次数；文献[70]方法(记为Fourfold Hankel matrix-based MC, FFH-MC)对由协方差矩阵构造的四重Hankel矩阵进行核范数最小化进行求解，需要对复杂度较高的四重Hankel矩阵进行SVD分解，其复杂度为 $\mathcal{O}\left(K_2\left(\frac{M+1}{2}\right)^6\left(\frac{N+1}{2}\right)^6\right)$ ，其中 K_2 为迭代次数。表3-2为不同算法的计算复杂度。

表 3-2 计算复杂度比较

算法	计算复杂度
IMFR-MC	$\mathcal{O}\left(K_1\left(\gamma(M-\gamma+1)(N-\eta+1)(P^3+P^2)+P^3\right)\right)$
MIMO-DC	$\mathcal{O}((MN)^2)$
FFH-MC	$\mathcal{O}\left(K_2\left(\frac{M+1}{2}\right)^6\left(\frac{N+1}{2}\right)^6\right)$

3.4 仿真结果与分析

为保证各算法对比的公平性，统一采用ESPRIT算法^[13]对IMFR-MC算法、MIMO-DC算法和FFH-MC算法恢复出的完整协方差矩阵进行目标角度估计，以基于完整协方差矩阵直接进行ESPRIT算法估计的目标角度为参照，同时采用角度估计的RMSE作为缺失数据重建性能的衡量指标，并引入克拉美罗界(Cramer Rao Bound, CRB)作为基准，CRB定义为^[11]

$$\text{CRB} = \frac{\sigma^2}{2} \left[\text{Re}(\mathbf{D}^H \mathbf{\Pi}_A^\perp \mathbf{D}) \right]^{-1} \quad (3-33)$$

式中， $\mathbf{D} = \left[\frac{\partial \mathbf{d}}{\partial \varphi_1}, \dots, \frac{\partial \mathbf{d}}{\partial \varphi_p}, \frac{\partial \mathbf{d}}{\partial \theta_1}, \dots, \frac{\partial \mathbf{d}}{\partial \theta_p} \right]$ ，其中， $\mathbf{d} = \left[(\mathbf{A}\mathbf{s}_1)^T, \dots, (\mathbf{A}\mathbf{s}_Q)^T \right]^T$ ， $\mathbf{A} = \mathbf{A}_t \odot \mathbf{A}_r$ ，

$\Pi_A^\perp = I_Q \otimes [I_{MN} - A(A^H A)^{-1} A^H]$; σ^2 为噪声功率, $\text{Re}(\cdot)$ 为取实部操作。

仿真实验中, 设置收发阵元数分别为 $M=5$, $N=15$ 。假设有 $P=3$ 个远场目标, 其角度分别为 $(\theta_1, \varphi_1) = (-10^\circ, 5^\circ)$, $(\theta_2, \varphi_2) = (6^\circ, 13^\circ)$, $(\theta_3, \varphi_3) = (20^\circ, 25^\circ)$ 。第 m 个发射阵元发射的波形信号为 $\mathbf{w}_m = (1+j)/\sqrt{2} \mathbf{h}_m$, 其中 $\mathbf{w}_m$ 为 $\mathbf{W}$ 的第 m 行; $\mathbf{h}_m$ 表示维度为 256×256 的Hadamard矩阵的第 m 行。信噪比定义为 $\text{SNR} = 10 \log_{10} (\|\mathbf{X}_q - \mathbf{Z}_q\|_F^2 / \|\mathbf{Z}_q\|_F^2)$ 。目标角度估计的均方根误差定义为 $\text{RMSE} = \sqrt{\frac{1}{2PM_T} \sum_{p=1}^P \sum_{i=1}^{M_T} \left\{ (\hat{\theta}_{p,i} - \theta_p)^2 + (\hat{\varphi}_{p,i} - \varphi_p)^2 \right\}}$, 其中 M_T 为蒙特卡洛实验次数, $\hat{\theta}_{p,i}$ 和 $\hat{\varphi}_{p,i}$ 分别为第 i 次蒙特卡洛实验中第 p 个目标的DOD和DOA估计值。

3.4.1 算法估计目标角度星座图

设置 MIMO 雷达故障发射阵元位置集合为 $\Omega_T = [3]$, 故障接收阵元位置集合为 $\Omega_R = [2, 4, 7, 12, 14]$, $\text{SNR} = -5\text{dB}$, $Q = 100$, $M_T = 100$ 。图 3.3 为阵元失效时目标角度估计星座图, 图 3.3(a)和图 3.3(b)分别为 ESPRIT 算法和 IMFR-MC 算法的角度估计星座图。由 3.3 可知, 故障阵元会导致阵列接收数据缺失, 致使协方差矩阵的完整结构遭到破坏, 此时直接使用 ESPRIT 算法无法有效地估计目标角度, 具有较差的目标角度估计精度; 而 IMFR-MC 方法能有效地恢复故障阵元缺失数据, 估计出的目标角度精度较高。




图 3.3 阵元失效时目标角度估计星座图

3.4.2 各算法 RMSE 随 SNR 变化关系

本次实验中，阵列故障阵元位置设置与实验 3.4.1 相同， $Q=100$ ， $M_T=100$ 。图 3.4 为不同方法的 RMSE 随 SNR 变化的曲线图。由图 3.4 可知，由于目标的 DOD 和 DOA 不同，MIMO 雷达协方差矩阵具有块 Toeplitz 特性而非 Toeplitz 特性，因此采用差分处理技术的 MIMO-DC 算法无法填补故障阵元缺失数据，其目标角度估计误差较大。FFH-MC 算法和 IMFR-MC 算法对故障阵元的缺失数据进行了有效填补，在低信噪比区域两者几乎具有相同的性能，而在高信噪比区域 IMFR-MC 算法的角度估计精度优于 FFH-MC 算法。




图 3.4 不同方法的 RMSE 随 SNR 变化曲线图

3.4.3 各算法 RMSE 随快拍数变化关系

设置信噪比为 -5dB ，发射阵列和接收阵列的故障阵元位置设置与仿真实验 3.4.1 中相同， $M_T=100$ 。图 3.5 为 RMSE 随快拍数变化的曲线图，图 3.5 中除 MIMO-DC 算法的目标角度估计精度较差以外，其余方法随着快拍数的增多，角度估计精度均有所提升，但 IMFR-MC 算法明显优于 FFH-MC 算法。




图 3.5 不同方法的 RMSE 随快拍数变化曲线图

3.4.4 各算法 RMSE 随失效阵元数变化关系

假设接收阵列中的随机失效阵元数从 1 至 8 之间变化，且每次实验随机选取失效阵元位置，发射阵列失效阵元位置设置与实验 3.4.1 相同， $\text{SNR} = -5\text{dB}$ ， $Q = 100$ 。图 3.6 为不同方法的 RMSE 随失效接收阵元数变化的曲线图，除 MIMO-DC 算法的角度估计性能普遍较差以外，FFH-MC 算法与 IMFR-MC 算法的 RMSE 随着接收失效阵元数量的增加均有不同程度的升高，但 IMFR-MC 算法总体上比 FFH-MC 算法具有更低的 RMSE 值。




图 3.6 不同方法的 RMSE 随接收失效阵元数变化曲线图

3.4.5 各算法的运行时间

本仿真实验参数与实验 3.4.1 相同。实验仿真软件为 MATLAB2018a, CPU 为 Intel Core i5-4570, 内存为 8GB。由表 3-3 可知, MIMO-DC 算法的运算时间最短, 但角度估计误差较大; FFH-MC 算法和 IMFR-MC 算法均能实现目标角度的有效估计, 相较于 FFH-MC 算法, IMFR-MC 算法的运行时间更短、角度估计精度更高。

表 3-3 不同算法的运行时间


算法	IMFR-MC	FFH-MC	MIMO-DC
时间/s	0.1090	4.1881	0.0023
RMSE/°	0.0474	0.0883	12.1283

3.5 基于 AWR1843 毫米波雷达实测数据验证

在 3.4 节中, 基于仿真数据对 IMFR-MC 算法的有效性进行了验证, 为进一步验证 IMFR-MC 算法在实际应用中的有效性, 本文基于德州仪器(Texas Instruments, TI)公司 FMCW MIMO 雷达搭建了实测数据采集平台。首先介绍了实测数据采集实验中的 FMCW MIMO 雷达平台, 然后分析 FMCW MIMO 雷达虚拟阵列的天线布局和回波信号数据的解析格式, 最后通过采集的实测数据来验证 IMFR-MC 算法的有效性。

3.5.1 FMCW MIMO 雷达平台简介

本次实验平台选取的是 TI 公司的 AWR1843 毫米波雷达设备, 是一款工作在 76 至 81GHz 频段的调频连续波(FMCW)雷达传感器系统^[93]。如图 3.7 所示, AWR1843 采用低功耗 45nm RF CMOS 工艺, 实现了内置锁相环和 ADC 的单芯片 3 发 4 收天线系统, 此外 AWR1843 支持串行外设接口、串行传输总线、通用异步收发传输器等多种通信协议, 具备 4GHz 带宽, 可以测量目标距离、速度和角度信息。



(a) 正面图

(b) 背面图

图 3.7 AWR1843 雷达设置实物图

由图 3.8 可知 AWR1843 雷达开发板主要包括 4 个子系统：射频子系统(RF/Analog sub-system)、处理器子系统(Radio processor)、DSP 子系统、Master 子系统等。射频前端包括 3 个发射通道和 4 个接收通道；后端处理器则对采集的原始回波数据进行处理。为了获得原始回波数据，可以通过 DCA1000EVM 数据采集卡进行数据采集，二者之间的信号接口为 60 针高密度连接器，连接示意图如图 3.9 所示。




图 3.8 AWR1843 芯片功能框图




图 3.9 AWR1843 与 DAC1000EVM 连接示意图

为了满足用户开发需求，TI 公司提供了相应的软件 mmWave Studio 用于控制雷达开发板和数据采集卡进行数据采集，该软件可以设置 AWR1843 工作在 TDM(Time-Division-Multiplexing)-MIMO 模式，发射天线 T_1 、 T_2 、 T_3 分时发射信号，且任意两个发射通道之间不存在重叠，在接收天线 R_1 、 R_2 、 R_3 、 R_4 端进行匹配滤波后可形成具有 12 个虚拟阵元的面阵，可同时探测目标的水平方位角和俯仰角。为使实测数据与 3.2 节中仿真数据产生方式保持一致，且本文仅估计目标相对于雷达的水平方位角，在实测数据采集时，仅利用图 3.10 中发射天线 T_1 和 T_3 所形成的虚拟线阵用于后续分析计算。图 3.10 中， $d = \frac{\lambda}{2}$ ， λ 为信号波长。




图 3.10 AWR1843 虚拟阵列形成示意图

在个人电脑端，通过软件 mmWave Studio 软件可以设置 AWR1843 雷达参数以及信号波形等信息，然后通过以太网接收 DCA1000EVM 上传的原始回波数据，并以“.bin”

二进制文件形式保存。AWR1843 雷达原始时域波形数据分为实部和虚部，分别按照 I 路数据和 Q 路数据形式保存，表 3-4 为 TI 公司给出的 AWR1843 雷达数据的读取格式， M 为每个 Chrip 信号的采样数。在 TDM-MIMO 工作模式下，3 个发射天线依次发射信号，在 Chrip1 时刻第一个发射天线工作，4 个接收天线同时接收，形成具有 I、Q 两路的雷达数据。类似地，在 Chrip2 和 Chrip3 时刻，第二个和第三个发射天线依次工作。最终经匹配滤波形成的 12 个虚拟通道数据可被解析为 $8 \times MN_{Chrip}$ 的矩阵，其中 N_{Chrip} 为 Chrip 信号数。

表 3-4 AWR1843 雷达数据读取格式

Chrip1	RX1I0	RX1I1	...	...	RX1I M-1
	RX1Q0	RX1Q1	...	...	RX1Q M-1
	RX2I0	RX2I1	...	...	RX2I M-1
	RX2Q0	RX2Q1	...	...	RX2Q M-1
	RX3I0	RX3I1	...	...	RX3I M-1
	RX3Q0	RX3Q1	...	...	RX3Q M-1
	RX4I0	RX4I1	...	...	RX4I M-1
	RX4Q0	RX4Q1	...	...	RX4Q M-1
Chrip2	RX1I0	RX1I1	...	...	RX1I M-1
	RX1Q0	RX1Q1	...	...	RX1Q M-1
	RX2I0	RX2I1	...	...	RX2I M-1
	RX2Q0	RX2Q1	...	...	RX2Q M-1
	RX3I0	RX3I1	...	...	RX3I M-1
	RX3Q0	RX3Q1	...	...	RX3Q M-1
	RX4I0	RX4I1	...	...	RX4I M-1
	RX4Q0	RX4Q1	...	...	RX4Q M-1
Chrip3	RX1I0	RX1I1	...	...	RX1I M-1
	RX1Q0	RX1Q1	...	...	RX1Q M-1
	RX2I0	RX2I1	...	...	RX2I M-1
	RX2Q0	RX2Q1	...	...	RX2Q M-1
	RX3I0	RX3I1	...	...	RX3I M-1
	RX3Q0	RX3Q1	...	...	RX3Q M-1
	RX4I0	RX4I1	...	...	RX4I M-1
	RX4Q0	RX4Q1	...	...	RX4Q M-1

3.5.2 基于雷达实测数据的算法验证




图 3.11 实测数据采集平台示意图

图 3.11 为个人电脑通过 USB 接口与雷达实测数据采集平台连接示意图，通过 mmWave Studio 软件将雷达参数配置到 AWR1843 雷达模块上，具体参数配置见表 3-5。

表 3-5 AWR1843 雷达参数

参数	值
FMCW 起始频率	77GHz
发射天线数	3
接收天线数	4
带宽	1798.92MHz
Chirp 个数	32
采样点数	256
采样率	10MHz

为克服室外场地以及外界背景杂波干扰对实测数据采集造成的影响，本文实测数据采集实验在微波暗室内进行，图 3.12 为实测数据采集场景图。两个角反射器与雷达平台处于同一高度，位于同一水平线上的 2 个角反射器之间的距离为 1.88m，2 个角反射器与雷达之间的距离分别为 2.42m，可以计算得出两个角反射器相对于雷达的方位角分别为 -22.8° 和 22.8° 。




图 3.12 微波暗室实验场景图

当实测数据 bin 文件被采集到电脑后，利用 MATLAB 读取解析出原始时域波形数据，其形式如表 3-4 所示，然后将实部和虚部组合为回波数据。通过对回波数据的每一个 Chrip 进行 1D FFT 处理可得到目标距离信息，从而估计目标与雷达之间的距离；在距离维 FFT 基础上，对 Chrip 维进行 FFT 处理可得到目标速度信息，从而获得目标的速度。考虑到本文所测量目标为一组相干目标，利用 ESPRIT 等超分辨算法无法进行目标角度估计，因此在天线维对多个接收天线单元的 2D FFT 结果做 1D FFT，即 3D FFT^[94] 处理可以得到目标距离-速度-角度结果，通过检测 FFT 结果的峰值信息从而估计出目标方位角。

由于本实验场景中目标是静止的，即不涉及目标速度的研究，因此本文利用距离维和角度维 FFT 处理 AWR1843 雷达在 TDM-MIMO 工作模式采集到的实测数据，当 T_1 、 T_3 发射天线分时工作时，2 发 4 收的 MIMO 阵列可以形成 8 个虚拟阵元，此时雷达系统

的角度分辨率为 $\theta_{\text{res}} = \frac{\lambda}{8d} \times \frac{180^\circ}{\pi} \approx 14.3^\circ$ ，可以分辨出 2 个目标。

假设 2 发 4 收 MIMO 雷达阵列中第二个接收通道故障，即对第二个接收通道数据置零，此时虚拟阵列中第 2、6 个失效，其示意图如图 3.13 所示。




图 3.13 阵元失效时虚拟阵列形成示意图

考虑到实测场景中两个角反射器为一组相干目标，此时部分能量会干扰到噪声子空间，导致 MUSIC、ESPRIT 等角度估计算法会失效，在实际应用中，常常利用数字波束形成(Digital Beam Forming, DBF)进行角度测量^[95]。在利用 IMFR-MC 算法恢复实测数据中缺失元素后，采用 DBF 方法得到的目标角度谱估计图如图 3.14 所示。由于 AWR1843 雷达收发天线的个数较少并且雷达硬件的角度分辨能力限制，因此从图中可以看出阵元正常时采用 DBF 方法估计出的目标角度与实际场景下的真实角度有一定的偏差。此外，阵元失效时直接采用 DBF 方法对应的旁瓣出现上升，出现伪峰干扰影响，且目标所在尖峰位置发生偏移。由于 IMFR-MC 算法恢复了失效阵元缺失数据，因此 IMFR-MC 算法对应目标尖峰位置与阵元正常时对应的目标尖峰位置基本一致，且有效地抑制了旁瓣上升的影响。




图 3.14 不同方法的目标角度谱估计图

3.6 本章小结

双基地 MIMO 雷达收发阵列中出现失效阵元时,其协方差矩阵中会产生大量结构性缺失数据,严重影响了传统角度估计算法的性能。为此,本文提出一种基于低秩 Hankel 矩阵分解的失效阵元缺失数据恢复方法。基于 SVD 分解从不完整协方差矩阵中提取出维度较低的矩阵因子,通过分析矩阵因子中行和列间相关性,将矩阵因子变换为块 Hankel 矩阵,并对其施加核范数约束,从而建立不完整矩阵因子的重构模型;为了有效降低算法的运算时间,利用 Hankel 矩阵分解性质,基于低秩矩阵拟合算法重新优化了核范数约束;采用 ADMM 算法设计了不完整矩阵因子重构模型的求解算法,以获得完整的矩阵因子,从而增强阵元故障下的角度估计性能。仿真结果表明:本文方法可以有效缓解因阵元失效而导致 MIMO 雷达角度估计性能恶化的影响,实现高精度的角度估计。此外,实测数据也验证了 IMFR-MC 算法恢复失效阵元缺失数据的有效性。

第四章 基于因子矩阵先验信息的失效阵元缺失数据恢复方法

4.1 引言

受益于矩阵填充理论的发展,近些年来,众多学者对张量填充算法展开了深入研究。在图像处理、地震数据处理等领域中已经开展了张量框架下缺失数据恢复问题的研究。在重建视觉数据时,考虑到常见的低秩约束不足以恢复缺失率极其高的彩色或 3D 图像数据,文献[96]提出基于全变分的 SPC-TV(Smoothness PARAFAC Tensor Completion-Total Variation)模型和二次变分的 SPC-QV(Smoothness PARAFAC Tensor Completion-Quadratic Variation)模型,并考虑平滑约束以及低秩近似优化策略,以提高在高缺失率下的张量填充精度。文献[97]为利用观测数据之间的先验信息提高缺失数据重建精度,联合利用模式内和交叉模式正则化,并基于类 EM(Expectation Maximization)算法和梯度优化算法重建具有缺失元素的张量,以提高张量分解时的预测精度。但是,大多数张量填充算法都假设不完整观测张量中缺失数据为随机性分布,这与阵元失效下 MIMO 雷达观测数据张量中缺失数据分布情况相违背。当阵元受损时, MIMO 雷达协方差张量中存在大量的切片缺失的情况,也称其为结构性缺失。此时,常见的张量填充算法在重建结构性缺失数据时会失效,如何从张量框架下利用 MIMO 雷达虚拟阵列输出数据的多维结构,恢复失效阵元缺失数据以改善角度估计精度是至关重要的。

为提高 MIMO 雷达协方差张量中结构性缺失数据的恢复精度,本文基于张量低 CP 秩分解模型,通过利用因子矩阵的 Vandermonde 结构特征,将因子矩阵重新排列为块 Hankel 矩阵并施加核范数惩罚项,联合利用因子矩阵之间的潜在信息建立不完整协方差张量重建模型;接着,本文基于 ADMM 算法推导出此模型的完整求解算法,从而重建出完整的协方差张量;最后,仿真结果验证了本章所提方法可以有效恢复协方差张量中切片缺失数据,具备较高的角度估计精度。

4.2 基于因子矩阵先验信息的协方差张量重构方法

大部分张量填充方法只能恢复张量数据中随机缺失的元素,而不能恢复结构性缺失数据。文献[91]为处理结构性缺失数据恢复问题,将因子矩阵的 Vandermonde 结构融入

到低 CP 秩张量填充算法中,提出一种高维复指数信号重建方法,此方法也适用于 MIMO 雷达失效阵元缺失数据恢复问题,但该方法忽略了因子矩阵之间的相关性,在重构协方差张量缺失数据时存在不稳定性。为提高低 CP 秩张量填充算法的有效性,本章基于因子矩阵的 Vandermonde 结构特征以及因子矩阵之间的潜在比例关系提出一种协方差张量缺失数据恢复方法。

4.2.1 MIMO 雷达协方差张量重构模型

类似于文献[85],通过利用 MIMO 雷达固有的多维数据结构,式(3-5)中协方差矩阵 $\mathbf{R}$ 可重新排列为一个四阶协方差张量 $\mathcal{R} \in \mathbb{C}^{M \times N \times M \times N}$

$$\mathcal{R} = \mathcal{G} \times_1 \mathbf{A}_t \times_2 \mathbf{A}_r \times_3 \mathbf{A}_t^* \times_4 \mathbf{A}_r^* + \mathcal{Z} \quad (4-1)$$

式中, $\mathcal{G} \in \mathbb{C}^{P \times P \times P \times P}$ 为对角核心张量,其位于 (p, p, p, p) 位置处的元素为 ρ_p , 其余位置处为 0; $\mathcal{Z}$ 为噪声协方差张量。

当存在失效阵元时,基于式(4-1)可表示 MIMO 雷达协方差张量 $\tilde{\mathcal{R}}$ 为

$$\tilde{\mathcal{R}} = \mathcal{G} \times_1 \tilde{\mathbf{A}}_t \times_2 \tilde{\mathbf{A}}_r \times_3 \tilde{\mathbf{A}}_t^* \times_4 \tilde{\mathbf{A}}_r^* + \tilde{\mathcal{Z}} \quad (4-2)$$

式中, $\tilde{\mathcal{Z}}$ 为阵元失效下噪声协方差张量。

为说明阵元失效下 MIMO 雷达协方差张量 $\tilde{\mathcal{R}}$ 中缺失数据分布情况,假设 MIMO 雷达具有 $M=7$ 个发射阵元和 $N=8$ 个接收阵元,收发阵列中阵元受损位置分别为 $\Omega_T = [2, 4, 6]$ 和 $\Omega_R = [2, 5, 7]$, 其协方差张量 $\tilde{\mathcal{R}}$ 示意图如图 4.1 所示。




图 4.1 四阶协方差张量 $\tilde{\mathcal{R}}$ 示意图

根据式(4-1)可以看出,当忽略噪声项时,协方差张量 $\mathcal{R}$ 可以简洁地表示为张量 CP

分解形式，如下所示

$$\mathcal{R} = \llbracket \mathbf{g}; \mathbf{A}_t, \mathbf{A}_r, \mathbf{A}_t^*, \mathbf{A}_r^* \rrbracket \quad (4-3)$$

式中, $\mathbf{g} = [\rho_1, \rho_2, \dots, \rho_P]^T \in \mathbb{C}^{P \times 1}$ 。值得注意地, 总是可以通过缩放因子矩阵, 使得向量 $\mathbf{g}$ 中的所有元素均为 1。为简洁表示, 省略 $\mathbf{g}$, 公式(4-3)可重新表述为

$$\mathcal{R} = \llbracket \bar{\mathbf{A}}_t, \bar{\mathbf{A}}_r, \bar{\mathbf{A}}_t^*, \bar{\mathbf{A}}_r^* \rrbracket \quad (4-4)$$

根据阵列导向矩阵的定义, 因子矩阵 $\mathbf{A}_t$ 和 $\mathbf{A}_r$ 均为 Vandermonde 矩阵。式(4-4)中 $\bar{\mathbf{A}}_t$ 和 $\bar{\mathbf{A}}_r$ 是利用常数项对 $\mathbf{A}_t$ 和 $\mathbf{A}_r$ 进行缩放得到的, 因此, 缩放后的因子矩阵 $\bar{\mathbf{A}}_t$ 和 $\bar{\mathbf{A}}_r$ 也具有 Vandermonde 矩阵结构。此外, 除非满足某些强特定条件(例如: 正交性), 否则矩阵分解不是唯一的^[51]。尽管如此确定张量的秩至今仍存在争议, 但张量的低 CP 秩分解形式在非强特定条件下通常是唯一的^[15]。文献[89]基于 Kruskal 定理给出了 CP 分解唯一性的充分条件。

Kruskal 定理: 令 k_A 表示矩阵 $\mathbf{A}$ 的 Kruskal 秩, 对于式(4-3)所表示的 CP 分解模型, 若存在

$$k_{\mathbf{A}_t} + k_{\mathbf{A}_r} + k_{\mathbf{A}_t^*} + k_{\mathbf{A}_r^*} \geq 2P + 3 \quad (4-5)$$

那么, 无论如何排列或缩放因子矩阵, 因子矩阵 $\mathbf{A}_t$ 、 $\mathbf{A}_r$ 、 $\mathbf{A}_t^*$ 和 $\mathbf{A}_r^*$ 均是唯一的。考虑到 CP 分解后的置换效应和缩放影响, 分解协方差张量 $\mathcal{R}$ 估计因子矩阵时的扰动影响可以表示为

$$\mathbf{U}^{(1)} = \bar{\mathbf{A}}_t = \mathbf{A}_t \mathbf{\Pi} \mathbf{A}_1 + \mathbf{N}_1 \quad (4-6)$$

$$\mathbf{U}^{(2)} = \bar{\mathbf{A}}_r = \mathbf{A}_r \mathbf{\Pi} \mathbf{A}_2 + \mathbf{N}_2 \quad (4-7)$$

$$\mathbf{U}^{(3)} = \bar{\mathbf{A}}_t^* = \mathbf{A}_t^* \mathbf{\Pi} \mathbf{A}_3 + \mathbf{N}_3 \quad (4-8)$$

$$\mathbf{U}^{(4)} = \bar{\mathbf{A}}_r^* = \mathbf{A}_r^* \mathbf{\Pi} \mathbf{A}_4 + \mathbf{N}_4 \quad (4-9)$$

式中, $\mathbf{U}^{(1)} \in \mathbb{C}^{M \times P}$, $\mathbf{U}^{(2)} \in \mathbb{C}^{N \times P}$, $\mathbf{U}^{(3)} \in \mathbb{C}^{M \times P}$ 和 $\mathbf{U}^{(4)} \in \mathbb{C}^{N \times P}$ 表示因子矩阵, $\mathbf{\Pi} \in \mathbb{C}^{P \times P}$ 表示置换矩阵, $\mathbf{A}_1$, $\mathbf{A}_2$, $\mathbf{A}_3$ 和 $\mathbf{A}_4$ 为 $P \times P$ 的实值对角矩阵, 其对角元素代表估计因子矩阵时的缩放效应, $\mathbf{N}_1$, $\mathbf{N}_2$, $\mathbf{N}_3$ 和 $\mathbf{N}_4$ 表示拟合误差。忽略拟合误差项^[90], 根据式(4-6), 可

以推导出

$$\mathbf{A}_1 = \mathbf{U}^{(1)} (\mathbf{I} \mathbf{A}_1)^{-1} = \mathbf{U}^{(1)} \mathbf{A}_1^{-1} \mathbf{I}^{-1} \quad (4-10)$$

将式(4-10)代入式(4-8)中，可以得到

$$\mathbf{U}^{(3)} = \mathbf{U}^{(1)*} \mathbf{A}_1^{-1} \mathbf{A}_3 = \mathbf{U}^{(1)*} \mathbf{\Delta}^{(3)} \quad (4-11)$$

式中， $\mathbf{\Delta}^{(3)} = \mathbf{A}_1^{-1} \mathbf{A}_3$ 为 $P \times P$ 的对角矩阵。类似地，可以得到

$$\mathbf{U}^{(4)} = \mathbf{U}^{(2)*} \mathbf{A}_2^{-1} \mathbf{A}_4 = \mathbf{U}^{(2)*} \mathbf{\Delta}^{(4)} \quad (4-12)$$

通过式(4-11)和式(4-12)，可以看出因子矩阵 $\mathbf{U}^{(3)}$ 可以利用对角矩阵 $\mathbf{\Delta}^{(3)}$ 乘以因子矩阵 $\mathbf{U}^{(1)}$ 的共轭直接获得，类似地，因子矩阵 $\mathbf{U}^{(4)}$ 也可以通过这种方式直接获得。

若目标个数 $P=3$ ，不完整协方差张量 $\tilde{\mathcal{R}}$ 经 CP 分解后因子矩阵先验信息示意图如图 4.2 所示，不完整协方差张量 $\tilde{\mathcal{R}}$ 经 CP 分解后，基于因子矩阵的 Vandermonde 结构特点，将不完整因子矩阵排列为块 Hankel 矩阵以建立有效的核范数约束项，并推导出因子矩阵之间的潜在比例关系。




图 4.2 不完整协方差张量 CP 分解示意图

基于上述推导，本文联合利用因子矩阵的 Vandermonde 矩阵结构和因子矩阵之间的潜在关系，设计了一种基于低 CP 秩的张量填充算法用于重建失效阵元缺失数据。为了充分利用因子矩阵先验信息，建立如下张量填充模型

$$\begin{aligned}
& \min_{\mathbf{U}^{(1)}, \mathbf{U}^{(2)}, \mathbf{U}^{(3)}, \mathbf{U}^{(4)}} \sum_{n=1}^4 \left\| \mathcal{H}(\mathbf{U}^{(n)}) \right\|_* \\
& \text{s.t. } \mathbf{U}^{(3)} = \mathbf{U}^{(1)*} \Delta^{(3)}, \mathbf{U}^{(4)} = \mathbf{U}^{(2)*} \Delta^{(4)} \\
& \mathcal{P}_{\Omega}(\tilde{\mathcal{R}}) = \mathcal{P}_{\Omega}(\llbracket \mathbf{U}^{(1)}, \mathbf{U}^{(2)}, \mathbf{U}^{(3)}, \mathbf{U}^{(4)} \rrbracket)
\end{aligned} \tag{4-13}$$

式中, Ω 表示不完整协方差张量 $\tilde{\mathcal{R}}$ 中已知元素的索引, $\mathcal{P}_{\Omega}(\cdot)$ 表示矩阵空间在集合 Ω 上的投影算子

$$\left[\mathcal{P}_{\Omega}(\mathcal{X}) \right]_{i_1, i_2, i_3, i_4} = \begin{cases} \mathcal{X}_{i_1, i_2, i_3, i_4}, & \text{if } (i_1, i_2, i_3, i_4) \in \Omega \\ 0, & \text{otherwise} \end{cases} \tag{4-14}$$

定义 $\mathcal{H}$ 为块 Hankel 矩阵构造运算, 表示将矩阵 $\mathbf{U} = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_R] \in \mathbb{C}^{S \times P}$ 构造为块 Hankel 矩阵 $\mathcal{H}(\mathbf{U}) = [\mathcal{T}(\mathbf{u}_1), \mathcal{T}(\mathbf{u}_2), \dots, \mathcal{T}(\mathbf{u}_R)] \in \mathbb{C}^{S_1 \times S_2 \times P}$ 且 $S_1 + S_2 = S + 1$; 其中 $\mathcal{T}$ 表示 Hankel 矩阵构造运算, 表示将向量 $\mathbf{u} \in \mathbb{C}^{S \times 1}$ 构造为 Hankel 矩阵 $\mathcal{T}(\mathbf{u}) \in \mathbb{C}^{S_1 \times S_2}$ 且 $S_1 + S_2 = S + 1$

$$\begin{aligned}
& \mathcal{T} : \mathbf{u} \in \mathbb{C}^{S_1 + S_2 - 1} \rightarrow \mathcal{T}(\mathbf{u}) \in \mathbb{C}^{S_1 \times S_2} \\
& [\mathcal{T}(\mathbf{u})]_{k, l} = [\mathbf{u}]_{k+l-1}, \forall 1 \leq k \leq S_1, 1 \leq l \leq S_2
\end{aligned} \tag{4-15}$$

式中, $[\cdot]_{k, l}$ 表示矩阵的第 (k, l) 个元素; $[\cdot]_{k+l-1}$ 表示向量的第 $k+l-1$ 个元素。

同时定义 $\mathcal{H}$ 的逆运算 $\mathcal{H}^{-1}$ 为

$$\mathcal{H}^{-1} = [\mathcal{T}^{-1}(\mathbf{u}_1), \mathcal{T}^{-1}(\mathbf{u}_2), \dots, \mathcal{T}^{-1}(\mathbf{u}_R)] \in \mathbb{C}^{S \times P} \tag{4-16}$$

式中, $\mathcal{T}$ 的逆运算 $\mathcal{T}^{-1}$ 为

$$\begin{aligned}
& \mathcal{T}^{-1} : \mathbf{U} \in \mathbb{C}^{S_1 \times S_2} \rightarrow \mathcal{T}^{-1}(\mathbf{U}) \in \mathbb{C}^{S_1 + S_2 - 1} \\
& [\mathcal{T}^{-1}(\mathbf{U})]_{k, l} = \frac{1}{i} \sum_{k+l-1=i} \mathbf{U}(k, l), \forall 1 \leq k \leq S_1, 1 \leq l \leq S_2
\end{aligned} \tag{4-17}$$

根据 $\mathcal{H}$ 和 $\mathcal{H}^{-1}$ 的定义, 可以看出

$$\mathcal{H}^{-1} \mathcal{H}(\mathbf{U}) = \mathbf{U} \in \mathbb{C}^{S \times P} \tag{4-18}$$

为减小误差影响, 利用最小二乘项替代线性约束项 $\mathcal{P}_{\Omega}(\tilde{\mathcal{R}}) = \mathcal{P}_{\Omega}(\llbracket \mathbf{U}^{(1)}, \mathbf{U}^{(2)}, \mathbf{U}^{(3)}, \mathbf{U}^{(4)} \rrbracket)$, 最后得到以下凸优化模型

$$\min_{\mathbf{U}^{(1)}, \mathbf{U}^{(2)}, \mathbf{A}^{(3)}, \mathbf{A}^{(4)}} \sum_{n=1}^2 \left\| \mathcal{H}(\mathbf{U}^{(n)}) \right\|_* + \sum_{n=3}^4 \left\| \mathcal{H}(\mathbf{U}^{(n-2)*} \mathbf{A}^{(n)}) \right\|_* + \frac{\lambda}{2} \left\| \mathcal{P}_{\Omega}(\tilde{\mathcal{R}}) - \mathcal{P}_{\Omega}(\left[\left[\mathbf{U}^{(1)}, \mathbf{U}^{(2)}, \mathbf{U}^{(1)*} \mathbf{A}^{(3)}, \mathbf{U}^{(2)*} \mathbf{A}^{(4)} \right] \right] \right\|_{\text{F}}^2 \quad (4-19)$$

式中, λ 为正则化参数。

4.2.2 重构模型的优化求解算法

研究表明 ADMM 算法在许多应用中可以有效地求解凸优化和非凸优化问题, 为求解(4-19), 引入辅助变量 $\{\mathbf{M}^{(n)}\}_{n=1}^4$, $\mathbf{M}^{(n)} = \mathcal{H}(\mathbf{U}^{(n)}), n=1, 2$; $\mathbf{M}^{(n)} = \mathcal{H}(\mathbf{U}^{(n-2)*} \mathbf{A}^{(n)}), n=3, 4$ 。问题(4-19)的等价形式可表示为

$$\min_{\mathbf{U}^{(1)}, \mathbf{U}^{(2)}, \mathbf{A}^{(3)}, \mathbf{A}^{(4)}} \sum_{n=1}^4 \left\| \mathbf{M}^{(n)} \right\|_* + \frac{\lambda}{2} \left\| \mathcal{P}_{\Omega}(\tilde{\mathcal{R}}) - \mathcal{P}_{\Omega}(\left[\left[\mathbf{U}^{(1)}, \mathbf{U}^{(2)}, \mathbf{U}^{(1)*} \mathbf{A}^{(3)}, \mathbf{U}^{(2)*} \mathbf{A}^{(4)} \right] \right] \right\|_{\text{F}}^2 \quad (4-20)$$

s.t. $\mathbf{M}^{(n)} = \mathcal{H}(\mathbf{U}^{(n)}), n=1, 2, \mathbf{M}^{(n)} = \mathcal{H}(\mathbf{U}^{(n-2)*} \mathbf{A}^{(n)}), n=3, 4$

为简洁表示, 给出以下定义 $\mathcal{U} = \{\mathbf{U}^{(1)}, \mathbf{U}^{(2)}\}$, $\Delta = \{\mathbf{A}^{(3)}, \mathbf{A}^{(4)}\}$, $\mathcal{M} = \{\mathbf{M}^{(1)}, \mathbf{M}^{(2)}, \mathbf{M}^{(3)}, \mathbf{M}^{(4)}\}$ 和 $\mathcal{D} = \{\mathbf{D}^{(1)}, \mathbf{D}^{(2)}, \mathbf{D}^{(3)}, \mathbf{D}^{(4)}\}$ 。

然后, 问题(4-20)的增广拉格朗日函数为

$$\begin{aligned} \mathcal{L}_{\beta}(\mathcal{U}, \Delta, \mathcal{M}, \mathcal{D}) = & \sum_{n=1}^2 \left(\left\| \mathbf{M}^{(n)} \right\|_* + \frac{\beta}{2} \left\| \mathcal{H}(\mathbf{U}^{(n)}) - \mathbf{M}^{(n)} \right\|_{\text{F}}^2 + \left\langle \mathbf{D}^{(n)}, \mathcal{H}(\mathbf{U}^{(n)}) - \mathbf{M}^{(n)} \right\rangle \right) \\ & + \sum_{n=3}^4 \left(\left\| \mathbf{M}^{(n)} \right\|_* + \frac{\beta}{2} \left\| \mathcal{H}(\mathbf{U}^{(n-2)*} \mathbf{A}^{(n)}) - \mathbf{M}^{(n)} \right\|_{\text{F}}^2 \right. \\ & \left. + \left\langle \mathbf{D}^{(n)}, \mathcal{H}(\mathbf{U}^{(n-2)*} \mathbf{A}^{(n)}) - \mathbf{M}^{(n)} \right\rangle \right) \\ & + \frac{\lambda}{2} \left\| \mathcal{P}_{\Omega}(\tilde{\mathcal{R}}) - \mathcal{P}_{\Omega}(\left[\left[\mathbf{U}^{(1)}, \mathbf{U}^{(2)}, \mathbf{U}^{(1)*} \mathbf{A}^{(3)}, \mathbf{U}^{(2)*} \mathbf{A}^{(4)} \right] \right] \right\|_{\text{F}}^2 \end{aligned} \quad (4-21)$$

式中, $\beta > 0$ 为惩罚因子; $\mathbf{D}^{(n)}$ 为拉格朗日乘子矩阵。采用 ADMM 迭代算法交替地优化每一个变量, 其迭代框架如下

(a) 更新 $\mathcal{U}$: 在第 k 次迭代中, 为更新变量 $\mathcal{U}$, 需求解以下优化问题

$$\min_{\mathcal{U}} \mathcal{L}_{\beta_k}(\mathcal{U}, \Delta_k, \mathcal{M}_k, \mathcal{D}_k) \quad (4-22)$$

通过固定其他变量, 将(4-22)转化为只与变量 $\mathbf{U}^{(n)}$ 有关的平滑凸优化问题

$$\min_{\mathbf{U}^{(n)}} \frac{\lambda}{2} \left\| \mathcal{P}_{\Omega^{(n)}}(\mathbf{R}_{(n)}) - \mathcal{P}_{\Omega^{(n)}}(\mathbf{U}^{(n)} \mathbf{P}_k^{(n)}) \right\|_{\text{F}}^2 + \frac{\beta_k}{2} \left\| \mathcal{H}(\mathbf{U}^{(n)}) - \mathbf{M}_k^{(n)} + \mathbf{D}_k^{(n)} / \beta_k \right\|_{\text{F}}^2 \quad (4-23)$$

$$+ \frac{\beta_k}{2} \left\| \mathcal{H}(\mathbf{U}^{(n)*} \Delta^{(n+2)}) - \mathbf{M}_k^{(n+2)} + \mathbf{D}_k^{(n+2)} / \beta_k \right\|_{\text{F}}^2, n=1, 2$$

式中, $\mathbf{P}_k^{(n)} = (\mathbf{U}_k^{(4)} \odot \cdots \odot \mathbf{U}_k^{(n+1)} \odot \mathbf{U}_k^{(n-1)} \odot \cdots \odot \mathbf{U}_k^{(1)})^T$, $\mathbf{R}_{(n)}$ 和 $\mathcal{P}_{\Omega^{(n)}}(\cdot)$ 分别表示张量 $\tilde{\mathcal{R}}$ 和 $\mathcal{P}_{\Omega}(\tilde{\mathcal{R}})$ 的模式- n 展开。因为(4-23)是一个矩阵最小二乘问题, 其解可被视为一个线性系统的解, 满足

$$\lambda \mathcal{P}_{\Omega^{(n)}}(\mathbf{U}^{(n)} \mathbf{P}_k^{(n)}) \mathbf{P}_k^{(n)\text{H}} + \beta_k \mathcal{H}^{-1} \mathcal{H}(\mathbf{U}^{(n)}) = \lambda \mathcal{P}_{\Omega^{(n)}}(\mathbf{R}_{(n)}) \mathbf{P}_k^{(n)\text{H}} + \beta_k \mathbf{B}_n \quad (4-24)$$

式中, $\mathbf{B}_n = \mathcal{H}^{-1}(\mathbf{M}_k^{(n)} - \mathbf{D}_k^{(n)} / \beta_k)$ 。此外, 本文可以求解得到 $\mathbf{U}^{(n)}$ 的每一行(即 $\{\mathbf{U}^{(n)}(i, :)\}_{i=1}^{I_n}$, 且 $n=1$ 时 $I_1 = M$; $n=2$ 时 $I_2 = N$) 的闭式解, 因此可以通过更新 $\mathbf{U}^{(n)}$ 的每一行 $\mathbf{U}^{(n)}(i, :)$ 以更新 $\mathbf{U}^{(n)}$ 。定义常数矩阵 $\mathbf{C} = \lambda \mathcal{P}_{\Omega^{(n)}}(\mathbf{R}_{(n)}) \mathbf{P}_k^{(n)\text{H}} + \beta_k \mathbf{B}_n$ 和 $\mathbf{W}_i = \text{diag}(\Omega^{(n)}(i, :))$, 问题(4-24)可被分解为一系列子问题

$$\lambda \mathbf{U}^{(n)}(i, :)\mathbf{P}_k^{(n)} \mathbf{W}_i \mathbf{P}_k^{(n)\text{H}} + \beta_k \mathbf{U}^{(n)}(i, :) = \mathbf{C}(i, :) \quad (4-25)$$

因此行向量 $\mathbf{U}^{(n)}(i, :)$ 的闭式解为

$$\mathbf{U}^{(n)}(i, :) = \mathbf{C}(i, :) \left[\lambda \mathbf{P}_k^{(n)} \mathbf{W}_i \mathbf{P}_k^{(n)\text{H}} + \beta_k \mathbf{I} \right]^{-1} \quad (4-26)$$

不难看出变量 $\mathbf{U}^{(n)}$ 的闭式解可以通过其所有行 $\{\mathbf{U}^{(n)}(i, :)\}_{i=1}^{I_n}$ 得到。

(b) 更新 Δ : 通过固定其他变量, 求解下列的优化问题更新变量 Δ

$$\min_{\Delta} \mathcal{L}_{\beta_k}(\mathcal{U}_{k+1}, \Delta, \mathcal{M}_k, \mathcal{D}_k) \quad (4-27)$$

其等价于以下凸优化问题

$$\min_{\Delta^{(n)}} \frac{\lambda}{2} \left\| \mathcal{P}_{\Omega^{(n)}}(\mathbf{R}_{(n)}) - \mathcal{P}_{\Omega^{(n)}}(\mathbf{U}_k^{(n-2)*} \Delta^{(n)} \mathbf{P}_k^{(n)}) \right\|_{\text{F}}^2 + \frac{\beta_k}{2} \left\| \mathcal{H}(\mathbf{U}_k^{(n-2)*} \Delta^{(n)}) - \mathbf{M}_k^{(n)} + \mathbf{D}_k^{(n)} / \beta_k \right\|_{\text{F}}^2, n=3, 4 \quad (4-28)$$

类似地, 变量 $\{\Delta^{(n)}\}_{n=3}^4$ 的闭式解满足

$$\lambda \mathcal{P}_{\Omega^{(n)}}(\mathbf{U}_k^{(n-2)*} \Delta^{(n)} \mathbf{P}_k^{(n)}) \mathbf{P}_k^{(n)\text{H}} + \beta_k \mathcal{H}^{-1} \mathcal{H}(\mathbf{U}_k^{(n-2)*} \Delta^{(n)}) = \lambda \mathcal{P}_{\Omega^{(n)}}(\mathbf{R}_{(n)}) \mathbf{P}_k^{(n)\text{H}} + \beta_k \mathbf{B}_n \quad (4-29)$$

通过分析 $\{\mathbf{U}_k^{(n-2)*}\}_{n=3}^4$ 每一行闭式解的形式, 问题(4-29)也可以分解为一系列子问题进行求解

$$\lambda \mathbf{U}_k^{(n-2)}(i,:)^\ast \mathbf{A}_i^{(n)} \mathbf{P}_k^{(n)} \mathbf{W}_i \mathbf{P}_k^{(n)H} + \beta_k \mathbf{U}_k^{(n-2)}(i,:)^\ast \mathbf{A}_i^{(n)} = \mathbf{C}(i,:) \quad (4-30)$$

式中, $\mathbf{A}_i^{(n)} \in \mathbb{C}^{P \times P}$ 表示在 $\mathbf{U}_k^{(n-2)}$ 第 i 行分解问题中的对角矩阵, 其中 $i=1, 2, \dots, I_n$ 且 $n=3$ 时,

$I_3 = M$; $n=4$ 时 $I_4 = N$ 。因此 $\mathbf{A}_i^{(n)}$ 的闭式解为

$$\mathbf{A}_i^{(n)} = \left(\mathbf{U}_k^{(n-2)}(i,:)^\ast \right)^\dagger \mathbf{C}(i,:) \left[\lambda \mathbf{P}_k^{(n)} \mathbf{W}_i \mathbf{P}_k^{(n)H} + \beta_k \mathbf{I} \right]^{-1} \quad (4-31)$$

式中, $(\cdot)^\dagger$ 为广义逆运算。

考虑到求解每个 $\mathbf{A}_i^{(n)}$ 产生的误差, 对 $\mathbf{A}_i^{(n)}$ 进行取平均操作得到 $\mathbf{A}^{(n)}$ 以减小估计误差

$$\mathbf{A}^{(n)} = \frac{1}{I_n} \sum_{i=1}^{I_n} \mathbf{A}_i^{(n)}, n=3, 4 \quad (4-32)$$

(c) 更新 $\mathcal{M}$: 通过求解优化问题(4-33)和(4-34)更新变量 $\{\mathbf{M}^{(n)}\}_{n=1}^4$

$$\min_{\mathbf{M}^{(n)}} \left\| \mathbf{M}^{(n)} \right\|_* + \frac{\beta_k}{2} \left\| \mathcal{H}(\mathbf{U}_{k+1}^{(n)}) - \mathbf{M}^{(n)} + \mathbf{D}_k^{(n)} / \beta_k \right\|_F^2, n=1, 2 \quad (4-33)$$

$$\min_{\mathbf{M}^{(n)}} \left\| \mathbf{M}^{(n)} \right\|_* + \frac{\beta_k}{2} \left\| \mathcal{H}(\mathbf{U}_{k+1}^{(n-2)*} \mathbf{A}_{k+1}^{(n)}) - \mathbf{M}^{(n)} + \mathbf{D}_k^{(n)} / \beta_k \right\|_F^2, n=3, 4 \quad (4-34)$$

利用 SVT 算法^[37]求解核范数最小化问题, 式(4-33)和(4-34)的优化问题的闭式解为

$$\mathbf{M}^{(n)} = \text{SVT}_{1/\beta_k} \left(\mathcal{H}(\mathbf{U}_{k+1}^{(n)}) + \mathbf{D}_k^{(n)} / \beta_k \right), n=1, 2 \quad (4-35)$$

$$\mathbf{M}^{(n)} = \text{SVT}_{1/\beta_k} \left(\mathcal{H}(\mathbf{U}_{k+1}^{(n-2)*} \mathbf{A}_{k+1}^{(n)}) + \mathbf{D}_k^{(n)} / \beta_k \right), n=3, 4 \quad (4-36)$$

(d) 更新 $\mathcal{D}$: 通过以下表达式更新变量 $\{\mathbf{D}^{(n)}\}_{n=1}^4$

$$\mathbf{D}_{k+1}^{(n)} = \mathbf{D}_k^{(n)} + \beta_k \left(\mathcal{H}(\mathbf{U}_{k+1}^{(n)}) - \mathbf{M}_{k+1}^{(n)} \right), n=1, 2 \quad (4-37)$$

$$\mathbf{D}_{k+1}^{(n)} = \mathbf{D}_k^{(n)} + \beta_k \left(\mathcal{H}(\mathbf{U}_{k+1}^{(n-2)*} \mathbf{A}_{k+1}^{(n)}) - \mathbf{M}_{k+1}^{(n)} \right), n=3, 4 \quad (4-38)$$

综上所述, 式(4-20)的完整求解算法在表 4-1 中总结。

表 4-1 本章算法的求解步骤

算法 2: ADMM 算法求解式(4-20)的优化模型

输入: 不完整协方差张量 $\tilde{\mathcal{R}} \in \mathbb{C}^{M \times N \times M \times N}$, 索引集 Ω 和参数 λ

1: 初始化 $\mathbf{U}^{(1)}, \mathbf{U}^{(2)}, \mathbf{U}^{(3)}, \mathbf{U}^{(4)}, k = \Delta R = 1, \beta_0 = 10^{-1}, \rho = 1.1$

while $k < 10^3$ **and** $\Delta \mathcal{R} < 10^{-6}$ **do**

2: 通过求解(4-26)更新 $\mathbf{U}^{(n)}, n=1, 2$;

3: 通过求解(4-32)更新 $\mathbf{A}^{(n)}, n=3, 4$;

4: 通过求解(4-35)和(4-36)更新 $\mathbf{M}^{(n)}, n=1, 2, 3, 4$;

5: 通过求解(4-37)和(4-38)更新 $\mathbf{D}^{(n)}, n=1, 2, 3, 4$;

```

6: 通过  $\beta_{k+1} = \rho\beta_k$  更新  $\beta$ ;
7:  $\mathcal{R} = \left[ \left[ \mathbf{U}^{(1)}, \mathbf{U}^{(2)}, \mathbf{U}^{(1)*} \mathbf{\Delta}^{(3)}, \mathbf{U}^{(2)*} \mathbf{\Delta}^{(4)} \right] \right]$ ;
8:  $\Delta\mathcal{R} = \|\mathcal{R} - \mathcal{R}_{\text{last}}\|_{\text{F}} / \|\mathcal{R}_{\text{last}}\|_{\text{F}}$ ;
9:  $\mathcal{R}_{\text{last}} \leftarrow \mathcal{R}$ ;
end while
输出: 重建结果  $\mathcal{R} = \left[ \left[ \mathbf{U}^{(1)}, \mathbf{U}^{(2)}, \mathbf{U}^{(1)*} \mathbf{\Delta}^{(3)}, \mathbf{U}^{(2)*} \mathbf{\Delta}^{(4)} \right] \right]$ 

```

当算法 2 达到收敛条件,可以得到完整的双基地 MIMO 雷达虚拟阵列协方差张量,然后采用 ESPRIT 算法估计目标的角度。

4.2.3 收敛性与复杂度分析

本文基于定理 1 和定理 2 来阐述算法 2 的收敛性,并证明所提算法解的可行性。

定理 1: 算法 2 中序列 $\{\mathcal{U}_k\}$ 和 $\{\Delta_k\}$ 为柯西序列。

定理 2: 对于所有 $n \in \{1, 2, 3, 4\}$, 若均有 $\lim_{k \rightarrow \infty} \|\mathbf{D}_{k+1}^{(n)} - \mathbf{D}_k^{(n)}\|_{\text{F}} = 0$ 成立, 那么序列 $\{\mathcal{U}_k\}$ 和 $\{\Delta_k\}$ 的极限满足问题(4-19)的 Karush Kuhn Tucker(KKT)条件。

定理 1 和定理 2 的证明在附录中给出。

本章算法(记为 Factor Priors Tensor Completion, FP-TC)的计算复杂度主要为公式(4-35) 和 (4-36) 中 SVD 运算, 其计算复杂度为 $\mathcal{O}\left(2K_1 \min\left(S_1^2 S_2 P + S_1 (S_2 P)^2\right) + 2K_1 \min\left(\tilde{S}_1^2 \tilde{S}_2 P + \tilde{S}_1 (\tilde{S}_2 P)^2\right)\right)$, 其中 K_1 为算法迭代次数, $S_1 + S_2 = M + 1$, $\tilde{S}_1 + \tilde{S}_2 = N + 1$ 。HMRTC(Hankel Matrix nuclear norm Regularized low-CP-rank Tensor Completion^[91]) 算法的计算复杂度为 $\mathcal{O}\left(2K_2 \min\left(S_1^2 S_2 P + S_1 (S_2 P)^2\right) + 2K_1 \min\left(\tilde{S}_1^2 \tilde{S}_2 P + \tilde{S}_1 (\tilde{S}_2 P)^2\right)\right)$, 其中 K_2 为迭代次数。FFH-MC 算法计算复杂度为 $\mathcal{O}\left(K_3 \left(\frac{M+1}{2}\right)^6 \left(\frac{N+1}{2}\right)^6\right)$, 其中 K_3 为迭代次数。

表 4-2 计算复杂度比较

方法	计算复杂度
FP-TC	$\mathcal{O}\left(2K_1 \min\left(S_1^2 S_2 P + S_1 (S_2 P)^2\right) + 2K_1 \min\left(\tilde{S}_1^2 \tilde{S}_2 P + \tilde{S}_1 (\tilde{S}_2 P)^2\right)\right)$
HMRTC	$\mathcal{O}\left(2K_2 \min\left(S_1^2 S_2 P + S_1 (S_2 P)^2\right) + 2K_1 \min\left(\tilde{S}_1^2 \tilde{S}_2 P + \tilde{S}_1 (\tilde{S}_2 P)^2\right)\right)$
FFH-MC	$\mathcal{O}\left(K_3 \left(\frac{M+1}{2}\right)^6 \left(\frac{N+1}{2}\right)^6\right)$

4.3 仿真与分析

在本节中，为对比各个方法的缺失数据重建性能，对FP-TC、FFH-MC和HMRTC算法重建的协方差矩阵均采用ESPRIT算法进行目标角度估计。受限于目前实测数据采集条件，本文仅能利用AWR1843雷达开发板的2个发射天线和4个接收天线进行目标水平角度测量，此时通过实测数据构造的协方差张量发射维度过小，导致利用实测数据验证本章所提FP-TC算法遭受限制，因此仅对本章所提FP-TC算法进行仿真实验验证。在下列仿真实验中，设置收发阵元数分别为 $M=7$ 和 $N=15$ 。假设有 $P=3$ 个远场目标，其角度分别为 $(\theta_1, \varphi_1) = (0^\circ, 10^\circ)$ ， $(\theta_2, \varphi_2) = (5^\circ, 20^\circ)$ ， $(\theta_3, \varphi_3) = (10^\circ, 30^\circ)$ 。第 m 个发射阵元发射的波形信号为 $\mathbf{w}_m = (1+j)/\sqrt{2} \mathbf{h}_m$ ，其中 $\mathbf{w}_m$ 为 $\mathbf{W}$ 的第 m 行； $\mathbf{h}_m$ 表示维度为 256×256 的Hadamard矩阵的第 m 行。信噪比定义为 $\text{SNR} = 10 \log_{10} \left(\frac{\|\mathbf{X}_q - \mathbf{Z}_q\|_F^2}{\|\mathbf{Z}_q\|_F^2} \right)$ 。目标角度均方根误差定义为 $\text{RMSE} = \sqrt{\frac{1}{2PM_T} \sum_{p=1}^P \sum_{i=1}^{M_T} \left\{ \left(\hat{\theta}_{p,i} - \theta_p \right)^2 + \left(\hat{\varphi}_{p,i} - \varphi_p \right)^2 \right\}}$ ，其中 M_T 为蒙特卡洛实验次数， $\hat{\theta}_{p,i}$ 和 $\hat{\varphi}_{p,i}$ 分别为第 p 个目标在第 i 次蒙特卡洛实验中的DOD和DOA估计值。

4.3.1 各算法目标角度估计星座图

设置 MIMO 雷达发射故障阵元位置集合为 $\Omega_T = [2, 5]$ ，接收故障阵元位置集合为 $\Omega_R = [1, 4, 7, 12, 14]$ ， $\text{SNR} = -5\text{dB}$ ，快拍数为 $Q = 100$ ， $M_T = 100$ 。图 4.3 中(a)、(b)和(c)分别为阵元失效时 ESPRIT 算法、HMRTC 算法和 FP-TC 算法的角度估计结果星座图。图中符号“*”为目标角度估计值，符号“+”表示目标角度真实值。由图 4.3(a)可知，在没有对失效阵元缺失数据进行补偿的情况下，直接采用 ESPRIT 算法无法有效地估计目标角度值；而 FP-TC 算法和 HMRTC 算法皆利用阵列数据的多维结构来重建失效阵元缺失数据，如图 4.3(b)所示，由于补偿了阵元缺失数据，HMRTC 算法在大多数蒙特卡洛试验中，可以正确地估计出目标的角度，但在某些试验中观测到不正确的目标角度结果，这是因为 HMRTC 算法在重构故障阵元缺失数据时仅利用了因子矩阵的 Vandermonde 结构，而忽略了因子矩阵之间的关系，导致在重建由失效阵元缺失数据时出现不稳定的情况。从图 4.3(c)可以看出，得益于所提出的 FP-TC 算法充分利用因子矩

阵的 Vandermonde 结构以及因子矩阵之间的潜在关联信息，所以 FP-TC 算法在所有试验中均能准确地估计目标角度。




图 4.3 阵元失效时目标角度估计星座图

4.3.2 算法收敛性曲线图

在本次实验中，对比了 FP-TC 算法和 HMRTC 算法在迭代次数方面的收敛性。图 4.4 展示了收敛速率与迭代次数的关系曲线图，仿真参数与实验 4.3.1 相同。纵坐标为残差值 $\Delta \mathcal{R} = \|\mathcal{R}^{k+1} - \mathcal{R}^k\|_F / \|\mathcal{R}^k\|_F$ ，表示为对数形式，其中 $\mathcal{R}^k$ 表示第 k 次迭代时重建的协方差张量。从图 4.4 可以看出，随着迭代次数的增加，FP-TC 算法的残差值相对变化下降的更快，并且迅速收敛，而 HMRTC 算法需要更多的迭代才能达到收敛。由于 HMRTC 算法对因子矩阵进行随机初始化，其收敛速度较慢；而 FP-TC 算法通过对原始不完整的协方差张量进行 CP 分解得到的因子矩阵作为初始值，可以加快收敛速度，且可以降低

重构误差。




图 4.4 FP-TC 算法和 HMRTC 算法收敛性比较

4.3.3 各算法 RMSE 随 SNR 变化关系

本次实验设置信噪比变化范围为 $-30\text{dB} \sim 10\text{dB}$ ，其中仿真参数与仿真实验 4.3.1 相同，由图 4.5 可知，当发射和接收阵列存在失效阵元时，直接采用 ESPRIT 算法估计出的目标角度误差较大。由于对失效阵元缺失数据的破坏性影响进行了补偿，FFH-MC 算法、HMRTC 算法以及 FP-TC 算法在估计目标角度时均具有良好的 RMSE 性能。特别是在低 SNR 区域，上述算法估计效果几乎与正常阵列情况下的 ESPRIT 算法相当。此外，FP-TC 算法在相对较高的 SNR 下明显优于 FFH-MC 和 HMRTC 方法。一方面，FFH-MC 算法采用矩阵填充方法恢复失效阵元缺失数据，但忽略了 MIMO 雷达阵列数据中的多维结构，因此在高 SNR 区域与 FP-TC 算法相比性能较差；虽然 HMRTC 方法通过张量填充方法来补偿缺失的元素，但由于忽略了因子矩阵之间的潜在信息，仍然会导致性能下降，而 FP-TC 算法将低 CP 秩和因子先验信息增加到张量填充方法中，因此提高了失效阵元缺失数据恢复的稳定性，从而具备更好的角度估计性能。




图 4.5 不同算法的 RMSE 随 SNR 变化的曲线图

4.3.4 各算法 RMSE 随快拍数变化关系

图 4.6 为各算法在不同快拍数下的 RMSE 曲线图，其仿真参数与仿真实验 4.3.1 中相同。随着快拍数的逐渐增加，各算法的 RMSE 性能均有所提高，但 FP-TC 算法明显优于 FFH-MC 算法，这表明 MIMO 雷达阵列数据多维结构对重建失效阵元缺失数据具有重要的作用。此外，由于在张量填充中增加了因子矩阵之间的潜在比例约束，因此提高了缺失数据恢复的稳定性，FP-TC 算法相较于 HMRTC 算法具有更好的角度估计性能。




图4.6 不同算法的RMSE随快拍数变化曲线图

4.3.5 各算法 RMSE 随失效阵元数变化关系

在本次实验中，对比了不同接收失效阵元数时的各算法 RMSE 性能，以下是两种阵元失效场景：

场景 1：设置发射阵列失效阵元位置为 $\{4\}$ ，随机失效接收阵元数从 1 至 8 递增，且每次独立实验随机选取失效阵元位置。

场景 2：设置发射阵列失效阵元位置为 $\{2,5\}$ ，接收阵列阵元失效情况与场景 1 相同，在每次实验中随机选取位置。

在上述两种阵元失效场景下，不同算法的 RMSE 随接收失效阵元数变化的曲线图如图 4.7(a)和 4.7(b)所示，其中， $\text{SNR} = -5\text{dB}$ ， $Q = 100$ ， $M_T = 100$ 。由图 4.7(a)和 4.7(b)可知，随着接收失效阵元数的增加，各算法的 RMSE 均有不同程度的恶化，但 FP-TC 算法在两种场景下均具有最优的 RMSE 性能。




图4.7 不同算法的RMSE随接收失效阵元数变化曲线图

4.3.6 各算法的运行时间

最后，通过对比不同算法的平均运行时间来评估不同算法的计算效率，实验参数与实验4.3.1中相同。仿真软件为MATLAB R2018a，CPU为Intel Core i5 4570 CPU，内存为8GB RAM。由表4-3可知，相较于FFH-MC算法和HMRTC算法，FP-TC算法的运行时间更短，且角度估计性能更优。

表4-3 不同算法的运行时间

算法	FP-TC	HMRTC	FFH-MC
运行时间/s	0.2243	0.8495	19.9486
RMSE/°	0.0447	0.2065	0.0830

4.4 本章小结

为补偿因阵元失效而带来的角度估计性能损失,本章提出了一种基于因子矩阵先验信息的失效阵元缺失数据恢复方法。首先此方法将双基地 MIMO 雷达接收信号构造为四阶协方差张量表示形式;然后基于协方差张量的 CP 分解模型,联合利用因子矩阵的 Vandermonde 结构以及因子矩阵之间的潜在信息,对由因子矩阵排列而成的块 Hankel 矩阵进行核范数约束,并建立具有因子矩阵先验约束的张量填充模型;最后,利用 ADMM 算法求解此优化模型,并提出 FP-TC 算法用于解决协方差张量缺失数据重建问题。仿真实验表明,所提 FP-TC 算法重建失效阵元缺失数据不仅具有较好的角度估计性能,而且具有较高的计算效率。

第五章 总结与展望

5.1 本文总结

由于人为干扰、恶劣天气和硬件限制等因素影响,实际应用中 MIMO 雷达阵列极易发生阵元失效而出现数据缺失的问题。当 MIMO 雷达虚拟阵列信号出现大量缺失数据时,现有角度估计算法性能会显著下降。为提高阵元失效时目标角度估计精度,研究如何重建阵列缺失数据,从而降低失效阵元造成的不利影响显得极其关键。

针对此问题,本文首先基于矩阵框架,利用低秩 Hankel 矩阵分解理论对协方差矩阵中结构性缺失数据进行重建;同时,为挖掘双基地 MIMO 雷达虚拟阵列数据的多维结构特征,通过利用张量 CP 分解和因子矩阵先验提出基于因子矩阵先验信息的失效阵元缺失数据恢复方法。本文的主要工作总结如下:

(1) 首先,通过奇异值分解提取了 MIMO 雷达协方差矩阵的低维矩阵因子;由于传统低秩矩阵填充算法在解决结构性缺失数据时易失效,本文将不完整矩阵因子重新排列为块 Hankel 矩阵,并基于核范数约束建立不完整矩阵因子重构模型;然后,为避免核范数最小化求解中计算复杂度高的问题,采用低秩矩阵拟合方法将块 Hankel 矩阵分解为两个较低维度的矩阵,等价表达了核范数约束;最后,基于 ADMM 算法设计了所提重构模型的优化求解算法。实验结果表明,该方法能够有效地填补协方差矩阵中的缺失数据,提升阵元失效时的角度估计性能。

(2) 为利用双基地 MIMO 雷达接收信号的多维张量结构,构建了阵元故障下虚拟阵列四阶协方差张量模型;为解决因失效阵元而导致的部分切片数据完全丢失的问题,本文基于张量 CP 分解模型,通过利用因子矩阵先验信息,并引入了核范数惩罚项和凸松弛约束建立协方差张量重构模型;然后,基于 ADMM 算法提出此重构模型的优化求解算法,并完成了所提算法的收敛性证明。仿真验证结果表明,本文所提的张量填充方法可以有效重建 MIMO 雷达协方差张量中缺失数据,从而缓解因失效阵元导致的角度估计性能恶化的影响,实现高精度的角度估计。

5.2 未来展望

本文主要研究双基地 MIMO 雷达中失效阵元缺失数据恢复问题，分别在矩阵和张量框架下提出了两种失效阵元缺失数据恢复算法，虽然目前已有部分阶段性成果，但仍存在一些待解决的问题尚待研究，后期的研究方面主要分为以下两个部分。

(1) 本文所处理的是理想高斯白噪声下的 MIMO 雷达阵列缺失数据恢复问题，但在实际应用中，非理想情况下色噪声、冲击噪声的存在会导致 MIMO 雷达参数估计性能下降，进一步降低了 MIMO 雷达失效阵元缺失数据恢复性能。因此，考虑适用于混合噪声模型下的 MIMO 雷达失效阵元缺失数据恢复方法值得进一步研究。

(2) 本文在第四章中为挖掘协方差张量的结构特性，对协方差张量进行 CP 分解估计因子矩阵，但在实际情况下，观测到的 MIMO 雷达协方差张量信号会受到噪声干扰，估计的因子矩阵与真实因子矩阵之间存在扰动。考虑到张量 CP 分解存在置换效应、缩放效应和拟合误差，且拟合误差与回波信号中的噪声能量大小直接相关，在仿真实验中，可以较为容易地在 MIMO 雷达接收到的目标信号中加入不同程度的噪声，但如何量化 CP 分解中拟合误差较为困难。为了便于分析因子矩阵先验信息，本文忽略了拟合误差项，可能会导致所提方法对噪声引起的角度估计性能下降问题缺乏鲁棒性，如何有效分析张量 CP 分解中的拟合误差项是一个值得研究的方向。

参考文献

- [1] Li J, Stoica P. MIMO radar with colocated antennas[J]. IEEE Signal Processing Magazine, 2007, 24(5): 106-114.
- [2] Haimovich A, Blum R, Cimini L. MIMO radar with widely separated antennas[J] IEEE Signal Processing Magazine, 2008, 25(1): 116-129.
- [3] Zhang H, Liu W, Zong B, et al. An efficient power allocation strategy for maneuvering target tracking in cognitive MIMO radar[J]. IEEE Transactions on Signal Processing, 2021, 69: 1591-1602.
- [4] Xi F, Xiang Y, Zhang Z, et al. Joint Angle and Doppler frequency estimation for MIMO radar with one-bit sampling: A maximum likelihood-based method[J]. IEEE Transactions on Aerospace and Electronic Systems, 2020, 56(6): 4734-4748.
- [5] Dontamsetti S, Kumar R. A distributed MIMO radar with joint optimal transmit and receive signal combining[J]. IEEE Transactions on Aerospace and Electronic Systems, 2020, 57(1): 623-635.
- [6] Yu Z, Li J, Guo Q, et al. Efficient direct target localization for distributed MIMO radar with expectation propagation and belief propagation[J]. IEEE Transactions on Signal Processing, 2021, 69: 4055-4068
- [7] Abtahi A, Azghani M, Marvasti F. An adaptive iterative thresholding algorithm for distributed MIMO Radars[J]. IEEE Transactions on Aerospace and Electronic Systems, 2019, 55(2): 523-533.
- [8] Gao X, Roy S, Xing G. MIMO-SAR: A hierarchical high-resolution imaging algorithm for mmwave FMCW radar in autonomous driving[J]. IEEE Transactions on Vehicular Technology, 2021, 70(8): 7322-7334.
- [9] Liu J, Zhou S, Liu W, et al. Tunable adaptive detection in colocated MIMO radar[J]. IEEE Transactions on Signal Processing, 2018, 66(4): 1080-1092.

- [10] Hang H, Liu W, Zong B, et al. An efficient power allocation strategy for maneuvering target tracking in cognitive MIMO radar[J]. IEEE Transactions on Signal Processing, 2021, 69: 1591-1602.
- [11] Li J, Zhang X, Cao R, et al. Reduced-dimension MUSIC for angle and array gain-phase error estimation in bistatic MIMO radar[J]. IEEE Communications Letters, 2013, 17(3): 443-446.
- [12] Chen Z, Chen B, Qin G. Angle estimation using ESPRIT in MIMO radar[J]. Electronics Letters, 2008, 44(12): 770-771.
- [13] Chen J, Gu H, Su W. Angle estimation using ESPRIT without pairing in MIMO radar[J]. Electronics Letters, 2008, 44(24): 1422-1423.
- [14] Luo S, Y Wang, Li J, et al. Coarray tensor-based angle estimation for bistatic MIMO radar with a dilated moving receive array[J]. IEEE Transactions on Aerospace and Electronic Systems, 2023, 59(6): 8995-9009.
- [15] Wen F, Shi J, Zhang Z. Joint 2D-DOD, 2D-DOA, and polarization angles estimation for bistatic EMVS-MIMO radar via PARAFAC analysis[J]. IEEE Transactions on Vehicular Technology, 2020, 69(2): 1626-1638.
- [16] Haardt M, Roemer F, Del Galdo G. Higher-Order SVD-Based subspace estimation to improve the parameter estimation accuracy in multidimensional harmonic retrieval problems[J]. IEEE Transactions on Signal Processing, 2008, 56(7): 3198-3213.
- [17] 杨东, 廖桂生, 朱圣棋, 等. 阵列信号降采样低秩矩阵的恢复方法[J]. 西安电子科技大学学报(自然科学版), 2014, 41(5): 30-35.
- [18] Acharya O, Patnaik A. Antenna array failure correction[J]. IEEE Antennas and Propagation Magazine, 2017, 59(6): 106-115.
- [19] Zardi F, Oliveri G, Salucci M, et al. Minimum-complexity failure correction in linear arrays via compressive processing[J]. IEEE Transactions on Antennas and Propagation, 2020, 69(8): 4504-4516.
- [20] Gao S, Ma H, Liu H, et al. DOD and DOA estimation from incomplete data based on PARAFAC and atomic norm minimization method[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-14.

- [21] Jalal B, Elnahas O, Quan Z. Efficient DOA estimation under partially impaired antenna array elements[J]. IEEE Transactions on Vehicular Technology, 2022, 71(7): 7991-7996.
- [22] Liu C, Vaidyanathan P. Robustness of difference coarrays of sparse arrays to sensor failures—Part I: a theory motivated by coarray MUSIC[J]. IEEE Transactions on Signal Processing, 2019, 67(12): 3213-3226.
- [23] Liu C, Vaidyanathan P. Robustness of difference coarrays of sparse arrays to sensor failures—Part II: array geometries[J]. IEEE Transactions on Signal Processing, 2019, 67(12): 3227-3242.
- [24] Liu C, Vaidyanathan P. Novel algorithms for analyzing the robustness of difference coarrays to sensor failures[J]. Signal Processing, 2020, 171(107517).
- [25] Yeo B, Lu Y. Array failure correction with a genetic algorithm[J]. IEEE Transactions on Antennas and Propagation, 1999, 47(5): 823-828.
- [26] 孙兵, 吴晨曦, 阮怀林, 等. 阵元失效条件下的高精度 DOA 估计方法[J]. 电子学报, 2020, 48(9): 1688-1694.
- [27] 盘敏容, 蒋留兵, 车俐, 等. 基于协方差矩阵重构的互质阵列 DOA 估计[J]. 雷达科学与技术, 2020, 18(1): 1-6.
- [28] Huang Y, Zhao J, Wang Z, et al. Exponential signal reconstruction with deep Hankel matrix factorization[J]. IEEE Transactions on Neural Networks and Learning Systems, 2023, 34(9): 6214-6226.
- [29] Nion D, Sidiropoulos N. Tensor algebra and multidimensional harmonic retrieval in signal processing for MIMO Radar[J]. IEEE Transactions on Signal Processing, 2010, 58(11): 693-5705, Nov. 2010.
- [30] Tropp J, Laska J, Duarte M, et al. Beyond Nyquist: efficient sampling of sparse bandlimited signals[J]. IEEE Transactions on Information Theory, 2010, 56(1): 520-544.
- [31] Chi Y, Chen Y. Compressive two-dimensional harmonic retrieval via atomic norm minimization[J]. IEEE Transactions on Signal Processing, 2015, 63(4): 1030-1042.
- [32] Liu Y, Zhan Z, Cai J, et al. Projected iterative soft-thresholding algorithm for tight frames in compressed sensing magnetic resonance imaging[J]. IEEE Transactions on Medical Imaging, 2016, 35(9): 2130-2140.

- [33] Zha Z, Wen B, Yuan X, et al. Learning nonlocal sparse and low-rank models for image compressive sensing: nonlocal sparse and low-rank modeling[J]. IEEE Signal Processing Magazine, 2023, 40(1): 32-44.
- [34] Yen C, Tsai Y, Wang X. Wideband spectrum sensing based on sub-Nyquist sampling[J]. IEEE Transactions on Signal Processing, 2013, 61(12): 3028-3040.
- [35] Candes E, Tao T. The power of convex relaxation: near-optimal matrix completion[J]. IEEE Transactions on Information Theory, 2010, 56(5): 2053-2080.
- [36] Cande E, Recht B. Exact matrix completion via convex optimization[J]. Journal of the ACM(JACM), 2012, 58(3): 11:1-11:37.
- [37] Cai J, Candes E, Shen Z. A singular value thresholding algorithm for matrix completion[J]. SIAM Journal on Optimization, 2010, 20(4): 1956–1982.
- [38] Qu X, Mayzel M, Cai J, et al. Accelerated NMR spectroscopy with low-rank reconstruction[J]. Angewandte Chemie International Edition, 2015, 54(3): 852-854.
- [39] Zhang X, Lu H, Guo D, et al. Accelerated MRI reconstruction with separable and enhanced low-rank Hankel regularization[J]. IEEE Transactions on Medical Imaging, 2022, 41(9): 2486-2498.
- [40] Qiu T, Liao W, Huang Y, et al. An automatic denoising method for NMR spectroscopy based on low-rank Hankel model[J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-12.
- [41] Liu Z, Wu J, Yang J. Recovery of SAR missing data via structured matrix and augmented lagrangian multiplier[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-15.
- [42] Chen Y, Chi Y. Robust spectral compressed sensing via structured matrix completion[J]. IEEE Transactions on Information Theory, 2014, 60(10): 6576-6601.
- [43] Wu X, Yang Z, Stoica P, et al. Maximum likelihood line spectral estimation in the signal domain: A rank-constrained structured matrix recovery approach[J]. IEEE Transactions on Signal Processing, 2022, 70: 4156-4169.

- [44] Usevich K, Comon P. Hankel low-rank matrix completion: performance of the nuclear norm relaxation[J]. IEEE Journal of Selected Topics in Signal Processing, 2016, 10(4): 637-646.
- [45] Wu X, Yang Z, Z. Xu. Multichannel frequency estimation in challenging scenarios via structured matrix embedding and recovery(StruMER)[J]. IEEE Transactions on Signal Processing, 2023, 71: 3242-3256.
- [46] Xu G, Zhang B, Chen J, et al. Structured low-rank and sparse method for ISAR imaging with 2-D compressive sampling[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-14.
- [47] 应佳熙. 复指数信号重建及其在核磁共振波谱中的应用[D]. 厦门大学, 2017.
- [48] Hitchcock F. The expression of a tensor or a polyadic as a sum of products[J]. Studies in Applied Mathematics, 1927, 6(1-4): 164-189.
- [49] Zhao Q, Zhang L, Cichocki A. Bayesian CP factorization of incomplete tensors with automatic rank determination[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(9): 1751-1763.
- [50] Liu Y, Shang F, Jiao L, et al. Trace norm regularized CANDECOMP/PARAFAC decomposition with missing data[J]. IEEE Transactions on Cybernetics, 2015, 45(11): 2437-2448.
- [51] Kolda T, Bader B. Tensor decompositions and applications[J]. SIAM review, 2009, 51(3): 455-500.
- [52] Liu J, Musialski P, Wonka P. Tensor completion for estimating missing values in visual Data[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2013, 35(1): 208-220.
- [53] Bengua J, Phien H, Tuan H, et al. Efficient tensor completion for color image and video recovery: low-rank tensor train[J]. IEEE Transactions on Image Processing, 2017, 26(5): 2466-2479.
- [54] Ko C, Batselier K, Daniel L et al. Fast and accurate tensor completion with total variation regularized tensor trains. IEEE Transactions on Image Processing, 2020, 29: 6918-6931.

- [55] Li X, So H. Robust Low-rank tensor completion based on tensor ring rank via $\ell_{p,\varepsilon}$ -norm[J]. IEEE Transactions on Signal Processing, 2021, 69: 685-3698.
- [56] Zhou P, Lu C, Lin Z, et al. Tensor factorization for low-rank tensor completion[J]. IEEE Transactions on Image Processing, 2018, 27(3): 1152-1163.
- [57] Zhang Z, Ely G, Aeron S, et al. Novel methods for multilinear data completion and denoising based on tensor-SVD[C]// 2014 IEEE Conference on Computer Vision and Pattern Recognition, Columbus, OH, USA, 2014: 3842-3849.
- [58] Wu F, Li Y, Li C, et al. A fast tensor completion method based on tensor QR decomposition and tensor nuclear norm minimization[J]. IEEE Transactions on Computational Imaging, 2021, 7: 1267-1277.
- [59] Ahn C. Parallel detection algorithm using multiple QR decompositions with permuted channel matrix for SDM/OFDM[J]. IEEE Transactions on Vehicular Technology, 2008, 57(4): 2578-2582.
- [60] Yang D, Liao G, Zhu S, et al. SAR imaging with undersampled data via matrix completion[J]. IEEE Geoscience & Remote Sensing Letters, 2014, 11(9): 1539-1543.
- [61] Sun S, Bajwa W, Petropulu A. MIMO-MC radar: A MIMO radar approach based on matrix completion[J]. IEEE Transactions on Aerospace and Electronic Systems, 2015, 51(3): 1839-1852.
- [62] Yerriswamy T, Jagadeesha S. Fault tolerant matrix pencil method for direction of arrival estimation[J]. International Journal of Signal and image processing, 2011, 2(3): 55-67.
- [63] Weng Z, Wang X. Low-rank matrix completion for array signal processing[C]//IEEE International Conference on Acoustics, Speech and Signal Processing(ICASSP), 2012: 2697-2700.
- [64] Yang J, Yang X, Ye X, et al. Reconstruction of structurally-incomplete matrices with reweighted low-rank and sparsity priors[J]. IEEE Transactions on Image Processing, 2017, 26(3): 1158-1172.
- [65] Qiu W, Zhou J, Fu Q. Jointly using low-rank and sparsity priors for sparse inverse synthetic aperture radar imaging[J]. IEEE Transactions on Image Processing, 2020, 29(1): 100-115.

- [66] 方启林. 基于矩阵填充理论的阵元缺失数据的恢复[D]. 中国科学技术大学, 2020.
- [67] Ji Y, Wen C, Yan H, et al. Robust direction-of-arrival estimation approach using beamspace-based deep neural networks with array imperfections and element failure[J]. IET Radar, Sonar & Navigation, 2022, 16(11): 1761-1778.
- [68] Zhu C, Wang W, Chen H, et al. Impaired sensor diagnosis, beamforming and DOA estimation with difference co-array processing[J]. IEEE Sensors Journal, 2015, 15(7): 3773–3780.
- [69] Zhang W, Vorobyov A, Guo L. DOA estimation in MIMO radar with broken sensors by difference co-array processing[C]//2015 IEEE 6th International Workshop on Computational Advances in Multi-Sensor Adaptive Processing(CAMSAP), 2015: 321–324.
- [70] Chen J, Zhang T, Li J, et al. Joint sensor failure detection and corrupted covariance matrix recovery in bistatic MIMO radar with impaired arrays[J]. IEEE Sensors Journal, 2019, 19(14): 5834-5842.
- [71] Zhou C, Gu Y, He S, et al. A robust and efficient algorithm for coprime array adaptive beamforming[J]. IEEE Transactions on Vehicular Technology, 2017, 67(2): 1099-1112.
- [72] Zheng H, Zhou C, Shi Z, et al. Coarray tensor direction-of-arrival estimation[J]. IEEE Transactions on Signal Processing, 2023, 71: 1128-1142.
- [73] Zhou C, Gu Y, Fan X, et al. Direction-of-arrival estimation for coprime array via virtual array interpolation[J]. IEEE Transactions on Signal Processing, 2018, 66(22): 5956-5971.
- [74] Zheng H, Shi Z, Zhou C, et al. Coarray tensor completion for DOA estimation[J]. IEEE Transactions on Aerospace and Electronic Systems, 2023, 59(5): 5472-5486.
- [75] Xu F, Vorobyov S, Yang X. Joint DOD and DOA estimation in slow-time MIMO radar via PARAFAC decomposition[J]. IEEE Signal Processing Letters, 2020, 27: 1495-1499.
- [76] Cao M, Vorobyov S, Hassanien A. A interpolation for DOA estimation via tensor decomposition in 2-D MIMO radar[J]. IEEE Transactions on Signal Processing, 2017, 65(19): 5225-5239.
- [77] Xu B, Zhao Y, Cheng Z, et al. A novel unitary PARAFAC method for DOD and DOA estimation in bistatic MIMO radar[J]. Signal Processing, 2017, 138: 273-279.

- [78] Liu J, De Almeida A, So H. Target estimation in bistatic MIMO radar via tensor completion[J]. Signal Processing, 2016, 120: 654-659.
- [79] Candes E, Plan Y. Matrix completion with noise[J]. Proceedings of the IEEE, 2010, 98(6): 925-936.
- [80] Oseledets V. Tensor-train decomposition[J]. SIAM Journal on Scientific Computing, 2011, 33(5): 2295-2317.
- [81] Liu D, Sacchi M, Chen W. Efficient tensor completion methods for 5-D seismic data reconstruction: Low-rank tensor train and tensor ring[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-17.
- [82] Kisil I, Calvi G, Konstantinidis K, et al. Accelerating tensor contraction products via tensor-train decomposition[J]. IEEE Signal Processing Magazine, 2022, 39(5): 63-70.
- [83] Gillis N, Francois G. Accelerated multiplicative updates and hierarchical als algorithms for convex constraints[J]. Operation Research Letters, 2000, 26(3): 127-136.
- [84] Leurgans S, Ross R, Abel R. A decomposition for three-way arrays[J]. SIAM Journal on Matrix Analysis and Applications, 1993, 14: 1064-1083.
- [85] Cai C, Wen F, Huang D. New approach to angle estimation for bistatic MIMO radar with unknown spatially colored noise[J]. IEEE Access, 2018, 6: 24249-24255.
- [86] Xiong W, Cheng G, Schindelhauer C, et al. Robust matrix completion for elliptic positioning in the presence of outliers and missing Data[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-12.
- [87] Wang J, Ding M, Yarovoy A. Interference mitigation for FMCW radar with sparse and low-rank hankel matrix decomposition[J]. IEEE Transactions on Signal Processing, 2022, 70: 822-834.
- [88] Xu G, Zhang B, J Chen, et al. Sparse inverse synthetic aperture radar imaging using structured low-rank method[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-12.
- [89] Jiang T, Sidiropoulos N. Kruskal's permutation lemma and the identification of CANDECOMP/PARAFAC and bilinear models with constant modulus constraints[J]. IEEE Transactions on Signal Processing, 2004, 52(9): 2625-2636.

- [90] Zhou Z, Fang J, Yang L, et al. Low-rank tensor decomposition-aided channel estimation for millimeter wave MIMO-OFDM systems[J]. IEEE Journal on Selected Areas in Communications, 2017, 35(7): 1524-1538.
- [91] Ying J, Lu H, Wei Q, et al. Hankel matrix nuclear norm regularized tensor completion for N -dimensional exponential signals[J]. IEEE Transactions on Signal Processing, 2017, 65(14): 3702-3717.
- [92] Yang J, Zhu Y, Li K, et al. Tensor completion from structurally-missing entries by low-TT-rankness and fiber-wise sparsity[J]. IEEE Journal of Selected Topics in Signal Processing, 2018, 12(6): 1420-1434.
- [93] Texas Instruments. AWR1843 单芯片 76 至 81GHz 毫米波传感器数据表[EB/OL]. (2018-12-27) [2023-2-30]. <https://www.ti.com.cn/cn/lit/ds/symlink/awr1843.pdf>.
- [94] 陈思翔, 张云华, 杨杰芳. 一种 TDM-MIMO FMCW 车载毫米波雷达目标检测方法[J]. 遥感技术与应用, 2021, 36(4): 803-809.
- [95] 黄以兰. 车载毫米波雷达前视成像方法及系统设计[D]. 桂林电子科技大学, 2021.
- [96] Yokota T, Zhao Q, Cichocki A. Smooth PARAFAC decomposition for tensor completion[J]. IEEE Transactions on Signal Processing, 2016, 64(20): 5423-5436.
- [97] Narita A, Hayashi K, Tomioka R, et al. Tensor factorization using auxiliary information[J]. Data Mining and Knowledge Discovery, 2012, 25(2): 298-324.

附录 算法 2 收敛性证明

1 第四章定理 1 证明

在证明定理 1 和定理 2 之前, 首先证明算法 2 中一些变量是有界的, 然后分析整体算法的收敛性。在证明有界性之前, 先介绍以下引理。

引理 1^[50,91]: 设 $\mathcal{F}$ 为希尔伯特空间, 并由内积 $\langle \cdot, \cdot \rangle$ 导出范数 $\|\cdot\|$ 。 $y \in \partial\|\mathbf{x}\|$, $\partial\|\cdot\|$ 表示次梯度。若 $\mathbf{x} \neq \mathbf{0}$, 则 $\|\mathbf{y}\|^* = 1$; 若 $\mathbf{x} = \mathbf{0}$, 则 $\|\mathbf{y}\|^* \leq 1$, 其中 $\|\cdot\|^*$ 为 $\|\cdot\|$ 的对偶范数。

引理 2: 序列 $\{\mathbf{D}_k^{(n)}\}_{n=1}^4$ 是有界的。

证明: 根据问题(4-33)和(4-34)关于变量 $\mathbf{M}_{k+1}^{(n)}$ 的最优化条件, 可得

$$\begin{aligned} 0 &\in \partial\|\mathbf{M}_{k+1}^{(n)}\|_* - \mathbf{D}_k^{(n)} - \beta_k \left(\mathcal{H}(\mathbf{U}_k^{(n)}) - \mathbf{M}_{k+1}^{(n)} \right), n=1, 2 \\ 0 &\in \partial\|\mathbf{M}_{k+1}^{(n)}\|_* - \mathbf{D}_k^{(n)} - \beta_k \left(\mathcal{H}(\mathbf{U}_k^{(n-2)*} \mathbf{A}_k^{(n)}) - \mathbf{M}_{k+1}^{(n)} \right), n=3, 4 \end{aligned}$$

通过联合

$$\begin{aligned} \mathbf{D}_{k+1}^{(n)} &= \mathbf{D}_k^{(n)} + \beta_k \left(\mathcal{H}(\mathbf{U}_{k+1}^{(n)}) - \mathbf{M}_{k+1}^{(n)} \right), n=1, 2 \\ \mathbf{D}_{k+1}^{(n)} &= \mathbf{D}_k^{(n)} + \beta_k \left(\mathcal{H}(\mathbf{U}_k^{(n-2)*} \mathbf{A}_{k+1}^{(n)}) - \mathbf{M}_{k+1}^{(n)} \right), n=3, 4 \end{aligned}$$

可以自然地得到

$$\mathbf{D}_{k+1}^{(n)} \in \partial\|\mathbf{M}_{k+1}^{(n)}\|_*, n=1, 2, 3, 4$$

由引理 1 和文献[37]可知, 在谱范数中, 核范数的次梯度中每一个元素均以 1 为界。

因此, 可以进一步推导出 $\|\mathbf{D}_{k+1}^{(n)}\|_2 \leq 1$, 且序列 $\{\mathbf{D}_k^{(n)}\}_{n=1}^4$ 是有界的。

引理 3: 序列 $\{\mathbf{U}_k^{(n)}\}_{n=1}^2$ 、 $\{\mathbf{A}_k^{(n)}\}_{n=3}^4$ 及 $\{\mathbf{M}_k^{(n)}\}_{n=1}^4$ 是有界的。

证明: 根据算法迭代框架, 可以得出

$$\begin{aligned}
& \mathcal{L}_{\beta_k}(\mathcal{U}_{k+1}, \Delta_{k+1}, \mathcal{M}_{k+1}, \mathcal{D}_k) \leq \mathcal{L}_{\beta_k}(\mathcal{U}_k, \Delta_k, \mathcal{M}_k, \mathcal{D}_k) \\
& = \sum_{n=1}^2 \left(\left\langle \mathbf{D}_k^{(n)} - \mathbf{D}_{k-1}^{(n)}, \mathcal{H}(\mathbf{U}_k^{(n)}) - \mathbf{M}_k^{(n)} \right\rangle + \frac{\beta_k - \beta_{k-1}}{2} \left\| \mathcal{H}(\mathbf{U}_k^{(n)}) - \mathbf{M}_k^{(n)} \right\|_F^2 \right) \\
& + \sum_{n=3}^4 \left(\left\langle \mathbf{D}_k^{(n)} - \mathbf{D}_{k-1}^{(n)}, \mathcal{H}(\mathbf{U}_k^{(n-2)*} \mathbf{A}_k^{(n)}) - \mathbf{M}_k^{(n)} \right\rangle + \frac{\beta_k - \beta_{k-1}}{2} \left\| \mathcal{H}(\mathbf{U}_k^{(n-2)*} \mathbf{A}_k^{(n)}) - \mathbf{M}_k^{(n)} \right\|_F^2 \right) \\
& + \mathcal{L}_{\beta_{k-1}}(\mathcal{U}_k, \Delta_k, \mathcal{M}_k, \mathcal{D}_{k-1}) \\
& = \sum_{n=1}^4 \left(\frac{1}{\beta_{k-1}} \left\| \mathbf{D}_k^{(n)} - \mathbf{D}_{k-1}^{(n)} \right\|_F^2 + \frac{\beta_k - \beta_{k-1}}{2\beta_{k-1}^2} \left\| \mathbf{D}_k^{(n)} - \mathbf{D}_{k-1}^{(n)} \right\|_F^2 \right) + \mathcal{L}_{\beta_{k-1}}(\mathcal{U}_k, \Delta_k, \mathcal{M}_k, \mathcal{D}_{k-1}) \\
& = \frac{\beta_k + \beta_{k-1}}{2\beta_{k-1}^2} \sum_{n=1}^4 \left\| \mathbf{D}_k^{(n)} - \mathbf{D}_{k-1}^{(n)} \right\|_F^2 + \mathcal{L}_{\beta_{k-1}}(\mathcal{U}_k, \Delta_k, \mathcal{M}_k, \mathcal{D}_{k-1})
\end{aligned}$$

由于引理 2 中已证序列 $\{\mathbf{D}_k^{(n)}\}_{n=1}^4$ 有界, 因此 $\mathcal{L}_{\beta_{k-1}}(\mathcal{U}_k, \Delta_k, \mathcal{M}_k, \mathcal{D}_{k-1})$ 是有上界的。而且

$$\sum_{k=1}^{\infty} \frac{\beta_k + \beta_{k-1}}{2\beta_{k-1}^2} = \frac{\rho(\rho+1)}{2\beta_0(\rho-1)} < \infty$$

式中, $\rho \in (1.0, 1.1]$ 。结合公式

$$\begin{aligned}
& \sum_{n=1}^4 \left\| \mathbf{M}_k^{(n)} \right\|_* + \frac{\lambda}{2} \left\| \mathcal{P}_{\Omega}(\tilde{\mathcal{R}}) - \mathcal{P}_{\Omega}(\left\| \mathbf{U}_k^{(1)}, \mathbf{U}_k^{(2)}, \mathbf{U}_k^{(1)*} \mathbf{A}_k^{(3)}, \mathbf{U}_k^{(2)*} \mathbf{A}_k^{(4)} \right\|) \right\|_F^2 \\
& = \mathcal{L}_{\beta_{k-1}}(\mathcal{U}_k, \Delta_k, \mathcal{M}_k, \mathcal{D}_{k-1}) - \frac{1}{2\beta_{k-1}} \sum_{n=1}^4 \left(\left\| \mathbf{D}_k^{(n)} - \mathbf{D}_{k-1}^{(n)} \right\|_F^2 + 2 \left\langle \mathbf{D}_{k-1}^{(n)}, \mathbf{D}_k^{(n)} - \mathbf{D}_{k-1}^{(n)} \right\rangle \right)
\end{aligned}$$

是具有上界的, 可以得到序列 $\{\mathbf{M}_k^{(n)}\}_{n=1}^4$ 有界。根据等式

$$\mathcal{H}(\mathbf{U}_{k+1}^{(n)}) = \mathbf{M}_{k+1}^{(n)} + (\mathbf{D}_{k+1}^{(n)} - \mathbf{D}_k^{(n)}) / \beta_k \quad (n=1, 2)$$

$$\mathcal{H}(\mathbf{U}_{k+1}^{(n-2)*} \mathbf{A}_{k+1}^{(n)}) = \mathbf{M}_{k+1}^{(n)} + (\mathbf{D}_{k+1}^{(n)} - \mathbf{D}_k^{(n)}) / \beta_k \quad (n=3, 4)$$

可知, 序列 $\{\mathbf{U}_k^{(n)}\}_{n=1}^2$ 和 $\{\mathbf{A}_k^{(n)}\}_{n=3}^4$ 均有界。

基于上述引理, 接下来证明定理 1:

根据等式 $\mathbf{D}_{k+1}^{(n)} = \mathbf{D}_k^{(n)} + \beta_k (\mathcal{H}(\mathbf{U}_{k+1}^{(n)}) - \mathbf{M}_{k+1}^{(n)}), n=1, 2$ 与 $\mathbf{D}_{k+1}^{(n)} = \mathbf{D}_k^{(n)} + \beta_k (\mathcal{H}(\mathbf{U}_{k+1}^{(n-2)*} \mathbf{A}_{k+1}^{(n)}) - \mathbf{M}_{k+1}^{(n)}), n=3, 4$, 序列 $\{\mathbf{D}_k^{(n)}\}_{n=1}^4$ 的有界性以及 $\lim_{k \rightarrow \infty} \beta_k = \infty$, 可以得到

$$\lim_{k \rightarrow \infty} \left\| \mathcal{H}(\mathbf{U}_{k+1}^{(n)}) - \mathbf{M}_{k+1}^{(n)} \right\|_F = 0, n=1, 2$$

$$\lim_{k \rightarrow \infty} \left\| \mathcal{H}(\mathbf{U}_{k+1}^{(n-2)*} \mathbf{A}_{k+1}^{(n)}) - \mathbf{M}_{k+1}^{(n)} \right\|_F = 0, n=3, 4$$

因此, $\{\mathcal{U}_k, \Delta_k, \mathcal{M}_k\}$ 趋于一个可行性解

此外, 结合式 $\mathbf{D}_k^{(n)} = \mathbf{D}_{k-1}^{(n)} + \beta_{k-1} \left(\mathcal{H}(\mathbf{U}_k^{(n)}) - \mathbf{M}_k^{(n)} \right), n=1, 2$ 和式(4-24), 易得

$$\begin{aligned} \beta_k \mathcal{H}^{-1} \mathcal{H}(\mathbf{U}_{k+1}^{(n)} - \mathbf{U}_k^{(n)}) &= \lambda \mathcal{P}_{\Omega^{(n)}}(\mathbf{R}_{(n)}) \mathbf{P}_k^{(n)H} - \lambda \mathcal{P}_{\Omega^{(n)}}(\mathbf{U}_{k+1}^{(n)} \mathbf{P}_k^{(n)}) \mathbf{P}_k^{(n)H} \\ &\quad + \beta_k \mathcal{H}^{-1} \left(\mathbf{M}_k^{(n)} - \mathbf{D}_k^{(n)} / \beta_k - \mathcal{H}(\mathbf{U}_k^{(n)}) \right) \\ &= \lambda \mathcal{P}_{\Omega^{(n)}}(\mathbf{R}_{(n)}) \mathbf{P}_k^{(n)H} - \lambda \mathcal{P}_{\Omega^{(n)}}(\mathbf{U}_{k+1}^{(n)} \mathbf{P}_k^{(n)}) \mathbf{P}_k^{(n)H} \\ &\quad - \mathcal{H}^{-1} \left((\rho+1) \mathbf{D}_k^{(n)} - \rho \mathbf{D}_{k-1}^{(n)} \right), (n=1, 2) \end{aligned}$$

结合式(4-18), 可以得到

$$\mathbf{U}_{k+1}^{(n)} - \mathbf{U}_k^{(n)} = \frac{1}{\beta_k} \left(\lambda \mathcal{P}_{\Omega^{(n)}}(\mathbf{R}_{(n)}) \mathbf{P}_k^{(n)H} - \lambda \mathcal{P}_{\Omega^{(n)}}(\mathbf{U}_{k+1}^{(n)} \mathbf{P}_k^{(n)}) \mathbf{P}_k^{(n)H} - \mathcal{H}^{-1} \left((\rho+1) \mathbf{D}_k^{(n)} - \rho \mathbf{D}_{k-1}^{(n)} \right) \right) = \frac{\mathbf{L}_k}{\beta_k}$$

由于 $\mathbf{L}_k$ 有上界, 所以有 $\|\mathbf{U}_{k+1}^{(n)} - \mathbf{U}_k^{(n)}\|_F = O((\beta_k)^{-1})$, 进而可以推出

$$\begin{aligned} \|\mathbf{U}_m^{(n)} - \mathbf{U}_k^{(n)}\|_F &\leq \|\mathbf{U}_m^{(n)} - \mathbf{U}_{m-1}^{(n)}\|_F + \|\mathbf{U}_{m-1}^{(n)} - \mathbf{U}_{m-2}^{(n)}\|_F \\ &\quad + \cdots + \|\mathbf{U}_{k+1}^{(n)} - \mathbf{U}_k^{(n)}\|_F \\ &= \|\mathbf{L}_{m-1}\|_F / \beta_{m-1} + \|\mathbf{L}_{m-2}\|_F / \beta_{m-2} + \cdots + \|\mathbf{L}_k\|_F / \beta_k \\ &\leq \frac{\delta}{\beta_k} \left(\frac{1}{\rho_{m-k-1}} + \frac{1}{\rho_{m-k-2}} + \cdots + 1 \right) < \frac{\delta \rho}{\beta_k (1-\rho)} \end{aligned}$$

式中, $\delta = \max \{\|\mathbf{L}_{m-1}\|_F, \|\mathbf{L}_{m-2}\|_F, \cdots, \|\mathbf{L}_k\|_F\}$ 。因为 $\frac{\delta \rho}{\beta_k (1-\rho)} \rightarrow 0$, 所以 $\{\mathbf{U}_k^{(n)}\}_{n=1}^2$ 为柯西序列,

即序列 $\{\mathbf{U}_k\}$ 为柯西序列。

下面开始序列 $\{\Delta_k\}$ 的证明, 根据公式

$\mathbf{D}_k^{(n)} = \mathbf{D}_{k-1}^{(n)} + \beta_{k-1} \left(\mathcal{H}(\mathbf{U}_k^{(n-2)*} \Delta_k^{(n)}) - \mathbf{M}_k^{(n)} \right), n=3, 4$ 和式(4-29), 可以得到

$$\begin{aligned} \beta_k \mathcal{H}^{-1} \mathcal{H}(\Delta_{k+1}^{(n)} - \Delta_k^{(n)}) &= \lambda \left(\mathbf{U}_{k+1}^{(n-2)*} \right)^\dagger \mathcal{P}_{\Omega^{(n)}}(\mathbf{R}_{(n)}) \mathbf{P}_k^{(n)H} \\ &\quad - \lambda \left(\mathbf{U}_{k+1}^{(n-2)*} \right)^\dagger \mathcal{P}_{\Omega^{(n)}}(\mathbf{U}_{k+1}^{(n-2)*} \Delta_{k+1}^{(n)} \mathbf{P}_k^{(n)}) \mathbf{P}_k^{(n)H} \\ &\quad + \beta_k \left(\mathbf{U}_{k+1}^{(n-2)*} \right)^\dagger \mathcal{H}^{-1} \left(\mathbf{M}_k^{(n)} - \mathbf{D}_k^{(n)} / \beta_k - \mathcal{H}(\mathbf{U}_k^{(n-2)*} \Delta_k^{(n)}) \right) \\ &= \lambda \left(\mathbf{U}_{k+1}^{(n-2)*} \right)^\dagger \mathcal{P}_{\Omega^{(n)}}(\mathbf{R}_{(n)}) \mathbf{P}_k^{(n)H} \\ &\quad - \lambda \left(\mathbf{U}_{k+1}^{(n-2)*} \right)^\dagger \mathcal{P}_{\Omega^{(n)}}(\mathbf{U}_{k+1}^{(n-2)*} \Delta_{k+1}^{(n)} \mathbf{P}_k^{(n)}) \mathbf{P}_k^{(n)H} \\ &\quad - \left(\mathbf{U}_{k+1}^{(n-2)*} \right)^\dagger \mathcal{H}^{-1} \left((\rho+1) \mathbf{D}_k^{(n)} - \rho \mathbf{D}_{k-1}^{(n)} \right), (n=3, 4) \end{aligned}$$

结合式(4-18), 可以得到

$$\begin{aligned}\mathbf{A}_{k+1}^{(n)} - \mathbf{A}_k^{(n)} &= \frac{1}{\beta_k} \left(\mathbf{U}_{k+1}^{(n-2)*} \right)^\dagger \left(\lambda \mathcal{P}_{\Omega^{(n)}} \left(\mathbf{R}_{(n)} \right) \mathbf{P}_k^{(n)H} \right. \\ &\quad \left. - \lambda \mathcal{P}_{\Omega^{(n)}} \left(\mathbf{U}_{k+1}^{(n-2)*} \mathbf{A}_{k+1}^{(n)} \mathbf{P}_k^{(n)} \right) \mathbf{P}_k^{(n)H} \right. \\ &\quad \left. - \mathcal{H}^{-1} \left((\rho+1) \mathbf{D}_k^{(n)} - \rho \mathbf{D}_{k-1}^{(n)} \right) \right) \\ &= \mathbf{J}_k / \beta_k\end{aligned}$$

由于 $\mathbf{J}_k$ 有上界, 可以得到 $\|\mathbf{A}_{k+1}^{(n)} - \mathbf{A}_k^{(n)}\|_F = O((\beta_k)^{-1})$, 进而推出

$$\begin{aligned}\|\mathbf{A}_m^{(n)} - \mathbf{A}_k^{(n)}\|_F &\leq \|\mathbf{A}_m^{(n)} - \mathbf{A}_{m-1}^{(n)}\|_F + \|\mathbf{A}_{m-1}^{(n)} - \mathbf{A}_{m-2}^{(n)}\|_F \\ &\quad + \cdots + \|\mathbf{A}_{k+1}^{(n)} - \mathbf{A}_k^{(n)}\|_F \\ &= \|\mathbf{J}_{m-1}\|_F / \beta_{m-1} + \|\mathbf{J}_{m-2}\|_F / \beta_{m-2} + \cdots + \|\mathbf{J}_k\|_F / \beta_k \\ &\leq \frac{\gamma}{\beta_k} \left(\frac{1}{\rho_{m-k-1}} + \frac{1}{\rho_{m-k-2}} + \cdots + 1 \right) < \frac{\gamma \rho}{\beta_k (1-\rho)}\end{aligned}$$

式中, $\gamma = \max \{\|\mathbf{J}_{m-1}\|_F, \|\mathbf{J}_{m-2}\|_F, \dots, \|\mathbf{J}_k\|_F\}$, 因为 $\frac{\gamma \rho}{\beta_k (1-\rho)} \rightarrow 0$, 所以 $\{\mathbf{A}_k^{(n)}\}_{n=3}^4$ 为柯西序列。

类似地, $\{\mathbf{M}_k^{(n)}\}_{n=1}^4$ 也为柯西序列。

2 第四章定理 2 证明

证明定理 2: 设 $\{\tilde{\mathbf{U}}_k^{(n)}\}_{n=1}^2$ 和 $\{\tilde{\mathbf{A}}_k^{(n)}\}_{n=3}^4$ 为(4-19)的静态点, 则(4-19)的 KKT 条件可写为

$$0 \in \mathcal{H}^{-1} \left(\partial \left\| \mathcal{H}(\tilde{\mathbf{U}}^{(n)}) \right\|_* \right) + \lambda \mathcal{P}_{\Omega^{(n)}} \left(\tilde{\mathbf{U}}^{(n)} \tilde{\mathbf{P}}^{(n)} \right) \tilde{\mathbf{P}}^{(n)H} - \lambda \mathcal{P}_{\Omega^{(n)}} \left(\mathbf{R}_{(n)} \right) \tilde{\mathbf{P}}^{(n)H}, n=1, 2$$

$$0 \in \mathcal{H}^{-1} \left(\partial \left\| \mathcal{H}(\tilde{\mathbf{U}}^{(n-2)*} \tilde{\mathbf{A}}_k^{(n)}) \right\|_* \right) + \lambda \mathcal{P}_{\Omega^{(n)}} \left(\tilde{\mathbf{U}}^{(n-2)*} \tilde{\mathbf{A}}_k^{(n)} \tilde{\mathbf{P}}^{(n)} \right) \tilde{\mathbf{P}}^{(n)H} - \lambda \mathcal{P}_{\Omega^{(n)}} \left(\mathbf{R}_{(n)} \right) \tilde{\mathbf{P}}^{(n)H}, n=3, 4$$

式中, $\tilde{\mathbf{P}}^{(n)} = (\tilde{\mathbf{U}}^{(4)} \odot \cdots \odot \tilde{\mathbf{U}}^{(n+1)} \odot \tilde{\mathbf{U}}^{(n-1)} \odot \cdots \odot \tilde{\mathbf{U}}^{(1)})^T$ 。

根据算法 2 迭代过程, 第 $k+1$ 迭代中(4-23)和(4-28)的一阶最优性条件分别为

$$\begin{aligned}0 &= \lambda \mathcal{P}_{\Omega^{(n)}} \left(\mathbf{U}_{k+1}^{(n)} \mathbf{P}_{k+1}^{(n)} \right) \mathbf{P}_{k+1}^{(n)H} - \lambda \mathcal{P}_{\Omega^{(n)}} \left(\mathbf{R}_{(n)} \right) \mathbf{P}_{k+1}^{(n)H} \\ &\quad + \beta_k \mathcal{H}^{-1} \left(\mathcal{H} \left(\mathbf{U}_{k+1}^{(n)} \right) - \mathbf{M}_k^{(n)} + \mathbf{D}_k^{(n)} / \beta_k \right), n=1, 2\end{aligned}$$

$$\begin{aligned}0 &= \lambda \mathcal{P}_{\Omega^{(n)}} \left(\mathbf{U}_{k+1}^{(n-2)*} \mathbf{A}_{k+1}^{(n)} \mathbf{P}_{k+1}^{(n)} \right) \mathbf{P}_{k+1}^{(n)H} - \lambda \mathcal{P}_{\Omega^{(n)}} \left(\mathbf{R}_{(n)} \right) \mathbf{P}_{k+1}^{(n)H} \\ &\quad + \beta_k \mathcal{H}^{-1} \left(\mathcal{H} \left(\mathbf{U}_{k+1}^{(n-2)*} \mathbf{A}_{k+1}^{(n)} \right) - \mathbf{M}_k^{(n)} + \mathbf{D}_k^{(n)} / \beta_k \right), n=3, 4\end{aligned}$$

进而，式(4-33)和(4-34)的一阶最优性条件为

$$0 \in \partial \left\| \mathbf{M}_{k+1}^{(n)} \right\|_* + \beta_k \left(\mathbf{M}_{k+1}^{(n)} - \mathcal{H} \left(\mathbf{U}_{k+1}^{(n)} \right) \right) - \mathbf{D}_k^{(n)}, n=1, 2$$

$$0 \in \partial \left\| \mathbf{M}_{k+1}^{(n)} \right\|_* + \beta_k \left(\mathbf{M}_{k+1}^{(n)} - \mathcal{H} \left(\mathbf{U}_{k+1}^{(n-2)*} \mathbf{A}_{k+1}^{(n)} \right) \right) - \mathbf{D}_k^{(n)}, n=3, 4$$

可以得到

$$0 \in \partial \left\| \mathbf{M}_{k+1}^{(n)} \right\|_* - \mathbf{D}_{k+1}^{(n)}, n=1, 2, 3, 4$$

由于 $\left\{ \mathbf{U}_k^{(n)} \right\}_{n=1}^2$ 、 $\left\{ \mathbf{A}_k^{(n)} \right\}_{n=3}^4$ 和 $\left\{ \mathbf{M}_k^{(n)} \right\}_{n=1}^4$ 均为柯西序列，则 $\left\{ \mathbf{U}_\infty^{(n)} \right\}_{n=1}^2$ 、 $\left\{ \mathbf{A}_\infty^{(n)} \right\}_{n=3}^4$ 和 $\left\{ \mathbf{M}_\infty^{(n)} \right\}_{n=1}^4$ 分别是其极限点。根据式 $\lim_{k \rightarrow \infty} \left\| \mathcal{H} \left(\mathbf{U}_{k+1}^{(n)} \right) - \mathbf{M}_{k+1}^{(n)} \right\|_F = 0, n=1, 2$ 和 $\lim_{k \rightarrow \infty} \left\| \mathcal{H} \left(\mathbf{U}_{k+1}^{(n-2)*} \mathbf{A}_{k+1}^{(n)} \right) - \mathbf{M}_{k+1}^{(n)} \right\|_F = 0, n=3, 4$ ，可以得到 $\mathcal{H} \left(\mathbf{U}_\infty^{(n)} \right) = \mathbf{M}_\infty^{(n)}, n=1, 2$ 和 $\mathcal{H} \left(\mathbf{U}_\infty^{(n-2)*} \mathbf{A}_\infty^{(n)} \right) = \mathbf{M}_\infty^{(n)}, n=3, 4$ 。通过上述公式

$$0 = \lambda \mathcal{P}_{\Omega^{(n)}} \left(\mathbf{U}_{k+1}^{(n)} \mathbf{P}_{k+1}^{(n)} \right) \mathbf{P}_{k+1}^{(n)H} - \lambda \mathcal{P}_{\Omega^{(n)}} \left(\mathbf{R}_{(n)} \right) \mathbf{P}_{k+1}^{(n)H} \\ + \beta_k \mathcal{H}^{-1} \left(\mathcal{H} \left(\mathbf{U}_{k+1}^{(n)} \right) - \mathbf{M}_k^{(n)} + \mathbf{D}_k^{(n)} / \beta_k \right), n=1, 2$$

$$0 = \lambda \mathcal{P}_{\Omega^{(n)}} \left(\mathbf{U}_{k+1}^{(n-2)*} \mathbf{A}_{k+1}^{(n)} \mathbf{P}_{k+1}^{(n)} \right) \mathbf{P}_{k+1}^{(n)H} - \lambda \mathcal{P}_{\Omega^{(n)}} \left(\mathbf{R}_{(n)} \right) \mathbf{P}_{k+1}^{(n)H} \\ + \beta_k \mathcal{H}^{-1} \left(\mathcal{H} \left(\mathbf{U}_{k+1}^{(n-2)*} \mathbf{A}_{k+1}^{(n)} \right) - \mathbf{M}_k^{(n)} + \mathbf{D}_k^{(n)} / \beta_k \right), n=3, 4$$

与公式 $0 \in \partial \left\| \mathbf{M}_{k+1}^{(n)} \right\|_* - \mathbf{D}_{k+1}^{(n)}, n=1, 2, 3, 4$ ， $\lim_{k \rightarrow \infty} \left\| \mathbf{D}_{k+1}^{(n)} - \mathbf{D}_k^{(n)} \right\|_F = 0, n=1, 2, 3, 4$ ，有

$$0 \in \mathcal{H}^{-1} \left(\partial \left\| \mathcal{H} \left(\mathbf{U}_\infty^{(n)} \right) \right\|_* \right) + \lambda \mathcal{P}_{\Omega^{(n)}} \left(\mathbf{U}_\infty^{(n)} \mathbf{P}_\infty^{(n)} \right) \mathbf{P}_\infty^{(n)H} - \lambda \mathcal{P}_{\Omega^{(n)}} \left(\mathbf{R}_{(n)} \right) \mathbf{P}_\infty^{(n)H}, n=1, 2$$

$$0 \in \mathcal{H}^{-1} \left(\partial \left\| \mathcal{H} \left(\mathbf{U}_\infty^{(n-2)*} \mathbf{A}_\infty^{(n)} \right) \right\|_* \right) + \lambda \mathcal{P}_{\Omega^{(n)}} \left(\mathbf{U}_\infty^{(n-2)*} \mathbf{A}_\infty^{(n)} \mathbf{P}_\infty^{(n)} \right) \mathbf{P}_\infty^{(n)H} - \lambda \mathcal{P}_{\Omega^{(n)}} \left(\mathbf{R}_{(n)} \right) \mathbf{P}_\infty^{(n)H}, n=3, 4$$

式中， $\mathbf{P}_\infty^{(n)} = \left(\mathbf{U}_\infty^{(4)} \odot \dots \odot \mathbf{U}_\infty^{(n+1)} \odot \mathbf{U}_\infty^{(n-1)} \odot \dots \odot \mathbf{U}_\infty^{(1)} \right)^T$ 。

因此，序列 $\{\mathcal{U}_k\}$ 和 $\{\mathbf{A}_k\}$ 的极限点满足(4-19)的 KKT 条件。至此，FP-TC 算法收敛性证明完毕。