

基于双高斯先验的低秩矩阵分解模型

韦芳, 王长鹏*

(长安大学理学院, 陕西 西安 710064)

摘要:为了更好地拟合复杂噪声, 增强低秩矩阵分解模型的鲁棒性, 将双高斯先验引入到传统的高斯混合模型中, 提出了基于双高斯先验的低秩矩阵分解(low-rank matrix factorization with double Gaussian prior, DGP-LRMF)模型, 通过模型分解得到的2个矩阵均服从高斯先验, 从而实现对噪声的有效建模, 并在贝叶斯理论框架下利用EM算法实现模型参数的推断。实验结果验证了所提模型能够有效地处理含有复杂噪声的数据, 取得了更优且更具稳定性的去噪效果。

关键词:高斯混合模型; 低秩矩阵分解; 高斯先验

中图分类号: TP391

文献标志码: A

引用格式: 韦芳, 王长鹏. 基于双高斯先验的低秩矩阵分解模型[J]. 山东大学学报(理学版), 2023, 58(3): 101-108.

Low-rank matrix factorization with double Gaussian prior model

WEI Fang, WANG Chang-peng*

(School of Science, Chang'an University, Xi'an 710064, Shaanxi, China)

Abstract: In order to fit the complex noise better and enhance the robustness of the low-rank matrix factorization model, the dual Gaussian priors are introduced into the traditional Gaussian mixture model, and the model of low-rank matrix factorization with double Gaussian prior (DGP-LRMF) is proposed, it is assumed that two matrices obtained by model decomposition obey Gaussian priori to realize the effective modeling for noise, and the EM algorithm is used to deduce the model parameters in the framework of Bayesian theory. Experimental results show that the proposed model can effectively deal with the data with complex noise and obtain better and more stable denoising performance.

Key words: Gaussian mixture model; low-rank matrix decomposition; Gaussian prior

0 引言

图像作为数字多媒体技术的重要产物, 已成为人们传递、获取信息的重要方式。在图像的采集和传输过程中, 许多因素会导致图像含有复杂噪声, 因此有效去除图像中的噪声十分重要。近年来, 基于低秩理论的图像去噪方法取得了较好的实验结果, 其类型主要分为核范数最小化(nuclear norm minimization, NNM)方法^[1]和低秩矩阵分解(low-rank matrix factorization, LRMF)方法^[2-3]。

传统的LRMF方法通常使用 L_1 范数或Frobenius范数求解优化问题, Frobenius范数适用于处理高斯噪声, L_1 范数更适用于处理拉普拉斯噪声。面对现实中的复杂噪声, 学者们通过引入正则项或先验来降低模型对噪声的敏感性, 或者使用有限混合模型对噪声建模。这些方法虽然取得了一定的效果; 但在处理复杂噪声时以及运算速度上仍然不够理想, 因此本文基于以上2种思想, 提出了一种基于双高斯先验的低秩矩阵分解(low-rank matrix factorization with double Gaussian prior, DGP-LRMF)模型, 实现对复杂噪声的有效建模。

收稿日期: 2022-01-26; 网络出版时间: 2023-02-16 08:53:36

网络出版地址: <http://kns.cnki.net/kcms/detail/37.1389.N.20230215.1153.022.html>

基金项目: 国家自然科学基金青年项目(12001057); 长安大学中央高校基本科研业务费专项资金资助项目(300102122101)

第一作者简介: 韦芳(1999—), 女, 硕士研究生, 研究方向为机器学习。E-mail: 2766825663@qq.com

* 通信作者简介: 王长鹏(1985—), 男, 博士, 副教授, 研究方向为机器学习。E-mail: cpwang@chd.edu.cn

1 相关工作

LRMF 理论的基本思想是用 2 个或者多个低秩矩阵来近似表示观测矩阵,对给定的观测矩阵 $X \in \mathbf{R}^{dn}$, 矩阵分解问题可以表达为

$$\min_{U,V} \|W \cdot (X - UV)\|_F, \quad (1)$$

其中 $\|\cdot\|_F$ 表示矩阵的范数, $U \in \mathbf{R}^{dr}$ 、 $V \in \mathbf{R}^{rn}$ 为低秩矩阵,通常 $r \ll \min(d, n)$ 。观测矩阵 X 中的元素可以近似表示为 $x_{ij} \approx \sum_{t=1}^r u_{it} v_{tj}$, 因此,观测矩阵 X 的列向量可以视为矩阵 U 列向量的线性组合,进而称矩阵 U 为基矩阵, V 为系数矩阵。

基于 Frobenius 范数的矩阵分解问题,学者们提出了如 Damped Newton algorithm (DN)^[4]、Chen's method^[5]、Damped Wiberg (DW)^[6] 等一系列算法。Frobenius 范数假设数据中的噪声均服从高斯分布,所以更适用于高斯噪声,对现实问题中存在的非高斯噪声, Frobenius 范数无法实现有效拟合,因此,一些学者利用更加稳健的损失函数来代替 Frobenius 范数。

Torre 等^[7]提出了基于鲁棒 M 估计的子空间学习算法, Ke 等^[8]利用 L_1 范数来替代 Frobenius 范数,提出了鲁棒 L_1 范数的分解算法,其目标函数为

$$\min_{U,V} \|X - UV\|_1. \quad (2)$$

在 L_1 范数的框架下, Eriksson 等^[9]提出了 L_1 -Wibeg 算法, Meng 等^[10]提出了循环加权终值算法, Kim 等^[11]使用交替校正梯度方法来求解基于 L_1 范数的矩阵分解问题。由于 L_1 范数假设噪声服从拉普拉斯分布导出,因此更适用于处理拉普拉斯分布噪声,对其他噪声的处理不够理想。随后,一些学者提出将 $L_{2,1}$ 范数作为损失函数,虽然该范数结合了 L_1 范数和 Frobenius 范数的优点,但其缺乏概率可解释性。

假设噪声单一地服从高斯或拉普拉斯分布,不能有效拟合实际数据中的复杂噪声,因此一些学者提出在基矩阵或者系数矩阵上加入正则化或先验知识。Kim 等^[11]在非负基矩阵 U 和非负系数矩阵 V 上分别引入 L_1 正则项,每个子问题都通过非负性约束最小二乘算法来解决,其目标函数为:

$$\min_{U,V} \frac{1}{2} \left(\|X - UV\|_F^2 + \alpha \|U\|_F^2 + \beta \sum_{j=1}^n \|V_{\cdot j}\|_1^2 \right), \text{ s.t. } U \geq 0, V \geq 0, \quad (3)$$

$$\min_{U,V} \frac{1}{2} \left(\|X - UV\|_F^2 + \alpha \|V\|_F^2 + \gamma \sum_{i=1}^d \|U_{i \cdot}\|_1^2 \right), \text{ s.t. } U \geq 0, V \geq 0. \quad (4)$$

Min 等^[12]在稀疏奇异值分解中引入 L_1 范数和 L_0 范数的惩罚项,采用了交替迭代策略以及基于块坐标下降法求解问题。

基于 Laskshminarayanan 等^[13]、Salakhutdinov 等^[14]的工作, Wang 等^[15]使用 L_1 范数替代 Frobenius 范数,提出了鲁棒概率矩阵分解 (robust probabilistic matrix factorization, RPMF),其目标函数可以表达为

$$\min_{U,V} \|X - UV\|_1 + \frac{\gamma}{2} \|U\|_2^2 + \frac{\lambda}{2} \|V\|_2^2, \quad (5)$$

其中 γ, λ 为超参数。接着, Saddle 等^[16]提出一种混合成员分类模型,称为 GLAD (Gaussian-Laplace-Dirichlet model),该模型假设基矩阵和系数矩阵分别服从拉普拉斯先验及狄利克雷先验,其模型的数学表达式为

$$\min_{U,V} \sum_{i=1}^d \sum_{j=1}^n -\frac{1}{2\sigma^2} (x_{ij} - u_i \cdot v_j)^2 - n \sum_{i=1}^d \sum_{t=1}^r \frac{|u_{it}|}{\lambda} + \sum_{t=1}^r (\alpha_t - 1) \sum_{j=1}^n \log v_{tj}, \quad (6)$$

其中 u_i 为 U 的第 i 个行向量, v_j 为 V 的第 j 个列向量。

Meng 等^[17]提出了基于高斯混合模型的矩阵分解 (mixture of Gaussians, MOG) 模型,该模型假设噪声服从高斯混合分布,理论上高斯混合模型能够逼近任意的连续分布,因此,高斯混合模型能够有效地拟合服从高斯分布或拉普拉斯分布的噪声,其目标函数表达为

$$\max \sum_{i,j} \log \sum_{k=1}^K \pi_k N(x_{ij} | u_i \cdot v_j, \sigma_k), \quad (7)$$

其中 $N(x_{ij}|\mathbf{u}_i, \mathbf{v}_j, \sigma_k)$ 表示均值为 $\mathbf{u}_i \cdot \mathbf{v}_j$ 、方差为 σ_k 的高斯分布, K 是高斯混合模型中所含高斯分布个数, π_k 对应于第 k 个高斯分布的权重。随后, Cao 等^[18] 将噪声假设为服从指数幂的混合分布, 并提出了新的矩阵分解模型。Xu 等^[19] 提出自适应分位数矩阵分解模型。以上方法虽然在图像去噪上取得了良好的效果, 但在处理复杂噪声上的效果或运算代价还有待进一步改进。针对该问题, 本文提出了一种基于双高斯先验的低秩矩阵分解模型, 实现对复杂噪声的更有效处理。

2 DGP-LRMF

2.1 模型建立

受以上工作的启发, 本文假设观察数据矩阵 $\mathbf{X} \in \mathbf{R}^{d \times n}$ 中的元素 x_{ij} 表示为

$$x_{ij} = \mathbf{u}_i \cdot \mathbf{v}_j + \varepsilon_{ij}, \quad (8)$$

其中 $\mathbf{u}_i$ 为 $\mathbf{U}$ 的第 i 个行向量, $\mathbf{v}_j$ 为 $\mathbf{V}$ 的第 j 个列向量, ε_{ij} 表示元素 x_{ij} 上所含噪声。本文假设 ε_{ij} 服从混合高斯分布, 即有

$$\varepsilon_{ij} \sim p(\varepsilon), \text{ 其中 } p(\varepsilon) = \sum_{k=1}^K \pi_k N(\varepsilon|0, \sigma_k), \quad (9)$$

$N(\varepsilon|0, \sigma_k)$ 表示均值为 0、方差为 σ_k 的高斯分布, π_k 为混合系数且满足 $\sum_{k=1}^K \pi_k = 1 (0 < \pi_k < 1)$ 。

Wang 等^[20] 在基于高斯混合模型的框架下, 对基矩阵和系数矩阵分别引入稀疏先验以及拉普拉斯先验, 提出了一种针对混合高斯噪声的贝叶斯矩阵分解 (Bayesian matrix decomposition with mixture of Gaussian noise, BMD-MOG) 模型, 该模型提高了计算速度, 但对基矩阵与稀疏矩阵的构造要求较高, 且对混合噪声的拟合效果仍不够理想。对此我们在高斯混合模型的框架下, 提出了对基矩阵 $\mathbf{U}$ 和系数矩阵 $\mathbf{V}$ 分别给予均值为 0 的高斯分布先验, 即有

$$\mathbf{u}_i \sim N(0, \lambda_u), \quad \mathbf{v}_j \sim N(0, \lambda_v), \quad (10)$$

其中, λ_u 和 λ_v 为对应高斯分布的方差, 从而使模型更适用于复杂噪声的拟合。

根据 $\varepsilon_{ij} \sim p(\varepsilon)$ 可以得到 x_{ij} 的概率密度函数, 即

$$p(x_{ij}) = \sum_{k=1}^K \pi_k N(x_{ij}|\mathbf{u}_i \cdot \mathbf{v}_j, \sigma_k). \quad (11)$$

通过贝叶斯定理, 可以得到

$$p(\mathbf{U}, \mathbf{V}, \Sigma, \Pi | \mathbf{X}) = \frac{p(\mathbf{X} | \mathbf{U}, \mathbf{V}, \Sigma, \Pi) p(\mathbf{U} | \lambda_u) p(\mathbf{V} | \lambda_v)}{p(\mathbf{X})}, \quad (12)$$

其中 $\Sigma = \{\sigma_1, \sigma_2, \dots, \sigma_K\}$ 、 $\Pi = \{\pi_1, \pi_2, \dots, \pi_K\}$ 均为未知参数, $p(\mathbf{X})$ 为已知观测数据的概率密度函数, 从而有

$$p(\mathbf{U}, \mathbf{V}, \Sigma, \Pi) \propto p(\mathbf{X} | \mathbf{U}, \mathbf{V}, \Sigma, \Pi) p(\mathbf{U} | \lambda_u) p(\mathbf{V} | \lambda_v). \quad (13)$$

将式(13)的右边展开, 有

$$\begin{aligned} & p(\mathbf{X} | \mathbf{U}, \mathbf{V}, \Sigma, \Pi) p(\mathbf{U} | \lambda_u) p(\mathbf{V} | \lambda_v) \\ &= \prod_{i,j} \sum_{k=1}^K \pi_k N(x_{ij} | \mathbf{u}_i \cdot \mathbf{v}_j, \sigma_k) \prod_{i,t} N(u_{it} | 0, \lambda_u) \prod_{t,j} N(v_{tj} | 0, \lambda_v) \\ &= \prod_{i,j} \sum_{k=1}^K \pi_k \frac{1}{\sqrt{2\pi\sigma_k}} \exp\left(-\frac{(x_{ij} - \mathbf{u}_i \cdot \mathbf{v}_j)^2}{2\sigma_k}\right) \prod_{i,t} \frac{1}{\sqrt{2\pi\lambda_u}} \exp\left(-\frac{(u_{it})^2}{2\lambda_u}\right) \prod_{t,j} \frac{1}{\sqrt{2\pi\lambda_v}} \exp\left(-\frac{(v_{tj})^2}{2\lambda_v}\right). \end{aligned} \quad (14)$$

为了估计 $\mathbf{U}, \mathbf{V}, \Sigma, \Pi$, 我们利用最大似然估计方法, 将目标函数(14)转化为

$$\max_{\mathbf{U}, \mathbf{V}, \Sigma, \Pi} L(\mathbf{U}, \mathbf{V}, \Sigma, \Pi) = \sum_{i,j} \log\left(\sum_{k=1}^K \pi_k N(x_{ij} | \mathbf{u}_i \cdot \mathbf{v}_j, \sigma_k)\right) - \sum_{i,t} \frac{u_{it}^2}{2\lambda_u} - \sum_{t,j} \frac{v_{tj}^2}{2\lambda_v} + c, \quad (15)$$

其中 c 是与未知参数无关的常数。根据 Jensen 不等式, 上述优化问题等价于

$$\max_{\mathbf{U}, \mathbf{V}, \Sigma, \Pi} L(\mathbf{U}, \mathbf{V}, \Sigma, \Pi) = \sum_{i,j} \sum_{k=1}^K [\log \pi_k + \log N(x_{ij} | \mathbf{u}_i \cdot \mathbf{v}_j, \sigma_k)] - \sum_{i,t} \frac{u_{it}^2}{2\lambda_u} - \sum_{t,j} \frac{v_{tj}^2}{2\lambda_v} + c. \quad (16)$$

2.2 模型求解

针对优化问题(16), 本文利用 EM 算法^[21] 对模型求解, 目标函数中的 λ_u 和 λ_v 视为超参数。EM 算法

是一种迭代算法,用于含有隐变量概率参数模型的最大似然估计或极大后验概率估计。EM 算法包括 E 步和 M 步 2 个步骤,E 步是指利用对隐藏变量的现有估计值,计算其最大似然估计值;M 步是最大化在 E 步上求得的最大似然值来计算参数的值。M 步所得参数估计值被用于下一个 E 步计算中,这 2 个步骤不断交替迭代,直至收敛。

E 步:引入潜在变量 z_{ijk} , $k=1,2,\dots,K$, z_{ijk} 在 $\{0,1\}$ 中取值,当元素 x_{ij} 属于第 k 个高斯分量时, $z_{ijk}=1$, 否则 $z_{ijk}=0$, z_{ijk} 满足 $\sum_{k=1}^K z_{ijk}=1$ 。计算潜在变量 z_{ijk} 的条件期望如下:

$$r_{ijk}=E(z_{ijk})=\frac{\pi_k N(x_{ij}|\mathbf{u}_i, \mathbf{v}_j, \sigma_k)}{\sum_{k=1}^K \pi_k N(x_{ij}|\mathbf{u}_i, \mathbf{v}_j, \sigma_k)} \quad (17)$$

为了获得其余参数的迭代公式,根据 EM 算法,我们需要计算 Q 函数,即对引入潜在变量的对数似然函数求期望,具体数学表达式为

$$\begin{aligned} Q &= E_{Z|X}(L(\mathbf{U}, \mathbf{V}, \Sigma, \Pi)) \\ &= E_{Z|X} \left[\sum_{i,j} \sum_{k=1}^K z_{ijk} (\log \pi_k + \log N(x_{ij}|\mathbf{u}_i, \mathbf{v}_j, \sigma_k)) \right] - \sum_{i,t} \frac{u_{it}^2}{2\lambda_u} - \sum_{t,j} \frac{v_{tj}^2}{2\lambda_v} + c \\ &= \sum_{i,j} \sum_{k=1}^K r_{ijk} (\log \pi_k + \log N(x_{ij}|\mathbf{u}_i, \mathbf{v}_j, \sigma_k)) - \sum_{i,t} \frac{u_{it}^2}{2\lambda_u} - \sum_{t,j} \frac{v_{tj}^2}{2\lambda_v} + c \end{aligned} \quad (18)$$

M 步:通过更新迭代 Q 函数的参数使其达到最大化,只保留 Q 函数中与参数有关的项,目标函数为

$$\max_{\mathbf{U}, \mathbf{V}, \Sigma, \Pi} Q = \sum_{i,j} \sum_{k=1}^K r_{ijk} \left(\log \pi_k - \log \sqrt{2\pi\sigma_k} - \frac{(x_{ij} - \mathbf{u}_i \cdot \mathbf{v}_j)^2}{2\sigma_k} \right) - \sum_{i,t} \frac{u_{it}^2}{2\lambda_u} - \sum_{t,j} \frac{v_{tj}^2}{2\lambda_v}, \quad (19)$$

等价于

$$\min_{\mathbf{U}, \mathbf{V}, \Sigma, \Pi} D = \sum_{i,j} \sum_{k=1}^K r_{ijk} \left(-\log \pi_k + \log \sqrt{2\pi\sigma_k} + \frac{(x_{ij} - \mathbf{u}_i \cdot \mathbf{v}_j)^2}{2\sigma_k} \right) + \sum_{i,t} \frac{u_{it}^2}{2\lambda_u} + \sum_{t,j} \frac{v_{tj}^2}{2\lambda_v}. \quad (20)$$

更新 Π :根据文献[21],对于 $k=1,2,\dots,K$,参数 π_k 更新公式为:

$$N_k = \sum_{i,j} r_{ijk}, \quad (21)$$

$$\pi_k = \frac{N_k}{\sum_{k=1}^K N_k}. \quad (22)$$

更新 Σ :仅需考虑式(20)中与 Σ 有关的项,即

$$\min_{\Sigma} \sum_{i,j} r_{ijk} \log \sqrt{2\pi\sigma_k} + \sum_{i,j} r_{ijk} \frac{(x_{ij} - \mathbf{u}_i \cdot \mathbf{v}_j)^2}{2\sigma_k}. \quad (23)$$

对式(23)中的 σ_k 求偏导,并令其等于 0,得到 σ_k 的更新规则:

$$\sigma_k = \frac{\sum_{i,j} r_{ijk} (x_{ij} - \mathbf{u}_i \cdot \mathbf{v}_j)^2}{\sum_{i,j} r_{ijk}}. \quad (24)$$

更新 $\mathbf{U}$:仅考虑式(20)与 $\mathbf{U}$ 有关的项

$$\min_{\mathbf{U}} \sum_{i,j} \sum_{k=1}^K \frac{r_{ijk}}{2\sigma_k} (x_{ij} - \mathbf{u}_i \cdot \mathbf{v}_j)^2 + \sum_{i,t} \frac{u_{it}^2}{2\lambda_u}. \quad (25)$$

为了方便表示,令 $a_{ij} = \sum_{k=1}^K \frac{r_{ijk}}{\sigma_k}$,从而有矩阵 $\mathbf{A} = (a_{ij})_{dxn}$ 、 $\mathbf{A} \in \mathbf{R}^{dxn}$,将 $\mathbf{U}$ 的更新问题转化为对于 $\mathbf{U}$ 的每一个行向量 $\mathbf{u}_i$ 的迭代更新,通过简单的矩阵运算,式(25)可以转化为矩阵形式

$$\min_{\mathbf{u}_i} \frac{1}{2} \| (x_{i\cdot} - \mathbf{u}_i \cdot \mathbf{V}) \text{diag}(\sqrt{\mathbf{A}_i}) \|^2 + \frac{1}{2\lambda_u} \|\mathbf{u}_i\|_2^2, \quad (26)$$

其中 $\mathbf{A}_i$ 为矩阵 $\mathbf{A}$ 的第 i 行向量。

由式(26)得到 $\mathbf{u}_{i\cdot}$ 的更新公式

$$\mathbf{u}_{i\cdot} = \frac{x_{i\cdot} \text{diag} \sqrt{\mathbf{A}_{i\cdot}} \text{diag} \sqrt{\mathbf{A}_{i\cdot}}^T \mathbf{V}^T}{\mathbf{V} \text{diag} \sqrt{\mathbf{A}_{i\cdot}} \text{diag} \sqrt{\mathbf{A}_{i\cdot}}^T \mathbf{V}^T + \frac{1}{\lambda_u}} \quad (27)$$

更新 $\mathbf{V}$: $\mathbf{V}$ 的更新类似于 $\mathbf{U}$ 的更新,同理可得

$$\mathbf{v}_{\cdot j} = \frac{x_{\cdot j}^T \text{diag} \sqrt{\mathbf{A}_{\cdot j}} \text{diag} \sqrt{\mathbf{A}_{\cdot j}}^T \mathbf{U}}{\mathbf{U}^T \text{diag} \sqrt{\mathbf{A}_{\cdot j}} \text{diag} \sqrt{\mathbf{A}_{\cdot j}}^T \mathbf{U} + \frac{1}{\lambda_v}} \quad (28)$$

更新高斯分量的数目 K : 对于 $\forall i, j \in 1, 2, \dots, K$, 若满足 $\frac{|\sigma_i - \sigma_j|}{|\sigma_i + \sigma_j|} < \gamma$, 其中 γ 是一个极小值, 则将第 i 个高斯分量与第 j 个高斯分量合并, 混合高斯分量数目 K 减 1, 因此, K 的初始化可赋值为一个较大的数。此外, 当存在方差趋于 0 的高斯分量, 该高斯分量应当从模型中移除。

初始化: 矩阵 $\mathbf{V}$ 与 $\mathbf{U}$ 中元素的初始化参考文献[19]中的初始化方法。

迭代停止条件: 当目标函数值的变化小于给定阈值 ε 时, 停止更新。

综上, 整个优化过程总结为算法 1。

算法 1: 求解该模型的 EM 算法

输入: 观测矩阵 $\mathbf{X}$,

输出: $\mathbf{U}, \mathbf{V}, \Sigma, \Pi$,

1. 初始化 $\mathbf{U}, \mathbf{V}, \Sigma, \Pi$, 混合高斯分量的数目 K , 迭代停止的阈值 ε ;
2. 通过式(17)更新 r_{ijk} , $i=1, 2, \dots, d$; $j=1, 2, \dots, n$; $k=1, 2, \dots, K$;
3. 通过式(22)和(24)分别更新 Π, Σ ;
4. 通过式(27)更新 $\mathbf{U}$;
5. 通过式(28)更新 $\mathbf{V}$;
6. 更新高斯混合分量数目 K ;
7. 判断是否满足终止条件, 若满足则停止迭代, 否则重复步骤 2—6。

3 实验对比与分析

在合成数据与真实数据上分别与已有的 LRMF 模型 BMD-MOG^[20]、MOG^[17]、DW^[6]、ALM^[22]、RPMF^[15] 进行比较, 证实了本文提出的模型对处理复杂噪声的有效性。由于噪声生成的随机性, 评价指标取每组 20 次实验中 10 次最优结果的平均值。采用 MATLAB R2019b 进行编程, 所有实验在配置为 Intel(R) Core (TM) i5-8250U CPU @ 1.60 GHz 的计算机上进行。

3.1 评价指标

使用如下的评价指标^[20]:

$$E_1 = \|\mathbf{X}_{\text{noi}} - \tilde{\mathbf{U}}\tilde{\mathbf{V}}\|_1 / dn, E_2 = \|\mathbf{X}_{\text{noi}} - \tilde{\mathbf{U}}\tilde{\mathbf{V}}\|_F^2 / dn, \\ E_3 = \|\mathbf{X}_{\text{gt}} - \tilde{\mathbf{U}}\tilde{\mathbf{V}}\|_1 / dn, E_4 = \|\mathbf{X}_{\text{gt}} - \tilde{\mathbf{U}}\tilde{\mathbf{V}}\|_F^2 / dn,$$

其中 $\tilde{\mathbf{U}}, \tilde{\mathbf{V}}$ 是相应矩阵分解模型的输出矩阵。由于评价指标 E_3, E_4 对评估模型是否恢复正确的子空间更有意义^[20], 因此真实数据上的实验仅考虑评价指标 E_3, E_4 。对于以上 4 个评价指标, 其值越小, 表示模型恢复性能越好。

3.2 合成数据

将生成的不同类型合成数据进行 3 组实验, 在每组实验中随机生成 20 个大小为 20×40 、秩为 4 的低秩矩阵 $\mathbf{X}$, 它们中的每一个矩阵都由基矩阵 $\mathbf{U} \in \mathbf{R}^{d \times r}$ 和系数矩阵 $\mathbf{V} \in \mathbf{R}^{r \times m}$ 构成, 即 $\mathbf{X}_{\text{gt}} = \mathbf{U}\mathbf{V}$, $\mathbf{X}_{\text{gt}}$ 指未被噪声污染的干净观测矩阵, 对 $\mathbf{X}_{\text{gt}}$ 添加不同类型的噪声得到含噪观测矩阵 $\mathbf{X}_{\text{noi}}$, 在每组实验前对 $\mathbf{X}_{\text{gt}}$ 施加 20% 的缺失, 以验证 DGP-LRMF 模型具有处理观测矩阵含缺失值时的能力。

第一组实验:添加 80%服从 $N(0,0.1)$ 的高斯噪声,称该类噪声为高斯噪声 A;

第二组实验:添加 20%服从 $U(-5,5)$ 的稀疏噪声,20%服从 $N(0,0.2)$ 的高斯噪声,40%服从 $N(0,0.01)$ 的高斯噪声,称该类噪声为混合噪声 A;

第三组实验:添加 20%服从 $U(-5,5)$ 的稀疏噪声,40%服从 $N(0,1)$ 的高斯噪声,20%服从 $N(0,0.01)$ 的高斯噪声,称该类噪声为混合噪声 B。

实验结果展示在表 1,其中最优方法的结果加粗表示。

表 1 不同方法在合成数据上的比较
Table 1 Comparison of different methods on synthetic data

噪声类型	评价指标	DGP-LRMF	BMD-MOG	MOG	ALM	RPMF	DW
高斯噪声 A	E_1	0.349	0.569	0.356	0.356	0.373	0.355
	E_2	0.814	0.893	0.911	0.911	0.734	0.911
	E_3	0.135	0.592	0.048	0.048	0.281	0.048
	E_4	0.421	0.979	0.062	0.062	0.569	0.062
混合噪声 A	E_1	0.789	0.960	1.004	1.004	0.808	1.004
	E_2	1.384	1.375	1.432	1.431	1.414	1.433
	E_3	0.510	0.722	0.746	0.746	0.601	0.746
	E_4	0.807	1.017	1.033	1.032	0.927	1.033
混合噪声 B	E_1	0.716	0.907	0.817	0.817	0.738	0.817
	E_2	1.293	1.369	1.147	1.147	1.289	1.147
	E_3	0.349	0.696	0.575	0.575	0.415	0.575
	E_4	0.524	0.958	0.738	0.738	0.617	0.738

由实验结果可知,在包含高斯噪声 A 的合成数据实验中,DGP-LRMF 模型在指标 E_1 上取得了最优的实验结果;对于指标 E_2 、 E_3 和 E_4 ,模型 RPMF 或 MOG 表现更优。在包含混合噪声 A 和混合噪声 B 的实验中,DGP-LRMF 模型在指标 E_3 和 E_4 上都取得了最优的实验结果,证明其针对含有复杂噪声的数据能够更有效地恢复其子空间,进而更加适用于处理含有混合噪声的数据。

3.3 真实数据

首先,在 YALE 数据集上添加不同类型的噪声,4 组实验证实了 DGP-LRMF 模型在真实数据上处理不同噪声的有效性;其次,为了验证该模型处理复杂噪声的优越性,在 3 个常见的数据集 ORL、COIL、PIE 上分别施加 2 种不同的混合噪声,进一步验证 DGP-LRMF 模型对处理复杂噪声的有效性。

实验中所添加的噪声:

① 高斯噪声 B:40%服从 $N(0,1)$ 的高斯噪声;

② 混合噪声 C:20%服从 $U(-5,5)$ 的稀疏噪声,40%服从 $N(0,0.2)$ 的高斯噪声,20%服从 $N(0,0.01)$ 的高斯噪声;

③ 混合噪声 D:20%服从 $U(-5,5)$ 的稀疏噪声,40%服从 $N(0,1)$ 的高斯噪声,20%服从 $N(0,0.01)$ 的高斯噪声。

对于 YALE 数据集,在无噪声的情况下,除了 DW 以外,其余方法的表现效果相似。在添加高斯噪声 B、混合噪声 C 和混合噪声 D 的情况下,DGP-LRMF 模型都取得了最优实验结果,具有较好的处理复杂噪声的能力,实验结果见表 2,其中最优方法的结果加粗表示。

表 2 不同方法在 YALE 数据集上的比较
Table 2 Comparison of different methods on YALE dataset

噪声类型	评价指标	DGP-LRMF	BMD-MOG	MOG	ALM	RPMF	DW
无噪声	E_3	0.068	0.070	0.072	0.072	0.068	0.105
	E_4	0.101	0.104	0.098	0.098	0.109	0.141
高斯噪声 B	E_3	0.079	0.094	0.210	0.210	0.089	0.140
	E_4	0.126	0.126	0.271	0.270	0.132	0.183
混合噪声 C	E_3	0.084	0.090	0.409	0.410	0.095	0.235
	E_4	0.102	0.103	0.533	0.533	0.136	0.307
混合噪声 D	E_3	0.142	0.159	0.455	0.455	0.162	0.256
	E_4	0.215	0.217	0.586	0.586	0.229	0.333

为进一步验证所得结论,我们在不同的数据集中分别添加2种混合噪声进行实验,实验结果见表3,其中最优方法的结果加粗表示。由表3可知,在3种不同的数据集中,DGP-LRMF模型的性能明显提升,再一次验证其能够有效处理含有复杂噪声的实际数据。

表3 不同方法在3种数据集上的比较

Table 3 Comparison of different methods on three datasets

数据集	噪声类型	评价指标	DGP-LRMF	BMD-MOG	MOG	ALM	RPMF	DW
ORL 数据集	混合噪声 C	E_3	0.059	0.068	0.430	0.430	0.072	0.205
		E_4	0.084	0.091	0.560	0.560	0.099	0.271
	混合噪声 D	E_3	0.094	0.120	0.480	0.480	0.139	0.224
		E_4	0.167	0.172	0.617	0.617	0.201	0.295
COIL 数据集	混合噪声 C	E_3	0.069	0.078	0.437	0.435	0.081	0.226
		E_4	0.105	0.108	0.564	0.563	0.122	0.290
	混合噪声 D	E_3	0.133	0.168	0.487	0.486	0.171	0.246
		E_4	0.220	0.229	0.623	0.622	0.248	0.316
PIE 数据集	混合噪声 C	E_3	0.021	0.035	0.426	0.426	0.036	0.197
		E_4	0.039	0.052	0.554	0.553	0.053	0.258
	混合噪声 D	E_3	0.060	0.094	0.478	0.477	0.115	0.218
		E_4	0.136	0.196	0.614	0.613	0.175	0.285

4 结论

本文提出了一种基于双高斯先验的低秩矩阵分解(DGP-LRMF)模型,在高斯混合模型的框架下,对基矩阵和系数矩阵分别引入高斯先验,增强了模型的性能及推广能力。在合成数据上,无论是单一噪声还是混合噪声情况下,DGP-LRMF模型都取得较好的实验结果。在真实数据集上,相较于已有的LRMF模型,DGP-LRMF模型的性能明显提升,具有较好的处理复杂噪声的能力和鲁棒性,更加适用于含有复杂噪声的图像去噪问题。

参考文献:

- [1] HUANG Shimeng, WOLKOWICZ H. Low-rank matrix completion using nuclear norm minimization and facial reduction[J]. Journal of Global Optimization, 2018, 72(1):5-26.
- [2] CHEN Baiyu, YANG Zi, YANG Zhouwang. An algorithm for low-rank matrix factorization and its applications[J]. Neurocomputing, 2018, 275:1012-1020.
- [3] 刘璐, 张洪艳, 张良培. 基于光谱加权低秩矩阵分解的高光谱影像去噪方法[J]. 电子科技, 2020, 33(5):21-27.
LIU Lu, ZHANG Hongyan, ZHANG Liangpei. A method of hyperspectral imaging denoising based on spectral weighted low rank matrix factorization[J]. Journal of Electronic Technology, 2020, 33(5):21-27.
- [4] BUCHANAN A M, FITZGIBBON A W. Damped Newton algorithms for matrix factorization with missing data[C]//Conference on Computer Vision and Pattern Recognition. San Diego: IEEE, 2005: 316-322.
- [5] CHEN Pei. Optimization algorithms on subspaces: revisiting missing data problem in low-rank matrix[J]. International Journal of Computer Vision, 2008, 80(1):125-142.
- [6] OKATANI T, YOSHIDA T, DEGUCHI K. Efficient algorithm for low-rank matrix factorization with missing components and performance comparison of latest algorithms[C]//International Conference on Computer Vision. Barcelona: IEEE, 2011: 842-849.
- [7] TORRE F D L, BLACK M J. A framework for robust subspace learning[J]. International Journal of Computer Vision, 2003, 54(1/2):117-142.
- [8] KE Q, KANADE T. Robust L_1 norm factorization in the presence of outliers and missing data by alternative convex programming[C]//Computer Society Conference on Computer Vision and Pattern Recognition. San Diego: IEEE, 2005: 739-746.
- [9] ERIKSSON A, VAN D H A. Efficient computation of robust low-rank matrix approximations in the presence of missing data using the L_1 norm[C]//Computer Society Conference on Computer Vision and Pattern Recognition. San Francisco: IEEE,

2010; 771-778.

- [10] MENG Deyu, XU Zhongben, ZHANG Lei, et al. A cyclic weighted median method for L_1 low-rank matrix factorization with missing entries[C]//Proceedings of the Twenty-Seventh AAAI Conference on Artificial Intelligence. Bellevue: AAAI, 2013: 704-710.
- [11] KIM H, PARK H. Sparse non-negative matrix factorizations via alternating nonnegativity-constrained least squares for microarray data analysis[J]. Bioinformatics, 2007, 23(12):1495-1502.
- [12] MIN Wenwen, LIU Juan, ZHANG Shihua. Group-sparse SVD models via L_1 and L_0 norm penalties and their applications in biological data[J]. IEEE Transactions on Knowledge and Data Engineering, 2019, 33(2):536-550.
- [13] LAKSHMINARAYANAN B, BOUCHARD G, ARCHAMBEAU C. Robust Bayesian matrix factorization[C]//Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics. New York: JMLR, 2011: 425-433.
- [14] SALAKHUTDINOV R, MNH A. Probabilistic matrix factorization[J]. Advances in Neural Information Processing Systems, 2007, 20(2):1257-1264.
- [15] WANG Naiyan, YAO Tiansheng, WANG Jingdong, et al. A probabilistic approach to robust matrix factorization[C]//European Conference on Computer Vision. Florence: Springer, 2012: 126-139.
- [16] SADDIKI H, MCAULIFFE J, FLAHERTY P. GLAD: a mixed-membership model for heterogeneous tumor subtype classification[J]. Bioinformatics, 2014, 31(2):225-232.
- [17] MENG Deyu, TORRE F D L. Robust matrix factorization with unknown noise[C]//International Conference on Computer Vision. Sydney: IEEE, 2014: 1337-1344.
- [18] CAO Xiangyong, ZHAO Qian, MENG Deyu, et al. Robust low-rank matrix factorization under general mixture noise distributions[J]. IEEE Transactions on Image Processing, 2016, 25(10):4677-4690.
- [19] XU Shuang, ZHANG Chunxia, ZHANG Jianshe. Adaptive quantile low-rank matrix factorization[J]. Pattern Recognition, 2020, 103:1-16.
- [20] WANG Haohui, ZHANG Chihao, ZHANG Shihua. Robust Bayesian matrix decomposition with mixture of Gaussian noise[J]. Neurocomputing, 2021, 449:108-116.
- [21] DEMPSTER A P, LAIRD N M, RUBIN D B. Maximum likelihood from incomplete data via the EM algorithm[J]. Journal of the Royal Statistical Society: B, 1977, 39(1):1-38.
- [22] ZHENG Yinqiang, LIU Guangcan, SUGIMOTO S, et al. Practical low-rank matrix approximation under robust L_1 -norm[C]//Conference on Computer Vision and Pattern Recognition. Providence: IEEE, 2012: 1410-1417.

(编辑:于善清)