

分类号: TP391

U D C: D10621-308-(2019)0806-0

密 级: 公 开

编 号: 3160601006

成 都 信 息 工 程 大 学

硕 士 学 位 论 文

姓 名	张禹涵
学 号	3160601006
学 院	计算机学院
学 位 类 型	☒ 学术型 ☐ 专业学位
学 习 形 式	☒ 全日制 ☐ 非全日制
专 业 / 领 域	计算机应用技术
研 究 方 向	人工智能
校 内 导 师	符 颖 副 教 授
校 外 导 师	
论 文 完 成 时 间	2019 年 6 月

摘要

核磁共振是一种安全的活体成像技术，由这种成像技术得到的图像即为核磁共振图像(Magnetic Resonance Images, MRI)。医生通过 MRI 能够准确且快速地确认病人病情，确保最佳的治疗时机。因此，MRI 是帮助医生诊断病人病情的重要医学工具，但 MRI 在成像或者传输过程中易受噪声污染。这些噪声不仅严重影响医生对于病人病情诊断的精确性，还影响计算机对 MRI 后续处理的有效性，例如 MRI 的分割，配准和分类。MRI 中的纹理和细节结构包含重要的医学信息，在去除噪声的同时应尽可能地保留 MRI 本身的信息。因此，MRI 去噪算法的研究具有重要的意义和价值。

图像去噪是图像处理中一类常见的反问题，因而为了得到真实的解，需要限制解空间的大小。常见使去噪问题良态化的方法是在模型中引入图像先验，得到相应的正则项来限制图像的解空间。低秩矩阵分解去噪模型因其较好的去噪性能，近几年已成为研究的热点，但随着噪声强度的增加，噪声大大破坏图像的低秩性，该模型的去噪结果中会出现去噪不充分的情况。本文的研究内容是在低秩矩阵分解去噪模型中引入核磁共振图像的先验信息来提升模型的去噪效果，在去除噪声的同时最大程度地保留 MRI 本身的细节信息。本文主要研究内容如下：

（1）基于块先验的 MRI 低秩矩阵去噪算法

图像块中包含着丰富的结构信息，能为图像去噪提供足够的先验信息。本文将无噪核磁共振图像块的先验与核磁共振图像块的非局部自相性先验结合，通过学习的方式，用高斯混合模型来表征无噪核磁共振图像块的先验信息，然后基于图像块的非局部自相性，使用带有无噪核磁共振图像块先验的高斯混合模型对噪声核磁共振图像块进行聚类以保持图像块矩阵的低秩性，从而提升低秩矩阵分解模型的去噪效果。实验结果表明，无噪核磁共振图像块先验能较好地引导噪声图像块聚类，有助于低秩矩阵分解模型去噪性能的提升。

（2）基于梯度稀疏先验的 MRI 低秩矩阵去噪算法

为消除图像重建过程中由于图像块聚合操作造成的振铃效应，用超拉普拉斯分布来拟合MRI的梯度稀疏性，在模型中添加基于梯度稀疏性的超拉普拉斯正则项。实验结果表明，添加了超拉普拉斯正则项的低秩矩阵分解去噪算法能有效地抑制振铃效应的产生，在峰值信噪比上有约为2.8%的提升。同时，实验还对比分析了其他MRI去噪算法，实验结果表明，高噪声条件下，本文研究的基于图像先验的低秩矩阵分解MRI去噪算法能有效地去除噪声并较大程度地保留MRI本身的信息，在峰值信噪比和结构相似性两个客观图像评价指标上均有较大提升。

关键词：MRI去噪，高斯混合模型，自相似性，梯度稀疏性，低秩矩阵

ABSTRACT

Magnetic Resonance Imaging (MRI) is an effective and useful tool for medical diagnosis. However, the noise generated during image acquisition or transmission damages the MRI quality and seriously reducing the accuracy of these diagnoses. The noisy, low-quality MRI image affects the accuracy of automated computer analyses, such as classification, segmentation, and registration. The texture and detail structure in MRI contain important medical information, which should be preserved as much as possible while removing noise. Therefore, research into MRI denoising has become significant for obtaining high-quality MRI output.

Image denoising as an inverse problem is ill-posed. In order to get the true solution, it is necessary to limit the size of solution space. A common way to make the denoising problem well-conditioned is to introduce image prior in the model and obtain the corresponding regularization term to restrict the solution space. Denoising methods based on low rank matrix has become a research hotspot in recent years due to its good denoising performance. However, with the increase of noise level, the noise greatly influences the low rank of the image, and results in the denoising performance's insufficiency of the model. The research content of this paper is to introduce the prior information of MRI into the low rank matrix factorization denoising model to improve the denoising performance, so as to achieve the purpose of removing the noise in MRI and retaining the details of the MRI to the greatest extent. The main research contents of this paper are as follows:

(1) Image patches contain abundant structural information, which can provide sufficient prior for denoising. This paper combines the prior of noise-free MR image patches with the prior of non-local self-similarity of MR image patches. We characterize the prior of noise-free MR image patches by using the Gauss mixture model through learning. Then, based on the non-local self-similarity, image patches are clustered under the guidance of the learned Gaussian mixture model, so as to maintain the low-rank of image patch matrix and improve the denoising effect of the low rank matrix decomposition model. The experimental results show that the Gaussian mixture model with noise-free MR image patches prior can effectively guide the clustering of noisy image patches and help to improve the denoising performance of low rank matrix decomposition algorithm.

(2) In order to reduce the ringing artifacts caused by image patch aggregation in image reconstruction, the gradient sparsity of MRI is fitted by the Hyper Laplacian distribution, and a Hyper Laplacian regularization term based on gradient sparsity of MRI is added to the low rank matrix decomposition denoising model. The experimental results show that the algorithm with Hyper Laplacian terms in the model can effectively suppress ringing effect, and have an improvement of about 2.8% in peak signal-to-noise ratio. At the same time, several MRI denoising algorithms are compared with our method. The corresponding experimental results show that the low rank decomposition denoising algorithm based on MRI prior in this paper can retain the information of MRI itself to a large extent while removing noise effectively, and have a great improvement both in peak signal-to-noise ratio and structural similar image metric.

Key words: MRI denoising, Gaussian mixture model, Self-similarity, Gradient sparsity, Low rank matrix

目 录

论文总页数：55 页

第一章 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.3 本文主要工作及创新点	5
1.4 论文的组织结构	5
第二章 MRI 与去噪相关知识	7
2.1 MRI 成像原理	7
2.2 图像质量评价指标	8
2.2.1 均方误差	8
2.2.2 峰值信噪比	8
2.2.3 结构相似性	9
2.3 噪声	10
2.3.1 噪声模型	10
2.3.2 MRI 中噪声特性	12
2.4 MRI 去噪算法	13
2.4.1 各向异性滤波	13
2.4.2 非局部均值滤波	14
2.4.3 块匹配三维滤波	15
2.5 本章小结	17
第三章 基于块先验的 MRI 低秩矩阵去噪算法	18
3.1 低秩矩阵去噪相关理论	18
3.2 基于图像块先验的 MRI 低秩矩阵分解去噪算法	21
3.2.1 基于 GMM 的图像块聚类原理	21
3.2.2 去噪模型	22
3.3 实验与结果分析	25
3.3.1 参数估计	26
3.3.2 仿真实验结果及分析	28
3.3.3 真实实验结果及分析	30
3.4 本章小结	31
第四章 基于梯度稀疏先验的 MRI 低秩矩阵去噪算法	32

4.1 图像梯度.....	32
4.2 MRI 梯度性质.....	33
4.3 基于超拉普拉斯正则项的 MRI 低秩矩阵分解去噪算法.....	36
4.4 实验与结果分析.....	39
4.4.1 合成数据实验结果及分析.....	40
4.4.2 临床数据实验结果及分析.....	44
4.5 本章小结.....	46
第五章 总结与展望.....	47
5.1 总结.....	47
5.2 展望.....	47
参考文献.....	49
作者在读期间科研成果简介.....	54
致 谢.....	55

第一章 绪论

1.1 研究背景及意义

磁共振成像是一种利用巨型磁铁的强磁场来得到人体图像构造的活体成像技术，其原理可简化为：利用巨型磁铁产生强磁场使人体中的水分子与产生的磁场方向保持一致；然后断掉磁铁产生的磁场，让与磁场方向保持一致的水分子恢复到无磁场时的排列状态，在这一过程得到的人体图像即为核磁共振图像（Magnetic Resonance Image, MRI）。相比其他基于射线原理得到的医学图像，如 CT 断层扫描和 X 射线，基于核磁共振（Nuclear Magnetic Resonance, NMR）物理原理得到的核磁共振图像，在软组织成像上有更大的优势，能够得到更高分辨率的图像，也能更清楚地反映人体身体状况，有助于医生对肝内和颅内等小病灶病情的诊断。

MRI 能清楚地反映人体内的组织结构状况，是医生诊断病情的有效辅助工具，但 MRI 在成像或传输过程中易受噪声污染，得到的核磁共振图像往往带有噪声，这些噪声会使得图像中的组织边界模糊或不规则，给医生诊断病情带来较大的障碍。MRI 去噪一般从两个方向着手^[1]。一类是用时间换质量，在成像过程中通过增加扫描时间，使信噪比增加来提高图像质量。但在实际成像过程中，考虑到病人的舒适度和系统的工作效率，采集时间受限，因此图像的信噪比无法大幅度改善；另一类方法是对采集成功后的 MRI 做去噪处理。相比在采集过程中增加采集时间来提高信噪比的做法，对含有噪声的 MRI 进行去噪处理，更行之有效。MRI 去噪算法的目的是降低噪声功率，但 MRI 本身又包含着特殊的信息，并且人体不同部位的核磁共振图像具有不同的特点，对其做处理时应尽可能地保留这些细节信息。因此，研究 MRI 的去噪方法是很有必要和价值的。

图像去噪是图像处理中一种常见逆问题，通常通过引入图像本身的先验信息来使问题良态化，使得去噪结果更接近真实图像。图像的先验有很多，常见的有自相似性、局部平滑性、低秩性、稀疏性、统计特性和梯度稀疏性等等^[2-5]。图像中存在着相似或重复区域的性质被称为图像的自相似性；相邻像素点间的像素值相同或者变化很小这一特性被称作为图像的局部平滑性；稀疏性是指图像能被分解为许多独立不相关的分量^[6]；统计特性是指通过对大量图像进行建模、分析而得出的一般规律^[6]；图像中像素点之间的差值称为图像的梯度，因此图像梯度的稀疏性是指图像中大部分像素值之间的差值很小，几乎为零的性质；从线性代数矩阵的角度看，图像低秩性是指图像矩阵的低秩性，由于图像中存在较多重复的部分，因此图像矩阵的秩是远小于图像矩阵本身的行列数的，这一特性被称为图像的低

秩性。图像中包含的先验信息很丰富，在实际的去噪过程中如何合理地运用这些先验信息是取得好的去噪效果的关键。

1.2 国内外研究现状

许多 MRI 的去噪方法原本是针对自然图像提出的，因其在自然图像上取得比较好的去噪结果，转而被应用到医学图像领域，图 1-1 给出了图像去噪方法的分类示意图。如图 1-1 所示，图像去噪方法可分为基于滤波的方法，变换域方法，统计学习方法以及基于低秩的方法。

基于滤波的去噪方法是研究较多的去噪方法。1985 年，McVeigh 等人针对 MRI 中的高斯白噪声提出了基于空间和时域的滤波器^[7]。空间滤波器去噪的原理是减少图像中的高频信息。而图像中的纹理、边缘和噪声同属于高频信号，因此在空间滤波器去噪过程中，纹理和边缘信息等高频信号可能被当做噪声去除，导致该滤波器去噪结果中图像细节信息丢失严重，出现去噪结果趋于平滑的情况。典型的线性空间滤波器有均值滤波和高斯滤波^[8]。与空间滤波器去噪原理不同，时域滤波器则是通过选择合适的采样间隔来消除伪影和噪声。去噪效果与采样频率息息相关，若采样频率较小，时间滤波器会减弱图像边缘的信号；如果采样频率太大则可能引入额外的噪声^[9]。




图 1-1 图像去噪方法分类示意图

为了克服空间滤波器在去除噪声的同时会使得图像细节信息丢失的缺点, Perona 和 Malik 等人于 1990 年提出了各向异性滤波器(Anisotropic Diffusion Filter, ADF)^[10]。ADF 基于扩散方程来实现去噪和保留图像边缘。在 ADF 去噪过程中, 扩散方程中的扩散算子通过调整不同方向上(垂直方向和水平方向)局部梯度的强度来控制边界处的平滑情况, 因而 ADF 能克服空间滤波器的缺点, 实现保留图像边界、消除均匀区域的噪声和锐化图像边缘的目的。1992 年, Gerig 等人将 ADF 应用到二维和三维的 MRI 中, 用来去除均值为零的高斯白噪声^[11]。2009 年, Krissian 和 Aja-Fernandez 等人针对 MRI 中的莱斯噪声, 提出基于噪声驱动的各向异性滤波器^[12], 该滤波器在偏微分方程中用扩散矩阵代替扩散方程, 实现了标量到矢量的转换, 这种基于结构张量的特征向量将各向同性和线性局部结构的平滑性相结合, 能更好地消除图像边缘处的噪声^[1]。同时, 该滤波器每次迭代都使用线性最小均方误差滤波器, 且对噪声水平进行了估计, 所以该滤波器能够快速收敛, 总的扩散时间比较稳健。Buades 等人利用图像的冗余性, 提出基于图像块非局部自相似性的非局部均值去噪方法(Nonlocal Means, NLM)^[13], 打破了利用邻近小范围内的像素点来去除噪声的模式。Manjón 等人将 NLM 运用到二维 MRI 去噪中, 取得了很不错的去噪结果^[14]。由于 NLM 算法在去噪过程中需要计算每个像素点的权重, 时间开销较大, 若直接将 NLM 运用到三维 MRI 图像去噪中, 会使算法的时间复杂度急剧上升。为解决这个问题, Coupe 等人提出了 NLM 的多线程并行优化方法, 极大地缩短了运行时间^[15]。

除了基于滤波的方法, 基于变换域的方法也是常见的去噪方法, 其原理是把噪声图像投影到变换域得到变换系数, 通过分离图像信号和噪声信号的变换系数来达到将图像信号和噪声信号分离开来的目的, 再对图像信号的变换系数进行逆变换投影回到空域从而实现去噪^[16]。小波变换和块匹配三维滤波算法^[17](Block Match and 3-D Filtering, BM3D)都是常见的变换域去噪算法。小波变换方法的主要缺点是去噪过程中会消除图像中与噪声相似的小细节结构信息。BM3D 算法则将图像的非局部自相似性和小波变换方法结合, 一定程度上克服了小波变换方法的缺陷, 取得了很好的去噪效果, 因此常常被作为去噪算法的基准线, 此算法也已被用于 MRI 复原中^[18]。基于小波变换的去噪方法除了前文所述的缺点, 该类方法的另一个缺点是适用场景有限。比如该方法不适合描述边缘之类的高维信号和不能有效表示边缘光滑的图像区域。针对小波方法不能表示边缘等高维信号的缺点, Cande 和 Donoho 提出用各向异性和方向性来表示边缘方向的曲波变换^[19]; 针对小波变换方法不能有效表示光滑边缘图像区域的缺点, Do 和 Vetterli 等人提出了

具有捕捉图像轮廓和图像细节特性的轮廓波变换^[20]。Latha 等人将轮廓波变换方法用于 MRI 去噪中^[21]。

近几年，基于统计学习的去噪方法逐渐成为研究热点，特别是基于字典学习和基于图像块先验知识学习的方法^[6, 22]。基于字典学习这一类方法的去噪原理是利用图像的稀疏性，通过训练在大量图像数据集上得到一个冗余字典，再用训练得到的字典表示噪声图像，从而达到去噪的目的。Mairal 等人提出的同步稀疏表示算法（LSSC）将图像结构性和字典学习结合，进一步提升了基于字典学习方法的去噪性能^[23]。虽然基于字典学习的去噪方法取得了很好的效果并被应用于 MRI 中^[24]，但此种去噪方法忽略了图像本身的自相似性，且字典训练是一个非常费时的过程。图像块中包含丰富的局部结构信息，能够对图像去噪提供足够的先验信息，并且对小块图像进行去噪会大大减少计算量，提高计算效率。Yu 等人证明高斯混合模型和基于期望最大化的最大后验算法（MAP-EM）能为图像处理中的反问题提供通用且高效的解决方案，并由此提出了基于图像块的分段线性估计（Piecewise Linear Estimator, PLE）算法来求解图像反问题^[25]。Daniel 等人利用高斯混合模型对无噪图像块先验进行学习，提出块似然对数期望（Expected Patch log Likelihood, EPLL）算法^[26]。Daniel 等人还证明相比主成分分析（Principal Component Analysis, PCA），高斯模型等其他模型，高斯混合模型更适合对图像块信息进行统计建模。Chen 等人也利用高斯混合模型对图像块先验进行统计建模，提出了图像块聚类低秩正则化去噪算法^[27]。

矩阵的秩从数学定义上来看是指矩阵中行列式不为零的最大子式的阶数，是矩阵行或列中线性无关的最大行数或列数，因此秩能够很好地反映矩阵行或列的相关性。2011 年，Ma 等人发现并证明，在某些特定假设下，矩阵能分解成一个低秩矩阵和一个稀疏矩阵之和^[28]，这为低秩矩阵复原图像奠定了基础。近年来，利用低秩矩阵来对图像进行去噪也成为了热点。Liu 和 Wright 等人^[29, 30]利用这个观点，结合图像和噪声本身的特点，提出一种基于低秩矩阵分解去噪算法，通过对低秩矩阵进行核范数约束保证低秩性，对噪声进行稀疏约束保证稀疏性来对图像进行恢复，达到去噪的目的。但当噪声强度较大时，高强度噪声会削弱图像矩阵行列之间的相关性，破坏图像矩阵原有的低秩性。若在低秩去噪模型中对矩阵低秩性和噪声的稀疏性约束均保持不变，则会导致该模型的去噪性能下降，噪声残留于图像矩阵中。王圳萍等人通过在模型中添加全变差正则项来提升低秩去噪算法的去噪效果^[22]。Liu 等人通过引入 F 范数作为新的正则项来增强图像解的稳定性^[29]。低秩矩阵的求解可以利用奇异值分解 SVD 来求解，文献^[27]中提到，结构相

似的图像块聚集在一起能够使保留下来的特征值最大化，从而提高基于 SVD 求解的低秩矩阵分解算法的去噪性能。同样，基于低秩矩阵分解的去噪方法已被应用于 MRI 去噪中^[31]。

由于计算机硬件的飞速发展和海量数据集的开源，深度学习成为近两年的研究热点，许多研究人员也将其应用到图像去噪领域中。2012 年，Harmeling^[32]等人提出多层感知机(Multi layer perceptron, MLP)，取得了和 BM3D 类似的去噪效果。2014 年，Schmidt 等人提出的收缩领域级联算法(Cascade of Shrinkage Fields, CSF)^[33]和 Chen 等人于 2015 年提出的学习优化反应扩散过程的图像恢复算法^[34]均学习几层了滤波，都取得了较好的图像复原效果。2017 年，Mao 等人针对图像去噪和超分辨率重建中存在的问题，提出一种完全卷积编码和解码网络模型^[35]。虽然基于深度学习的去噪方法取得了不错的去噪效果，但该类方法需要丰富的数据集来训练神经网络的参数，相比自然图像较为丰富的数据集，医学图像的数据集获取相对艰难，所以以上基于深度学习的去噪方法均是针对自然图像，可能也正是由于这个原因，深度学习相关的医学图像去噪方法研究得相对较少。

1.3 本文主要工作及创新点

本文研究了基于图像先验的低秩矩阵分解 MRI 去噪算法，主要工作及创新点如下：

(1) 结合无噪图像块先验和图像块的非局部自相性，提出一种基于块先验的 MRI 低秩分解去噪算法。该算法使用带有无噪核磁共振图像块先验的高斯混合模型对噪声核磁共振图像块进行聚类，来保持核磁共振图像块矩阵的低秩性，以达到提升低秩矩阵分解模型去噪效果的目的。其中高斯混合模型的参数（均值，协方差矩阵以及权重）是通过对无噪核磁共振图像块进行学习训练得到的，因此得到高斯混合模型是带有无噪核磁共振图像块先验信息的。

(2) 在基于块先验的低秩矩阵分解去噪算法的基础上，利用超拉普拉斯分布来拟合 MRI 梯度的稀疏性，在模型中添加超拉普拉斯正则项来去除振铃效应，进一步提升低秩矩阵分解去噪算法的去噪效果，在去噪的同时尽可能地保留 MRI 本身的信息。

1.4 论文的组织结构

本文的主要内容和结构描述如下：

第一章为绪论。本章主要由以下内容构成：本文的研究背景和意义，MRI 去噪方法的国内外研究现状，对这些方法的归纳总结以及本文的主要研究工作、创

新点和文章的组织结构。

第二章为 MRI 成像和去噪相关知识。主要内容为 MRI 成像原理，图像质量评价指标，噪声模型以及相关去噪算法的原理介绍。

第三章为基于块先验的 MRI 低秩矩阵分解去噪算法，该章主要由三个部分组成。第一部分介绍低秩矩阵去噪算法相关原理；第二部分研究基于图像块先验的 MRI 低秩矩阵分解去噪算法，利用带有无噪图像块先验的高斯混合模型对噪声图像块进行聚类来提升低秩矩阵分解算法的去噪效果。第三部分内容是实验结果与分析，主要内容为实验环境、数据来源、模型中参数的说明以及实验结果的分析等组成。

第四章为基于梯度稀疏先验的 MRI 低秩矩阵分解去噪算法，主要研究振铃效应的消除。该章主要由三个部分构成，首先研究了 MRI 梯度的稀疏性质以及用超拉普拉斯分布拟合 MRI 梯度性质的合理性；其次，在第三章研究内容的基础上，在模型中添加基于梯度稀疏先验的超拉普拉斯正则项，得到本文最终的去噪模型；最后一部分内容是实验结果与分析，展示实验结果并进行分析，通过实验验证提出模型的有效性。

第五章为总结与展望。本章主要内容是对全文的研究内容进行总结并在展望中提出本文研究内容的不足以明确后续研究方向。

第二章 MRI 与去噪相关知识

2.1 MRI 成像原理

人体的主要成份是碳水化合物，其中水约占总成分的 55%，即人体内存在大量的水分子，因此也存在着大量的氢原子，氢原子核的质子在无外加磁场的情况下会进行自旋运动并产生磁场。由于各质子自旋运动的方向是随机的，因此产生磁场的方向也是随机的。在无外加磁场的情况下，各磁场相互抵消，人体内各氢原子自旋轴排列是随机无规律的，一旦加入外部磁场，就会统一各氢质子的自旋轴线方向，自旋的质子在外部磁场的作用下会发生和陀螺一样的进动，这种运动被称为拉莫尔进动（Larmor precession）。对进行拉莫尔进动的质子施加一定频率的射频，使其出现共振现象；随后停止射频脉冲，让所有的氢原子回到初始排列状态，在这个过程中氢原子核会释放之前吸收到的能量形成射电信号，要得到检查部位的核磁共振图像只需要检测出这些信号并对这些信号进行空间分辨。简单来说 MRI 就是在外强磁场的作用下，记录人体组织内氢原子原子核运动，经计算和处理后得到的图像。

核磁共振图像类型与弛豫过程相关，不同弛豫过程得到不同类型的核磁共振图像。弛豫过程是指原子核在一定条件下由激化状态回到平衡排列状态的过程^[36]。根据弛豫过程的不同，MRI 可以分为 T1 权重图像和 T2 权重图像。部分高能级氢质子释放能量后重新回到低能级的过程叫纵向弛豫，因纵向弛豫又被称为 T1 弛豫，因此得到的图像称为 T1 加权图像；同相氢质子间由于互相的排斥作用而逐渐失相的过程叫横向弛豫，同理，横向弛豫又称 T2 弛豫，因此得到的图像是 T2 加权图像。除此之外，反映组织间质子密度弛豫时间差别的 MRI 被称为质子密度加权 (PDW) 图像^[37]。图 2-1 给出了这三种 MRI 的示意图，如图所示图 2-1 (a) 是 T1 加权图像，图 2-1 (b) 是 T2 加权图像，图 2-1 (c) 是 PD 加权图像。



图 2-1 不同类型的 MRI 示意图

2.2 图像质量评价指标

图像质量评价指标对于算法的比较有重要的参考意义，通过对图像的特性进行分析研究，然后评估出图像失真程度的过程就叫做图像质量评价。图像质量评估方法从宏观上可以分成主观方法和客观方法^[38]。主观方法是指人通过视觉感官对图像质量作出定性判断。由于主观评价方法是通过人的主观感受得出的结果，不同的人会有不同的主观感受，因此没有明确的标准^[39]。客观评价是指通过某种数学模型得出图像质量结果，是对图像质量进行定量判断的方法。根据有无理想图像作为参考，客观图像质量评价模型有如下三种：无参考，半参考和全参考^[40]。无参考评价模型是指独立于理想图像的评价方法，一般用图像的统计特性指标来对图像质量进行评价。半参考质量评价模型是指以理想图像的部分特征作为参考，与评估图像的对应的部分特征进行分析对比，考察待评估图像与理想图像特征的相似性，从而得出质量结果的评价方法^[41]。在图像评价过程中参考原始图像全部信息的评价模型被称为全参考质量评价模型，此种评价模型可分成三类：基于结构相似度的方法，基于自然场景分析的方法以及基于视觉信息保真度的方法。本文所用的图像质量评价指标均属于全参考质量评价指标，下面分别介绍这些评价指标的计算方式。

2.2.1 均方误差

均方误差（Mean Square Error, MSE）是刻画参考的理想图像与待评价图像差异大小的指标。设参考理想图像为 f ，待评价图像为 g ，它们的尺寸大小为 $M \times N$ ，MSE 计算的是理想图像与待评价图像中所有同一坐标 (x, y) 上像素值误差平方和的均值，其计算公式如式子（2-1）所示：

$$MSE(f, g) = \frac{1}{MN} \sum_{i=1}^M \sum_{j=1}^N (f(i, j) - g(i, j))^2 \quad (2-1)$$

从 MSE 的定义可以看出，该指标计算了整幅图像的误差，因此，MSE 越小，说明待评估的图像越接近理想图像，质量越好。当图像尺寸较大时，MSE 值相应较大，为使表达简洁，常常对 MSE 开平方根得到均方误差根（Root Mean Square Error, RMSE）来作为评价指标。

2.2.2 峰值信噪比

峰值信噪比（Peak Signal-to-Noise Ratio, PSNR）可通过 MSE 来定义的，式子（2-2）给出了 PSNR 的计算公式：

$$PSNR(f, g) = 10 \log_{10} \left(\frac{L^2}{MSE(f, g)} \right) \quad (2-2)$$

其中， L 是峰值信号，8 位灰度图像中 L 为 255，则式子（2-3）可写作：

$$PSNR(f, g) = 10 \log_{10} \left(\frac{255^2}{MSE(f, g)} \right) \quad (2-3)$$

从式子（2-2）和（2-3）可以看出，MSE 越小即 f 和 g 之间误差越小时，PSNR 值越大。因此，PSNR 值越大，待评估图像越接近理想图像，质量越好。MSE 和 PSNR 只是从像素值的角度刻画了理想图像 f 和待评估图像 g 之间的误差，未能考虑人体视觉系统特性，因此可能出现 MSE 值较低或 PSNR 值较高，但人体视觉感受较差的情况。

2.2.3 结构相似性

虽然用 MSE 和 PSNR 作为评价指标来评价图像质量，简单且容易计算，但这两种指标未考虑到图像的结构，评价结果可能与人体感官不一致。而结构相似性（Structural Similar Image Metric, SSIM）则克服了这个缺点，从三个方面（亮度，对比度以及结构）来刻画理想图像 f 和待评估图像 g 之间的相似性，使得评价结果更符合人体感官。

亮度对比计算公式如式子（2-4）所示：

$$l(f, g) = \frac{2\mu_f \mu_g + c_1}{\mu_f^2 + \mu_g^2 + c_1} \quad (2-4)$$

对比度对比计算公式如式子（2-5）所示：

$$c(f, g) = \frac{2\sigma_f \sigma_g + c_2}{\sigma_f^2 + \sigma_g^2 + c_2} \quad (2-5)$$

结构对比计算公式如式子（2-6）所示：

$$s(f, g) = \frac{2\sigma_{fg} + c_3}{\sigma_f \sigma_g + c_3} \quad (2-6)$$

考虑亮度，对比度和结构三方面 SSIM 的计算公式如式子（2-7）所示：

$$SSIM(f, g) = (l(f, g))^\alpha \cdot (c(f, g))^\beta \cdot (s(f, g))^\gamma \quad (2-7)$$

其中 μ_f 、 μ_g 、 σ_f 和 σ_g 分别是参考的理想图像 f 和待评价图像 g 的均值和标准

差: σ_{fg} 是 f 和 g 的协方差。 $c_1 = (k_1 R)^2$ 、 $c_2 = (k_2 R)^2$ 和 $c_3 = c_2 / 2$ 为常数, 其中 R 为图像像素值范围, 且根据经验 k_1 和 k_2 分别取 0.01 和 0.03; 通常 $\alpha = \beta = \gamma = 1$, $SSIM \in [0, 1]$ 。
 $SSIM \rightarrow 1$ 则说明待评估图像 g 与理想参考图像 f 相似度很高, g 的图像质量好。

2.3 噪声

图像去噪的目的是去除图像中的噪声信号并尽可能地逼近真实图像信号。令 (x, y) 为图像中某个像素点的坐标, I_{Input} 为噪声图像, I_{Out} 为去噪图像, N 为噪声。如图 2-2 所示, 给定一个观测噪声图像 I_{Input} , 目的是求得原始图像的一个估计 $\hat{I}_{Out}$, 去噪过程通常被如公式 (2-8) 所示的模型表示:

$$I_{Out}(x, y) = N(x, y) + I_{Input}(x, y) \quad (2-8)$$




图 2-2 去噪过程示意图

2.3.1 噪声模型

噪声常产生于图像获取或传输过程中, 噪声名称大多来自于其概率服从的分布, 下面介绍几种常见噪声及其概率密度函数。

(1) 高斯噪声

高斯噪声是自然界中最常见的噪声之一, 常见于电子电路噪声和传感器噪声中, 其概率密度函数如公式 (2-9) 所示:

$$p(z) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(z-\bar{z})^2 / 2\sigma^2} \quad (2-9)$$

其中 z 为灰度值, $\bar{z}$ 、 σ 分别为 z 的均值和标准差。

(2) 瑞利噪声

瑞利噪声产生于激光脉冲在光纤的传输过程中，且可由两个高斯分布叠加得到，其概率密度函数如式（2-10）所示：

$$p(z) = \begin{cases} \frac{2}{b}(z-a)e^{-(z-a)^2/b}, & z \geq a \\ 0, & z < a \end{cases} \quad (2-10)$$

其中， a 、 b 为参数，该噪声概率密度函数的均值和方差分别是 $a + \sqrt{\pi b/4}$ 和 $\frac{b(4-\pi)}{4}$ 。

（3）伽马噪声

伽马噪声又名爱尔兰噪声，其概率密度函数如式（2-11）所示：

$$p(z) = \begin{cases} \frac{a^b z^{b-1}}{(b-1)!} e^{-az}, & z \geq a \\ 0, & z < a \end{cases} \quad (2-11)$$

其中， $a > 0$ ， b 为正整数，其概率密度函数的均值为 $\frac{b}{a}$ ，方差为 $\frac{b}{a^2}$ 。

（4）指数噪声

当式子（2-11）中的参数 $b=1$ 时，伽马噪声就退化为指数噪声，其概率密度函数如式（2-12）所示：

$$p(z) = \begin{cases} ae^{-az}, & z \geq 0 \\ 0, & z < 0 \end{cases} \quad (2-12)$$

（5）均匀噪声

均匀噪声的密度函数如式（2-13）所示：

$$p(z) = \begin{cases} \frac{1}{b-a}, & a \leq z \leq b \\ 0, & \text{其他} \end{cases} \quad (2-13)$$

（6）脉冲噪声

脉冲噪声的概率密度函数如式（2-14）所示：

$$p(z) = \begin{cases} P_a, & z = a \\ P_b, & z = b \\ 1 - P_a - P_b, & \text{其他} \end{cases} \quad (2-14)$$

根据 p_a 或 p_b 的不同情况，脉冲噪声会退化成单极脉冲噪声或者椒盐噪声。单极脉冲噪声是指当 p_a 或 p_b 不同时为零时的情况；椒盐噪声指 p_a 或 p_b 均不为零或近似相等

时的情况。

2.3.2 MRI 中噪声特性

2.3.1 小节介绍的噪声均是基于噪声与图像中的像素值相互独立的假设前提下，但在基于磁共振原理得到的 MRI 中，噪声依赖于图像信号，因此这个假设是不成立的^[42]。图 2-3 中给出了无噪仿真 MRI 和外加 15% 莱斯噪声后的噪声 MRI 的示意图。

设 $\mathbf{x}$ 为无噪 MRI 信号，则 $\mathbf{x}$ 可表示为： $\mathbf{x} = \sqrt{R^2 + I^2}$ ，其中 R 和 I 为两个不相关高斯分布的实部和虚部；设 $\mathbf{y}$ 为噪声 MRI 信号， $\mathbf{y}$ 可由 R 和 I 表示，如式 (2-15) 所示：

$$\mathbf{y} = \sqrt{(R + n_{real})^2 + (I + n_{imaginary})^2} \quad (2-15)$$

其中 n_{real} 和 $n_{imaginary}$ 为两个独立不相关高斯分布，表示噪声实部与虚部的信号，且 $n_{real} \sim N(0, \sigma^2)$ ， $n_{imaginary} \sim N(0, \sigma^2)$ 。MRI 中的噪声为莱斯 (Rician) 噪声，式 (2-16) 为莱斯噪声的概率密度函数：


$$p(\mathbf{y}|\mathbf{x}, \sigma) = \frac{\mathbf{y}}{\sigma^2} e^{-\frac{\mathbf{y}^2 + \mathbf{x}^2}{2\sigma^2}} I_0\left(\frac{\mathbf{x}\mathbf{y}}{\sigma^2}\right) u(\mathbf{y}) \quad (2-16)$$

其中， $I_0(\cdot)$ ， $\mu(\cdot)$ 分别是第一类修正贝塞尔 (Bessel) 函数和单位阶跃函数，从式子 (2-16) 可知，莱斯噪声与 MRI 信号相关。图像信噪比 (Signal noise ratio, SNR) 是 $\mathbf{x}$ 与 σ 的比值，在黑暗低信噪比的 MRI 区域，噪声分布近似于瑞利分布，如式 (2-17) 所示：

$$p(\mathbf{y}, \sigma) = \frac{\mathbf{y}}{\sigma^2} e^{-\frac{\mathbf{y}^2}{2\sigma^2}} u(\mathbf{y}) \quad (2-17)$$

在明亮高信噪比 MRI 区域，莱斯噪声分布近似于高斯分布^[9]，如式 (2-18) 所示：

$$p(\mathbf{y}|\mathbf{x}, \sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{\mathbf{y}^2 - \sqrt{\mathbf{x}^2 + \sigma^2}}{2\sigma^2}} u(\mathbf{y}) \quad (2-18)$$



(a) 仿真原始 MRI

(b) 噪声 MRI (15%)

图 2-3 莱斯噪声示意图

2.4 MRI 去噪算法

目前 MRI 去噪方法主要分成三大类：滤波方法，变换域方法和统计的方法。去噪的方法较多，本小结主要介绍基于滤波和变换域的三种去噪算法：各向异性滤波，非局部均值算法和块匹配三维滤波。

2.4.1 各向异性滤波

正如 1.2 节图像去噪方法的国内外研究现状中所述，空间滤波器在去噪的过程中会将图像纹理、边缘等高频信息当做噪声去除，使得去噪结果图像趋于平滑。为克服空间滤波器的缺点，Perona 和 Malik 等人提出一种非线性的各向异性滤波器^[10]（Anisotropic Diffusion Filter, ADF），该滤波器既能保留图像边界、消除均匀区域的噪声，又能实现边缘的锐化。整个算法是基于扩散热方程和二阶偏微分方程，通过选择不同方向上的局部梯度强度来达到在去除噪声的同时又保留图像边缘的目的。为简化表达，用 y 表示噪声图像，在 ADF 去噪过程中，初始噪声图像 y 的迭代过程 y_0 如式（2-19）和式（2-20）所示：

$$\frac{\partial y(x,t)}{\partial t} = \text{div}(c(x,t)\nabla y(x,t)) \quad (2-19)$$

$$y(x,0) = y_0(x) \quad (2-20)$$

其中， $\nabla y(x,t)$ 是图像中某个像素点 x 迭代 t 次的梯度； $\frac{\partial y(x,t)}{\partial t}$ 是 $y(x,t)$ 对 t 的偏导。

$c(x,t)$ 扩散系数如式（2-21）所示：

$$c(x,t) = g\|\nabla y(x,t)\| = e^{-\|\nabla y(x,t)\|/K^2} \quad (2-21)$$

其中 K 是扩散系数。Gerig 等人将 ADF 应用到了二维和三维 MRI 去噪，取得了较

好的效果^[11]。

2.4.2 非局部均值滤波

均值滤波、中值滤波等经典滤波器均是利用局部像素来去除噪声。而图像中的噪声和边缘细节结构都属于高频信号，这些基于局部像素点信息来去除噪声的方法会将图像中细节结构当做噪声去除，往往不能很好地保留图像本身的细节信息。Budes 等人于 2005 年提出的非局部均值（NLM）滤波充分利用图像非局部的自相似性来消除噪声^[13]，能克服均值滤波和中值滤波的缺点，在去除噪声的同时保留图像中的细微结构。同样的，Manjón 等人将 NLM 算法应用于 MRI 中^[14]，下面介绍 NLM 算法原理^[13]。

设噪声图像为 $u = \{u(i) | i = (x, y) \in \mathbb{R}^2\}$ ， $NLM[u]_i$ 为去噪图像中点 i 的像素值，点 i 的像素值是通过计算图像内所有像素点的权重平均值得到，计算公式如式（2-22）所示：

$$NLM[u]_i = \sum_{j \in I} w(i, j) u(j) \quad (2-22)$$

其中， $w(i, j) \in [0, 1]$ 是 i, j 之间的权重，若 i, j 两点的像素值很相似，则 $w(i, j) \rightarrow 1$ ；

否则， $w(i, j) \rightarrow 0$ 。设 N_k 是以像素点 k 为中心的一个正方形邻域，则 i, j 之间的相似性用欧式距离来刻画： $\|u(N_i) - u(N_j)\|_{2,a}^2$ ，其中 $a > 0$ 是高斯核的标准差。在含噪的邻域内，用欧式距离来刻画像素点 i, j 之间的相似性可得到等式（2-23）：

$$E\|u(N_i) - u(N_j)\|_{2,a}^2 = \|u(N_i) - u(N_j)\|_{2,a}^2 + 2a^2 \quad (2-23)$$

从公式（2-23）可以看出， i, j 之间的相似性与灰度值向量 $u(N_i)$ 和 $u(N_j)$ 相关，遵循像素点之间越相似，其权重越大的原则，权重 $w(i, j)$ 的定义如式子（2-24）所示：

$$w(i, j) = \frac{1}{Z(i)} e^{-\frac{E\|u(N_i) - u(N_j)\|_{2,a}^2}{h^2}} \quad (2-24)$$

$$Z(i) = \sum e^{-\frac{E\|u(N_i) - u(N_j)\|_{2,a}^2}{h^2}} \quad (2-25)$$

其中， $Z(i)$ 是归一化常数；算法平滑程度与 h 相关，因此 h 是滤波参数， h 越大，NLM 的去噪能力越强； h 越小，NLM 保留图像细节的能力越强。

从式子(2-22)可以看出, NLM 算法在去噪过程中需要计算每个像素点在搜索区域内的权重值, 因此 NLM 算法时间复杂度较高。Coupe 等人提出优化的多线程并行框架来解决三维 MRI 去噪中 NLM 算法时间复杂度较高的问题^[15]。

2.4.3 块匹配三维滤波

块匹配三维滤波(Block-matching and 3D filtering, BM3D)算法将图像非局部自相似性与小波滤波变换方法相结合, 是目前取得最好效果的去噪算法之一, 因此该算法常常作为去噪算法的基准线。图 2-4 是 BM3D 算法去噪的详细流程, 从图中可以看出该算法由先后两个估计过程构成: 基础估计和最终估计^[43-45]。这两个估计过程的流程大体相似, 都可简化为三个子过程: 相似块分组, 协同滤波过程以及聚集操作。

过程一: 基础估计

(1) 相似块分组

跟 NLM 类似, BM3D 中的图像块相似性度量也是基于欧式距离, 该算法在图像的一定搜索范围内寻找若干个相似块, 并将寻找到的这些相似块联合组成三维数组。设大小为 $N_1 \times N_1$ 的初始参照块为 P , 在一定范围内搜索到的相似块为 Q , S_p 和 S_q 表示参照块 P 和相似块 Q 左上角定点的像素值, 则搜索相似块这一过程可用公式 (2-26) 表示:

$$D(P, Q) = \frac{\|S_p - S_q\|}{N_1^2} \quad (2-26)$$

其中, $D(P, Q)$ 为 P , Q 间的距离, 即 P , Q 间的相似度。计算出每个相似块与参照块的相似度后, 再根据实际情况设定合适的阈值 τ_1 , 将 $D(P, Q)$ 小于阈值 τ_1 的图像块归属于同一集合, 再将集合内的所有相似图像块形成三维数组。

(2) 协同滤波过程

协同滤波过程是将相似块分组过程得到的三维数组进行如下操作: 首先进行二维的 Bior 小波变换和一维的阿达马变换(Hadamard Transform), 得到变换系数 r ; 其次, 对三维矩阵进行硬阈值收缩; 最后, 对三维数组进行一维和二维的逆变换得到去噪的图像块。可用如式 (2-27) 所示的硬阈值收缩公式调整变换系数:

$$r(x) = \begin{cases} 0, & |x| \leq \sigma\lambda_{3D} \\ x, & |x| > \sigma\lambda_{3D} \end{cases} \quad (2-27)$$

其中， x 为相似块集合中的图像块的个数， λ_{3D} 为收缩参数， σ 为噪声标准差。




图 2-4 BM3D 去噪过程示意图

（2）聚集操作

聚集操作是将协同滤波后的三维图像块矩阵重建成去噪图像的过程。通过硬阈值收缩后，每个图像块会有一个估计值，设 N_p 为三维矩阵经过硬阈值收缩后，矩阵中非零元素的个数，则可用等式（2-28）估计权值 w_p ：

$$w_p = \begin{cases} \frac{1}{N_p}, & N_p \geq 1 \\ 1, & N_p = 0 \end{cases} \quad (2-28)$$

通过式子（2-28）得到每个图像块的估计权重值后，对聚集过程中出现重叠的图像块的估计值进行加权平均就能重建得到基础估图像。

过程二：最终估计

从图 2-4 可以看出，最终估计的子过程与基础估计的子过程大致相同，同样有

三个子过程：相似块分组，协同滤波过程，聚集操作。虽然基础估计与最终估计过程大致相似，但最终估计目的是对基础估计得到的去噪图像进行再估计^[43]。

（1）相似块分组

将基础估计得到的去噪图像分块，重复相似块搜索过程得到相似块集合，再将集合整合成新的三维数组；再对噪声图像进行同样的操作得到另一个三维数组。至此，最终估计的相似块分组得到两个不同的三维矩阵。

（2）协同滤波

与基础估计过程的协同滤波过程不同的是，最终估计的协同滤波过程是对两个三维矩阵进行小波变换，得到变换系数 r' ；然后基于估计得到的三维矩阵和噪声的方差得到维纳滤波系数，用此系数通过公式（2-29）对从噪声图像得到的三维矩阵进行维纳滤波得到最终的权重 w ：

$$w = \frac{|r'|^2}{|r'|^2 + \sigma^2} \quad (2-29)$$

（3）聚集操作

与基础估计的聚集操作类似，最终估计的聚集操作是对重叠图像块的估计值进行加权平均，得到最终估计的去噪图像。

从上述 BM3D 去噪原理可以看出，基础估计过程和最终估计过程都要进行相似块分组操作，因此该算法的时间开销主要在寻找参照块的相似块上。理论上，相同条件下，BM3D 的时间复杂度比 NLM 高。

2.5 本章小结

本章介绍了 MRI 成像原理和去噪相关基础知识。首先介绍了 MRI 成像原理和三种不同类型的核磁共振图像；其次，介绍了图像质量评价指标相关概念和三种客观评价指标的计算方法；然后，介绍了几种常见的噪声模型和 MRI 中噪声的特性；最后介绍了各向异性滤波，非局部均值滤波以及块匹配三维滤波这三种去噪算法的原理。

第三章 基于块先验的 MRI 低秩矩阵去噪算法

通常来说,图像中存在较多的相似部分,从矩阵的角度来看,图像矩阵各行或各列的相关性很高,矩阵的秩远远小于矩阵的行列数,因此图像矩阵本身是具有低秩性;图像中存在的噪声会破坏图像矩阵的相关性,使得图像矩阵的秩升高,因此低秩矩阵去噪算法就是通过对图像矩阵的秩做限制来达到去噪的目的。但当噪声强度较大时,仅对图像的秩进行低秩限制会导致去噪结果中出现较多的噪声残留。本章基于图像块自相似性,通过带有无噪核磁共振图像块先验信息的高斯混合模型引导噪声图像块聚类来增加核磁共振图像块间的相关性,从而保持或者增强图像块矩阵的低秩性,以此达到提升低秩分解算法去噪效果的目的。

3.1 低秩矩阵去噪相关理论

设 $\mathbf{Y}$ 为带噪图像, $\mathbf{I}$ 是真实无噪图像, $\mathbf{N}$ 是噪声矩阵。根据 Ma 等人理论^[28]: 一个矩阵能分解成低秩矩阵和稀疏矩阵之和, 则可将 $\mathbf{Y}$ 作如(3-1)所示的分解:

$$\mathbf{Y} = \mathbf{I} + \mathbf{N} \quad (3-1)$$

其中 $\mathbf{I}$ 为具有低秩性的真实图像矩阵; $\mathbf{N}$ 为噪声矩阵。当 $\mathbf{N}$ 是高斯白噪声时, 可用主成分分析(PCA)来求解低秩矩阵 $\mathbf{I}$ 。设 $\mathbf{Y}, \mathbf{I}, \mathbf{N} \in \mathbb{R}^{m \times n}$, $a_{i,j} \in N(0 \leq i \leq m, 0 \leq j \leq n)$, 则真实图像 $\mathbf{I}$ 可通过式(3-2)所示的模型得到:

$$\min_{\mathbf{I}, \mathbf{N}} \|\mathbf{N}\|_F, \quad \text{s.t. } \text{rank}(\mathbf{I}) \leq r, \mathbf{Y} = \mathbf{I} + \mathbf{N} \quad (3-2)$$

其中, $\|\mathbf{N}\|_F = \sqrt{\left(\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2\right)}$ 表示矩阵 $\mathbf{N}$ 的 Frobenius 范数, $r \ll \min(m, n)$ 是矩阵 $\mathbf{I}$ 的秩。

当噪声图像 $\mathbf{Y}$ 中的噪声强度较小时, 对 $\mathbf{Y}$ 进行 PCA 操作, 得到最大的前 r 个奇异值对应的向量即可求得图像 $\mathbf{I}$ 的最优解^[46]。当噪声图像 $\mathbf{Y}$ 中的噪声较大且稀疏时, 式(3-2)所示的去噪模型的去噪结果中会包含大量的噪声残留, 出现去噪不充分的情况。为解决这个问题, Ding 等人提出鲁棒主成分分析算法^[47], 算法模型如(3-3)所示:

$$\min_{\mathbf{I}, \mathbf{N}} (\|\mathbf{N}\|_0, \text{rank}(\mathbf{I})), \quad \text{s.t. } \mathbf{Y} = \mathbf{I} + \mathbf{N} \quad (3-3)$$

由于模型(3-3)中 $\mathbf{I}$ 和 $\mathbf{N}$ 均是未知变量, 在实际过程中针对不同的情况对问题的求解有所偏重, 因此在模型中引入超参数 λ 来平衡噪声矩阵 $\mathbf{N}$ 的稀疏性和真实图

像 $\mathbf{I}$ 的低秩性，式 (3-3) 变为如 (3-4) 所示：

$$\min_{\mathbf{I}, \mathbf{N}} \lambda \|\mathbf{N}\|_0 + \text{rank}(\mathbf{I}), \quad \text{s.t. } \mathbf{Y} = \mathbf{I} + \mathbf{N} \quad (3-4)$$

模型 (3-4) 中需要对矩阵的 l_0 范数进行求解，而 l_0 范数求解是一个 NP 难问题，因此对式 (3-4) 进行凸松弛，用矩阵的 l_1 范数代替 l_0 范数近似求稀疏解，再用核范数代替函数 $\text{rank}(\cdot)$ 求解低秩解，可得到式子 (3-5)：

$$\min_{\mathbf{I}, \mathbf{N}} \lambda \|\mathbf{N}\|_1 + \|\mathbf{I}\|_*, \quad \text{s.t. } \mathbf{Y} = \mathbf{I} + \mathbf{N} \quad (3-5)$$

其中 $\|\mathbf{I}\|_*$ 是表示矩阵 $\mathbf{I}$ 所有奇异值之和的核范数 (Nuclear norm)，定义如式子 (3-6) 所示：

$$\|\mathbf{I}\|_* = \text{trace}(\sqrt{\mathbf{I}^T \mathbf{I}}) = \sum_{i=1}^{\min(m,n)} \beta_i \quad (3-6)$$

$\text{trace}(\cdot)$ 是对矩阵奇异值进行求和的求迹算子； β_i 是 $\mathbf{I}$ 的第 i 个奇异值。

基于低秩矩阵的去噪方法有很多，一般可分为两类^[48]：低秩矩阵分解方法 (Low rank matrix factorization, LRMF)^[49-51] 和核范数最小化方法 (Nuclear norm minimization, NNM)^[52-54]。LRMF 是给定噪声图像 $\mathbf{Y}$ ，基于某个数据项，寻求一个矩阵 $\mathbf{I}$ 来无限接近于 $\mathbf{Y}$ ，所求得的 $\mathbf{I}$ 即为潜在的真实图像。通常 LRMF 是非凸优化的，而 NNM 通常是凸优化的，可对 $\mathbf{I}$ 的核范数进行限制来求解 $\mathbf{I}$ 。NNM 最大的优点在于它可由非凸优化的 LRMF 凸松弛得到，是 LRMF 的近似凸优化解^[48]。Candes 等人证明大多数的低秩矩阵能通过 NNM 求得^[55]，并且 Cai 等人证明用软阈值算子 (Soft thresholding operation, STO) 易求解出以 F -范数为数据项的核范数最小化复原问题^[56]。STO $S_\lambda(x)$ 可用式子 (3-7) 表示：

$$S_\lambda(x) = \text{sgn}(x) \max(|x| - \lambda, 0) = \begin{cases} x - \lambda, & x > \lambda \\ x + \lambda, & x < -\lambda \\ 0, & \text{else} \end{cases} \quad (3-7)$$

其中 $\lambda > 0$ ， $x \in \mathbf{R}$ 。式 (3-7) 是实数域的表现形式，若将 x 扩展到矩阵空间变为 $\mathbf{X} \in \mathbb{R}^{m \times n}$ ，软阈值算子 $S_\lambda(x)$ 变为奇异值收缩算子 (Singular value shrinkage operator, SVSO) $S_\lambda(\mathbf{X})$ 。若设 $\text{rank}(\mathbf{X}) = r$ ，对 $\mathbf{X}$ 进行 SVD 分解可得到等式 (3-8)：

$$\mathbf{X} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T \quad (3-8)$$

其中 $\mathbf{U} \in \mathbb{R}^{m \times r}$, $\mathbf{V} \in \mathbb{R}^{n \times r}$ 分别是 $\mathbf{X}\mathbf{X}^T$ 和 $\mathbf{X}^* \mathbf{X}$ 的特征向量; $\mathbf{\Sigma} \in \mathbb{R}^{r \times r}$ 为对角矩阵, 其対角线上的元素是 $\mathbf{X}\mathbf{X}^T$ 和 $\mathbf{X}^* \mathbf{X}$ 特征向量对应的特征值。对于正常数 λ , 奇异值收缩算子可以定义为 $S_\lambda(\mathbf{X})$, 如式子 (3-9) 所示:

$$S_\lambda(\mathbf{X}) = \mathbf{U} S_\lambda(\mathbf{\Sigma}) \mathbf{V}^T \quad (3-9)$$

其中, $S_\lambda(\mathbf{\Sigma}) = \text{diag}(\{\beta_i - \lambda\}_{i=1}^r)$ 。用 F -范数作为数据项来表征本小节初始提到的去噪问题, 得到核范数最小化复原模型如 (3-10) 所示:

$$\hat{\mathbf{I}} = \arg \min_{\mathbf{I}} \|\mathbf{Y} - \mathbf{I}\|_F^2 + \lambda \|\mathbf{I}\|_*, \quad \text{s.t. } \mathbf{Y} = \mathbf{I} + \mathbf{N} \quad (3-10)$$

其解为 $S_\lambda(\mathbf{I})$ ^[48]。

图像矩阵可投影到某个能较好反映原图像特征的低维子空间, 并且图像矩阵的奇异值越大, 对应的特征向量相对是投影的主方向。但在投影过程中, 若所有的奇异值都被赋予同样的权重, 投影后的低维子空间可能就不能最大程度的反映原图像矩阵。而核范数最小化方法虽然已经被广泛用于低秩矩阵复原图像中, 但该方法为了保持模型的凸性, 在用软阈值算子求解模型的过程中, 每个奇异值都被赋予同等的重要性, 也就说每个奇异值的收缩权重值 λ 都相同, 即在用如 (3-7) 所示的软阈值算子求解核范数最小化问题的过程中不能充分发挥较大奇异值的作用。针对这个问题, Zhang 等人提出了截断核范数正则化方法^[57], 该算法的思想是只保留重要奇异值而将不重要的奇异值直接丢弃。Zhang 等人的做法虽然能够一定程度上解决在用软阈值方法求解核范数最小化过程中存在的问题, 但是该方法未能利用到所有奇异值的信息。而 Gu 等人提出的权重核范数最小化 (Weighted Nuclear Norm Minimization, WNNM) 方法^[48]较好地解决了软阈值方法在求解核范数最小化过程中存在的问题。Gu 等人提出的方法根据奇异值的大小或者某种先验, 赋予奇异值不同的权重, 在求解过程中充分且合理地利用了每个奇异值。Gu 等人定义矩阵 $\mathbf{I}$ 的权重核范数如 (3-11) 所示:

$$\|\mathbf{I}\|_{w,*} = \sum_i w_i \beta_i(\mathbf{I}) \quad (3-11)$$

其中 $w_i \geq 0$ 是奇异值 $\beta_i(\mathbf{I})$ 的权重, $\mathbf{W} = [w_1, w_2, \dots, w_n]$ 为所有奇异值权重构成的向量。Gu 等人还分别讨论了不同权重排列顺序下的 WNNM 优化方法结果, 当权重按非升序排列时, 等式 (3-12) 为 WNNM 求解模型 (3-10) 的解:

$$\hat{\mathbf{I}} = \mathbf{U} \mathbf{S}_w(\boldsymbol{\Sigma}) \mathbf{V}^T \quad (3-12)$$

根据 Gu 等人在文献[48]中所述的定理 1,在用基于非负权重向量的 WNNM 求解秩最小化问题时,其解 $\hat{\mathbf{I}}$ 能通过 SVD 被分解为 $\mathbf{U} \hat{\mathbf{B}} \mathbf{V}^T$, 其中 $\hat{\mathbf{B}}$ 是等式 (3-13) 的解:

$$\hat{\mathbf{B}} = \arg \min_{\mathbf{B}} \|\boldsymbol{\Sigma} - \mathbf{B}\|_F^2 + \|\mathbf{B}\|_{w,*} \quad (3-13)$$

再对 $\hat{\mathbf{B}}$ 进行 SVD 分解得到: $\mathbf{P} \boldsymbol{\Sigma}' \mathbf{Q}^T$, 当权重按任意顺序排列, 求解模型 (3-10) 的结果为 (3-14):

$$\hat{\mathbf{I}} = \mathbf{U} \hat{\mathbf{P}}^T \mathbf{S}_w(\boldsymbol{\Sigma}) \hat{\mathbf{Q}} \mathbf{V}^T \quad (3-14)$$

当权重按非降序排列时, 用 WNNM 求解模型 (3-10) 的解为 (3-15):

$$\hat{\mathbf{I}} = \mathbf{U} \mathbf{S}_w(\boldsymbol{\Sigma}) \mathbf{V}^T \quad (3-15)$$

对比式 (3-12) 和 (3-15), 可以发现当权重按奇异值大小升序或降序排列时, WNNM 求解得到的结果是相同的。

3.2 基于图像块先验的 MRI 低秩矩阵分解去噪算法

Daniel 等人在文献[26]中证明, 相比多元高斯模型, 主成分分析 (PCA) 以及独立成分分析 (ICA), 高斯混合模型 (GMM) 能更好地对无噪图像块先验进行统计建模。本章将无噪核磁共振图像块的先验信息与核磁共振图像块的自相性先验结合, 利用带有无噪图像块先验的高斯混合模型来引导噪声核磁共振图像块聚类从而提升低秩矩阵分解的去噪效果。下面先介绍图像块的高斯混合模型 (GMM) 聚类原理。

3.2.1 基于 GMM 的图像块聚类原理

3.2.1.1 图像块的 GMM 概率表示

在图像块集合中, 根据图像块间的相似程度, 可将结构相似程度高的图像块划为同一类, 则图像块集合能被划分成多个类。那么给定一副图像 $\mathbf{I}$, 将其划分为 m 个图像块并构成集合: $\mathbf{RI} = (\mathbf{R}_1 \mathbf{I}, \dots, \mathbf{R}_i \mathbf{I}, \dots, \mathbf{R}_m \mathbf{I})$, 其中 $\mathbf{R}_i \mathbf{I}$ 表示由图像 $\mathbf{I}$ 中的第 i 个图像块所构成的矩阵, 假定图像块集合 $\mathbf{RI}$ 能被划分成 K 类, 那么对于 $\mathbf{RI}$ 中任意一个图像块 $\mathbf{R}_i \mathbf{I}$, 其概率可以用 GMM 表示, 具体表达式如式 (3-16) 所示:

$$p(\mathbf{R}_i \mathbf{I} | \Theta) = \sum_{k=1}^K w_k p_k(\mathbf{R}_i \mathbf{I} | \mu_k, \Sigma_k) \quad (3-16)$$

其中, $\Theta = (\mu_1, \dots, \mu_k, \Sigma_1, \dots, \Sigma_k, w_1, \dots, w_k)$ 表示由 GMM 中各高斯类的均值 μ , 协方差矩阵 Σ 和权重 w 组成的集合; $p_k(R_i I | \mu_k, \Sigma_k)$ 是第 k 个高斯类的概率密度函数, 其表达式如 (3-17) 所示:

$$p_k(R_i I | \mu_k, \Sigma_k) = c \cdot \exp\left(-\frac{1}{2}(R_i I - \mu_k)^T \Sigma_k^{-1} (R_i I - \mu_k)\right) \quad (3-17)$$

其中 c 为归一化常数, 负指数为马氏距离, 刻化了 $R_i I$ 与 μ_k 之间的相关性。马氏距离克服了欧式距离不考虑数据间相关性的缺陷^[58], 能更加有效地衡量 $R_i I$ 与 μ_k 之间的相似度。

3.3.1.2 聚类

为简化表达, 用类标签 $C = (c_1, c_2, \dots, c_m)$, $c_i \in \{1, 2, \dots, K\}$ 来表示 $R_i I$ 所属的高斯类; $p(R_i I, c_i = k | \Theta)$ 表示在 GMM 参数集合 Θ 下, $R_i I (i = 1, \dots, m)$ 属于第 k 个高斯类的概率。假定图像块 $R_i I$ 与图像块 $R_j I (i, j = 1, \dots, m, i \neq j)$ 相互独立, 则在 GMM 参数空间 Θ 下, 将图像块集合 RI 聚成 K 类的概率可由式(3-18)表示:

$$p(RI, C | \Theta) = \prod_{i=1}^m p(R_i I, c_i | \Theta) \quad (3-18)$$

式(3-18)两边取对数得到式 (3-19):

$$\log p(RI, C | \Theta) = \sum_{i=1}^m \log p(R_i I, c_i | \Theta) = \sum_{i=1}^m \log p(c_i) p(R_i I | c_i) \quad (3-19)$$

再结合(3-16)式可得到等式 (3-20):

$$\sum_{i=1}^m \log p(c_i) p(R_i I | c_i) = \sum_{i=1}^m \log w_{c_i} p_{c_i}(R_i I | \mu_{c_i}, \Sigma_{c_i}) \quad (3-20)$$

3.2.2 去噪模型

给定一副噪声 $MRI Y$, 对其进行分块得到图像块集合 $RY = (R_1 Y, \dots, R_i Y, \dots, R_m Y)$ 。假定 GMM 参数集合 Θ 通过学习无噪核磁共振图像块的信息已知, 则基于 GMM 先验 Θ 可将 RY 划分成 K 类。用 $\bar{R}_k Y = [R_{k_1}, \dots, R_{k_{d(k)}}]$ 表示由第 k 类中所有图像块(向量化)构成的矩阵($d(k)$ 表示第 k 高斯类中所有相似图像块的数量), 因同一高斯类中的图像块包含的结构信息是相似的, 则可对 $\bar{R}_k Y$ 作如式 (3-21) 所示的分解:

$$\bar{R}_k Y = Z_k + n_k \quad (3-21)$$

式 (3-21) 中 Z_k , n_k 分别是低秩矩阵和噪声矩阵, 低秩矩阵即为去噪后的图像数据。假定图像中每个像素点上的噪声是独立同分布, 从条件概率角度看, 则 $p(\bar{R}_k Y | Z_k) \propto \exp\left(-\frac{1}{\sigma^2} \|\bar{R}_k Y - Z_k\|_F^2\right)$ 。最小化如 (3-22) 式所示的能量函数 $E(Z_k)$ 可得到 Z_k 的值:

$$E(Z_k) = \tau \|Z_k\|_* + \frac{1}{\sigma^2} \|\bar{R}_k Y - Z_k\|_F^2 \quad (3-22)$$

其中 τ 是正常数, σ 是噪声标准差; $\|\cdot\|_*$ 是矩阵核范数, $\|\cdot\|_F$ 是矩阵的 Frobenius 范数。如 (3-22) 式所示的秩最小化问题, 可通过权重核范数最小化方法优化求解^[48]。令 $U \Sigma V^T$ 是 $\bar{R}_k Y$ 的 SVD 分解, 则:

$$\hat{Z}_k = U S_w(\Sigma) V^T \quad (3-23)$$

其中 $S_w(\Sigma)$ 是奇异值收缩算子。

综合以上分析, 给定噪声 $MRI Y$, 结合了无噪核磁共振图像块先验 (GMM 先验) 和核磁共振图像块自相似性先验的低秩分解去噪模型如式 (3-24) 所示, 通过该模型可从噪声 $MRI Y$ 中重建无噪 $MRI I$:

$$(\hat{I}, \hat{C}, \{\hat{Z}_k\}) = \arg \min_{I, C, \{Z_k\}} \frac{\lambda}{\sigma^2} \|Y - I\|_2^2 - \log p(RI, C | \Theta) + \sum_{k=1}^K E(Z_k) \quad (3-24)$$

其中 λ 为正常数, σ 为噪声标准差。图 3-1 为在 GMM 先验下的聚类结果。图 3-1 (a) 为 15% 莱斯噪声下的噪声图像; 图 3-1 (b) 为噪声图像的聚类结果; 图 3-1 (c) ~ (e) 为在 GMM 先验下本文方法循环了 1, 3 和 6 次的聚类结果; 图 3-1 (f) 为无噪 MRI 的聚类结果, 作为去噪效果的参考。不同的颜色代表不同的类别, 从图 3-1 中可以看出, 随着循环次数的增加, 复原结果的聚类图 (图 3-1 (c) ~ (e)) 越来越接近于无噪 MRI 的聚类结果图 (图 3-1 (f)), 这说明带有无噪图像块先验的 GMM 能有效引导图像块聚类, 有助于提升低秩分解去噪算法的效果。

如 2.3.2 小节中所讲, MRI 中噪声是莱斯噪声。在明亮高信噪比区域, 莱斯噪声分布近似于高斯噪声; 在黑暗低信噪比区域, 莱斯噪声分布近似于瑞利分布, 噪声信号依赖于 MRI 信号, 不同区域噪声的不同分布增加了去噪的难度。Nowak 认为在核磁共振平方幅度图像中, 噪声信号与 MRI 信号之间产生了大小为 $2\sigma^2$ 的偏差, 由此提出核磁共振幅度图像平方法^[19]: 在 MRI 的平方信号值中减去 $2\sigma^2$ 的偏差就能得到真实核磁共振图像平方幅度值。因此, 对由 (3-24) 得到 MRI 信号 $\hat{I}$ 进行平方, 并进行如式 (3-25) 所示的偏差校正可得到最终复原的 MRI 信号 I_{final} :

$$\mathbf{I}_{final} = \sqrt{\hat{\mathbf{I}}^2 - 2\sigma^2 \mathbf{E}} \quad (3-25)$$

其中 $\mathbf{E}$ 是与 $\hat{\mathbf{I}}$ 同型的单位矩阵。




图 3-1 无噪核磁共振图像块先验的有效性

观察目标函数可知，在 GMM 先验已通过训练得到的情况下，仍有三个量未知：类标签 C 、低秩矩阵 Z_k 以及待复原的原始无噪 MRI $\mathbf{I}$ 。用噪声 MRI $\mathbf{Y}$ 初始化真实 MRI $\mathbf{I}$ ，本章使用交替最小化方法求解这三个未知变量。

1. 估计类标签 C

在这个子问题中，固定变量 $\mathbf{I}$ ，通过式 (3-26) 来优化求解类标签 C ：

$$C = \arg \max_k p(k | R_i \mathbf{I}) = \frac{w_k p_k(R_i \mathbf{I} | u_k, \Sigma_k)}{\sum_{j=1}^K w_j p_j(R_j \mathbf{I} | u_j, \Sigma_j)}, \quad k=1,2,\dots,K; i=1,2,\dots,m \quad (3-26)$$

2. 估计低秩矩阵 Z_k

将 Z_k 从模型中分离出来得到等式 (3-27)：

$$\hat{Z}_k = \arg \min_{Z_k} \frac{1}{\sigma^2} \|\bar{R}_k \mathbf{I} - Z_k\|_F^2 + \tau \|Z_k\|_* \quad (3-27)$$

式 (3-27) 是一个典型的低秩最小化问题，用 3.1 节中的介绍的权重核范数最小化方法求解即得：

$$\hat{Z}_k = US_w(\Sigma)V^T \quad (3-28)$$

3. 重建 MRI $\hat{I}$

将 $\hat{I}$ 从模型中分离出来得到:

$$\hat{I} = \arg \min_I \lambda \|Y - I\|_2^2 + \sum_{k=1}^K \|\bar{R}_k I - Z_k\|_F^2 \quad (3-29)$$

式子 (3-29) 是二次优化问题, 可近似用以下等式求解:

$$\hat{I} = \left(\lambda E + \sum_k (\bar{R}_k)^T \bar{R}_k \right)^{-1} \times \left(\lambda Y + \sum_k (\bar{R}_k)^T Z_k \right) \quad (3-30)$$

归纳总结上述讨论, 可得到如算法 3-1 所示的流程:

算法 3-1 基于块先验的 MRI 低秩矩阵分解去噪算法流程

输入: 噪声 MRI Y , GMM 参数空间 Θ , 类标签个数 K 和噪声的标准差 σ

初始化: $I^0 = Y$

Step1. 循环: **for** $k=1:K$ **do**

 计算图像块的条件概率通过式 $p(k|R_i I)$

End for

Step2. 得到类标签 C' , 通过等式 (3-26)

Step3. 循环: **for** $k=1:K$ **do**

 Step3.1. 将第 k 类中的所有图像块向量化并合在一起构成矩阵 $\bar{R}_k I'$;

 Step3.2. 计算 Z'_k , 通过等式 (3-28);

End for

Step4. 重建图像, 计算 I' 通过等式 (3-30);

Step5. 进行偏差校正得到最后的去噪图像: $I_{final} = \sqrt{\max(0, \hat{I}^2 - 2\sigma^2 E)}$

输出: 无噪 MRI I_{final}

3.3 实验与结果分析

本小节实验内容主要由参数 K 的确定、在仿真和真实 MRI 数据上的实验结果与分析三部分构成。本文的实验均在内存大小为 8GB, 处理器为 Intel(R) Core(TM) i3CPU(3.70GHz), 操作系统为 Windows 10 的计算机设备, 实验平台为 MTALAB 的环境下进行 (如 3-1 表)。图 3-2 为本小节的实验对象示意图, 其中图 3-2 (a) 来自文献[14], 图 3-2 (b) 和 (c) 来自文献[18], 图 3-2 (d) 为真实 MRI 数据, 采集于 3T 的 Philips Intera Achieva MRI 扫描仪。

表 3-1 实验环境参数

操作系统版本	Windows10 专业版
处理器	Intel(R) Core(TM) i3CPU(3.70GHz)
内存大小	8GB
平台	MATLAB

3.3.1 参数估计

在无噪核磁共振图像块集合上可通过 EM 算法^[59]训练得到 GMM 参数集合 Θ ，但在学习这些参数之前，需要确定 GMM 中的另一个参数即高斯类别数 K 。本文中 GMM 中的高斯类别数 K 是根据实验经验确定的。训练集 T 中的图像块是由 50 幅来自 Brian web 仿真 MRI 数据库(Simulated Brain Database, SBD)^[60]的无噪 MRI 统一分块而成，图像块数量大小约为 7×10^6 。在无噪 MR 图像块训练集 T 上针对不同 K 值(90、100、120 和 150)进行训练，得到相应的 GMM 先验；再将学习到 GMM 先验分别用于噪声 MR 图像块聚类，然后进行低秩矩阵分解去噪处理，得到对应的去噪结果。




图 3-2 实验对象。(a) ~ (c) 为仿真数据，(d) 为真实数据


表 3-2 不同 K 值在不同噪声强度下去噪结果的 PSNR(dB)比较 (图 3-2(b))

K	1%	3%	5%	7%
90	42.1950	34.7205	31.1461	28.8141
100	42.2060	34.7157	31.1650	28.8332
120	42.2032	34.7184	31.1578	28.8190
150	42.2064	34.7183	31.1462	28.8174

表 3-3 不同 K 值在不同噪声强度下去噪结果的 PSNR(dB)比较 (图 3-2(c))

K	1%	3%	5%	7%
90	42.9309	35.3210	31.8808	29.6625
100	42.9257	35.3454	31.9099	29.6730
120	42.9246	35.3312	31.8742	29.6687
150	42.9344	35.3363	31.8982	29.6847

表 3-2 和表 3-3 分别为不同 K 值($K=90$ 、 100 、 120 和 150) 在 1%、3%、5% 和 7% 噪声强度下在图 3-2 (b) 和 (c) 上去噪结果的 PSNR 值; 图 3-3 为不同 K 值在不同噪声强度下在 SBD 上的 RMSE 曲线图; 图 3-4 为图 3-3 在 3% 莱斯噪声条件下的 RMSE 放大图。从表 3-2 和表 3-3 中可以看出, 相同噪声强度下, 不同 K 值在相同图像上去噪结果的 PSNR 值相差很小; 从图 3-3 和图 3-4 也可以看出, 相同噪声强度下, 不同 K 值去噪结果的 RMSE 曲线也几乎重合或差距很小。但分析比较表 3-2, 表 3-3 和图 3-4 中的实验结果, 当 K 为 100 的时候, 取得的效果相对较好。因此, 本文 GMM 中的高斯类别数 K 取 100, 在如表 3-1 所示的实验环境下, 学习含有 100 个高斯类的 GMM 参数集合 Θ 需要花费大约 20 小时。

图 3-3 不同 K 值下的 RMSE 曲线




图 3-4 3%噪声强度下的 RMSE 放大曲线

3.3.2 仿真实验结果及分析

为验证本章算法的有效性,分别应用本章算法与 MRI 去噪算法—非局部均值 NLM^[14]、偏差校正的非局部均值(Unbiased Nonlocal Means, UNLM)^[14]、ADF^[11]和 BM3D 在仿真 MRI 数据上(图 3-2 (a))进行去噪对比实验。NLM, UNLM, ADF 和 BM3D 的代码来源于原作者。由于 Dabov 等人提出的 BM3D^[45]是针对自然图像中的高斯噪声提出去噪算法,本文中用作对比实验的 BM3D 经过方差稳定变换(Variance stabilization transformation, VST)^[61]能去除莱斯噪声,此方法在本文中简称为 BM3D-VST。模型中参数 λ 固定为 0.18。在如图 3-2 (a)所示 MRI 中,加入强度为 5%的莱斯噪声,使用 ADF、NLM、UNLM, BM3D-VST 四种方法作为对比实验,验证本章算法的有效性。图 3-5 显示了 ADF, NLM, UNLM, BM3D-VST 和本章方法的去噪结果。由图 3-5 可知,相比之下,ADF 的去噪结果中有少许噪声残留;NLM、UNLM, BM3D-VST 和本章方法均能有效地去除所加的莱斯噪声,但本章方法去噪结果更接近原始图像,取得了更好的复原效果。




图 3-5 5%莱斯噪声强度下各方法去噪结果


表 3-4 各方法在不同莱斯噪声强度下去噪结果的 PSNR(dB)比较

方法	噪声强度		
	1%	3%	5%
加噪图像	39.58	29.97	25.51
ADF	29.77	29.14	26.85
NLM	39.64	33.03	28.77
UNLM	43.62	37.34	33.88
BM3D-VST	43.15	36.31	33.47
本章方法	44.36	37.51	34.54

同时，表 3-4 和表 3-5 也给出了这 5 种去噪算法在图 3-2 (a) 上外加 1%、3%、5% 莱斯噪声强度后去噪结果的 PSNR 值和 SSIM 值。观察表 3-4 和表 3-5 可知，本章方法取得到了较高的 PSNR 值和 SSIM 值。在这三种噪声强度下，本章方法较 ADF 在 PSNR 值上至少有 7dB 提升，对应 SSIM 值上有 0.08~0.18 的提升；较 NLM 在 PSNR 值上有 5dB 左右的提升，对应 SSIM 值有 0.07~0.16 的提升；较 UNLM 在 PSNR 值上有 0.17~0.74dB 提升，对应 SSIM 值有 0.02~0.05 的提升；较 BM3D-VST 在 PSNR 值上有 1dB 左右提升，对应 SSIM 值有 0.01 的提升。从数值上也说明本章方法在有效去除 MRI 中的莱斯噪声的同时，能够较好的保留 MRI 本身的结构信息。

表 3-5 各方法在不同莱斯噪声强度下去噪结果的 SSIM 比较

方法	噪声强度		
	1%	3%	5%
加噪图像	0.90	0.76	0.64
ADF	0.91	0.88	0.78
NLM	0.92	0.84	0.80
UNLM	0.99	0.96	0.91
BM3D-VST	0.99	0.97	0.95
本章方法	0.99	0.98	0.96



(a) ADF (b) NLM (c) UNLM (d) 本章方法

图 3-6 真实 MRI 数据去噪结果。从左向右，分别为 ADF，NLM，UNLM 和本章方法的去噪结果；从上向下，(a) 列—(d) 列分别为各方法的去噪结果、局部放大图和残差图

3.3.3 真实实验结果及分析

为进一步验证本章方法的有效性，应用 ADF，NLM，UNLM 和本章方法在真实数据上进行去噪实验。除 ADF 外，NLM，UNLM 和本章方法进行去噪处理的前

提是已知图像的噪声标准差,为了实验的顺利进行,实验过程中采用 Rajan 等人提出^[62]的方法估计真实 MRI (图 3-2 (d)) 的噪声标准差为 1。图 3-6 为 4 种方法在真实 MRI 数据(图 3-2 (d))上的去噪结果。从左到右分别为 ADF, NLM, UNLM 和本章方法的去噪结果;从上向下分别为各方法对应的全局去噪结果图,局部放大图和残差图(去噪结果与真实 MRI 之差)。从图 3-6 所示的各方法去噪结果和局部放大图来看,这 4 种方法均能有效地去除图像中的莱斯噪声。但通过分析比较图 3-6 中各方法的残差结果图可知,ADF 的残差结果(图 3-6 (a) 列第三行)中包含明显的图像轮廓和纹理细节信息;NLM 残差结果(图 3-6 (b) 列第三行)中包含较明显的边缘信息;图 3-6 (c) 第三行为 UNLM 残差结果,其中包含的边缘轮廓信息较 ADF 和 NLM 少;图 3-6 (d) 列为本章算法去噪残差结果,其中包含的图像轮廓最不明显,也基本不包含纹理结构,这说明本章方法在真实 MRI 复原上保留图像轮廓和纹理细节的能力最好。

3.4 本章小结

本章首先介绍了低秩矩阵去噪相关原理;然后结合核磁共振图像块的自相似性和无噪核磁共振图像块先验信息,通过带有无噪核磁共振图像块先验的高斯混合模型对噪声核磁共振图像块聚类来增强图像块矩阵的低秩性,从而提升低秩矩阵分解算法的去噪效果;最后,通过实验验证本章方法的有效性。实验结果证明,本章的方法相较于 ADF, NLM, UNLM 和 BM3D-VST 在视觉上和数值上都有较大的提升。

第四章 基于梯度稀疏先验的 MRI 低秩矩阵去噪算法

虽然基于块先验的 MRI 低秩矩阵分解去噪算法已经取得了较好的去噪效果，但是在重建清晰图像的过程中由于图像块的聚合操作，图像的像素点重叠，会引起振铃效应。因此，本章的重点是在第三章方法的基础上引入 MRI 的梯度先验来消除振铃效应，进一步提升去噪效果。

4.1 图像梯度

在介绍图像梯度之前，先介绍数学领域中梯度相关的预备知识。

定义 1：二元函数的偏导数^[63]

设二元函数 $z = f(x, y)$, (x_0, y_0) 是 $z = f(x, y)$ 定义域内某点，固定 y_0 ， x_0 增量为 Δx ，则函数 z 在 x 方向上的偏导数为：

$$\frac{\partial z}{\partial x} = \lim_{\Delta x \rightarrow 0} \frac{f(x_0 + \Delta x, y_0) - f(x_0, y_0)}{\Delta x} \quad (4-1)$$

同理，函数 z 在 y 方向上的偏导数为：

$$\frac{\partial z}{\partial y} = \lim_{\Delta y \rightarrow 0} \frac{f(x_0, y_0 + \Delta y) - f(x_0, y_0)}{\Delta y} \quad (4-2)$$

若 $z = f(x, y)$ 表示一副图像，图像 $f(x, y)$ 在计算机设备中的存在形式常常是二维离散信号，所以图像的导数一般用有限差分表示。因此，图像 $f(x, y)$ 在 x 方向上的偏导数为：

$$\frac{\partial z}{\partial x} = f(x_0 + 1, y_0) - f(x_0, y_0) \quad (4-3)$$

图像 $f(x, y)$ 在 y 方向上的偏导数为：

$$\frac{\partial z}{\partial y} = f(x_0, y_0 + 1) - f(x_0, y_0) \quad (4-4)$$

定义 2：梯度^[63]

设函数 $z = f(x, y)$ 在其定义域 D 内有一阶连续偏导数，则对于任一点 (x, y) ， $((x, y) \in D)$ ，都可以得到一个向量 $grad(f)$ ：

$$grad(f) = [g_x, g_y]^T = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} = \frac{\partial f}{\partial x} \vec{i} + \frac{\partial f}{\partial y} \vec{j} \quad (4-5)$$

$grad(f)$ 就是 $z = f(x, y)$ 在点 (x, y) 处的梯度，从式 (4-5) 可以看出，梯度 $grad(f)$ 是一

个向量, (x,y) 处梯度的方向为 $z = f(x,y)$ 在该点处变化最快的方向。最大变化率的值就是梯度的模, 记为 $M(x,y)$, 则 $M(x,y)$ 表达式如式 (4-6) 所示:

$$M(x,y) = |\text{grad}(f)| = \sqrt{\left(\frac{\partial f}{\partial x}\right)^2 + \left(\frac{\partial f}{\partial y}\right)^2} \quad (4-6)$$

梯度的方向 θ 如式 (4-7) 所示:

$$\theta = \tan^{-1}\left(\frac{g_x}{g_y}\right) \quad (4-7)$$

同样, 对于一副图像 $z = f(x,y)$, 某像素点梯度的方向就是图像中该点像素值变化最大的方向。一般而言, 由于图像中的像素值满足连续性, 即相邻图像区域内的像素值变化不明显, 因此梯度模值很小或接近于零。正是由于这个原因, 梯度稀疏先验常常在图像复原中被用来保持图像的细节信息。值得注意的是 $M(x,y)$, g_x 和 g_y 均是与原图像大小相同的图像, 因为它们是 x 和 y 在图像中所有像素位置上发生变化时产生的。

4.2 MRI 梯度性质

为分析 MRI 梯度具有的性质, 本小节对一幅无噪 MRI (图 3-2 (a)) 分别求其水平和垂直方向的梯度, 并作出对应的梯度直方图和经验概率分布图 (图 4-1 至图 4-4)。




图 4-1 水平方向的梯度直方图




图 4-2 垂直方向的梯度直方图

从图 4-1 和图 4-2 可以看出，无噪 MRI 水平和垂直方向上的梯度值大多数为零或接近于零；从垂直和水平两个方向的梯度经验概率分布图（图 4-3 和图 4-4）也可以看出，梯度值为零时出现的概率最大，这些实验结果都说明无噪核磁共振图像的梯度是稀疏的。




图 4-3 水平方向的梯度经验分布图




图 4-4 垂直方向的梯度经验分布图

为找到合适的模型来拟合 MRI 梯度稀疏性质，图 4-5 给出了高斯分布和拉普拉斯分布拟合 MRI 梯度分布的曲线图。如图 4-5 所示，蓝色曲线为无噪 MRI 的梯度经验分布曲线；红色曲线和蓝绿色曲线分别为拉普拉斯（Laplacian）分布和高斯（Gaussian）分布拟合 MRI 梯度分布的情况。从图中可以看出，相比高斯分布和拉普拉斯分布，无噪 MRI 的梯度经验分布更稀疏。超拉普拉斯分布（Hyper Laplacian distribution, HLD）能较好地拟合具有这种特性的曲线。超拉普拉斯分布的概率密度函数如式（4-8）所示：

$$f(x|\mu, b) = \frac{1}{2b} \exp\left(-\frac{|x - \mu|^\alpha}{b}\right) \quad (4-8)$$

其中 μ 和 b 分别位置参数和尺度参数。当 $\alpha=2$ ，（4-8）式为高斯分布；当 $\alpha=1$ ，（4-8）式为拉普拉斯分布。令 $\mu=0$ ，图像 I 基于梯度稀疏性的超拉普拉斯先验可等价于（4-9）：

$$f(I) \propto \exp\left(-|\nabla I|_\alpha\right) \quad (4-9)$$




图 4-5 无噪 MRI 梯度经验分布拟合曲线

4.3 基于超拉普拉斯正则项的 MRI 低秩矩阵分解去噪算法

正如本章开头所述虽然基于图像块先验的 MRI 低秩矩阵分解去噪算法已经取得了较好的去噪效果，但是在重建清晰图像的过程中由于图像块像素点重叠会引起振铃效应（图 4-6（b））。Chang 等人在高光谱图像中，利用高光谱图像的梯度稀疏性来消除图像中的振铃效应^[64]，Liu 等人也发现 MRI 梯度具有稀疏性^[65]。结合 4.2 节所述，超拉普拉斯分布能较好拟合无噪 MRI 梯度经验分布，因此，为消除振铃效应，本小结在第三章的基础上，在低秩分解去噪模型中引入了超拉普拉斯正则项。




图 4-6 梯度稀疏先验的有效性

为验证基于 MRI 稀疏梯度先验的超拉普拉斯正则项的有效性，图 4-6 给出了模型中有无超拉普拉斯正则项两种情况的实验结果。如图 4-6 所示，图 4-6（a）为

9%莱斯噪声强度下的噪声图像；图 4-6 (b) 为第三章方法的去噪结果；图 4-6 (c) 为本章方法的去噪结果。比较图 4-6 (b) 和 (c)，带有梯度稀疏先验的本章方法比不含梯度稀疏先验的第三章方法，在 PSNR 值上有约 0.7dB 的提升，能有效地减少振铃效应，提升去噪效果。同时表 4-1 给出了不同莱斯噪声强度下，模型中有无超拉普拉斯 (Hyper Laplacian, HL) 正则项两种情况在 T1w 上的定量实验结果。从表 4-1 可以看出，相比第三章方法，在相同噪声强度下，本章方法在 PSNR 值上均有约 2dB 左右的提升；在 SSIM 值上约有 0.1 左右的提升。因此，在模型中添加基于 MRI 梯度稀疏先验的超拉普拉斯正则项是合理的，本文方法的整体框架如图 4-7 所示。

表 4-1 各方法在不同噪声级别下的 PSNR 值和 SSIM 值

是否有 HL 项	3%	7%	11%	15%
No	36.10 0.96	30.14 0.86	26.75 0.77	24.44 0.69
Yes	37.85 0.98	32.50 0.94	29.25 0.89	26.75 0.84




图 4-7 本文方法的整体框架

给定噪声 MRI $\mathbf{Y}$ ，从 $\mathbf{Y}$ 中复原出 $\mathbf{I}$ 的最终模型如 (4-10) 所示：

$$\left(\hat{\mathbf{I}}, \hat{\mathbf{C}}, \{\hat{\mathbf{Z}}_k\}\right) = \arg \min_{\mathbf{I}, \mathbf{C}, \{\mathbf{Z}_k\}} \frac{\lambda}{\sigma^2} \|\mathbf{Y} - \mathbf{I}\|_2^2 + \xi \left(-\log p(\mathbf{R}\mathbf{I}, \mathbf{C} | \Theta) + \sum_{k=1}^K E(\mathbf{Z}_k) \right) + \psi \|\nabla \mathbf{I}\|_p \quad (4-10)$$

其中 ∇ 是梯度算子； $p \in [0, 1]$ 为控制稀疏性的参数， λ ， ξ 和 ψ 是正则化参数； σ 是噪声标准差； $\|\mathbf{Y} - \mathbf{I}\|_2^2$ 数据保真项； $\log p(\mathbf{R}\mathbf{I}, \mathbf{C} | \Theta)$ 为聚类正则项； $E(\mathbf{Z}_k) = \sum_{k=1}^K \left(\tau \|\mathbf{Z}_k\|_* + \frac{1}{\sigma^2} \|\bar{\mathbf{R}}_k \mathbf{I} - \mathbf{Z}_k\|_F^2 \right)$ 为低秩正则项； $\|\nabla \mathbf{I}\|_p$ 为超拉普拉斯正则项。

本章方法是在第三章方法基础上添加了基于梯度稀疏先验的超拉普拉斯正则项，类标签 $\mathbf{C}$ 和低秩矩阵 $\mathbf{Z}_k$ 的求解与 3.2.2 小节求解方法相同，但图像 $\mathbf{I}$ 的求解方

法略有不同, $\mathbf{I}$ 的求解过程如下:

从式 (4-10) 中分离与 $\mathbf{I}$ 不相关的变量, 可以得到式 (4-11):

$$\hat{\mathbf{I}} = \arg \min_{\mathbf{I}} \frac{1}{\sigma^2} \sum_{k=1}^K \|\bar{\mathbf{R}}_k \mathbf{I} - \mathbf{Z}_k\|_F^2 + \frac{\lambda}{\sigma^2} \|\mathbf{Y} - \mathbf{I}\|_2^2 + \psi \|\nabla \mathbf{I}\|_p \quad (4-11)$$

为求解上式, 用替代方向乘数法(ADMM)^[66], 通过引入辅助变量 $\mathbf{H}$ (与 $\mathbf{I}$ 同样大小) 可得式子 (4-12):

$$\{\hat{\mathbf{I}}, \hat{\mathbf{H}}\} = \arg \min_{\mathbf{I}, \mathbf{H}} \frac{\xi}{\sigma^2} \sum_{k=1}^K \|\bar{\mathbf{R}}_k \mathbf{I} - \mathbf{Z}_k\|_F^2 + \frac{\lambda}{\sigma^2} \|\mathbf{Y} - \mathbf{I}\|_2^2 + \psi \|\mathbf{H}\|_p + \frac{\alpha}{2} \left\| \mathbf{H} - \nabla \mathbf{I} - \frac{\Upsilon}{\alpha} \right\|_F^2 \quad (4-12)$$

其中 Υ 是拉格朗日乘子, ξ 和 α 是正常数。将 (4-12) 分解为如下两个子问题以便于求解:

(1) 分离与 $\mathbf{H}$ 不相关的变量, 可以得到:

$$\hat{\mathbf{H}} = \arg \min_{\mathbf{H}} \psi \|\mathbf{H}\|_p + \frac{\alpha}{2} \left\| \mathbf{H} - \nabla \mathbf{I} - \frac{\Upsilon}{\alpha} \right\|_F^2 \quad (4-13)$$

考虑到算法的收敛性和准确性, 这里应用广义迭代收缩算法^[67]来求解式 (4-13) 的非凸 l_p 范数最小化问题。

(2) 同理, 通过类似的方法估计 $\mathbf{I}$, 分离与 $\mathbf{I}$ 不相关的变量可得到如 (4-14) 所示的等式:

$$\hat{\mathbf{I}} = \arg \min_{\mathbf{I}} \frac{\xi}{\sigma^2} \sum_{k=1}^K \|\bar{\mathbf{R}}_k \mathbf{I} - \mathbf{Z}_k\|_F^2 + \frac{\lambda}{\sigma^2} \|\mathbf{Y} - \mathbf{I}\|_2^2 + \frac{\alpha}{2} \left\| \mathbf{H} - \nabla \mathbf{I} - \frac{\Upsilon}{\alpha} \right\|_F^2 \quad (4-14)$$

再次对式 (4-14) 运用 ADMM 方法, 通过引入与 $\mathbf{I}$ 相同大小的辅助变量 $\mathbf{M}$ 分离变量 $\mathbf{I}$ 和 $\bar{\mathbf{R}}_k \mathbf{I}$ 可得:

$$\{\hat{\mathbf{I}}, \hat{\mathbf{M}}\} = \arg \min_{\mathbf{I}, \mathbf{M}} \frac{\lambda}{\sigma^2} \|\mathbf{Y} - \mathbf{I}\|_2^2 + \frac{\alpha}{2} \left\| \mathbf{H} - \nabla \mathbf{I} - \frac{\Upsilon}{\alpha} \right\|_F^2 + \frac{\xi}{\sigma^2} \sum_{k=1}^K \|\bar{\mathbf{R}}_k \mathbf{M} - \mathbf{Z}_k\|_F^2 + \frac{\beta}{2} \left\| \mathbf{M} - \mathbf{I} - \frac{\Upsilon_1}{\beta} \right\|_F^2 \quad (4-15)$$

其中 Υ_1 是拉格朗日乘子, β 是正常数, 可用等式 (4-16) 近似迭代求解等式 (4-15):

$$\begin{cases} \mathbf{I}^{(l+1)} = \arg \min_{\mathbf{I}} \frac{\lambda}{\sigma^2} \|\mathbf{Y} - \mathbf{I}\|_2^2 + \frac{\alpha}{2} \left\| \mathbf{H} - \nabla \mathbf{I} - \frac{\Upsilon}{\alpha} \right\|_F^2 + \frac{\beta}{2} \left\| \mathbf{M}^{(l)} - \nabla \mathbf{I} - \frac{\Upsilon_1^{(l)}}{\beta} \right\|_F^2 \\ \mathbf{M}^{(l+1)} = \arg \min_{\mathbf{M}} \frac{\xi}{\sigma^2} \sum_{k=1}^K \|\bar{\mathbf{R}}_k \mathbf{M} - \mathbf{Z}_k\|_F^2 + \frac{\beta}{2} \left\| \mathbf{M} - \mathbf{I}^{(l+1)} - \frac{\Upsilon_1}{\beta} \right\|_F^2 \\ \Upsilon_1^{(l+1)} = \Upsilon_1^{(l)} + \beta^l (\mathbf{I}^{(l+1)} - \mathbf{M}^{(l+1)}) \\ \beta^{(l+1)} = \rho \beta^{(l)} \end{cases} \quad (4-16)$$

其中 $\rho > 1$ 。而变量 $\mathbf{I}$ ， $\mathbf{M}$ 可由等式 (4-17) 和 (4-18) 近似求解：

$$\mathbf{M}^{(l+1)} = \left(2\sigma^2 \sum_{k=1}^K \bar{\mathbf{R}}_k^T \bar{\mathbf{R}}_k + \beta^{(l)} \mathbf{E} \right) \left(2\sigma^2 \sum_{k=1}^K \bar{\mathbf{R}}_k \mathbf{z}_k + \beta^{(l)} \mathbf{I}^{(l+1)} + \Upsilon_1^{(l)} \right) \quad (4-17)$$

$$\mathbf{I}^{(l+1)} = \mathcal{F}^{-1} \left(\frac{\mathcal{F} \left(\mathbf{y} + \nabla^T \left(\alpha^{(l)} \mathbf{H} - \Upsilon \right) + \left(\beta^{(l)} \mathbf{M}^{(l)} - \Upsilon_1^{(l)} \right) \right)}{1 + \alpha^{(l)} \left(\mathcal{F}(\nabla) \right)^2 + \beta^{(l)}} \right) \quad (4-18)$$

其中 $\mathcal{F}$ 和 $\mathcal{F}^{-1}$ 分别是二维傅里叶变换和其逆变换， $\mathbf{E}$ 是单位矩阵。

本章所提出的 MRI 去噪模型是非凸优化的，因此所求得的模型的解不一定是全局最优解。但在迭代过程中发现本章算法可以在一定迭代次数内收敛。图 4-8 是本文方法在 15% 莱斯噪声强度下，在 SBD 上的收敛曲线。从图中可以看出，在 15% 的莱斯噪声条件下，本文方法迭代 25 次左右时，能量曲线基本趋于平缓，达到了收敛的状态。




图 4-8 本文方法在 SBD 上的收敛曲线

4.4 实验与结果分析

本章的实验环境跟第三章实验环境相同，具体的环境参数见表 3-1。根据实验经验，模型中涉及的参数 λ ， ξ ， ψ 和 p 分别固定为 0.19，1，0.05 和 0.8；图像块大小固定为 10×10 。用 ADF^[11]，UNLM^[14]和 BM3D 三种方法作为对比实验，验证本章算法的有效性。正如 3.3.2 中所述，由于 Dabov 等人提出的 BM3D^[45]是针对自然图像中的高斯噪声提出去噪算法，本章中用作对比实验的 BM3D 也是经过方差

稳定变换 (Variance stabilization transformation, VST)^[61]能去除莱斯噪声, 统一简称为 BM3D-VST。UNLM, BM3D 和 VST 的代码来自作者主页; 根据文献[68]设置 ADF 中的相关参数, 使 ADF 达到较好的去噪性能。实验结果除定性的视觉比较外, 还用客观评价指标 PSNR、SSIM 来进行定量比较。

4.4.1 合成数据实验结果及分析

实验中涉及到的合成 MRI 数据 T1 权重图像 (T1w), T2 权重图像 (T2w) 和 PD 权重图像 (PDw) 均来自 SBD^[60]。三种类型图像的尺寸均为 $181 \times 217 \times 181$, 均选取第 90 个切片作为实验对象。三种对比方法和本章方法的实验结果见图 4-9 至图 4-12 和表 4-1 至 4-3。




图 4-9 各种方法在 5%噪声强度下的去噪结果及其一维信号变化曲线图 (T1w)

图 4-9 为各方法在 5%莱斯噪声下在 T1w 上的去噪结果和一维像素值变化曲线 (图中中心红线处)。图 4-9 (a) 是供对比参考的无噪 MRI; 图 4-9 (b) 是外加 5%莱斯噪声的 MRI; 图 4-9 (c) 到图 4-9 (f) 显示了各算法的去噪结果。从图 4-9 (c) 可以看出, ADF 的去噪结果中的少量残余噪声。从图 4-9 (d) 至图 4-9 (f) 可以看出, UNLM, BM3D-VST 和本章方法能有效地去除噪声, 取得了良好的视觉效果。同时, 从图 4-9 底部所示的各方法去噪结果的一维像素值变化曲线可以得

出相同的结论。图 4-9 (b) 下方是噪声 MRI 的一维像素值曲线，其一维信号（红色）相比无噪 MRI 的一维信号曲线（蓝色），波动很大；图 4-9 (c) 中 ADF 一维信号曲线（品红）与无噪 MR 图像一维信号有明显的差异；BM3D-VST 和本章方法相比 UNLM，它们的一维信号曲线和无噪 MRI 一维信号更接近。仔细对比观察图 4-9 (e) 和 (f)，本章方法的一维信号曲线比 BM3D-VST 的更接近无噪 MRI 的一维信号曲线。这说明相比 ADF，UNLM 和 BM3D-VST，本章方法在视觉上取得了更好的去噪效果。




图 4-10 各种方法在 11% 莱斯噪声强度下的去噪结果 (PDw) ((a) ~ (d) 为各方法的去噪结果; (e) ~ (f) 为各方法的冗余图像; 从左到右方法依次为 ADF, UNLM, BM3D-VST 和本章方法)




图 4-11 各种方法在 11% 莱斯噪声强度下的去噪结果 (T2w) ((a)~(d) 为各方法的去噪结果; (e)~(f) 为各方法的冗余图像; 从左到右方法依次为 ADF, UNLM, BM3D-VST 和本章方法)

图 4-10 显示了各方法在外加 11% 莱斯噪声的 PDw 上的去噪结果。图 4-10(a)~(d) 显示了 ADF, UNLM, BM3D-VST 和本章方法的去噪结果; 图 4-10(e)~(h) 显示了与 (a)~(d) 对应的冗余图像 (去噪结果与噪声图像之差)。从图 4-10 可以看出, 相比 ADF 和 UNLM, BM3D-VST 和本章方法取得了更好的去噪结果, 对应的冗余图像中也几乎不包含的图像细节信息。但如表 4-2 所示, 本章方法在 11% 的莱斯噪声的条件下比 BM3D-VST 取得了更高的 PSNR 值和 SSIM 值。

为进一步验证本章方法的有效性, 在外加 11% 的 T2w 上进行了去噪实验, 实验结果如图 4-11 所示。对比所有方法的去噪结果可知, 本章方法的冗余图像中含有图像的细节最少, 去噪结果中保留的图像细节信息最多。表 4-3 也显示了, 在 11% 的噪声条件下, 本章方法去噪结果取得了最高的 PSNR 值和 SSIM 值。




图 4-12 各方法在不同图像上的去噪结果 (PSNR (dB) /SSIM)

为了对本章方法的有效性进行定量地评估，图 4-12 显示了 T1w、PDw 和 T2w 三种 MRI 在不同莱斯噪声强度下各方法去噪结果的 PSNR 和 SSIM 曲线。从图 4-12 可以看出，相比其他三种方法，本章方法在三种 MRI 的去噪结果中几乎都取得了最高的 PSNR 值和 SSIM 值，这也从数值上证明本章方法取得了更好的去噪性能。

表 4-2 至表 4-4 给出了各方法更详细的数值去噪结果。对于 T1w 图像，当莱斯噪声强度低于 7% 时，本章比其他方法获得了更好的性能；当噪声强度增加时，BM3D-VST 的 PSNR 值略好于本章算法，但本章方法取得了较高的 SSIM 值。对于 PDw 图像，本章方法在 PSNR 值上相比 BM3D-VST 提升了约 0.767 dB（15% 噪声）和 1.131 dB（11% 噪声），相应的 SSIM 提升了 0.0111 和 0.0148；相比 UNLM，本章方法在 PSNR 值上提升了 1.359 dB（11% 噪声）和 1.176 dB（15% 噪声），相应的 SSIM 提升了 0.0815 和 0.0962；对于 T2w 图像，与 BM3D-VST 相比，本章方法在 PSNR 值提升 0.389 dB~1.305 dB，相应的 SSIM 提升 0.0022~0.033；与 UNLM 相比，PSNR 值和 SSIM 值分别提升 0.342 dB~1.064 dB 和 0.0025~0.0952。

表 4-2 各方法在不同噪声级别下的 PSNR 值和 SSIM 值（T1w）

Method	3%		7%		11%		15%	
	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM
Noise	30.121	0.736 4	22.711	0.524 4	18.731	0.378 6	16.053	0.282 0
ADF	29.708	0.899 3	23.131	0.547 5	19.117	0.389 9	16.303	0.287 6
UNLM	37.627	0.951 0	31.924	0.875 6	28.529	0.793 7	26.005	0.712 2
BM3D-VST	36.758	0.978 3	32.079	0.931 8	29.552	0.882 6	27.704	0.821 5
本章方法	37.849	0.979 6	32.506	0.939 3	29.246	0.892 8	26.746	0.839 6

表 4-3 各方法在不同噪声强度下的 PSNR 值和 SSIM 值（PDw）

Method	3%		7%		11%		15%	
	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM
Noise	29.884	0.735 8	22.361	0.495 6	18.389	0.372 5	15.653	0.291 1
ADF	30.068	0.867 8	23.054	0.531 2	18.856	0.384 5	15.920	0.296 9
UNLM	36.706	0.957 2	31.345	0.885 4	28.235	0.799 1	26.272	0.742 8
BM3D-VST	36.063	0.952 2	31.013	0.913 4	28.463	0.865 8	26.681	0.827 9
本章方法	37.163	0.952 0	32.096	0.911 2	29.594	0.880 6	27.448	0.839 0

表 4-4 各方法在不同噪声强度下的 PSNR 值和 SSIM 值（T2w）

Method	3%		7%		11%		15%	
	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM
Noise	29.878	0.772 2	22.382	0.589 3	18.451	0.482 8	15.760	0.400 2
ADF	29.630	0.908 6	22.930	0.621 1	18.850	0.495 5	15.989	0.405 1
UNLM	35.518	0.958 9	29.846	0.902 1	26.502	0.821 5	24.290	0.770 0
BM3D-VST	34.555	0.959 2	29.236	0.932 2	27.504	0.883 6	24.608	0.832 2
本章方法	35.860	0.961 4	30.185	0.929 9	27.566	0.905 0	24.997	0.865 2

4.4.2 临床数据实验结果及分析

为进一步验证本章算法的鲁棒性，选用 UNLM 和 BM3D-VST 作为对比实验

的方法，在临床 MRI 数据上进行去噪处理。临床 MRI 数据来自 IXI 数据集 (<http://brain-development.org/>)，与第三章类似，本章的对比实验在进行去噪之前也需要知道噪声的标准差，本章也采用 Rajan 等人^[62]提出的方法来估计临床数据中噪声的标准差。UNLM，BM3D-VST 和本章方法在临床数据上的去噪结果如图 4-13 和图 4-14 所示。




图 4-13 各方法在真实 PDw 图像上的去噪结果（估计的 $\sigma = 5$ ），从上向下：去噪结果，放大图像和对应方法的冗余图像；从左至右：UNLM，BM3D_VST 和本章方法

如图 4-13 和图 4-14 所示，UNLM，BM3D-VST 和本章方法均能有效地抑制图像中的莱斯噪声；但是从放大区域（图 4-13 和图 4-14 第二行图像）和冗余残差图像（图 4-13 和图 4-14 第三行图像）来看，本章方法的去噪结果中包含较少的图像残差和取得了更好的视觉效果。这些实验结果说明，相比 UNLM，BM3D-VST，本章方法的去噪效果在临床数据上有更好的表现，更能有效地抑制噪声并最大程

度地保留图像本身的细节信息。




图 4-14 各方法在真实 T1w 图像上的去噪结果（估计的 $\sigma=1$ ），从上向下：去噪结果，放大图像和对应方法的冗余图像；从左至右：UNLM，BM3D_VST 和本章方法

4.5 本章小结

为去除在重建过程中由于像素点重叠造成的振铃效应，本章研究了无噪 MRI 梯度性质，用实验证明了在模型中添加基于 MRI 梯度稀疏性的超拉普拉斯正则项的合理性。实验结果说明，本章方法能有效地抑制振铃效应的产生，在去除噪声的同时能较大程度地保留 MRI 本身的信息，相比 ADF，UNLM 和 BM3D-VST 这三种 MRI 去噪方法，在数值和视觉上均有较大的提升。

第五章 总结与展望

5.1 总结

核磁共振图像 (MRI) 能清楚地反映人体内的组织结构状况, 是帮助医生诊断病情的有效工具, 但 MRI 在成像或传输过程中易受噪声污染, 得到的 MRI 往往带有噪声。这些噪声会降低图像的信噪比和对比度, 使得图像中一些组织边界不规则和模糊不清, 给医生诊断病情造成了障碍。因此, MRI 去噪的研究具有重要的意义和价值。图像去噪是图像预处理中一个常见的反问题, 所谓反问题就是该问题是不适定的, 其解不一定存在或者出现其解存在但不唯一或不稳定的情况。针对图像去噪这类的反问题, 一般的做法是在模型中引入图像先验来缩小或限制解的范围使其良态化。本文的主要研究内容就是针对 MRI 中的噪声, 在低秩矩阵分解去噪模型中引入 MRI 的先验信息, 在去除噪声的同时最大程度地保留 MRI 本身的细节信息。本文的工作可以从下面的几个方面进行概括:

(1) 介绍了本文的研究背景, MRI 成像原理和图像去噪相关的基础知识, 包括噪声相关模型, MRI 中噪声的特点, 各向异性滤波算法, 非局部均值滤波算法和块匹配三维滤波算法这三种 MRI 去噪算法的原理。

(2) 研究了低秩矩阵复原图像的原理、求解方法及其不足之处。针对其不足之处, 提出了基于块先验的 MRI 低秩矩阵去噪算法。在去噪模型中引入无噪核磁共振图像块的先验和核磁共振图像块非局部自相似性先验来提升模型的去噪效果。在无噪核磁共振图像块集合上训练高斯混合模型的参数, 使得高斯混合模型带有无噪核磁共振图像块的先验信息; 然后用学习得到的高斯混合模型对噪声核磁共振图像块进行聚类, 来加强核磁共振图像块矩阵的低秩性, 以便低秩矩阵分解去噪算法能更好地复原出真实的 MRI。实验结果说明了提出方法的有效性。

(3) 针对基于块先验的 MRI 低秩矩阵去噪算法在重建图像过程中出现振铃效应的现象, 研究了 MRI 梯度性质, 提出了基于梯度稀疏先验的 MRI 低秩矩阵分解去噪算法。该算法利用超拉普拉斯分布来拟合 MRI 梯度的稀疏性, 在模型中添加超拉普拉斯正则项来消除振铃效应。实验结果说明基于梯度稀疏先验的 MRI 低秩矩阵分解去噪算法能有效地去除振铃效应, 并且在高噪声条件下, 相比其他 MRI 去噪算法在数值上和视觉上都有较大的提升。

5.2 展望

本文的主要研究内容是利用 MRI 先验信息来提升低秩矩阵分解模型的去噪性能。研究过程中涉及到的图像先验信息有: 无噪 MR 图像块先验、图像块的

非局部自相似性以及梯度稀疏先验。在仿真和真实 MRI 数据上的实验结果都充分证明了本文方法的有效性，但本文方法仍存在一些问题有待继续研究：

(1) MRI 是帮助医生诊断病人病情的有力工具，MRI 去噪算法的目的是降低图像中噪声功率，但由于 MRI 中包含着特殊的医学信息，并且人体不同部位的 MRI 具有不同的特点，MRI 中任一细微结构都会影响医生对于病人病情的诊断。本文方法在去噪过程中虽然能较大程度地保留 MRI 本身的细节纹理信息，但难免会平滑掉一些细节信息，因此本文方法的实用性需要进一步研究。

(2) 在无噪核磁共振图像块数据集上训练高斯混合模型之前需要确定高斯混合模型的类别数 K ，而本文中的高斯类别数 K 是通过实验确定的。根据实验经验，随着 K 值和图像块大小的增加，训练的时间成本会相应增加。假设训练集中共有 t 个图像块 ($t \gg K$)，则 K 的取值范围为 $[1, t]$ ，则得到合适的高斯类别数 K 的时间成本将非常高。就如何得到合适 K 这一问题，可考虑采用变分贝叶斯推断方法对 K 进行估计，自适应确定 K 。目前，图形处理器 (GPU) 因其计算能力的强大，在图像处理上有较为广泛的应用。因此，除用变分贝叶斯推断方法来自适应确定 K 外，也可考虑使用 GPU 来加速训练过程。

(3) 本文研究的方法是针对 MRI 切片中的噪声问题，是一种针对二维图像的去噪方法。理论上来说，相比二维 MRI，三维 MRI 图像块之间的自相似性更高。因此，可考虑将本方法扩展至三维 MRI 去噪中。

参考文献

- [1] More S, V. V. Hanchate. A Survey on Magnetic Resonance Image Denoising Methods[J]. International Research Journal of Engineering and Technology, 2016, 03(05): 250-256.
- [2] Mandelbrot B B. The fractal geometry of nature /Revised and enlarged edition[J]. New York W.h.freeman & Co.p, 1983, -1
- [3] Pentland A P. Fractal-based description of natural scenes[J]. IEEE Trans Pattern Anal Mach Intell, 1984, PAMI-6(6): 661-674.
- [4] Huang J, Mumford D. Statistics of natural images and models[C]. IEEE , 1999:541-547.
- [5] 郭德全, 杨红雨, 刘东权等. 基于稀疏性的图像去噪综述[J]. 计算机应用研究, 2012, 29(2): 406-413.
- [6] 黄静静. 基于图像块先验和Bootstrap的图像去噪算法研究[D]. 西安电子科技大学, 2015.
- [7] Mcveigh E R, Henkelman R M, Bronskill M J. Noise and filtration in magnetic resonance imaging[J]. Medical Physics, 1985, 12(5): 586.
- [8] 张璐. 医学图像去噪方法分析与比较[D]. 上海交通大学, 2010.
- [9] Mohan J, Krishnaveni V, Guo Y. A survey on the magnetic resonance image denoising methods[J]. Biomedical Signal Processing & Control, 2014, 9(1): 56-69.
- [10] Perona P, and Jitendra Malik. Scale-space and edge detection using anisotropic diffusion[J]. IEEE Transactions on pattern analysis and machine intelligence, 1990, 12(7): 629-639.
- [11] Gerig G, Kübler O, Kikinis R, et al. Nonlinear anisotropic filtering of MRI data[J]. IEEE transactions on medical imaging, 1992, 11(2): 221-32.
- [12] Krissian K, Aja-Fernandez S. Noise-driven anisotropic diffusion filtering of MRI[J]. IEEE Transactions on Image Processing A Publication of the IEEE Signal Processing Society, 2009, 18(10): 2265-2274.
- [13] Buades A, Coll B, Morel J M. A Non-Local Algorithm for Image Denoising[C]. 2005: 60-65 vol. 2.
- [14] Manjón J V, Carbonellcaballero J, Lull J J, et al. MRI denoising using non-local means[J]. Medical Image Analysis, 2008, 12(4): 514-523.
- [15] Coupé P, Yger P, Barillot C. Fast non local means denoising for 3D MR images[C].

- 2006: 33-40.
- [16] 姚波旭. 基于低秩矩阵分解的非局部稀疏模型图像去噪方法研究[D]. 西安电子科技大学, 2014.
- [17] Dabov K, Foi A, Katkovnik V, et al. Image restoration by sparse 3D transform-domain collaborative filtering[J]. 2008, 6812(8): 681207.
- [18] Eksioğlu E M. Decoupled Algorithm for MRI Reconstruction Using Nonlocal Block Matching Model: BM3D-MRI[J]. Journal of Mathematical Imaging & Vision, 2016, 56(3): 430-440.
- [19] Starck J-L, Candes E J, Donoho D L. The curvelet transform for image denoising[J]. IEEE Transactions on Image Processing, 2002, 11(6): 670-684.
- [20] MN D, M V. The contourlet transform: an efficient directional multiresolution image representation[J]. IEEE transactions on image processing : a publication of the IEEE Signal Processing Society, 2005, 14(12): 2091-2106.
- [21] Parthiban L, Subramanian R. Medical Image Denoising using X-lets[C]. 2007:1-6.
- [22] 王圳萍. 基于低秩矩阵恢复的图像去噪算法研究[D]. 西南交通大学, 2015.
- [23] Mairal J, Bach F, Ponce J, et al. Non-local sparse models for image restoration[C]. 2010: 2272-2279.
- [24] Chen J, Liu S, Huang M, et al. Dictionary Learning for MRI Denoising based on Modified K-SVD[J]. Journal of Imaging Science & Technology, 2017, 61(3).
- [25] Yu G, Sapiro G, Mallat S. Solving Inverse Problems With Piecewise Linear Estimators: From Gaussian Mixture Models to Structured Sparsity[J]. IEEE Transactions on Image Processing, 2012, 21(5): 2481-2499.
- [26] Zoran D, Weiss Y. From learning models of natural image patches to whole image restoration[C]. 2011: 479-486.
- [27] Chen F, Zhang L, Yu H. External Patch Prior Guided Internal Clustering for Image Denoising[C]. 2015: 603-611.
- [28] Li X, Ma Y, Wright J. Robust principal component analysis?[J]. Journal of the ACM (JACM), 2011, 58(3): 11.
- [29] Liu X, Ma J, Zhang X, et al. Image denoising of low-rank matrix recovery via joint Frobenius norm[J]. Journal of Image & Graphics, 2014.
- [30] Wright J, Ganesh A, Rao S, et al. Robust Principal Component Analysis: Exact Recovery of Corrupted Low-Rank Matrices[J]. Advances in Neural Information

- Processing Systems, 2009, 87(4): 20:3–20:56.
- [31] Lyra-Leite D M, Carvalho J L A D. Improved MRI reconstruction and denoising using SVD-based low-rank approximation[C]. 2012:1-6.
- [32] Harmeling S, Schuler C J, Burger H C. Image denoising: Can plain neural networks compete with BM3D?[C]. 2012: 2392-2399.
- [33] Schmidt U, Roth S. Shrinkage Fields for Effective Image Restoration[C]. 2014: 2774-2781.
- [34] Chen Y, Pock T. On learning optimized reaction diffusion processes for effective image restoration[C]. 2015: 5261-5269.
- [35] Mao X J, Shen C, Yang Y B. Image Denoising Using Very Deep Fully Convolutional Encoder-Decoder Networks with Symmetric Skip Connections[J]. 2016.
- [36] 核磁共振成像原理[M],科学出版社, 2007.
- [37] 医学影像诊断学[M],世界图书出版广东有限公司, 2012.
- [38] Zhou W, Alan Conrad B, Hamid Rahim S, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE Trans Image Process, 2004, 13(4): 600-612.
- [39] Martens J B, Meesters L. Image dissimilarity[J]. Signal Processing, 1998, 70(3): 155-176.
- [40] 刘书琴, 毋立芳, 宫玉等. 图像质量评价综述[J]. 中国科技论文, 2011, 06(7): 501-506.
- [41] 何南南, 解凯, 李桐等. 图像质量评价综述[J]. 北京印刷学院学报, 2017, 25(2): 47-50.
- [42] Gonzalez R C, Wintz P. Digital image processing[M]. 2010.
- [43] 石健, 汪洋, 黄海风等. BM3D 算法在海洋 SAR 图像去噪中的应用[J]. 雷达科学与技术, 2016, 14(1): 24-32.
- [44] 基于BM3D的图像去噪算法研究[D]. 西安电子科技大学, 2017.
- [45] Dabov K, Foi A, Katkovnik V, et al. Image denoising by sparse 3-D transform-domain collaborative filtering[J]. IEEE Transactions on Image Processing, 2007, 16(8): 2080-209.
- [46] 基于低秩矩阵恢复的算法及应用研究[D]. 天津大学, 2016.
- [47] Xinghao D, Lihan H, Lawrence C. Bayesian robust principal component

- analysis[J]. IEEE Transactions on Image Processing, 2011, 20(12): 3419-3430.
- [48] Gu S, Zhang L, Zuo W, et al. Weighted Nuclear Norm Minimization with Application to Image Denoising[C]. 2014: 2862-2869.
- [49] Buchanan A M, Fitzgibbon A W. Damped Newton Algorithms for Matrix Factorization with Missing Data[C]. 2005: 316-322.
- [50] Eriksson A, Hengel A V D. Efficient Computation of Robust Low-Rank Matrix Approximations in the Presence of Missing Data using the L-1 Norm[C]. 2010: 1681-1690.
- [51] Qifa Ke T K. Robust L1 norm factorization in the presence of outliers and missing data by alternative convex programming[C]. 2005: 739-746.
- [52] Candes E J, Li X, Ma Y, et al. Robust Principal Component Analysis?[J]. Journal of the Acm, 2011, 58(3): 1-37.
- [53] Wright J, Ganesh A, Rao S, et al. Robust principal component analysis: Exact recovery of corrupted low-rank matrices via convex optimization[C]. 2009: 2080-2088.
- [54] Donoho D L, Matan G, Andrea M. The phase transition of matrix recovery from Gaussian measurements matches the minimax MSE of matrix denoising[J]. Proceedings of the National Academy of Sciences of the United States of America, 2013, 110(21): 8405-8410.
- [55] Candès E J, Recht B. Exact Matrix Completion via Convex Optimization[J]. Foundations of Computational Mathematics, 2009, 9(6): 717-772.
- [56] Cai J-F, Candès E J, Shen Z. A singular value thresholding algorithm for matrix completion[J]. SIAM Journal on Optimization, 2010, 20(4): 1956-1982.
- [57] Zhang D, Yao H, Ye J, et al. Matrix completion by Truncated Nuclear Norm Regularization[C]. 2012: 2192-2199.
- [58] 阴盼强, 路东明, 袁渊. 基于马氏距离的改进非局部均值图像去噪算法[J]. 计算机辅助设计与图形学学报, 2016, 28(3): 404-410.
- [59] Dempster A P, Laird N M, Rubin D B. Maximum likelihood from incomplete data via the EM algorithm[J]. Journal of the Royal Statistical Society, 1977, 39(1): 1-38.
- [60] Cocosco C A, Kollokian V, Kwan R K-S, et al. Brainweb: Online interface to a 3D MRI simulated brain database[C]. Citeseer, 1997:
- [61] Foi A. Noise estimation and removal in MR imaging: The variance-stabilization

- approach[C]. 2011: 1809-1814.
- [62] Rajan J, Poot D, Juntu J, et al. Noise measurement from magnitude MRI using local estimates of variance and skewness[J]. Physics in Medicine & Biology, 2010, 55(16): 441-449.
- [63] 同济大学数学系. 高等数学下册[M].高等教育出版社, 2014.
- [64] Chang Y, Yan L, Zhong S. Hyper-Laplacian Regularized Unidirectional Low-Rank Tensor Recovery for Multispectral Image Denoising[C]. 2017: 5901-5909.
- [65] Liu R W, Shi L, Huang W, et al. Generalized total variation-based MRI Rician denoising model with spatially adaptive regularization parameters[J]. Magnetic Resonance Imaging, 2014, 32(6): 702-720.
- [66] Lin X B, Qiu T S. Denoise MRI images using sparse 3D transformation domain collaborative filtering[C]. 2011: 233-236.
- [67] Zuo W, Meng D, Zhang L, et al. A Generalized Iterated Shrinkage Algorithm for Non-convex Sparse Coding[C]. 2013: 217-224.
- [68] Mohan J, Krishnaveni V, Guo Y. MRI denoising using nonlocal neutrosophic set approach of Wiener filtering[J]. Biomedical Signal Processing & Control, 2013, 8(6): 779-791.

作者在读期间科研成果简介

1 会议

- [1] Yuhan Zhang , Shurong Zou, Ying Fu, et al. MRI denoising using image patch prior based on Gasussian mixture model. ISMRM 2018 (Abstract)
- [2] Yuhan Zhang, Ying Fu, Zhipeng Yang, et al. MRI Denoising via the Combination of Nonlocal Self-Similarity Prior and Gradient Sparsity Prior. ISBI 2019 (Abstract)

2 学术论文

- [3] Yuhan Zhang, Zhipeng. Yang, Jinrong. Hu, et.al. MRI Denoising Using Low Rank Prior and Sparse Gradient Prior[J], IEEE Access, vol. 7, pp. 45858-45865, 2019.
- [4] 张禹涵, 符颖, 杨智鹏等. 基于无噪图像块先验的 MRI 低秩分解去噪算法研究. 成都信息工程大学学报. (已录用)

3 专利与获奖

- [5] 发明专利, 符颖, 邹书蓉, 张禹涵. 基于图像块自相性先验的核磁共振图像去噪方法.
- [6] 发明专利, 张禹涵, 吴涛, 吴锡等. 基于并行超算网格云平台的 GRAPES 系统优化方法.
- [7] 第五届全国并行应用挑战赛, 杨晓东, 张禹涵, 肖丹等. 西部及东北赛区三等奖, 2017. 10.

致 谢

光阴似箭，三年的研究生生活已经接近尾声。三年时光，我收获很多。借此机会向每一位给予我帮助的老师 and 同学表示最衷心地感谢。

首先要感谢的是我的导师符颖副教授，感谢符老师在我研究生期间对我学习上的指导。从论文选题，开题，中期到论文的完成，符老师花费了很多时间进行指导和修正，特别是在论文工作进展不顺利的时候，给我鼓励，和我一起讨论解决思路，因此，论文工作的完成离不开符老师的帮助。感谢符老师在学习上对我进行的督促，使我的专业理论水平有了很大的训练和提高。同时，我要感谢我的另一位导师邹书蓉教授，感谢邹老师研究生三年期间在学习上和生活上对我的诸多关心。同时，邹老师精益求精的工作态度，为人谦和的人格魅力也使我获益良多。在论文结束之际，向我的两位导师表示最衷心地感谢。

然后，论文工作的完成也离不开计算机学院领导们的支持，感谢领导们为我们提供非常好的科研环境；感谢杨智鹏和胡金蓉两位老师对我论文工作提出的指导意见；感谢和我一起度过三年快乐时光的同学、实验室的师兄、师弟和师妹们，感谢你们对我学习上和生活上的帮助。

最后，我要由衷地感谢我的家人，谢谢你们经济上对我的支持和生活上对我无微不至的关怀，感谢你们在精神上的奉献和物质上的付出。