



分类号: TP391

学校代码: 11066

学 号: 202200358067

烟台大学

专 业 学 位 硕 士 论 文

基于对比学习的混合图神经网络推荐模型研究

Contrastive Learning and Mixed-Graph Neural Networks for Recommender Systems

研究生姓名: 陈浩

指 导 教 师: 马文明 教授

专业学位类别: 电子信息

专业学位领域: 软件工程

论文提交日期: 2025年 6 月 11 日

摘要

图神经网络（GNN）作为一种强大的基于图的学习方法，近年来在推荐系统领域产生了重大影响。监督学习作为 GNN 较为常用的范式，本身依赖高质量的标记数据进行训练，但数据稀疏是推荐系统所面临的挑战。为了缓解数据稀释，结合对比学习和图神经网络的方法应运而生，用于解决推荐系统的挑战并且展现出强大的性能，其核心是通过数据增强来解决数据稀疏问题。尽管取得了成功，但大多数现有研究使用随机添加或删除方式扰动图结构，或者通过聚类生成增强视图。通过这两种策略获得的交互信息并未完全捕捉用户-物品的交互而且这些方法可能无法很好地保留用户与物品之间的交互信息，甚至可能丢失一些信息。

本文针对上述问题提出了两种推荐方法：基于噪声扰动的深浅层图对比学习推荐方法和基于混合矩阵分解的图对比学习推荐方法，主要贡献如下：

（1）提出了一种基于噪声扰动的深浅层图对比学习推荐模型（DSGCL）。结合了矩阵分解（Matrix Factorization, MF）和混合噪声扰动来实现数据增强。通过利用低秩矩阵分解捕捉全局信息，融合全局协作信息来进行建模。基于用户与物品的评分交互矩阵进行低秩矩阵分解，获取全局协作信息嵌入表示。然后在 GNN 的传播过程中，加入混合噪声进行特征扰动，得到主视图嵌入表示。再将主视图嵌入表示与全局协作信息嵌入表示进行融合，得到对比视图嵌入表示。最后，将主视图嵌入表示作为主任务进行推荐，主视图嵌入表示与对比视图嵌入表示进行对比学习作为辅助任务。在两个公开的数据集上验证了该方法在部分推荐场景中的有效性。在 ML-100K 数据集上与次优基线相比，Recall@10 达到了 0.2202 提升约 5.5%，Recall@20 达到了 0.3331 提升约 3.4%。而 NDCG@10 达到了 0.3995 提升约 7.2%，NDCG@20 达到了 0.3964 提升了约 6%。

（2）提出了一种基于混合矩阵分解的图对比学习推荐模型（HMFGCL）。该方法在 DSGCL 的基础上对数据增强模块进行了优化，通过融合 MF 和奇异值分解（Singular Value Decomposition, SVD）两种不同的矩阵分解方式来互补的进行全局信息的获取从而优化数据增强部分。首先，基于用户与物品的评分交互矩阵分别进行低秩矩阵分解和奇异值分解，获取不同的全局协作信息嵌入表示。然后，在 GNN 传

播过程中,加入混合噪声进行特征扰动,得到主视图嵌入表示。接下来,将获取的两部分不同的全局协作信息嵌入表示进行融合。然后将融合后的全局协作信息嵌入表示与主视图嵌入表示融合,得到融合了全局协作信息的对比视图嵌入表示。最后,进行主任务推荐与对比学习辅助任务。在三个公开的数据集上验证了该方法在部分推荐场景中的有效性。在 ML-100K 数据集上与次优基线相比,Recall@10 达到了 0.2232 提升约 7%, Recall@20 达到了 0.334 提升约 3.6%。而 NDCG@10 达到了 0.4034 提升约 8.2%, NDCG@20 达到了 0.4001 提升了约 6.9%。在 DSGCL 的基础上性能提升约 1%。

关键词: 对比学习; 图神经网络; 推荐系统; 协同过滤

Abstract

Graph Neural Networks (GNNs), as a powerful graph-based learning approach, have recently made significant impacts in the field of recommendation systems. While supervised learning, a widely adopted paradigm for GNNs, inherently relies on high-quality labeled data for training, data sparsity remains a critical challenge in recommendation scenarios. To mitigate data scarcity, methods integrating contrastive learning with GNNs have emerged, addressing challenges in recommendation systems and demonstrating robust performance. Their core mechanism lies in leveraging data augmentation to alleviate sparse data issues. Despite their success, most existing studies employ random edge addition/removal to perturb graph structures or utilize clustering-based approaches to generate augmented views. However, interaction patterns obtained through these strategies fail to comprehensively capture user-item relationships. Such methods may inadequately preserve critical interaction information between users and items, potentially discarding essential semantic features.

To address the above issues, this paper proposes two recommendation methods: Deep and Shallow Graph Contrastive Learning with Embedding Noise Perturbation and Hybrid Matrix Factorization Based Graph Contrastive Learning for Recommendation System. The main contributions are as follows:

(1) This paper presents a Deep and Shallow Graph Contrastive Learning for Recommender Systems with Embedding Noise Disturbance (DSGCL). Initially, low-rank matrix factorization is performed on the user-item rating interaction matrix to obtain global collaborative information embeddings. Then, during the GNN propagation process, mixed noise is added for feature perturbation to generate the main view embeddings. Next, the main view embeddings and the global collaborative information embeddings are fused to produce contrastive view embeddings. Finally, the main view embeddings are used for the primary recommendation task, while contrastive learning is performed as an auxiliary task between the main view and contrastive view embeddings. The effectiveness of this method is validated in partial recommendation scenarios using two public datasets. On the ML-100K dataset, compared to the suboptimal baseline, Recall@10 achieves 0.2202 with an improvement of approximately 5.5%, and Recall@20 reaches 0.3331 with a 3.4% enhancement. NDCG@10 attains 0.3995 with an improvement of approximately 7.2%,

while NDCG@20 achieves 0.3964 with a 6.0% gain.

(2) This paper presents a Hybrid Matrix Factorization Based Graph Contrastive Learning for Recommendation System (HMFGCL). This method optimizes the data augmentation module based on DSGCL. First, low-rank matrix factorization and SVD are performed on the user-item rating interaction matrix to obtain different global collaborative information embeddings. During the GNN propagation process, mixed noise is added for feature perturbation to generate the main view embeddings. The two different global collaborative information embeddings are then fused. The fused global collaborative information embeddings and the main view embeddings are subsequently combined to produce the contrastive view embeddings that incorporate global collaborative information. Finally, the primary recommendation task is performed alongside the contrastive learning auxiliary task. The effectiveness of this method is validated in partial recommendation scenarios using three public datasets. Compared to the suboptimal baseline on the ML-100K dataset, Recall@10 reached 0.2232, an increase of about 7%, and Recall@20 reached 0.334, an increase of about 3.6%. Meanwhile, NDCG@10 reached 0.4034, an increase of about 8.2%, and NDCG@20 reached 0.4001, an increase of about 6.9%. The performance improved by approximately 1% based on DSGCL.

Key words: Contrastive Learning; Graph Neural Networks; Recommendation Systems; Collaborative Filtering

目 录

1 绪论.....	1
1.1 研究背景和意义.....	1
1.2 研究现状.....	2
1.2.1 协同过滤.....	2
1.2.2 基于图神经网络的推荐.....	3
1.2.3 图自监督学习.....	3
1.2.4 对比学习推荐.....	4
1.3 主要研究内容.....	5
1.4 研究内容及组织结构.....	6
2 基础理论知识	7
2.1 推荐算法概述.....	7
2.1.1 推荐问题的定义.....	7
2.1.2 用户-物品交互矩阵	8
2.1.3 基于图的推荐.....	8
2.2 图对比学习算法.....	8
2.3 本章小结.....	10
3 基于噪声扰动的深浅层图对比学习推荐模型	11
3.1 引言.....	11
3.2 模型描述.....	11
3.2.1 相关定义.....	12
3.2.2 模型框架概述.....	12
3.2.3 获取全局信息的浅层模块.....	14
3.2.4 基于混合噪声扰动的深层模块.....	14
3.2.5 深浅层信息结合的损失函数.....	15
3.2.6 算法实现.....	16
3.3 实验分析.....	18
3.3.1 实验设置.....	18
3.3.2 基线方法介绍.....	20
3.3.3 对比实验.....	21
3.3.4 超参数探索实验.....	22
3.3.5 损失函数分析.....	26
3.3.6 数据集稀疏度分析.....	27
3.3.7 消融实验.....	28
3.4 本章小结.....	29

4 基于混合矩阵分解的图对比学习推荐模型	30
4.1 引言.....	30
4.2 模型描述.....	30
4.2.1 相关定义.....	31
4.2.2 模型框架概述.....	31
4.2.3 混合数据增强预处理.....	32
4.2.4 信息在网络中的传递.....	33
4.2.5 视图生成与损失函数计算.....	34
4.2.6 算法实现.....	35
4.3 实验设计与分析.....	37
4.3.1 实验设置.....	37
4.3.2 对比实验.....	38
4.3.3 超参数探索实验.....	41
4.3.4 损失函数分析.....	46
4.3.5 数据集稀疏度分析.....	47
4.3.6 消融实验.....	49
4.4 本章小节.....	50
5 总结和展望.....	51
5.1 总结.....	51
5.2 展望.....	51
参考文献.....	53

1 绪论

1.1 研究背景和意义

随着互联网的飞速发展,信息过载成为了新出现的问题。从而导致用户面临着大量的产品选择,因此想要识别与用户的兴趣和偏好相符合的内容就变得很困难。所以需要一种方式来帮助用户从众多选项中能够选择到最相关的内容,推荐系统便应运而生^[1]。总体来说,推荐系统已经从最早的协同过滤(Collaborative Filtering, CF)发展到基于内容的推荐,再发展到兼顾个性化与多样化的推荐,不断出现新的算法和技术也在不断满足用户对于个性化推荐的需求,提升了推荐的准确性和用户体验。

最近的研究表明图神经网络(Graph Neural Network, GNN)在基于图的推荐系统中占据重要地位^[2],其核心是聚合邻居信息来获取用户和物品之间的交互信号^[3]。基于 GNN 的推荐方法通常采用一个或多个消息传递层来获取用户和物品的低阶和高阶信息,然后将嵌入传播到用户-物品交互图上^[4-5]。许多基于 GNN 的方法都采取监督学习范式,这类方法的特点是需要足够多且高质量的标记数据来进行训练。但数据稀疏性是许多推荐系统在实际应用场景中面临的挑战^[6],所以从有限的交互数据中获取高质量的用户和物品表示是一项具有挑战性的任务。在此背景下,对比学习(Contrastive Learning, CL)所体现出来的优势为缓解数据稀疏提供了一个可能的解决方案^[7]。

随着近几年对比学习在机器学习领域再次崛起,其在推荐系统中也同样发挥了重要作用。不同于依赖人工标注的监督学习,对比学习的创新之处在于挖掘数据内在关联性充分利用自身固有的信息进行学习。通过最大化正样本对之间的相似性和负样本对之间的差异性来学习用户和项目的特征表示。通过空间映射技术,将相似类的样本映射到相似的特征空间,不同类的样本映射到不同的特征空间,确保相似样本的接近,不同样本的远离。这种无监督特性使得对比学习在数据稀疏场景中表现突出。相关的研究成果也证明 CL 在自监督和无监督学习的各个领域受到了广泛关注并取得了一定成功。

由于对比学习的核心问题是视图生成器如何生成对比样本,所以在基于图的推荐系统中应用 CL 来增强图时,如何设计一个有效的视图生成器是一个值得关注的问题。

题。

1.2 研究现状

本文的研究内容旨在设计推荐模型实现在电影、购物、音乐等部分场景下的推荐。本文针对这些推荐场景设计了两种推荐方法：一种是嵌入噪声扰动的深度与浅层图对比学习推荐模型；另一种是基于混合矩阵分解的图对比学习推荐模型。接下来介绍推荐模型的发展现状。

1.2.1 协同过滤

协同过滤算法是最早且最流行的推荐系统算法之一，在整个领域得到广泛采用。协同过滤背后的原理是识别与目标用户相似的用户，并利用他们的偏好来推断目标用户的偏好。协同过滤主要是通过寻找目标用户的近似邻居定位可比用户，然后根据近似邻居的偏好来预测目标用户的偏好。基本思想是通过考虑用户过去的偏好和其他志趣相投的用户的选择不向用户推荐商品（基于挖掘用户的偏好并预测用户可能喜欢的产品）^[8]。

协同过滤算法中应用最多的是基于邻域的推荐方法，主要包括两种主要算法：第一种是基于用户的协同过滤（UserCF），原理是向目标用户推荐与其兴趣相似的其他用户喜欢的商品；第二种是基于物品的协同过滤（ItemCF），原理是向目标用户推荐与其喜欢的商品相似的商品。

深度学习方法的不断创新发展，也推动了推荐系统的研究，而且使用深度学习还可以展现出方法在提取特征信息方面的优势。文献[9]设计了一种联合特征提取网络，同时将用户和项目嵌入潜在空间利用二者间的项目相似度预测用户感兴趣的内容。文献[10]优化了基于 K 临近的协同过滤算法，引入用户认知相似性特征取得了不错的效果。文献[11]提出一种融合社交网络的协同过滤推荐框架，通过综合用户评分行为与社交网络关系构建相似性度量模型改进了用户协同过滤算法。文献[12]提出的 MMSS_MKR 架构创新性地引入知识图谱实体交叉压缩机制。该模型通过双向门控网络（Bi-GRU）动态调整知识图谱嵌入维度，例如在电影推荐场景中，将导演-演员关系网络与用户观影记录进行跨模态对齐。但需注意，知识图谱的构建成本可能限制其在小规模业务场景的应用。文献[13]的 UPSI 方法通过三层注意力网络（PASR）重

构用户偏好。这种设计虽能缓解新用户冷启动问题，但也存在过度依赖社交图谱完整性的风险。

1.2.2 基于图神经网络的推荐

在过去的几年里 GNN 因其能够模拟不同场景中的各种用户关系，成为推荐系统中的一种常用方法。GNN 模型的核心技术是能够推断和利用节点之间的关系信息。经典的 GNN 模型通常由节点表示学习和图结构传播两部分组成。节点表示的更新可以通过聚合来自本地节点及其邻居节点的信息来实现，利用修改后的节点表示将信息传播到整个图形从而更新其他节点完成信息传播。现有的研究有许多基于 GNN 的模型并在不同的推荐场景中展示了强大的性能。

图卷积网络（Graph Convolutional Network, GCN）是图神经网络中应用最广泛的模型^[14-15]。GCN 模型通过利用多个卷积层来获取节点特征，从而在相邻节点之间聚合信息以获取全局上下文信息，将局部信息转换为全局信息^[16-22]。文献[16]利用 GCN 和特定时间序列模型，通过捕获时空特征成功预测了交通流量。该模型由多图卷积网络模块和门控循环单元两部分组成，通过多图卷积运算捕获流量传播流的整体空间特征。

此外，还有许多其他的图神经网络推荐模型。文献[17]提出的 DiffRec 构建了基于分数匹配的扩散框架，其逆向过程通过 SDE 方程实现。其扩展方案包含动态噪声调度机制和记忆增强采样器，有效缓解了长尾商品推荐中的曝光偏差问题。文献[18]通过量化嵌入空间的几何特性，提出对齐度和均匀度双指标评估体系。MHCH 模型^[19]在推荐场景中部署了用户-社交-兴趣三阶超图卷积，其社交通道采用动态超边构建策略。IHDT^[20]模型创新性地将双塔网络与 GAT 结合，其时空特征编码器采用门控机制验证了异构信息融合的有效性。文献[21]提出了一种可用于跨域信息融合的特定矩阵分解算法，分别采用了四种不同的技术来说明融合方法的推荐性能优于非融合方法。文献[22]提出了 AESR 多头自注意力机制。配合 Node2Vec 预训练，仅需 500 个用户样本即可实现较低图结构重建误差，显著优于传统 GCN 方法。

1.2.3 图自监督学习

自监督学习（Self-Supervised Learning, SSL）是通过使用大量未标记数据进行模

型训练来克服标签数据稀疏问题的学习方式^[23]。自监督学习的核心在于利用数据内部的固有信息自动生成标签信息以用于模型训练^[24]。可以通过设计一个任务从未标记样本中自动生成标签或掩码使模型能够学习样本的内在特征和表示^[25]。与无监督学习方法相比的优点是需要更少的标签数据但具有更强的泛化能力且适用于更广泛的场景^[26]。自监督方法可以最大化数据利用率从而提高数据的使用效率为解决推荐系统中的数据稀疏问题提供了一个值得探索的解决方案^[27]。

由于不同领域的自监督学习的成功，最近的工作将自监督学习应用于推荐系统并取得了比较成功的结果。现有的基于图的 SSL 方法主要分为三类^[28]：1) 对比式，即通过比较不同的增强来学习数据间的共性和差异。GCC 模型^[29]是一个图自监督预训练框架，通过多个图的通用拓扑属性来提取信息。而 InfoGraph 模型^[30]的主要任务是获得图的分层表示嵌入。2) 生成式，即强调数据的内在信息，监督信号是图本身的特征和结构，通常是通过代理任务例如特征或结构重建来实现。Node Attribute 和 Embedding Denoising 就是基于 AE 架构的代理任务，原理是将噪声引入节点特征中生成包含噪声信息的节点特征矩阵然后实现干净节点特征的重建。3) 预测式，即使用直接统计分析或专业知识生成伪标签然后根据生成的伪标签来推断出数据标签关系从而创建基于预测的代理任务。例如，Pairwise Distance 是一种典型的基于上下文的代理任务，通过预测各个节点对之间的最短路径来保留全局拓扑信息。

文献[31]提出的 GraphCL 利用多种图增强策略来生成对比视图，融合包括节点和边缘扰动、属性掩码和子图生成在内的技术来合并不同的信息。文献[32]提出的 GCA 模型保证了图的内在结构和属性在数据增强过程中不变，并采用了两种不同层次的数据增强方法来生成视图。文献[33]提出的 AutoSSL 模型提出使用多个辅助任务来结合各种自监督任务从而进行图增强，改进 SSL 范式。文献[34]提出了 SGPGRec，这是一种端到端的自监督图神经网络模型，具有生成建议的预训练功能。它利用节点的特征和节点间的关系来获得自监督信号。

1.2.4 对比学习推荐

因为对比学习以自监督的方式运行所以成为了解决推荐系统中数据稀疏问题的有效方法。最近的研究将对比学习应用于基于图的推荐系统在解决数据稀疏问题方面表现良好^[28,35,59-60]。最早将对比学习应用于推荐系统的模型是文献[35]提出的 S³-

Rec, 通过随机屏蔽一部分属性和项目来生成增强序列将对比学习与序列推荐相结合鼓励不同增强之间的一致性来训练模型。文献[36]提出了一种解决冷启动问题的新方法, 通过最大化物品特征和协作信号之间的一致性来缓解数据稀疏。弱监督对比学习框架 WCL^[37]为解决实例间的类别冲突问题提供了新颖的思路。COTREC^[38]创新性的构建了两个不同的编码器来容纳不同的视图, 通过在会话内和会话之间捕获信息即使用基于会话的图来实现不同视图的创建并通过共同训练完成对比学习。CLSA^[39]提出了一个数据增强的通用框架, 通过对弱增强和强增强数据进行对比证明强增强优于弱增强。文献[40]提出的 DuoRec 介绍了使用随机丢弃策略进行数据增强。但这种随机增强方法可能会导致关键数据的丢失。与随机丢弃策略不同的 CL4Rec 模型^[41]提出采用重新排序和截断来增强连续数据。文献[42]提出的 NCL 结合了 MLP 和 GMF 子模型并集成了不同的特征提取方法从而更好地适应不同类型的特征并捕获用户和物品与其上下文之间的相关性。文献[28]提出的 SGL 模型利用了节点丢弃的图增强来更好地训练。文献[43]提出的 SimGCL 讨论了节点扰动中的均匀性问题并提出了一种添加噪声的图增强技术。文献[44]提出的 LightGCL 模型提出了一种由奇异值分解结合全局上下文实现的图增强方法取得了良好的结果。文献[45]提出的 GNNCL 方法将噪声和聚类集成到 GNN 的框架中取得了显著的成果。文献[46]提出了一种结合正负样本信息生成信息更加丰富的难负样本的混合采样的图对比学习方法达到了不错的性能。

1.3 主要研究内容

本文基于对比学习和图神经网络提出了部分场景下的推荐模型, 包括电影、购物和音乐等方面, 主要研究内容分为以下两个部分:

(1) 提出了一种嵌入噪声扰动的深层与浅层图对比学习推荐方法 (DSGCL)。该方法主要研究多个推荐场景下模型的一般形式, 比如电影、购物等。由于涉及多种场景, 因此该部分以物品指代电影、音乐等。模型基于用户对物品的打分情况生成用户与物品的交互矩阵。然后基于交互矩阵进行低秩矩阵分解, 分解为低维的隐向量, 获得全局协作信息嵌入表示。然后, 基于交互矩阵在 GNN 的传播过程中, 加入混合噪声对特征进行扰动, 提升嵌入表示的质量, 得到主视图嵌入。对比视图的构建是通过将主视图嵌入表示与全局协作信息进行表示融合。最后, 执行推荐任务与对比学习

辅助任务。实验表明，提出的 DSGCL 算法在多个指标上性能有所提升。

(2) 提出了一种基于混合矩阵分解的图对比学习推荐方法 (HMFGL)。该方法是在 DSGCL 的基础上进行优化，同样是针对多个推荐场景下的一般推荐。该方法针对对比视图的生成进行了增强，增强了模型获取全局信息的能力。首先基于用户物品的交互矩阵分别进行低秩矩阵分解和奇异值分解，获取两部分全局协作信息。在 GNN 的传播过程中，同样采取添加混合噪声的方式进行特征扰动得到主视图嵌入表示。对比视图的生成相比较于 DSGCL 增加了融合奇异值分解产生的全局协作信息，从而得到了融合两部分全局协作信息的对比视图嵌入表示。最后进行推荐任务与对比学习辅助任务。实验证明，提出的 HMFGL 算法在多个指标上相较于 DSGCL 性能有所提升。

1.4 研究内容及组织结构

第一章：阐述了对比学习以及推荐系统的研究背景与意义，总结了国内外各个场景下推荐的研究现状，介绍了本文的研究内容及组织结构。

第二章：回顾了推荐系统的相关理论与算法，主要包括推荐系统的相关算法以及对比学习的相关理论与算法。

第三章：提出了嵌入噪声扰动的深层与浅层图对比学习推荐模型。该模型通过使用混合噪声扰动和矩阵分解的方式获取主视图表示嵌入与全局协作信息表示嵌入，并将二者进行融合产生对比视图进而完成基于对比学习的推荐。最后，通过多组实验证明了提出模型的有效性。

第四章：提出了基于混合矩阵分解的图对比学习推荐模型。该方法基于第三章提出的模型进行了优化，提升了数据增强部分。通过低秩矩阵分解和奇异值分解两种不同的矩阵分解方式获取全局协作信息。在生成对比视图部分增加了全局信息的获取，提升了对比视图的表示质量。再将主视图表示嵌入与对比视图表示嵌入进行基于对比学习的推荐。多组实验证明了提出模型的有效性。

第五章：对本文的研究进行总结，并对下一步的研究方向进行展望。

2 基础理论知识

2.1 推荐算法概述

由于信息过载问题的出现，推荐系统成为了现代互联网服务中不可或缺的一部分。它通过获取用户的历史交互数据分析用户的喜好，为用户推荐个性化的服务内容。本节将介绍推荐系统的相关理论与算法基础。

2.1.1 推荐问题的定义

推荐算法通常是将用户感兴趣的物品推荐给用户，使用的信息通常是标签、打分、评论等隐式反馈。




图 2-1 基于内容的推荐

如图 2-1 所示，给定 m 个用户和 n 个物品，其中，物品 1 和物品 2 是相似的，因为他们拥有共同的标签喜剧，又因为用户 1 与物品 1 发生了交互，那么算法就认为，物品 2 对于用户 1 来说是可能感兴趣的，因此将物品 2 推荐给用户 1。

综上所述，给定一个用户-物品交互图 $G = (U, V)$ ，方法的目标是通过提取图 G 中的用户物品交互信息生成邻接矩阵 A 并训练函数 F 进行推荐。

$$\hat{y}_{u,v} = F(u, v | G, A, \Pi) \quad (2-1)$$

其中， u 是用户， v 是物品， $\hat{y}_{u,v}$ 表示用户 u 和物品 v 之间的交互概率，在函数 F 中，

Π 表示附加参数。 F 的目标是通过分析用户-物品交互数据来提高推荐性能以及提取用户偏好、关系和全局信息。该功能通过预测用户与商品互动的概率来提供个性化推荐,从而提高用户满意度。

2.1.2 用户-物品交互矩阵

推荐系统使用的信息主要来自隐性反馈。隐式反馈是通过购买、点击、评级等操作隐式提供的。假设有 I 个用户,由 $U = \{u_1, u_2, \dots, u_I\}$ 表示;有 J 个物品,由 $V = \{v_1, v_2, \dots, v_J\}$ 表示。交互可以表示为 $R \in \mathbb{R}^{I \times J}$,其中如果用户 u 与物品 v 交互,则每个元素 $r_{uv} = 1$,否则 $r_{uv} = 0$ 。

2.1.3 基于图的推荐

基于图的推荐方法,可用数据可以表示为用户-项二分图 $G = \{U \cup V, A\}$,其中 $U \cup V$ 表示节点集, A 是邻接矩阵,定义如下^[48]:

$$A = \begin{bmatrix} 0^{I \times I} & R \\ R^T & 0^{J \times J} \end{bmatrix} \quad (2-2)$$

基于图的推荐方法更新通过多个图卷积聚合来自相邻节点的信息而生成的节点嵌入。给定初始节点嵌入 E_0 ,嵌入的更新过程如下:

$$E^l = D^{-\frac{1}{2}} A D^{-\frac{1}{2}} E^{l-1} \quad (2-3)$$

其中 D 是图 G 的度矩阵, E^l 和 E^{l-1} 分别表示第 l 层和第 $l-1$ 层的节点嵌入。当图卷积层数为 L 时,将读出最终的节点嵌入,如下所示:

$$E = \text{Output}(E^0, E^1, \dots, E^L) \quad (2-4)$$

在基于图的推荐方法中,模型参数的优化通常涉及使用成对排名损失:

$$L_{rec} = \sum_{u=0}^{I-1} \sum_{(i,j) \in D_u} -\log \sigma(\hat{r}_{ui} - \hat{r}_{uj}) + \lambda \|E^0\|^2 \quad (2-5)$$

这里, σ 表示 sigmoid 激活函数, λ 是正则化系数。 $D_u = \{(i,j)|i \in R_u \cap j \notin R_u\}$ 表示包含用户 u 的正样本和负样本的训练数据,其中 R_u 是用户 u 与之交互的物品集。

2.2 图对比学习算法

在基于对比学习的推荐方法中 GCL (Graph Contrastive Learning) 通常被用作辅助任务补充用于推荐的主要任务。利用自监督信号来执行补充任务并在多任务框架

内运行：

$$L = L_{rec} + \alpha L_{cl} \quad (2-6)$$

其中 α 用作自监督任务的超参数，控制对比学习的重要性。 L_{cl} 通常在图对比学习中使用 InfoNCE 损失函数：

$$L_{cl} = \sum_{i=0}^I -\log \frac{\exp\left(e'_i, \frac{e''_i}{\tau}\right)}{\sum_{j=0}^I \exp\left(e'_i, \frac{e''_j}{\tau}\right)} \quad (2-7)$$

其中 τ 表示温度系数。 e'_i 和 e''_i 分别代表节点 i 对应的主视图嵌入和增强视图嵌入，它们是两个对比目标嵌入，与节点 j 相同。此损失函数促进了每个节点的比较表示的连贯性。




图 2-2 基于结构增强的数据增强

当将目光转移到数据增强时，基于 GCL 的方法通常分为两种类型^[50]：第一种是结构增强。如图 2-2 所示，结构增强涉及通过不同的随机扰动方法获得两个增强视图， G' 和 G'' ，从而生成对比表示：

$$E' = \eta(G', E^0), E'' = \eta(G'', E^0) \quad (2-8)$$

其中 $\eta(\cdot)$ 表示图形编码器。因为推荐系统中使用的信息通常是稀疏的所以随机扰动生成增强视图的方式可能会引入噪声并导致某些信息的丢失从而影响图对比学习模型的有效性。

第二种类型是特征增强。如图 2-3 所示，特征增强向节点嵌入添加了随机噪声，然后使用 GCN 生成对比嵌入表示：

$$E' = \eta(E^0, \varepsilon \rho'), E'' = \eta(E^0, \varepsilon \rho'') \quad (2-9)$$




图 2-3 基于特征增强的数据增强

这里， ρ' 和 ρ'' 代表噪声，现有的模型大多使用均匀噪声即 $\rho', \rho'' \sim U(0,1)$ 。 ε 代表用于调节噪声的幅度的噪声控制参数。使用此方法能够限制噪声大小达到噪声控制但通用和固定的噪声控制参数可能不适合泛化到具有独特特征的节点。

2.3 本章小结

本章阐述了推荐系统基础定义与算法和图对比学习的基础定义与算法，简述了推荐系统的问题定义以及推荐的实现过程，对通常的推荐场景进行了概括；介绍了图对比学习的通用对比损失计算函数和两种常用图增强方式。

3 基于噪声扰动的深浅层图对比学习推荐模型

3.1 引言

随着互联网的发展而产生的信息过载问题使得用户在海量的选择中挑选自己感兴趣的物品变得困难，所以需要个性化的推荐系统帮助用户获取感兴趣物品的信息从而提高用户体验。但数据稀疏性以及数据标签信息的不足使得传统的推荐系统能力受限从而重新体现了对比学习的优势。

对比学习的核心原理是将来自同一类的样本映射到相似的特征空间，并将来自不同类的样本映射到不同的特征空间，从而确保相似的样本是接近的而不同的样本是遥远的。CL 在推荐中最典型的应用是用一定的方法增强用户-项二分图，比如随机丢弃一定比例的节点或边，然后最大化一致表示的相似度。

现有的图增强方法中最常用的随机扰动方式可能导致有价值的结构信息丢失从而导致表示学习的误差。启发式对比学习方法的有效性很大程度上取决于视图生成器从而限制了模型的适应性使其容易受到不稳定用户的行为的影响。大多数现有的基于 GNN 的对比推荐系统都受到过度平滑问题的限制从而产生无差别表示问题。

为解决这些问题，提出了一种基于噪声扰动的深浅层图对比学习推荐模型 (DSGCL)。利用添加混合噪声来扰动特征并使用矩阵分解来引导图增强，以捕获用户-物品交互信息，并将全局上下文信息纳入对比学习表示中。首先，基于用户对物品的打分情况生成用户物品交互矩阵。然后，将该矩阵进行低秩矩阵分解产生低维隐向量作为全局协作信息嵌入表示。然后，基于交互矩阵在 GNN 的传播过程中，加入混合噪声对特征进行扰动，提升嵌入表示的质量，得到主视图嵌入。对比视图的构建是通过将主视图嵌入表示与全局协作信息进行表示融合。然后，进行推荐任务与对比学习辅助任务。在两个公共数据集上的实验表明该方法的有效性。

3.2 模型描述

本节详细介绍了 DSGCL 模型。首先，对问题进行公式化并介绍了该方法中使用的相关符号与定义。然后，介绍了 DSGCL 方法的总体框架。最后，介绍方法的各个部分，包括基于嵌入噪声的深层模块，获取全局协作信息的浅层模块以及对比学习的实现。

3.2.1 相关定义

定义 3.1 用户集和物品集: U 和 V 分别表示用户和物品的集合。 $U = \{u_1, u_2, \dots, u_i\}$, $V = \{v_1, v_2, \dots, v_j\}$, 其中 u_i 和 v_j 分别表示一个用户和一个物品且 $u_i \in U$, $v_j \in V$ 。

定义 3.2 用户嵌入和物品嵌入: $E^{(u)}$ 和 $E^{(v)}$ 分别表示用户嵌入和物品嵌入, $E^{(u)} = \{e_1^u, e_2^u, \dots, e_i^u\}$, $E^{(v)} = \{e_1^v, e_2^v, \dots, e_j^v\}$, 其中 e_i^u 和 e_j^v 分别表示一个用户的嵌入和一个物品的嵌入。

定义 3.3 扰动嵌入: 基于定义 3.2 给出扰动嵌入定义, 扰动嵌入 Z_l 是前向传播第 l 层基于用户嵌入和物品嵌入, 在传播过程中加入混合噪声进行扰动生成的嵌入。

定义 3.4 混合噪声: 混合噪声 Δ 是基于均匀噪声和高斯噪声以一定比例混合生成的噪声。

定义 3.5 低秩矩阵: 低秩矩阵 $\bar{A}$ 是由用户物品交互归一化邻接矩阵 A 进行低秩矩阵分解产生的近似矩阵。

定义 3.6 聚合嵌入: 基于定义 3.3 和定义 3.5 给定 G_l 为第 l 层聚合了全局协作信息的聚合嵌入, 聚合嵌入是由扰动嵌入融合低秩近似矩阵的全局协作信息生成的嵌入。

本章使用的重要概念以及符号如表 3-1 所示。

表 3-1 本章中使用的符号

符号	描述
U/V	用户/物品
$E^{(u)}/E^{(v)}$	用户嵌入/物品嵌入
Z_l	l 层的扰动嵌入
G_l	l 层聚合了全局协作信息的嵌入
Δ	混合噪声
A	用户物品交互归一化邻接矩阵
$\bar{A}$	分解后的低秩矩阵

3.2.2 模型框架概述

本节详细描述了提出的方法 DSGCL。如图 3-1 所示, 该方法主要包括三部分。第一部分是基于混合噪声干扰的 GNN 主干, 即用于捕获本地图依赖的深层模块。第

二部分是由低秩矩阵分解引导的增强部分，即用于获取全局信息的浅层模块以增强图对比学习。最后则是对比学习的实现。




图 3-1 DSGCL 的整体架构

用户-物品交互的归一化邻接矩阵 A 是从用户-物品交互图 G 中提取的稀疏矩阵，该矩阵作为方法基本数据，而 G 是通过数据集生成的。

归一化邻接矩阵 A 是浅层模块的核心组件，我们对 A 进行低秩矩阵分解。用户的潜在特征矩阵表示为 $\bar{P}_k$ ，物品的潜在特征矩阵表示为 $\bar{Q}_k$ ，其中 k 是潜在向量的维数。此过程会保留重要的全局信息。

在训练过程中，通过多个前向传播层，迭代地聚合初始用户嵌入 E_0^u 和初始物品嵌入 E_0^v ，将噪声 Δ 添加到嵌入中同时结合矩阵 A 的信息，获得用户和物品的表示嵌入 $Z^{(u)}$ 和 $Z^{(v)}$ 。 l 层的用户和物品嵌入分别表示为 Z_l^u 和 Z_l^v 。这些构成了深层模块的主要内容。

最后，算法使用传播层的聚合结果 $Z^{(u)}$ 和 $Z^{(v)}$ 作为主要推荐任务的基础。将 MF 生成的潜在特征矩阵 $\bar{P}_k$ 和 $\bar{Q}_k$ 与每一层的聚合结果融合，得到结合了全局协作信息的用户嵌入 $G^{(u)}$ 和物品嵌入 $G^{(v)}$ ，它们从全局角度表示嵌入，即对比视图嵌入。然后将 $G^{(u)}$ 和 $G^{(v)}$ 与由聚合层生成的节点嵌入 $E^{(u)}$ 和 $E^{(v)}$ 使用对比损失函数 InfoNCE 进行比较，作为辅助任务来增强主要任务的推荐结果。

3.2.3 获取全局信息的浅层模块

为了提高图对比学习的推荐性能, 算法引入全局信息学习, 通过使用 MF 方法从全局角度获取用户和物品之间共享的重要协作信号。算法专门对归一化邻接矩阵 A 进行矩阵分解运算, 将其分解为两个矩阵 $\bar{A} = \bar{P}_k \bar{Q}_k^T$ 。重建的矩阵 $\bar{A}$ 表示归一化邻接矩阵 A 的低秩近似矩阵, 其中 $\bar{P}_k \in \mathbb{R}^{m \times k}$ 表示用户的潜在特征矩阵, $\bar{Q}_k \in \mathbb{R}^{n \times k}$ 表示物品的潜在特征矩阵, k 表示潜在向量的维度。

基于矩阵分解的图结构学习有两个好处。为了保留图中的主要信息, 算法首先通过低秩分解保存了重要的用户-物品交互。然后, 新生成的图形结构结合了用户-物品交互, 以全局保留总体协作信号。给定 $\bar{A}$, 在每一层重建的用户-物品关系图上进行消息传递。

$$g_{i,l}^{(u)} = \sigma(\bar{A}_{i,:} \cdot E_{l-1}^{(v)}) \quad (3-1)$$

$$g_{j,l}^{(v)} = \sigma(\bar{A}_{:,j} \cdot E_{l-1}^{(u)}) \quad (3-2)$$

其中, $\bar{A}$ 表示低秩矩阵分解后的隐向量矩阵。

$$\bar{P}_k, \bar{Q}_k = MF(A, k) \quad (3-3)$$

$$\bar{A}_{MF} = \bar{P}_k \bar{Q}_k^T \quad (3-4)$$

根据上述四个公式, 重写消息传递过程公式如下:

$$G_l^{(u)} = \sigma(\bar{A}_{MF} E_{l-1}^{(v)}) = \sigma(\bar{P}_k \bar{Q}_k^T E_{l-1}^{(v)}) \quad (3-5)$$

$$G_l^{(v)} = \sigma(\bar{A}_{MF}^T E_{l-1}^{(u)}) = \sigma(\bar{Q}_k \bar{P}_k^T E_{l-1}^{(u)}) \quad (3-6)$$

上述公式中的 $G_l^{(u)}$ 和 $G_l^{(v)}$ 是融合了全局协作信息的用户和物品嵌入集。特别注意, 模型在训练过程中只保留了可以存储低维度信息的 $\bar{P}_k$ 和 $\bar{Q}_k$ 。 $\bar{P}_k$ 和 $\bar{Q}_k$ 是通过预处理阶段运行 MF 预先计算产生从而提高模型的运行效率。

3.2.4 基于混合噪声扰动的深层模块

为每个用户 u_i 和物品 v_j 分配一个嵌入向量 $e_i^{(u)}, e_j^{(v)} \in \mathbb{R}^d$, 其中 d 表示嵌入维度大小, 这是协作过滤算法中的常见做法。然后将 $E^{(u)} \in \mathbb{R}^{I \times d}$ 和 $E^{(v)} \in \mathbb{R}^{J \times d}$ 定义为所有用户和物品的集合, 其中 I 和 J 表示用户和物品的数量。聚合过程涉及利用两层前向传播层从每个节点的邻居收集信息。在 l 层中, 聚合过程表示如下:

$$z_{i,l}^{(u)} = \sigma \left(A_{i,:} \cdot \left(E_{l-1}^{(v)} + e_{l-1}^{(v)'} \right) \right) \quad (3-7)$$

$$z_{j,l}^{(v)} = \sigma \left(A_{:,j} \cdot \left(E_{l-1}^{(u)} + e_{l-1}^{(u)'} \right) \right) \quad (3-8)$$

其中, $z_{i,l}^{(u)}$ 和 $z_{j,l}^{(v)}$ 表示用户 u_i 和物品 v_j 在第 l 层的聚合嵌入。 $\sigma(\cdot)$ 表示激活函数, 其中使用了恒等函数。 A 表示归一化邻接矩阵。 $e_{l-1}^{(v)'}$ 和 $e_{l-1}^{(u)'}$ 是混合噪声。受文献[49]的启发, 算法应用混合噪声来扰乱用户和物品的嵌入, 以提高表示的一致性。噪声的产生过程表示如下:

$$e_i' = e_i + \Delta_i \quad (3-9)$$

其中, 噪声向量 Δ_i 满足 $\|\Delta_i\|^2 = \varepsilon$ 并且 ε 是一个小常数。此外, 它还满足:

$$\Delta = \omega \odot (l_1 \times N_i' + l_2 \times N_i''), \omega \in \mathbb{R}^d \sim U(0,1) \quad (3-10)$$

其中, l_1 和 l_2 是两个超参数, 其中 $l_1 + l_2 = 1$ 。 N_i' 和 N_i'' 是高斯噪声和均匀噪声, 其形状与 e_i 相同, 并且:

$$N_i' \sim \mathcal{N}(0,1), N_i'' \sim \text{Uniform}(0,1) \quad (3-11)$$

这样可以让 e_i 和 Δ_i 处于同一个超球体中, 使得向 e_i 中添加噪声并不会导致明显的偏差反而会略微增强 e_i 中的信息, 从而保证增强的一致性。

3.2.5 深浅层信息结合的损失函数

如图 3-2 所示, 在传统的 GCL 方法 (如文献[43]) 中生成对比视图的嵌入是通过相同的数据增强方法构建两个额外的视图并使用 InfoNCE 当做对比损失函数。但从原始视图生成的嵌入仅用于进行推荐任务并不直接参与 InfoNCE 损失函数的计算。设置这种三视图对比学习方法可能是为了解决主视图嵌入的误导性表示, 从而减低数据增强方法对原始视图嵌入的潜在负面影响。

DSGCL 放弃了传统的三视图范式, 通过浅层模块获得的全局协作信息来创建对比视图。在 InfoNCE 损失函数中比较的两个目标是深层模块创建的主视图嵌入 $z_{i,l}^{(u)}$ 、 $z_{j,l}^{(v)}$ 和结合了全局协作信息的增强视图 $g_{i,l}^{(u)}$ 、 $g_{j,l}^{(v)}$ 。通过这种方式可以简化基于图的对比学习框架。公式如下:

$$L_{CL}^{(u)} = \sum_{i=0}^I \sum_{l=0}^L -\log \frac{\exp \left(s \left(z_{i,l}^{(u)}, g_{i,l}^{(u)} / \tau \right) \right)}{\sum_{i'=0}^I \exp \left(s \left(z_{i,l}^{(u)}, g_{i',l}^{(u)} / \tau \right) \right)} \quad (3-12)$$




图 3-2 三视图对比学习范式

$$L_{CL}^{(v)} = \sum_{j=0}^J \sum_{l=0}^L -\log \frac{\exp \left(s \left(z_{j,l}^{(v)}, g_{j,l}^{(v)} / \tau \right) \right)}{\sum_{j'=0}^J \exp \left(s \left(z_{j',l}^{(v)}, g_{j',l}^{(v)} / \tau \right) \right)} \quad (3-13)$$

其中， $s(\cdot)$ 表示余弦相似性， τ 表示温度系数。

$$L = L_r + \lambda_1 \cdot \left(L_s^{(u)} + L_s^{(v)} \right) + \lambda_2 \cdot \|\Theta\|_2^2 \quad (3-14)$$

$$L_r = \sum_{i=0}^I \sum_{s=1}^S \max(0, 1 - \hat{y}_{i,p_s} + \hat{y}_{i,n_s}) \quad (3-15)$$

在公式(3-14)和公式(3-15)中，展示了对比学习损失的并发优化以及推荐任务对主要目标函数的调整。推荐的总损失主要包括两部分，即主任务推荐损失 L_r 和对比学习损失 $L_s^{(u)}$ 和 $L_s^{(v)}$ 。这里， $\hat{y}_{i,p_s}$ 和 $\hat{y}_{i,n_s}$ 代表用户 i 的正负物品对的预测分数。

3.2.6 算法实现

算法 3-1 提供算法的实现过程。设定有几个输入：归一化邻接矩阵 A 、用户嵌入 $E^{(u)}$ 、物品嵌入 $E^{(v)}$ 、训练参数 $\{W_i, b_i\}_{i=1}^L$ 、 $\{u\}_{u \in U}$ 、 $\{v\}_{v \in V}$ 。输出是预测函数 $F(u, v)$ 。

该算法定义了一个函数 MF 用于获取全局协作信息，主要输入参数是用户-物品交互归一化邻接矩阵 A 、潜在向量维度 k 、用户嵌入 $E^{(u)}$ 、物品嵌入 $E^{(v)}$ 和优化迭代 T 。

该函数计算 Frobenius 范数作为损失函数，并采用简单的梯度下降来优化损失函数，从而得到低秩近似矩阵 $\bar{A}$ 。矩阵分解后返回用户潜在特征矩阵 $\bar{P}_k$ 和 $\bar{Q}_k$ 。该函数用于低秩矩阵分解，获取用户和物品的全局信息，用于后续的特征融合。

算法 3-1 DSGCL(基于噪声扰动的深浅层图对比学习推荐算法)

输入：归一化邻接矩阵 A ，用户嵌入 $E^{(u)}$ ，物品嵌入 $E^{(v)}$ ，训练参数 W_i, b_i

输出：预测函数 $F(u, v)$

函数 MF (A, k, T): 获取全局协作信息

按照交互矩阵 $\tilde{A}$ 和隐向量维度 k 分解矩阵得到低秩近似矩阵 $\bar{A}$

from t to T do

1 $\bar{A}_t = \bar{P}_{kt} \bar{Q}_{kt}^T$

2 $loss = \text{Frobenius}(A, \bar{A}_t)$

3 梯度下降优化， $t++$ 直到收敛或达到 T

返回 $\bar{P}_k, \bar{Q}_k^T$

1 初始化参数 W_i, b_i

2 根据函数 MF 获取全局协作信号 $\bar{P}_k, \bar{Q}_k^T$

3 for u, v in A

4 获取用户的扰动嵌入 $z^{(u)}$ 和物品的扰动嵌入 $z^{(v)}$

5 获取融合了全局协作信息的用户嵌入 $g^{(u)}$ 和物品嵌入 $g^{(v)}$

6 计算对比损失 $L_{CL}^{(u)}, L_{CL}^{(v)}$

8 计算预测标签 $\hat{y}_{uv} = f(z^{(u)}, z^{(v)})$

7 梯度下降优化参数

9 end for

10 返回预测函数 F

算法的主循环迭代更新参数，直到每批用户 u 和物品 v 计算的损失函数达到收敛。首先，算法使用函数 MF 来获取矩阵分解后用户和物品的潜在特征矩阵 $\bar{P}_k$ 和 $\bar{Q}_k$ 。然后，使用 GCN 将邻接矩阵 A 与前一层节点特征表示 E 融合，并增加噪声，以获得用户的扰动嵌入表示 $z^{(u)}$ 和物品的扰动嵌入表示 $z^{(v)}$ 。

随后，用户的扰动嵌入表示 $z^{(u)}$ 与从函数 MF 获得的潜在特征矩阵 $\bar{P}_k$ 和 $\bar{Q}_k$ 融合，得到用户的对比视图表示 $g^{(u)}$ 。同样，物品的扰动嵌入表示 $z^{(v)}$ 与从函数 MF 获得的潜在特征矩阵 $\bar{P}_k$ 和 $\bar{Q}_k$ 融合，以获得物品的对比视图表示 $g^{(v)}$ 。 $g^{(u)}$ 和 $g^{(v)}$ 分别代表融

合了全局协作信息的用户嵌入和融合了全局协作信息的物品嵌入。

接下来, 计算 InfoNCE 损失函数以辅助推荐主任务。算法使用从主视图生成的用户和物品的表示 $z^{(u)}$ 和 $z^{(v)}$, 以及融合了全局协作信息的对比表示 $g^{(u)}$ 和 $g^{(v)}$, 分别计算用户对比损失 $L_{CL}^{(u)}$ 和物品对比损失 $L_{CL}^{(v)}$ 。然后, 使用函数 $f(\cdot)$ 利用用户扰动嵌入 $z^{(u)}$ 和物品扰动嵌入 $z^{(v)}$ 来预测用户与物品的交互。

最后, 通过梯度下降迭代细化参数, 直到收敛, 得到预测函数 F 。

通过整合上述步骤来估计算法的时间复杂度, 公式如下:

$$O(C_{MF} + N \times (C_{GCN} + L \cdot C_{agg}) + C_{grad}) \quad (3-16)$$

公式(3-16)中, L 表示网络深度。 C_{MF} 表示矩阵分解运算的时间复杂度。 C_{agg} 表示聚合运算的时间复杂度。 C_{GCN} 表示 GCN 中消息传递的时间复杂度。 C_{grad} 表示执行梯度下降以更新参数的时间复杂度。

3.3 实验分析

为了验证提出方法的有效性, 在本节中进行了大量的实验验证。本章的实验基于两个公开的数据集 MovieLens-100K (ML-100K) 和 ModCloth。首先介绍了本研究中使用的实验设置。然后介绍详细实验分析。主要包括: 对比实验、探索超参数实验、损失函数分析、数据集稀疏性实验、消融实验。最后对所有实验进行总结。

3.3.1 实验设置

1) 实验环境

本章实验使用基于 pytorch^[50]开发的 RecBole 框架^[51-52]实现。所有的实验都是基于开源平台 RecBole 框架进行的, 使用平台能够进行快速原型设计和推荐算法评估。RecBole 提供了一个可容纳各种推荐任务包括传统推荐、顺序推荐和基于知识图谱的推荐的平台, 通过提供灵活高效的算法开发和评估平台来促进推荐系统领域的研究。平台支持许多的推荐算法并提供全面的实验工具如数据集预处理、超参数调优和结果分析等。凭借其模块化的架构和易读的文档使研究人员和相关从业者能够轻松运行、比较和复现最先进的推荐模型。实验的运行环境是一台搭载 Intel(R) Core(TM) i7-6800k 3.40GHz CPU 和 8G RAM 的计算机。

2) 数据集

本章使用两个公开的数据集 ML-100K 和 ModCloth-1000 证明 DSGCL 的有效性。表 3-2 中提供了数据集的详细描述。

ML-100K 由 GroupLens 研究实验室维护的经典推荐系统数据集，数据集内容主要是 MovieLens 网站上用户对电影的评分。ML-100K 数据集作为基准的数据集对推荐系统和机器学习领域的研究和评估起到了重要的作用。

ModCloth-1000 数据集是通过 ModCloth 数据集随机抽取了 1000 名用户数据作为实验使用的数据集。由 ModCloth 网站提供，数据集内包含大量服装产品和用户评论包含详细的产品属性例如名称、描述、价格和品牌以及反映偏好、尺寸感知和质量评估的用户评分和文本评论。ModCloth 数据集是各种分析任务包括市场趋势分析、用户行为研究以及推荐系统的开发和评估的宝贵资源。

表 3-2 数据集描述

数据集	用户数量	物品数量	稀疏度
ML-100K	943	1682	93.70%
ModCloth-1000	1000	278	99.8747%

3) 数据预处理

为了对数据集进行分割，按照 RecBole 的分割规则 7:3 分割为训练集和测试集。训练集用于模型训练，测试集用于训练模型后进行预测和推荐并计算推荐性能。

4) 参数设置

对于超参数设置，将嵌入大小配置为 128，并使用学习率为 0.001 的 Adam 优化器。L2 正则化的系数设置为 0.00005，聚合层数设置为 2，这是研究中常用的参数。对比学习损失函数的系数设置为 0.005，而噪声系数设置为 0.1。噪声比例设置为 8:2（高斯噪声：均匀噪声），矩阵分解的维度设置为 5。有关单个超参数设置的进一步探索实验将在后续小节中详细说明。对于其他对比方法的参数设置，按照 RecBole 提供的最佳参数进行设置。

5) 评估指标

本章实验使用两个评估指标来评估方法性能。包括 Recall@k、NDCG@k，分别由如下公式表示：

$$Recall@k = \frac{1}{N} \sum_u \frac{|S_u \cap T_u|}{|T_u|} \quad (3-17)$$

$$NDCG@k = \frac{\sum_{i=1}^p \frac{2^{rel_i} - 1}{\log_2(i+1)}}{\sum_{i=1}^{|REL|} \frac{2^{rel_i} - 1}{\log_2(i+1)}} \quad (3-18)$$

其中, S_u 表示预测出的需要推荐的物品的集合, T_u 表示真实的测试集中被推荐的集合。 rel_i 表示推荐列表中排名第 i 的物品, $|REL|$ 表示将原始的召回集合 R 按照得分从大到小排序后的集合。

3.3.2 基线方法介绍

接下来介绍与 DSGCL 进行比较的基线方法。

DMF^[53] 是推荐系统中的经典方法之一, 它是基于矩阵分解实现的。

GCMC^[54] 是一种将图卷积神经网络与矩阵相结合的推荐算法, 提出了一个可微分的消息传递图自动编码器框架, 用于获取用户和物品表示。

NGCF^[2] 是一种将用户和物品之间的交互信息建模为图并应用图卷积运算来学习用户和物品嵌入的基于神经网络的图卷积 CF 算法。

EASE^[55] 是一种基于用户行为序列的推荐算法, 使用一种称为“专业知识模型”的特征学习方法, 将原始序列中物品之间的共现关系转换为低维特征向量, 从而减小模型参数规模和计算复杂性。

LightGCN^[56] 是一种结合图神经网络的用于协作筛选的轻量级推荐算法。该算法利用多层图卷积网络 (GCN) 从交互矩阵中学习嵌入, 能够捕获用户和物品之间的相关性。

ENMF^[57] 是一种采用非采样策略并依赖于简单矩阵分解框架的神经网络算法。此算法利用神经网络从实体矩阵中学习嵌入, 其中用户和物品的实体矩阵产生于用户-物品交互矩阵。

SimpleX^[58] 证明了损失函数和负采样率的选择具有同等重要性, 是首先应用余弦对比损失 (CCL), 并将 CCL 与一个简单的统一协同滤波模型进行融合的算法。

SGL^[28] 将自监督学习应用于用户-物品图, 从而提高了 GCN 在推荐任务中的性能。该方法利用自监督任务作为辅助, 通过自监督加强了节点表示学习。

SimGCL^[43]探讨了图增强在对比学习中的必要性并提出放弃图增强技术将均匀噪声引入嵌入空间以创建对比视图从而学习更均匀的表示分布。

LightGCL^[44]是 2023 年提出的对比学习模型，引入了利用奇异值分解进行对比增强，获得跨层表示分布，通过增强的全局协作关系来增强图对比学习。

DirectAU^[18]专注于协同过滤（CF）中表示的所需属性，通过超球体上的对齐和均匀性来衡量 CF 表示的质量，从而证明提高对齐和均匀性可以提高推荐性能。

DiffRec^[62]通过调节噪声注入强度来保留个性化信号，通过项目语义分组利用频谱聚类来降维，在潜在空间中进行扩散过程，并通过时间戳驱动指数衰减加权捕获时间用户偏好变化。

XSimGCL^[49]通过消除对数据额外的增强操作来改进 SimGCL，使模型更加轻量。还提出了跨层对比的思想，在保持良好性能的同时进一步降低了时间成本。

3.3.3 对比实验

表 3-3 ML-100K 数据集上的 Recall@k 和 NDCG@k 比较

ML-100K 数据集				
方法	Recall@10	Recall@20	NDCG@10	NDCG@20
DMF	0.1956	0.3067	0.3495	0.355
GCMC	0.164	0.2413	0.3039	0.2969
NGCF	0.1994	0.3124	0.1819	0.3643
EASE	0.1779	0.2481	0.2139	0.2525
LightGCN	0.166	0.2505	0.3051	0.301
ENMF	0.1657	0.2561	0.2989	0.2987
SimpleX	0.183	0.2864	0.3385	0.3381
SGL	0.2033	0.3129	0.3807	0.3774
SimGCL	0.1055	0.1701	0.1448	0.1616
LightGCL	<u>0.2086</u>	<u>0.3223</u>	<u>0.3726</u>	<u>0.3743</u>
DirectAU	0.1207	0.1922	0.171	0.188
XSimGCL	0.1343	0.2196	0.2086	0.223
DiffRec	0.2132	0.319	0.2196	0.2474
DSGCL	0.2202	0.3331	0.3995	0.3964

表 3-3、表 3-4 展示了与基线方法相比较的性能结果。将次优基线的结果用下划线标记，DSGCL 的结果加粗标记。

如表 3-3 和表 3-4 所示, DSGCL 在 ML-100K 数据集和 ModCloth 数据集上性能均高于基线方法。

在 ML-100K 数据集上, 与次优基线 LightGCL 相比, DSGCL 的 Recall@10 和 NDCG@10 分别提高了 5.56%和 7.22%而 Recall@20 和 NDCG@20 的提升分别为 3.35%和 5.90%。在 ModCloth-1000 数据集上的 DSGCL 比次优基线有了显著改进, Recall@10 和 NDCG@10 提高了约 30%而 Recall@20 和 NDCG@20 的增加也接近 30%, 充分证明了 DSGCL 在处理小数据集方面的优势。

表 3-4 ModCloth-1000 数据集上的 Recall@k 和 NDCG@k 比较

ModCloth-1000 数据集				
方法	Recall@10	Recall@20	NDCG@10	NDCG@20
DMF	0.1552	0.2556	0.0797	0.1048
GCMC	0.1573	0.2582	0.0817	0.1069
NGCF	0.1833	0.2274	0.0834	0.1039
EASE	0.2042	0.2926	0.1139	0.1363
LightGCN	0.1422	0.2144	0.0796	0.0979
ENMF	0.1946	0.2879	0.1106	0.1346
SimpleX	0.2015	0.2581	0.1092	0.1236
SGL	0.06	0.1001	0.0301	0.0404
SimGCL	0.0614	0.1142	0.0292	0.0426
LightGCL	<u>0.2529</u>	<u>0.2957</u>	<u>0.1987</u>	<u>0.2096</u>
DirectAU	0.0618	0.1157	0.0413	0.0551
XSimGCL	0.1259	0.1841	0.082	0.0974
DiffRec	0.2559	0.2905	0.1914	0.2048
DSGCL	0.3309	0.3728	0.2594	0.2704

3.3.4 超参数探索实验

本节探讨了多个超参数在不同尺度上对方法性能的影响。通过观察矩阵分解维度 k 的变化来观测 DSGCL 的性能变化讨论潜在向量的维度对推荐性能的影响。调整均匀噪声和高斯噪声之间的比例来观察性能变化, 探索噪声比例对方法性能的影响。改变传播层层数的大小观察模型性能的变化, 探索聚合层数对方法性能的影响。最后调整嵌入维度的大小观察模型性能的变化, 探索嵌入维度对方法性能的影响。

1) 低秩矩阵分解的隐向量维度分析

本实验探讨了 DSGCL 在不同矩阵分解维度下的性能,反映了矩阵分解维度对推荐效果的影响。通过观察矩阵分解维度在 ML-100K 数据集上的性能来分析改变矩阵分解维度对该方法性能的影响,如图 3-3 所示。该图表明,当矩阵分解的维数为 5 时,该方法的性能达到峰值;但是,随着维度的增加,方法的有效性会降低。




图 3-3 隐向量维度对 DSGCL 在 ML-100K 数据集上性能的影响

该数据集上的实验结果表明,较小的矩阵分解(潜在向量)维度足以捕获用户和物品之间的全局信息。潜在向量维度为 5 时 Recall 在 k 为 10 和 20 时都达到最高的值分别为 0.2202 和 0.3331 而 NDCG 在 k 为 10 和 20 时的值分别为 0.3995 和 0.3964。这些结果可能表明较小的维度能够充分表示用户和物品之间的潜在信息。当潜在向量维度 k 值增加到 30 时性能下降的原因可能是过大的维度导致方法获取了冗余信息,降低了模型识别复杂模式的能力。

综上,矩阵分解中潜在向量的维度在基于图神经网络的推荐方法中有着重要作用。调整潜在向量维度会显著影响方法的性能,过大或过小的维度都会降低推荐的有效性。

2) 噪声比例分析

本实验探讨了 DSGCL 在两种不同比例噪声产生的混合噪声干扰影响下的方法性能从而讨论各种噪声比例对方法有效性的影响。在 ML-100K 数据集上调整两种噪声的比例时方法的性能如图 3-4 所示。图中数据表明当高斯噪声与均匀噪声的比例为 8:2 时达到性能峰值, Recall@10 和 NDCG@10 的值分别为 0.2202 和 0.3995 而

Recall@20 和 NDCG@20 的值分别为 0.3352 和 0.398。对比之下单独使用高斯噪声的 Recall@10 和 NDCG@10 的值分别下降为 0.2139 和 0.3936 而 Recall@20 和 NDCG@20 的值分别下降为 0.3304 和 0.3948。单独使用均匀噪声同样出现了性能下降, Recall@10 和 NDCG@10 的值分别下降为 0.2185 和 0.3983。这表明随着推荐列表中物品数量的增加, 两种不同噪声之间的互相影响逐渐变得明显, 当高斯噪声或均匀噪声的比例增加时推荐的性能往往会下降。




图 3-4 噪声比例对 DSGCL 在 ML-100K 数据集上性能的影响

该数据集上的实验结果表明, 适当的混合噪声干扰 (适当的噪声比例) 有助于方法性能的提升。因为对比学习方法的嵌入表示质量与一致性和对齐性高度相关, 适当的混合噪声干扰可能有助于增强表示的一致性和对齐性进而提高推荐方法的性能。混合噪声比例为 8:2 (高斯噪声: 均匀噪声) 时的 Recall@10 和 NDCG@10 的值达到最高表明该比例在表示均匀性和对齐性方面产生了最大的正面影响。混合噪声比例为 9:1 时的 Recall@20 和 NDCG@20 的值达到最高表明随着推荐物品数量的增加, 高斯噪声可能起着更重要的作用。在其他情况下, 随着高斯或均匀噪声逐渐增加性能往往会下降的原因可能是过多的单一噪声会降低表示质量, 从而降低模型检测复杂噪声的能力。

综上, 混合噪声的比例在无监督学习对比方法中至关重要。选择合适的混合噪声比率会显著影响表示质量, 从而影响方法的性能, 因为过于单一的噪声会损害推荐效果。

3) 网络层数分析

本实验调查了不同聚合层深度对建议性能的影响。实验在 ML-100K 数据集上观察了该方法的性能，结果如图 3-5 所示。

在 ML-100K 数据集上的结果展示了 DSGCL 的性能随着网络层数的变化发生变化的趋势。当网络层数为 2 时 Recall@10 和 NDCG@10 分别达到最大值为 0.2202 和 0.3995。当网络层数只有 1 时 Recall@20 和 NDCG@20 分别达到最大值为 0.3373 和 0.3991。这可能表明随着推荐物品数量的增加，更多的聚合层会引入过多的干扰信息或不相关的信息进而导致性能下降。性能的下降随着聚合层数的增加变得越来越明显。当网络层数为 4 时 Recall@10 和 Recall@20 的值减少到 0.2157 和 0.3319 而 NDCG@10 和 NDCG@20 的值减少到 0.3963 和 0.397。这可能表明过多的聚合层会捕获冗余信息进而导致方法性能下降。




图 3-5 网络层数对 DSGCL 在 ML-100K 数据集上性能的影响

对上述实验结果的分析表明图神经网络的聚合层数对推荐性能有一定的影响。选择合适的聚合层数是提高方法的性能的关键因素，过小或过大的聚合层数通常都会对性能产生负面作用。

4) 嵌入维度分析

本实验探索了 DSGCL 在不同嵌入维度上的性能来揭示嵌入大小对推荐效果的影响。如基于 ML-100K 数据集上的图 3-6 所示，实验结果突出了一个一致的趋势：当嵌入维度设置为 128 时方法表现出最高性能。随着维度的增加或减少方法的性能会明显下降。

ML-100K 数据集上的实验结果表明, 当嵌入维度配置为 128 时该方法达到最佳性能, Recall@10 和 Recall@20 的值分别为 0.2202 和 0.3331 而 NDCG@10 和 NDCG@20 的值分别为 0.3995 和 0.3964。表明适当的维度有助于低维潜在向量捕获被忽视的信息。随着维度的减小性能会明显下降, Recall@10 和 Recall@20 的值最低下降到 0.2043 和 0.3134 而 NDCG@10 和 NDCG@20 的值最低分别下降至 0.3689 和 0.3708。表明较小的嵌入维度无法从原始数据中保留足够的有用信息。当维度达到 256 时性能会下降, Recall@10 和 Recall@20 的值下降到 0.214 和 0.33 而 NDCG@10 和 NDCG@20 的值分别下降至 0.392 和 0.3928。原因可能是过大的维度捕获了冗余信息进而增加了模型的复杂性并遇到过拟合问题。




图 3-6 嵌入维度对 DSGCL 在 ML-100K 数据集上性能的影响

对上述实验结果的讨论表明图神经网络的嵌入维度对推荐性能有一定影响。选择合适的嵌入维度是提高方法性能的关键因素, 太小和太大的嵌入维度通常都会对性能产生负面作用。

3.3.5 损失函数分析

在本节中, 探讨了 ML-100K 和 ModCloth-1000 数据集上损失函数的变化, 并进行了比较和分析, 如图 3-7 所示。选择了次优基线 LightGCL 作为观察损失值趋势收敛的参考。

如图 3-7 左图所示, 很明显, 在 ML-100K 数据集上, DSGCL 表现出更好的性能, 实现了更低的损失值和更快的下降趋势。这表明它卓越的学习能力和更好的泛化能力。与 DSGCL 相比, LightGCL 的下降趋势同样不错, 但损失值高于 DSGCL。

在 ModCloth-1000 数据集上 DSGCL 的损失值也达到了较低的水平。但受限于较低的数据集复杂度以及较少的用户和物品数量，DSGCL 和 LightGCL 都表现出良好的下降趋势，损失值从 0.8 下降到 0.2 左右。这可能表明两种方法在此数据集上都表现出良好的泛化能力且有效地避免了过度拟合。

综上，损失函数的收敛对于基于图的对比学习推荐方法具有显著的影响，更快的下降趋势和较低损失值对于提高推荐方法的性能至关重要所以设计适当的模型架构和损失函数对提高方法性能非常重要。




图 3-7 两个数据集上损失函数变化

3.3.6 数据集稀疏度分析

本实验探讨了在不同稀疏水平的 ML-100K 数据集下方法性能的趋势。实验以不同比例从 ML-100K 数据集中随机采样数据，以分析数据集稀疏度对方法性能的影响，如图 3-8 所示。实验结果突出了一个显著的趋势：数据集的稀疏度越大模型性能越差，随着数据集稀疏度的降低模型性能会提高。

如图 3-8 中显示当 ML-100K 数据集的稀疏度为 0.3(30%)时 DSGCL 的性能最差，Recall@10 和 Recall@20 的值分别为 0.1608 和 0.1785 而 NDCG@10 和 NDCG@20 的值分别为 0.0771 和 0.1009。这表明随着数据集变得稀疏，模型学习到的用户-物品交互信息减少会导致模型性能下降。随着数据集的稀疏度降低模型性能逐渐提高。除了没调整稀疏度前的 ML-100K 原数据集外，数据集稀疏度为 0.7(70%)时 Recall@10 和 Recall@20 的值分别为 0.1541 和 0.2554 而 NDCG@10 和 NDCG@20 的值分别为

0.1863 和 0.2144。这可能表明随着方法从数据集中捕获更多信息，模型可学习内容的增加使得模型性能提高。

综上，数据集的稀疏度会显著影响模型的性能。数据集的稀疏度越大通常意味着数据集中的用户-物品交互信息越少，导致模型可以捕获的信息越少，从而降低模型的性能。因此，在考虑模型性能时，不应忽视数据集稀疏性的影响。




图 3-8 数据集稀疏度对 DSGCL 性能的影响

3.3.7 消融实验

该小节探讨了矩阵分解模块和混合噪声干扰模块对 ML-100K 数据集上方法性能的影响。如图 3-9 所示，介绍了三种变体：DSGCL-M（仅保留 MF 模块）、DSGCL-N（仅保留混合噪声扰动模块）和 DSGCL-R（两者都不保留）。




图 3-9 消融实验结果

在 ML-100K 数据集上的实验结果表明，对于 Recall，DSGCL-N（仅保留混合噪

声扰动)和 DSGCL-M(仅保留矩阵分解)都显示出一些改进, $R@10$ 分别为 0.2128 和 0.2117, $R@20$ 分别为 0.3238 和 0.3251。这表明, 在无监督对比学习中, 获取有关用户-物品交互的全局信息并增强表示的一致性和对齐度对于方法性能的改进同样重要。当矩阵分解和混合噪声扰动都被移除时, 性能会下降, 这表明这两种方法对推荐结果都有帮助。

图 3-9 中的数据显示仅保留矩阵分解 (DSGCL-M) 方法的性能最佳, $NDCG@10$ 和 $NDCG@20$ 的值分别为 0.388 和 0.3888。这表明全面的用户和物品交互数据有助于增强 $NDCG$ 提高推荐系统的性能。仅保留混合噪声扰动 (DSGCL-N) 方法的性能有所降低, $NDCG@10$ 和 $NDCG@20$ 的值分别为 0.3798 和 0.3791。去除矩阵分解和混合噪声扰动 (DSGCL-R) 方法的性能明显降低, $NDCG@10$ 和 $NDCG@20$ 的值分别为 0.3726 和 0.3724 突出了矩阵分解获取全局信息和混合噪声扰动对推荐性能的积极影响。

3.4 本章小结

本章引入了 DSGCL 将全局信息与混合噪声扰动相结合。方法利用浅层模块的矩阵分解方法来捕获用户-物品对之间的全局信息生成用于对比学习的增强视图, 通过深层模块中的混合噪声扰动增强了嵌入表示的一致性和质量。在两个公共数据集上进行的综合实验表明在部分场景中的 DSGCL 与基线方法相比具有优势, 尤其是在小型数据集上。

4 基于混合矩阵分解的图对比学习推荐模型

4.1 引言

在基于图的推荐系统中图神经网络（GNN）发挥了重要的作用^[2]。GNN 中的多个传播层实现了邻域信息的聚合整合上下文信息用来生成用户和物品嵌入，其中还包含了用户和物品的高阶交互信息^[3]用于迭代细化用户-物品交互图^[4-5]。监督学习中的数据稀疏^[6]是由于缺乏高质量标记数据进行训练而导致用户交互信息不足和推荐性能下降。因此对比学习（CL）所展示的优势再次为这个问题提供了可能的解决方案^[7]。

最近的研究再次强调了对比学习与传统的监督学习相比在图机器学习领域的优势。能够在标签或类别信息不足的情况下获取足够信息的原理是将相似样本尽可能靠近而将不同样本推得更远达到最大化相似性并扩大差异的目的。正是这一特性使 CL 与其他方法相比在处理数据稀疏问题时表现出更好的性能，在多个领域取得了一定的成果。

由于对比学习的核心问题是视图生成器如何生成和识别对比样本，因此在应用 CL 来增强基于图的推荐系统时，设计一个有效的视图生成器是关键。最常见的方法是使用启发式生成器进行数据增强^[57]。虽然这些方法取得了一定成功，但也暴露了一些问题。首先，随机增强技术虽然简单地生成了对比视图，但存在信息丢失或受相关信息干扰的问题。其次，这种视图生成器对于个人用户来说泛化性很差，这使得本已稀缺的信息更加难以使用。

鉴于这些局限性和挑战本章提出了 HMFGCL。HMFGCL 采用了两种技术进行图增强：低秩矩阵分解和奇异值分解并将二者结合起来生成用于对比学习的扰动视图。这使 HMFGCL 不仅能够捕获基本的用户-物品交互信息还可以整合全局上下文信息。其次在图神经网络的传播过程中引入混合噪声扰动来提高嵌入表示的质量^[49]从而解释用户之间的依赖关系。在三个公共数据集上的广泛实验结果验证了 HMFGCL 的合理性和稳健性。

4.2 模型描述

本节详细阐述了 HMFGCL 的实现细节。首先，对问题进行公式化并介绍使用的

相关符号与定义。然后，介绍了 HMFGCL 方法的总体框架。最后，介绍方法的各个部分，包括数混合据增强预处理模块、信息传递过程以及对比学习模块。

4.2.1 相关定义

本章使用的主要符号在表 4-1 中，并附有相关描述。除第三章给出的定义之外，给出如下新定义：

定义 4.1 低秩近似矩阵：低秩近似矩阵 $\tilde{A}$ 是由用户物品交互归一化邻接矩阵 A 进行低秩矩阵分解产生的近似矩阵。

定义 4.2 近似矩阵：近似矩阵 $\hat{A}$ 是由用户物品交互归一化邻接矩阵 A 进行奇异值分解产生的近似矩阵。

定义 4.3 聚合嵌入：基于定义 4.1 和定义 4.2 给定 G 为聚合了全局协作信息的聚合嵌入，聚合嵌入是由扰动嵌入融合低秩近似矩阵与近似矩阵的全局协作信息生成的嵌入。

表 4-1 本章使用的符号

符号	描述
A	用户物品交互归一化邻接矩阵
$\tilde{A}$	MF 分解后的低秩近似矩阵
$\hat{A}$	SVD 分解后的近似矩阵
Z	扰动嵌入
G	聚合了全局协作信息的嵌入

4.2.2 模型框架概述

如图 4-1 所示，HMFGCL 主要分为三个部分。第一部分是由 MF 和 SVD 引导的混合数据增强预处理模块，旨在互补的获取全局协作信息。第二部分是信息传播过程，涉及添加混合噪声捕获本地用户-物品依赖关系。第三部分是对比学习模块，包括局部依赖与全局协作信号的融合和对比损失的计算。

作为基本数据的用户物品交互归一化邻接矩阵 A （表示用户与物品交互）是从用户与物品交互图 G 中提取的稀疏矩阵， G 是通过数据集生成的。

首先，在数据增强预处理模块中，对归一化邻接矩阵 A 进行了两个独立的矩阵分解过程，即由 MF 和 SVD 引导的低秩矩阵分解。用户潜在特征矩阵表示为 $\tilde{P}_k$ 和 $\hat{P}_q$ ；

物品潜在特征矩阵表示为 $\tilde{Q}_k$ 和 $\hat{Q}_q$ ，其中 k 是 MF 中潜在向量的维数， q 是 SVD 中最大奇异值的数量。两种因式分解方法都保留了重要的全局信息，为随后的互补融合做准备。




图 4-1 HMFGL 的整体架构

在数据传播过程的聚合层中引入混合噪声 Δ 来进行特征扰动，增强表示的均匀性来优化嵌入质量。通过多个聚合层，迭代更新初始嵌入 E_0^u 和 E_0^v ，以及归一化邻接矩阵 A ，得到最终用户嵌入 $E^{(u)}$ 和物品嵌入 $E^{(v)}$ 。

在对比学习模块中，第一步涉及将本地依赖关系与全局协作信息集成，以形成对比视图。算法将 MF 生成的潜在特征矩阵 $\tilde{P}_k$ 和 $\tilde{Q}_k$ 与从 SVD 分解中获得的潜在特征矩阵 $\hat{P}_q$ 和 $\hat{Q}_q$ 合并为辅助信息。然后将这些辅助信息与每一层的聚合结果相结合，得出用户表示嵌入 $G^{(u)}$ 和物品表示嵌入 $G^{(v)}$ ，它们包含全局协作信息，形成对比视图。第二步是对比损失的计算。算法使用图神经网络的最终聚合结果 $z^{(u)}$ 和 $z^{(v)}$ 作为对比学习任务的主视图，并将它们与包含全局协作信息的对比视图 $G^{(u)}$ 和 $G^{(v)}$ 进行对比，以计算 InfoNCE 对比损失。最后，使用这种对比损失来纠正使用主视图的推荐的主要任务。

4.2.3 混合数据增强预处理

通过预处理引入全局协作信息，并通过 MF 和 SVD 的互补采集方法最大限度地提取这些信息，准备创建对比视图。算法对归一化邻接矩阵 A 执行两次矩阵分解过程。使用 MF，将其分解为低阶近似矩阵 $\tilde{A} = \tilde{P}\tilde{Q}^T$ ，其中 $\tilde{P} \in \mathbb{R}^{m \times k}$ 表示用户潜在特征矩阵，

$\tilde{Q} \in \mathbb{R}^{n \times k}$ 表示物品潜在特征矩阵。 k 表示隐向量的维度。同样，使用 SVD 将归一化邻接矩阵 A 分解为近似矩阵 $\hat{A} = \hat{P}\hat{S}\hat{Q}^T$ ，其中 $\hat{P} \in \mathbb{R}^{m \times q}$ 表示用户潜在特征矩阵， $\hat{Q} \in \mathbb{R}^{n \times q}$ 表示物品潜在特征矩阵。 q 表示最大奇异值的数量。公式如下：

$$\tilde{P}_k, \tilde{Q}_k = MF(A, k), \tilde{A}_{MF} = \tilde{P}_k \tilde{Q}_k^T \quad (4-1)$$

$$\hat{P}_q, \hat{S}_q, \hat{Q}_q = SVD(A, q), \hat{A}_{SVD} = \hat{P}_q \hat{S}_q \hat{Q}_q^T \quad (4-2)$$

采用这两种矩阵分解方法的基本原理是两方面：首先，MF 和 SVD 都可以通过低秩分解来保留重要的用户-物品交互，即全局协作信息。其次，通过利用这两种方法结合形成的互补关系，最大限度地获取全局信息。这种方法增强了对用户偏好的捕捉和整体信息收集。

4.2.4 信息在网络中的传递

HMFGCL 的主体部分主要是生成推荐任务和对比学习任务的主视图。通常情况下基于图的推荐方法利用多个聚合层从相邻节点收集信息，形成新的节点嵌入。假设初始节点嵌入为 E_0 ，则图神经网络的更新过程定义如下：

$$E_l = D^{-\frac{1}{2}} A D^{-\frac{1}{2}} E_{l-1} \quad (4-3)$$

上述公式中， D 是度矩阵，记录与每个节点关联的边的数量 E_l 和 E_{l-1} 分别表示第 l 层和第 $l-1$ 层的节点嵌入。当图卷积层数为 L 时，最终的节点嵌入读取如下：

$$E = Out(E_0, E_1, \dots, E_L) \quad (4-4)$$

$Out(\cdot)$ 并不指代特定的方法，因为有对每一层求和或将最后一层的结果作为最终输出等多种方法可以用来处理聚合层的结果。

在此基础上，提出了 GNN 的实现：首先，为每个用户 u_m 和每个物品 v_n 分配一个嵌入向量 $e_m^{(u)}$ 和 $e_n^{(v)} \in \mathbb{R}^d$ ，其中 d 表示嵌入大小，这是推荐系统中的常见做法。然后，将 $E^{(u)} \in \mathbb{R}^{M \times d}$ 和 $E^{(v)} \in \mathbb{R}^{N \times d}$ 分别定义为所有用户和物品的集合，其中 M 和 N 表示用户和物品数量。最后，引入混合噪声干扰嵌入，公式如下：

$$e'_m = e_m + \Delta_m, e'_n = e_n + \Delta_n \quad (4-5)$$

噪声向量 Δ_m 满足 $|\Delta_m|^2 = \epsilon$ ，并且 ϵ 是一个小常数。向量 Δ_n 的操作类似， Δ_m 和 Δ_n 的维度都与 e_m 和 e_n 相同。此外，噪声向量公式如下：

$$\Delta = \omega \odot (l_1 \times N_u + l_2 \times N_g), \omega \in \mathbb{R}^d \sim U(0,1) \quad (4-6)$$

上述公式中， l_1 和 l_2 是控制两个噪声比例的两个超参数， $l_1 + l_2 = 1$ 。 N_g 和 N_u 分

别是高斯噪声和均匀噪声，并且满足：

$$N_g \sim \mathcal{N}(0,1), N_u \sim \text{Uniform}(0,1) \quad (4-7)$$

这种方法的目的是使用轻量级的噪声扰动来增强嵌入的均匀性，从而提高表示质量。基于公式(4-3)和公式(4-5)，将 GNN 聚合过程重写如下：

$$E_l = D^{-\frac{1}{2}} A D^{-\frac{1}{2}} E'_{l-1} \quad (4-8)$$

E'_{l-1} 表示在添加噪声后在层 $l-1$ 处的嵌入表示，特别是对于 l 层处的用户 m 和物品 n ：

$$z_{m,l}^{(u)} = \sigma \left(A_{m,:} \cdot E_{l-1}^{(v)'} \right) \quad (4-9)$$

$$z_{n,l}^{(v)} = \sigma \left(A_{:,n} \cdot E_{l-1}^{(u)'} \right) \quad (4-10)$$

$z_{m,l}^{(u)}$ 和 $z_{n,l}^{(v)}$ 表示用户 m 和物品 n 在 l 层的聚合嵌入。函数 $\sigma(\cdot)$ 表示激活函数， A 是归一化邻接矩阵。 $E_{l-1}^{(v)'}$ 和 $E_{l-1}^{(u)'}$ 分别表示添加噪声后 $l-1$ 层的物品嵌入和用户嵌入。

4.2.5 视图生成与损失函数计算

首先，融合全局协作信息 $\tilde{A}_{MF}$ 和 $\hat{A}_{SVD}$ ，以形成对比视图嵌入。根据公式(4-1)和公式(4-2)，可以得到：

$$G_l^{(u)} = \sigma \left(\tilde{A}_{MF} E_{l-1}^{(v)} \hat{A}_{SVD} \right) = \sigma \left(\tilde{P}_k \tilde{Q}_k^T E_{l-1}^{(v)} \hat{P}_q \hat{S}_q \hat{Q}_q^T \right) \quad (4-11)$$

$$G_l^{(v)} = \sigma \left(\tilde{A}_{MF}^T E_{l-1}^{(u)} \hat{A}_{SVD}^T \right) = \sigma \left(\tilde{Q}_k \tilde{P}_k^T E_{l-1}^{(u)} \hat{Q}_q \hat{S}_q \hat{P}_q^T \right) \quad (4-12)$$

$G_l^{(u)}$ 和 $G_l^{(v)}$ 表示与全局协作信号融合的用户和物品嵌入，表示包含全局协作信息的对比视图。从公式(4-11)和公式(4-12)中，得到了用户 m 和物品 n 在 l 层的信息融合过程：

$$g_{m,l}^{(u)} = \sigma \left(\tilde{A}_{m,:} \cdot E_{l-1}^{(v)} \cdot \hat{A}_{m,:} \right) \quad (4-13)$$

$$g_{n,l}^{(v)} = \sigma \left(\tilde{A}_{:,n} \cdot E_{l-1}^{(u)} \cdot \hat{A}_{:,n} \right) \quad (4-14)$$

从公式(4-11)和公式(4-12)中获得的 $G_l^{(u)}$ 和 $G_l^{(v)}$ 对应对比视图嵌入。

对于对比损失的计算，传统的 GCL 方法通常采用三视图范式，通过数据增强生成两个额外的视图进行对比学习，而主视图不直接参与 InfoNCE 计算。然而，这种范式提升了方法架构的复杂性，因为这两种视图都需要通过图神经网络进行学习。HMFGL 放弃了传统的三视图结构，主视图生成的嵌入 $E^{(u)}$ 和 $E^{(v)}$ 是 InfoNCE 计算

的一部分，而对比视图嵌入 $G^{(u)}$ 与 $G^{(v)}$ 构成了另一部分。对于用户 m 和物品 n ，给出对比损失公式如下：

$$L_{CL}^{(u)} = \sum_{m=0}^M \sum_{l=0}^L -\log \frac{\exp\left(s\left(z_{m,l}^{(u)}, g_{m,l}^{(u)}/\tau\right)\right)}{\sum_{m'=0}^M \exp\left(s\left(z_{m',l}^{(u)}, g_{m',l}^{(u)}/\tau\right)\right)} \quad (4-15)$$

$$L_{CL}^{(v)} = \sum_{n=0}^N \sum_{l=0}^L -\log \frac{\exp\left(s\left(z_{n,l}^{(v)}, g_{n,l}^{(v)}/\tau\right)\right)}{\sum_{n'=0}^N \exp\left(s\left(z_{n',l}^{(v)}, g_{n',l}^{(v)}/\tau\right)\right)} \quad (4-16)$$

上述公式中， $S(\cdot)$ 表示余弦相似度， τ 表示温度。

$$L = L_r + \lambda_1 \cdot \left(L_s^{(u)} + L_s^{(v)}\right) + \lambda_2 \cdot \|\Theta\|_2^2 \quad (4-17)$$

$$L_r = \sum_{m=0}^M \sum_{s=1}^S \max(0, 1 - \hat{y}_{m,p_s} + \hat{y}_{m,n_s}) \quad (4-18)$$

在公式(4-17)和公式(4-18)中，详细阐述了对比学习损失的并发优化和推荐任务的主要目标函数的调整。具体来说， $\hat{y}_{m,p_s}$ 和 $\hat{y}_{m,n_s}$ 表示用户 m 的正物品对和负物品对的预测分数。

4.2.6 算法实现

算法 4-1 描述了所提出方法的实现过程。输入包括用户物品交互归一化邻接矩阵 A 、低秩矩阵分解维度 k 、最大奇异值数量 q 、优化迭代 T 、用户嵌入 $E^{(u)}$ 和物品嵌入 $E^{(v)}$ ，训练参数 W_i 、 b_i ，输出是预测函数 $F(u, v)$ 。

算法定义了两个函数。第一个是 MF，旨在捕获用户和物品全局信息用于后续的特征融合。主要输入参数是用户物品交互归一化邻接矩阵 A 、潜在向量维数 k 和优化迭代次数 T 。该函数计算 Frobenius 范数作为损失函数，并采用简单的梯度下降进行优化，目的是得到低阶近似矩阵 $\tilde{A}$ 。完成后，函数返回潜在特征矩阵 $\tilde{P}_k$ 和 $\tilde{Q}_k$ 。第二个函数是 SVD，其作用与 MF 相似。通过奇异值分解获得用户和物品全局信息用于后续的特征融合。主要参数是用户物品交互矩阵 A 和最大奇异值的数量 q 。此函数的核心是使用 Pytorch 框架内 torch 库中的 torch.svd_lowrank()函数来获取近似矩阵 $\hat{A}$ 。函数返回近似特征矩阵 $\hat{P}_q$ ， $\hat{S}_q$ 和中间矩阵 $\hat{Q}_q$ 。

算法的主循环迭代地更新参数，直到每批用户 u 和物品 v 达到收敛。首先，算法

利用 MF 和 SVD 函数来获得用户的潜在特征矩阵, $\tilde{P}_k$ 和 $\hat{P}_q$, 物品的潜在特征矩阵 $\tilde{Q}_k$ 和 $\hat{Q}_q$ 以及中间矩阵 $\hat{S}_q$ 。随后, 使用 GNN 将邻接矩阵 A 与前一层的节点特征表示 E 聚合, 并引入噪声以获得用户表示 $z^{(u)}$ 和物品表示 $z^{(v)}$ 。

算法 4-1 HMFGCL(基于混合矩阵分解的图对比学习推荐算法)

输入: 归一化邻接矩阵 A , 用户嵌入 $E^{(u)}$, 物品嵌入 $E^{(v)}$, 训练参数 $\{W_i, b_i\}_{i=1}^L$

输出: 预测函数 $F(u, v)$

函数 MF (A, k, T): 获取全局协作信息

按照交互矩阵 A 和隐向量维度 k 分解矩阵得到低秩近似矩阵 $\tilde{A}$

from t to T do

1 $\tilde{A}_t = \tilde{P}_{kt} \tilde{Q}_{kt}^T$

2 $loss = \text{Frobenius}(A, \tilde{A}_t)$

3 梯度下降优化, $t++$ 直到收敛或达到 T

返回 $\tilde{P}_k, \tilde{Q}_k$

函数 SVD (A, q): 获取全局协作信息

按照交互矩阵 A 和最大奇异值数量 q 分解产生近似矩阵 $\hat{A}$

即 $\hat{P}_q, \hat{S}_q, \hat{Q}_q = \text{svd_lowrank}(A, q)$

返回 $\hat{P}_q, \hat{S}_q, \hat{Q}_q$

1 初始化参数 W_i, b_i

2 根据函数 MF 获取全局协作信号 $\tilde{P}_k, \tilde{Q}_k^T$

3 根据函数 SVD 获取全局协作信号 $\hat{P}_q, \hat{S}_q, \hat{Q}_q$

3 for u, v in A

4 获取用户的扰动嵌入 $z^{(u)}$ 和物品的扰动嵌入 $z^{(v)}$

5 获取融合了全局协作信息的用户嵌入 $g^{(u)}$ 和物品嵌入 $g^{(v)}$

6 计算对比损失 $L_{CL}^{(u)}, L_{CL}^{(v)}$

8 计算预测标签 $\hat{y}_{uv} = f(z^{(u)}, z^{(v)})$

7 梯度下降优化参数

9 end for

10 返回预测函数 F

将用户嵌入表示 $z^{(u)}$ 与从 MF 函数获得的潜在特征矩阵 $\tilde{P}_k, \tilde{Q}_k$, 以及从 SVD 函数中获得的潜在特征矩阵 $\hat{P}_q, \hat{S}_q, \hat{Q}_q$ 融合, 导出用户的对比视图表示嵌入, 表示为 $g^{(u)}$ 。

同样，物品嵌入表示 $z^{(v)}$ 与从 MF 函数获得的潜在特征矩阵 $\tilde{P}_k, \tilde{Q}_k$ ，以及 SVD 函数中的潜在特征矩阵 $\hat{P}_q, \hat{S}_q, \hat{Q}_q$ 融合，导出物品的对比视图表示嵌入，表示为 $g^{(v)}$ 。因此， $g^{(u)}$ 和 $g^{(v)}$ 反映了富含全局协作信息的用户和物品嵌入。

计算辅助任务的 InfoNCE 损失函数，以帮助主任务细化表示嵌入。算法使用主视图的用户和物品嵌入 $z^{(u)}$ 和 $z^{(v)}$ ，以及包含全局协作信息的对比视图嵌入 $g^{(u)}$ 和 $g^{(v)}$ ，作为计算 InfoNCE 损失的基础。具体来说，算法计算用户对比损失 $L_{CL}^{(u)}$ 和物品对比损失 $L_{CL}^{(v)}$ 。最后，使用函数 $f(\cdot)$ 来完成用户-物品交互的预测。

最后，通过梯度下降迭代地细化参数，直到收敛，得到预测函数 F 。

通过整合上述步骤来估计算法的时间复杂度，公式如下：

$$O(C_{MF} + C_{SVD} + N \times (C_{CD}NN + L \cdot C_{agg}) + C_{grad}) \quad (4-19)$$

公式(4-19)中， L 表示网络的深度， C_{MF} 表示 MF 操作的时间复杂度， C_{SVD} 表示 SVD 操作的时间复杂度， C_{agg} 表示聚合操作的时间复杂度， C_{GNN} 表示在 GNN 中传递消息的时间复杂度， C_{grad} 表示执行梯度下降以更新参数的时间复杂度。

4.3 实验设计与分析

在本节中，为了确认 HMFGL 的有效性，进行了大量的实验验证。本章的实验基于三个公开的数据集 ML-100K、ModCloth 以及 LastFM。首先，介绍了本研究中使用的实验设置。随后，介绍详细实验分析。主要包括：对比实验、超参数探索实验、损失函数分析、消融实验。最后，将对实验进行总结。

4.3.1 实验设置

1) 实验环境

本章使用基于 pytorch^[50]开发的 RecBole 框架^[51-52]实现方法。RecBole 框架在第三章中已经介绍，这里不再赘述。

实验的运行环境配置有一台搭载 Intel(R) Core(TM) i7-6800k 3.40GHz CPU 和 8G RAM 的计算机。

2) 数据集

本章使用三个公开的数据集 ML-100K、ModCloth-1000 和 LastFM-1000 证明 HMFGL 的有效性。表 4-2 中提供了数据集的详细描述。

除第三章已经介绍过的 ML-100K 数据集和 ModCloth-1000 数据集以外, LastFM-1000 通过 LastFM 数据集预处理得到, 通过随机选择 1000 个用户及其相关物品得到了用于实验的数据集。LastFM 是推荐系统和音乐推荐研究中常用的数据集, 用于评估算法在涉及用户物品交互和稀疏数据的场景中的性能。该数据集主要包括用户收听记录的信息。

表 4-2 数据集描述

数据集	用户数量	物品数量	稀疏度
ML-100K	943	1682	93.70%
ModCloth-1000	1001	278	99.87%
LastFM-1000	1001	1192	99.72%

3) 数据预处理

为了对数据集进行分割, 按照 RecBole 的分割规则, 按照 7:3 分割为训练集和测试集。训练集用于模型训练, 而测试集用于训练模型后进行预测和推荐并计算推荐性能。

4) 参数设置

对于超参数设置, 将嵌入大小配置为 64, 并使用学习率为 0.001 的 Adam 优化器。L2 正则化系数设置为 0.00005, 网络层数设置为 2, 这是以前研究中常用的参数。自监督学习损失函数的系数设置为 0.003, 而噪声系数设置为 0.1。噪声比设置为 8:2 (高斯噪声: 均匀噪声), 矩阵分解的维数设置为 5, 最大奇异值数量为 5。后续章节将详细阐述关于单个超参数设置的进一步探索实验。

5) 评估指标

本章实验使用两个评估指标 Recall@k、NDCG@k 来评估方法性能。Recall 和 NDCG 在第三章中已经介绍, 在此不再赘述。

4.3.2 对比实验

表 4-3、表 4-4 和表 4-5 展示了与基线方法相比较的性能结果。基线方法在第三章中已经详细介绍过, 在此就不再赘述。将次优基线的结果用下划线标记, HMFGCL 的结果加粗标记。

表 4-3 ML-100K 数据集上的 Recall@k 和 NDCG@k 比较

ML-100K 数据集				
方法	Recall@10	Recall@20	NDCG@10	NDCG@20
DMF	0.1947	0.3060	0.3487	0.3552
GCMC	0.1639	0.2411	0.3041	0.2966
NGCF	0.1997	0.3121	0.1821	0.3637
EASE	0.1783	0.2486	0.2143	0.2527
LightGCN	0.1662	0.2507	0.3053	0.3012
ENMF	0.1659	0.2563	0.2991	0.2989
SimpleX	0.1831	0.2863	0.3375	0.3381
SGL	0.2037	0.3131	0.3809	0.3776
SimGCL	0.1057	0.1705	0.1451	0.1618
LightGCL	<u>0.2086</u>	<u>0.3223</u>	<u>0.3726</u>	<u>0.3743</u>
DirectAU	0.1209	0.1925	0.1712	0.1888
XSimGCL	0.1346	0.2197	0.2088	0.2231
DiffRec	0.2032	0.319	0.2196	0.2474
HMFGCL	0.2232	0.334	0.4034	0.4001

表 4-4 ModCloth-1000 数据集上的 Recall@k 和 NDCG@k 比较

ModCloth-1000 数据集				
方法	Recall@10	Recall@20	NDCG@10	NDCG@20
DMF	0.1553	0.2549	0.0801	0.1052
GCMC	0.1567	0.2578	0.0819	0.1071
NGCF	0.1837	0.2269	0.0837	0.1043
EASE	0.2045	0.2924	0.1144	0.1362
LightGCN	0.1425	0.2142	0.0795	0.0981
ENMF	0.1945	0.2877	0.1112	0.1349
SimpleX	0.2017	0.2579	0.1097	0.1245
SGL	0.061	0.1001	0.0305	0.0408
SimGCL	0.0617	0.1142	0.0296	0.0426
LightGCL	<u>0.2529</u>	<u>0.2957</u>	<u>0.1987</u>	<u>0.2096</u>
DirectAU	0.0621	0.1159	0.0415	0.0553
XSimGCL	0.1262	0.1844	0.0821	0.0974
DiffRec	0.2519	0.2905	0.1914	0.2048
HMFGCL	0.2785	0.3232	0.2206	0.2321

如表 4-3、表 4-4 和表 4-5 所示, HMFGCL 在三个公共数据集上的表现优于所有基线。

在 ML-100K 数据集上与次优基线 LightGCL 相比, HMFGCL 的 Recall@10 和 NDCG@10 的值分别上涨了 7.01%和 8.27%而 Recall@20 和 NDCG@20 值的提升分别为 3.63%和 6.89%。在 ModCloth-1000 数据集上的 Recall@10 和 NDCG@10 的值分别上涨了 10.12%和 11.02%而 Recall@20 和 NDCG@20 的值则分别上涨了 9.30%和 10.73%。在 LastFM-1000 数据集上的 Recall@10 和 NDCG@10 的值上涨幅度约为 10.24%和 7.85%而 Recall@20 和 NDCG@20 值的提升则约为 7.39%和 7.44%。这些结果体现了 HMFGCL 的优势。

表 4-5 LastFM 数据集上的 Recall@k 和 NDCG@k 比较

LastFM-1000 数据集				
方法	Recall@10	Recall@20	NDCG@10	NDCG@20
DMF	0.0678	0.1023	0.0793	0.0981
GCMC	0.1068	0.1526	0.1274	0.1527
NGCF	0.1441	0.2157	0.1691	0.2081
EASE	0.1718	0.2426	0.2065	0.2457
LightGCN	0.167	0.2355	0.2027	0.2406
ENMF	0.1645	0.2318	0.1974	0.2341
SimpleX	0.1323	0.2024	0.1416	0.1804
SGL	0.1719	0.2401	0.2075	0.245
SimGCL	0.032	0.0436	0.0382	0.0446
LightGCL	0.1679	0.2369	0.2025	0.2405
DirectAU	0.0882	0.1404	0.0979	0.1266
XSimGCL	0.1635	0.2384	0.2006	0.2421
DiffRec	<u>0.1812</u>	<u>0.2544</u>	<u>0.218</u>	<u>0.2583</u>
HMFGCL	0.1815	0.2544	0.2184	0.2584

作为在 DSGCL 基础上改进的方法, 实验同样证明 HMFGCL 的性能优于改进前的 DSGCL。在 ML-100K 数据集上, HMFGCL 的评估指标 Recall@10 和 NDCG@10 分别提升了 1.36%和 1%左右。Recall@20 和 NDCG@20 分别提升了 0.3%和 0.93%左右, 证明算法优化图增强方法后, 对于精确推荐是有一定提升的。

4.3.3 超参数探索实验

本节调整了几个超参数值来研究它们对所提出方法性能的影响。改变潜在向量的维数 k 和最大奇异值的数量 q 讨论这些因素如何影响方法的性能。改变图神经网络中的聚合层数讨论网络深度对性能的影响。调整嵌入维度的大小讨论嵌入大小对方法的影响。

1) 潜在向量维度的影响

该部分研究了潜在向量的维度对矩阵分解方法性能的影响。如表 4-6 和表 4-7 所示,在 ML-100K 和 LastFM-1000 数据集上进行实验观察方法性能的变化。数据显示,当潜在向量的维度为 5 时, HMFGL 达到了最佳性能。随着维度的逐渐增加, 方法的性能略有下降。

表 4-6 中的实验结果可以得出,当维度为 5 时方法达到了最佳性能。在 ML-100K 数据集上当维度为 5 时 Recall@10 和 Recall@20 的值分别为 0.2232 和 0.3351 而 NDCG@10 和 NDCG@20 的值分别是 0.4034 和 0.4008。随着维度增加到 10、15 和 20 时方法的性能表现出不同程度的降低。当维度为 10 时性能降低最为显著, Recall@10 和 Recall@20 的值分别为 0.2189 和 0.3322 而 NDCG@10 和 NDCG@20 的值分别是 0.3973 和 0.3963。

表 4-6 隐向量维度在 ML-100K 数据集上的实验结果

ML-100K 数据集				
隐向量维度	Recall@10	Recall@20	NDCG@10	NDCG@20
5	0.2232	0.3351	0.4034	0.4008
10	0.2189	0.3322	0.3973	0.3963
15	0.2201	0.3296	0.399	0.3959
20	0.2227	0.3319	0.4032	0.3977

表 4-7 隐向量维度在 LastFM-1000 数据集上的实验结果

LastFM-1000 数据集				
隐向量维度	Recall@10	Recall@20	NDCG@10	NDCG@20
5	0.1815	0.2544	0.2184	0.2584
10	0.1716	0.2419	0.2092	0.248
15	0.1719	0.2434	0.207	0.2459
20	0.1701	0.2438	0.2057	0.2459

表 4-7 中基于 LastFM-1000 数据集的实验结果可以得出相似的结论。当维度为 5 时方法表现最佳, Recall@10 和 Recall@20 的值分别为 0.1815 和 0.2544 而 NDCG@10 和 NDCG@20 的值分别是 0.2184 和 0.2584。随着维度的增加方法的性能降低。当为维度为 20 时性能最差。在这个维度下 Recall@10 和 Recall@20 的值分别为 0.1701 和 0.2438 而 NDCG@10 和 NDCG@20 的值分别是 0.2057 和 0.2459。

综上, 矩阵分解中较小的潜在向量维度能够捕获用户和项目的潜在特征。反而大的潜在向量维度可能会导致冗余信息随之增加产生更多的噪声降低方法的性能。所以矩阵分解中潜在向量的维度对方法性能其关键作用, 因为潜在向量维度的不同选择会对性能产生不同的影响。

2) 最大奇异值数量的影响

该部分探讨了 SVD 中奇异值数量对方法性能的影响。在 ML-100K 数据集和 LastFM-1000 数据集上进行实验观察了调整奇异值数量时方法性能的变化。如图 4-2 和图 4-3 所示, 方法性能随奇异值变化的趋势很明显。当奇异值的数量为 5 时, 方法的性能最佳。




图 4-2 ML-100K 数据集上最大奇异值数量的影响

在 ML-100K 数据集上, 如图 4-2 所示, 随着最大奇异值数量的增加模型性能曲线呈下降趋势。当最大奇异值的数量为 5 时方法达到了最佳性能, Rrecall@10 和 NDCG@10 的值分别为 0.2232 和 0.4034 而 Recall@20 和 NDCG@20 的值分别为 0.3351 和 0.4008。这表明增加最大奇异值的数量不一定能增强方法获得的有效信息反而可能会引入噪声干扰导致性能下降。




图 4-3 LastFM 数据集上最大奇异值数量的影响

在 LastFM-1000 数据集上, 如图 4-3 所示的曲线展现了类似的趋势。随着最大奇异值的数量增加到 20 时的 Recall@10 的值从 0.1815 减小到 0.1714 而 NDCG@10 的值从 0.2184 减小到 0.2098。Recall@20 和 NDCG@20 的值也出现明显的下降, Recall@20 的值从 0.2544 下降到 0.2492 而 NDCG@20 的值从 0.255 下降到 0.2503。这进一步证实了最大奇异值数量的选择对方法性能的影响。

综上, SVD 中最大奇异值的数量是影响 HMFGCL 性能的关键因素。选择适当数量的最大奇异值会显著增强模型性能而过多的奇异值可能会引入不相关的信息对方法的性能起负面作用。

3) 网络层数的影响

本实验研究了不同聚集层深度对该方法性能的影响。通过调整聚合层的数量, 观察到该方法在 ML-100K 数据集和 LastFM-1000 数据集上的性能变化, 分别如图 4-4 和图 4-5 所示。

如图 4-4 所示, 随着网络层数的变化方法的性能在 ML-100K 数据集上存在明显变化。当网络层数为 2 时 Recall@10 和 NDCG@10 达到的最大值分别为 0.2232 和 0.4034。在只有 1 层网络层的情况下 Recall@20 和 NDCG@20 达到的最大值分别为 0.3352 和 0.3996。随着网络层数的增加性能的降低变得越来越明显。当网络层数为 4 时 Recall@10 和 Recall@20 的值分别降低到 0.2194 和 0.3343 而 NDCG@10 和 NDCG@20 的值降低到 0.3994 和 0.399。




图 4-4 ML-100K 数据集上网络层数的影响




图 4-5 LastFM 数据集上网络层数的影响

在 LastFM-1000 数据集上,如图 4-5 所示,观察到的方法性能随网络层数变化的变化趋势与 ML-100K 数据集上类似。当网络层数为 2 时 Recall@10 和 NDCG@10 达到的最大值分别为 0.1815 和 0.2184。只有 1 层网络层的情况下 Recall@10 和 NDCG@10 的值分别为 0.1684 和 0.2028。随着网络层数的增加性能也会降低,当网络层数为 4 时 Recall@10 和 Recall@20 的值分别降低到 0.1713 和 0.2439 而 NDCG@10 和 NDCG@20 的值降低到 0.2115 和 0.2483。这表明随着推荐物品数量的增加,更复杂的网络结构可能会捕获冗余信息引入过多的噪声干扰或无关信息对性能产生负面作用。

综上,图神经网络中网络层数对推荐性能有一定的影响。选择合适的网络层数是提高方法性能的关键因素,过小或过大的网络层数通常都会对性能产生负面作用。

4) 嵌入维度的影响

本实验在 ML-100K 和 LastFM-1000 数据集上调整了方法中的嵌入维度,以观察

方法性能变化的趋势。如图 4-6 和图 4-7 中的评估指标曲线所示, 当嵌入维数为 64 时, 该方法达到了最佳性能。当嵌入维度增加或减少时, 性能会不同程度地恶化。

在 ML-100K 数据集上, 如图 4-6 所示, 曲线总体呈上升趋势。当嵌入维数增加到 64 时, 该方法达到最大性能, Recall@10 和 NDCG@10 分别达到 0.2232 和 0.4034, Recall@20 和 NDCG@20 分别达到 0.3363 和 0.4008。继续将维度增加到 128 会导致性能略有下降, Recall@10 和 NDCG@10 分别降至 0.2218 和 0.4033, Recall@20 和 NDCG@20 分别降至 0.3346 和 0.4001。在嵌入维度为 16 时观察到最小性能, 此时性能显著恶化, Recall@10 和 NDCG@10 分别仅达到 0.1583 和 0.287, Recall@20 和 NDCG@20 分别达到 0.2316 和 0.2821。




图 4-6 ML-100K 数据集上嵌入维度的影响

在 LastFM-1000 数据集上, 如图 4-7 所示, 评估指标曲线显示出类似的趋势。随着嵌入维度从 16 增加到 64 性能逐渐提高到最佳, Recall@10 的值从 0.074 提升到 0.1851 而 NDCG@10 的值从 0.0868 提升到 0.2184。当嵌入维度增加到 128 时性能略有下降, Recall@10 和 NDCG@10 的值分别降低至 0.1724 和 0.2077 而 Recall@20 和 NDCG@20 的值分别降低至 0.2417 和 0.2456。曲线的变化趋势表明适当的维度有助于捕获准确的交互信息。太小的维度缺乏收集足够信息的能力导致有用信息的丢失进而导致方法性能下降。过大的维度弥补了信息的不足但也面临着信息冗余的问题。冗余的信息会干扰方法识别关键信息的能力导致方法过度关注不相关数据从而降低性能。




图 4-7 LastFM-1000 数据集上嵌入维度的影响

综上，嵌入维度对基于图神经网络的推荐方法的性能有显著影响。过大或过小的嵌入维度都会降低推荐方法的性能。因此，选择合适的嵌入维数对提高方法性能具有积极作用。

4.3.4 损失函数分析

本实验研究了 ML-100K 和 LastFM-1000 数据集中损失值的变化，并进行了比较和分析，如图 4-8 所示。实验选择前 50 个训练轮次作为分析样本，同时选择次优基线 LightGCL 作为比较基准，观察损失值的收敛趋势。




图 4-8 两个数据集上损失函数的变化

在 ML-100K 数据集上，HMFGCL 表现出卓越的性能，与次优基线相比，下降趋

势略快, 损失值较低。这表明它具有出色的学习能力和改进的泛化能力。与 LightGCL 相比, HMFGCL 也呈现出有利的下降趋势, 尽管其损失值高于 HMFGCL。

在 ModCloth-1000 数据集上, HMFGCL 与次优基线相同, 也实现了较低的损失值。HMFGCL 和 LightGCL 都表现出同样优秀的下降趋势。这可能表明两种方法在 ModCloth-1000 数据集上都表现出了良好的泛化能力并有效地避免了过拟合。

综上, 损失函数的设计在基于图的对比学习推荐方法中很关键。更快的下降趋势和更低的损失值对于提高推荐方法的性能有正向的意义。如何构建模型架构并设计更合理的损失函数对于提高方法的性能至关重要。

4.3.5 数据集稀疏度分析

本节探讨了 HMFGCL 在三个不同数据集的不同稀疏度下的性能变化趋势。以不同比例分别从 ML-100K、ModCloth-1000 和 LastFM-1000 数据集中随机采样数据分析数据稀疏性对方法性能的影响。如图 4-9、图 4-10 和图 4-11 所示。观察三图性能变化趋势得出以下结论: 数据集的稀疏度对方法的性能有着显著的影响, 数据集的稀疏度越大, 方法的性能越差。随着数据集稀疏度的降低, 方法的性能会逐渐提升到正常水平。




图 4-9 ML-100K 数据集上稀疏度影响

在 ML-100K 数据集上, 如图 4-9 所示, 当数据集稀疏度为 0.3 (30%) 时方法性能最差, Recall@10 和 Recall@20 的值分别为 0.1079 和 0.1692 而 NDCG@10 和 NDCG@20 的值分别为 0.0736 和 0.0938, 这些值是很不理想的。随着数据集的稀疏度减小方法的性能逐渐提升。当数据集稀疏度为 0.7 (70%) 时 Recall@10 和 Recall@20

的值分别提升至 0.1553 和 0.2486 而 NDCG@10 和 NDCG@20 的值分别提升至 0.1814 和 0.2065。

在 ModCloth-1000 数据集上, 如图 4-10 所示, 数据集稀疏度为 0.3 (30%) 时方法性能最差, Recall@10 和 Recall@20 的值分别为 0.0723 和 0.1175 而 NDCG@10 和 NDCG@20 的值分别为 0.0382 和 0.0497。当数据集稀疏度为 0.7 (70%) 时性能显著提升, Recall@10 和 Recall@20 的值分别为 0.174 和 0.2312 而 NDCG@10 和 NDCG@20 的值分别为 0.1238 和 0.1381, 但相较于原数据集上的性能差距依然非常明显。




图 4-10 ModCloth-1000 数据集上稀疏度影响




图 4-11 LastFM-1000 数据集上稀疏度影响

如图 4-11 所示, 在 LastFM-1000 数据集上的结果显示了与前两个数据集相同的趋势, 数据集稀疏度为 0.5 (50%) 时的 R@10 和 R@20 仅分别为 0.1124 和 0.1733, N@10 和 N@20 分别为 0.0912 和 0.1164, 相较于原数据集稀疏度下的各个性能指标, 仅有 40%到 60%的数值, 差距明显。

由上述的实验结果可以表明,数据集的稀疏性会显著影响方法的性能,直观的反应了方法对可学习数据量的依赖性,较大的数据集稀疏度意味着数据集中反应用户和项目的交互信息少,从而方法所能学习的信息少,导致方法性能下降。因此,为了保证方法的性能,不应该忽视数据集稀疏度所带来的影响。

4.3.6 消融实验

本节研究了混合矩阵分解模块对 ML-100K 和 LastFM-1000 数据集上该方法性能的影响。如表 4-8 和表 4-9 所示,展示了三种变体之间的性能差异: HMFGCL-M (仅保留 MF 模块)、HMFGCL-S (仅保留 SVD 模块) 和 HMFGCL-R (两者均未保留)。

表 4-8 ML-100K 数据集上的消融实验

变体	ML-100K 数据集			
	Recall@10	Recall@20	NDCG@10	NDCG@20
HMFGCL-R	0.166	0.2505	0.3051	0.301
HMFGCL-M	0.2168	0.3287	0.395	0.3928
HMFGCL-S	0.2133	0.3283	0.3858	0.3862
HMFGCL	0.2232	0.334	0.4034	0.4

如表 4-8 所示, 总体而言, HMFGCL-M (仅保留 MF) 和 HMFGCL-S (仅保留 SVD) 都显示出了改进, 保留两者都实现了最大的性能, 表明该模块在 ML-100K 和 LastFM-1000 数据集上的有效性。在 ML-100K 数据集上, HMFGCL-R 的性能最低, Recall@10 和 Recall@20 分别仅为 0.166 和 0.2505, NDCG@10 和 NDCG@20 分别为 0.3051 和 0.301, 表明性能显著下降。相比之下, HMFGCL-M 和 HMFGCL-S 都显示出明显的改善, Recall@10 分别增加到 0.2168 和 0.2133, NDCG@10 分别提高到 0.395 和 0.3858。

如表 4-9 所示, LastFM-1000 数据集上的实验结果表明, HMFGCL-R 的指标显著降低, Recall@10 的值从 0.1815 降至 0.1669, NDCG@10 的值从 0.2184 降至 0.2026。此外, HMFGCL-M 和 HMFGCL-S 的性能也出现了显著降低, Recall@10 的值分别降至 0.1646 和 0.1728, NDCG@10 的值分别降至 0.1979 和 0.2086。由此可知, 算法采用的混合矩阵分解模块是有效的, 且对整合全局协作信息是有帮助的, 能够提高方法的性能。

表 4-9 LastFM 数据集上的消融实验

变体	LastFM-1000 数据集			
	Recall@10	Recall@20	NDCG@10	NDCG@20
HMFGCL-R	0.1669	0.2357	0.2026	0.2406
HMFGCL-M	0.1646	0.2321	0.1979	0.2351
HMFGCL-S	0.1728	0.2486	0.2086	0.25
HMFGCL	0.1815	0.2544	0.2184	0.2584

4.4本章小节

本章引入了 HMFGCL，方法融合了矩阵分解和奇异值分解技术，并且结合混合噪声扰动整合了全局协作信息。方法首先利用 MF 和 SVD 来捕获用户项目之间的全局协作信息，然后将二者所获取的信息进行融合，生成用于对比学习的增强视图。此外，通过在图神经网络的前向传播过程中引入混合噪声来提高嵌入表示的均匀性和质量。在三个公共数据集上进行的实验表明，与基线方法相比，HMFGCL 在特定场景中具有一定优势，特别是在小数据集上的表现。

5 总结和展望

5.1 总结

本文主要研究基于嵌入噪声扰动的深浅层图对比学习推荐模型和基于混合矩阵分解的图对比学习推荐模型。针对部分推荐场景下对比视图的生成容易丢失重要信息的问题,本文采用本地依赖加全局协作信息融合的方式创建对比视图,解决了信息丢失问题。并在主视图的生成过程中采用混合噪声扰动的方式,提高主视图嵌入表示的质量,从而获取更准确的用户偏好。最终,通过充分的实验证明了方法的有效性。

本文的第三章介绍了基于嵌入噪声扰动的深浅层图对比学习推荐模型。首先,基于用户与物品的评分交互矩阵进行低秩矩阵分解,获取全局协作信息嵌入表示。然后,在 GNN 的传播过程中,加入混合噪声进行特征扰动,得到主视图嵌入表示。接下来,将主视图嵌入表示与全局协作信息嵌入表示进行融合,得到对比视图嵌入表示。最后,将主视图嵌入表示作为主任务进行推荐,主视图嵌入表示与对比视图嵌入表示进行对比学习作为辅助任务。最后,在 ML-100K 和 ModCloth 两个公开的数据集上进行了充分的实验,结果证明该方法在性能上优于目前先进的方法,进而证明了该方法在部分推荐场景下的有效性。

本文的第四章介绍了基于混合矩阵分解的图对比学习推荐模型。该方法在第三章的方法的基础上对数据增强模块进行了优化。首先,基于用户与物品的评分交互矩阵分别进行低秩矩阵分解和奇异值分解,获取不同的全局协作信息嵌入表示。然后,在 GNN 传播过程中,加入混合噪声进行特征扰动,得到主视图嵌入表示。接下来,将获取的两部分不同的全局协作信息嵌入表示进行融合。然后将融合后的全局协作信息嵌入表示与主视图嵌入表示融合,得到融合了全局协作信息的对比视图嵌入表示。最后,进行主任务推荐与对比学习辅助任务。最后,在 ML-100K、ModCloth 和 LastFM 三个数据集上进行了充分的实验,结果证明 HMFGCL 在性能上由于目前先进的方法,并且在 DSGCL 的基础上有一定的提升,进而证明了该方法在部分推荐场景下的有效性。

5.2 展望

根据提出方法的局限性,在未来有几个值得探索的方向。突破数据集大小的限制

可以考虑设计更高效的对比学习框架来应对。例如采用分布式的对比学习策略将大规模数据集分割成多个子集，在每个子集上进行对比学习后将各子集的模型进行融合。还可以探索基于采样的对比学习方法，通过精心设计的数据采样策略来减少计算复杂度同时保持对比学习的有效性。在对比视图的生成和融合方面，可以探索更多创新的方法。可以设计多模态的对比学习框架，利用物品的文本、图像等多模态信息生成丰富的对比视图。还可以研究基于自适应的权重分配策略，根据不同的场景和任务动态地调整各个对比视图的重要性。结合生成对抗网络（GAN）的技术生成更具挑战性的对比样本也是不错的方向。冷启动问题方面，可以探索结合图神经网络与对比学习的新方法。可以利用图对比学习技术，通过对比不同的图结构或节点表示来增强模型的冷启动能力。还可以研究基于元学习（Meta-Learning）的策略，使模型能够快速适应新用户或新物品的特征。在实际应用方面，基于对比学习的推荐系统可以与领域特定的知识相结合，以提升推荐的质量。比如在电商推荐中可以结合用户的购买历史和浏览行为，设计更精准的对比学习策略。在社交媒体推荐中，可以结合用户的社会关系和动态内容，构建更复杂的对比视图。探索可解释的对比学习推荐模型也是一个重要的研究方向。

综上所述，基于对比学习的推荐系统在数据集效率、视图生成与融合、冷启动问题和实际应用等方面仍有很大的研究空间和潜力，值得进一步探索和挖掘。

参考文献

- [1] Ricci F, Rokach L, Shapira B. Introduction to recommender systems handbook[M]//Recommender systems handbook. Boston, MA: springer US, 2010: 1-35.
- [2] Wang X, He X, Wang M, et al. Neural graph collaborative filtering[C]//Proceedings of the 42nd international ACM SIGIR conference on Research and development in Information Retrieval. 2019: 165-174.
- [3] Chen L, Wu L, Hong R, et al. Revisiting graph based collaborative filtering: A linear residual graph convolutional network approach[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(01): 27-34.
- [4] Li X, Sun L, Ling M, et al. A survey of graph neural network based recommendation in social networks[J]. Neurocomputing, 2023, 549: 126441.
- [5] Sarkar J L, Majumder A, Panigrahi C R, et al. Tourism recommendation system: A survey and future research directions[J]. Multimedia tools and applications, 2023, 82(6): 8983-9027.
- [6] Yuan H, Hernandez A A. User cold start problem in recommendation systems: A systematic review[J]. IEEE access, 2023, 11: 136958-136977.
- [7] Jing M, Zhu Y, Zang T, et al. Contrastive self-supervised learning in recommender systems: A survey[J]. ACM Transactions on Information Systems, 2023, 42(2): 1-39.
- [8] 张明星, 张骁雄, 刘姗姗, 等. 利用知识图谱的推荐系统研究综述[J]. Journal of Computer Engineering & Applications, 2023, 59(4).
- [9] Alharbe N, Rakrouki M A, Aljohani A. A collaborative filtering recommendation algorithm based on embedding representation[J]. Expert Systems with Applications, 2023, 215: 119380.
- [10] Nguyen L V, Vo Q T, Nguyen T H. Adaptive KNN-based extended collaborative filtering recommendation services[J]. Big Data and Cognitive Computing, 2023, 7(2): 106.
- [11] Fareed A, Hassan S, Belhaouari S B, et al. A collaborative filtering recommendation framework utilizing social networks[J]. Machine Learning with Applications, 2023, 14: 100495.
- [12] Liu X, Yang Z, Cheng J. Music recommendation algorithms based on knowledge graph

-
- and multi-task feature learning[J]. Scientific Reports, 2024, 14(1): 2055.
- [13] Cui P, Yin B, Xu B. The application of social recommendation algorithm integrating attention model in movie recommendation[J]. Scientific Reports, 2023, 13(1): 16938.
- [14] Mao K, Zhu J, Xiao X, et al. UltraGCN: ultra simplification of graph convolutional networks for recommendation[C]//Proceedings of the 30th ACM international conference on information & knowledge management. 2021: 1253-1262.
- [15] Yang Y, Guan Z, Li J, et al. Interpretable and efficient heterogeneous graph convolutional network[J]. IEEE Transactions on Knowledge and Data Engineering, 2021, 35(2): 1637-1650.
- [16] Yang H, Li Z, Qi Y. Predicting traffic propagation flow in urban road network with multi-graph convolutional network[J]. Complex & Intelligent Systems, 2024, 10(1): 23-35.
- [17] Wang W, Xu Y, Feng F, et al. Diffusion recommender model[C]//Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2023: 832-841.
- [18] Wang C, Yu Y, Ma W, et al. Towards representation alignment and uniformity in collaborative filtering[C]//Proceedings of the 28th ACM SIGKDD conference on knowledge discovery and data mining. 2022: 1816-1825.
- [19] Yu J, Yin H, Li J, et al. Self-supervised multi-channel hypergraph convolutional network for social recommendation[C]//Proceedings of the web conference 2021. 2021: 413-424.
- [20] He Q, Li X, Cai B. Graph neural network recommendation algorithm based on improved dual tower model[J]. Scientific Reports, 2024, 14(1): 3853.
- [21] Meng X. Cross-domain information fusion and personalized recommendation in artificial intelligence recommendation system based on mathematical matrix decomposition[J]. Scientific Reports, 2024, 14(1): 7816.
- [22] 杨纪元, 马沐阳, 任鹏杰, 等. 基于自监督的预训练在推荐系统中的研究[J]. 《山东大学学报 (理学版)》, 2024, 59(7): 1-26.
- [23] Zhu Y, Xu Y, Liu Q, et al. An empirical study of graph contrastive learning[J]. arXiv preprint arXiv:2109.01116, 2021.
- [24] Hassani K, Khasahmadi A H. Contrastive multi-view representation learning on
-

-
- graphs[C]//International conference on machine learning. PMLR, 2020: 4116-4126.
- [25] Peng Z, Huang W, Luo M, et al. Graph representation learning via graphical mutual information maximization[C]//Proceedings of The Web Conference 2020. 2020: 259-270.
- [26] Zhu Y, Xu Y, Yu F, et al. Deep graph contrastive representation learning[J]. arXiv preprint arXiv:2006.04131, 2020.
- [27] Wu Z, Shu L, Xu Z, et al. Robust tensor graph convolutional networks via t-svd based graph augmentation[C]//Proceedings of the 28th ACM SIGKDD conference on knowledge discovery and data mining. 2022: 2090-2099.
- [28] Wu J, Wang X, Feng F, et al. Self-supervised graph learning for recommendation[C]//Proceedings of the 44th international ACM SIGIR conference on research and development in information retrieval. 2021: 726-735.
- [29] Qiu J, Chen Q, Dong Y, et al. Gcc: Graph contrastive coding for graph neural network pre-training[C]//Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining. 2020: 1150-1160.
- [30] Sun F Y, Hoffmann J, Verma V, et al. Infograph: Unsupervised and semi-supervised graph-level representation learning via mutual information maximization[J]. arXiv preprint arXiv:1908.01000, 2019.
- [31] You Y, Chen T, Sui Y, et al. Graph contrastive learning with augmentations[J]. Advances in neural information processing systems, 2020, 33: 5812-5823.
- [32] Zhu Y, Xu Y, Yu F, et al. Graph contrastive learning with adaptive augmentation[C]//Proceedings of the web conference 2021. 2021: 2069-2080.
- [33] Jin W, Liu X, Zhao X, et al. Automated self-supervised learning for graphs[J]. arXiv preprint arXiv:2106.05470, 2021.
- [34] Min X, Li W, Yang J, et al. Self-supervised graph neural network with pre-training generative learning for recommendation systems[J]. Scientific Reports, 2022, 12(1): 15882.
- [35] Zhou K, Wang H, Zhao W X, et al. S3-rec: Self-supervised learning for sequential recommendation with mutual information maximization[C]//Proceedings of the 29th ACM international conference on information & knowledge management. 2020: 1893-1902.
- [36] Wei Y, Wang X, Li Q, et al. Contrastive learning for cold-start
-

-
- recommendation[C]//Proceedings of the 29th ACM International Conference on Multimedia. 2021: 5382-5390.
- [37] Zheng M, Wang F, You S, et al. Weakly supervised contrastive learning[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 10042-10051.
- [38] Xia X, Yin H, Yu J, et al. Self-supervised graph co-training for session-based recommendation[C]//Proceedings of the 30th ACM international conference on information & knowledge management. 2021: 2180-2190.
- [39] Wang X, Qi G J. Contrastive learning with stronger augmentations[J]. IEEE transactions on pattern analysis and machine intelligence, 2022, 45(5): 5549-5560.
- [40] Qiu R, Huang Z, Yin H, et al. Contrastive learning for representation degeneration problem in sequential recommendation[C]//Proceedings of the fifteenth ACM international conference on web search and data mining. 2022: 813-823.
- [41] Xie X, Sun F, Liu Z, et al. Contrastive learning for sequential recommendation[C]//2022 IEEE 38th international conference on data engineering (ICDE). IEEE, 2022: 1259-1273.
- [42] Lin Z, Tian C, Hou Y, et al. Improving graph collaborative filtering with neighborhood-enriched contrastive learning[C]//Proceedings of the ACM web conference 2022. 2022: 2320-2329.
- [43] Yu J, Yin H, Xia X, et al. Are graph augmentations necessary? simple graph contrastive learning for recommendation[C]//Proceedings of the 45th international ACM SIGIR conference on research and development in information retrieval. 2022: 1294-1303.
- [44] Cai X, Huang C, Xia L, et al. LightGCL: Simple yet effective graph contrastive learning for recommendation[J]. arXiv preprint arXiv:2302.08191, 2023.
- [45] Chen J, Zhou J, Ma L. Gnncl: A graph neural network recommendation model based on contrastive learning[J]. Neural Processing Letters, 2024, 56(2): 45.
- [46] 袁琮淇, 刘渊, 刘静文. 基于混合采样的图对比学习推荐算法[J]. Application Research of Computers/Jisuanji Yingyong Yanjiu, 2023, 40(5).
- [47] 黄恒.结合注意力机制的图对比学习推荐方法[D].江西财经大学,2024.
- [48] Yang Y, Wu Z, Wu L, et al. Generative-contrastive graph learning for recommendation[C]//Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2023: 1117-1126.
-

-
- [49] Yu J, Xia X, Chen T, et al. XSimGCL: Towards extremely simple graph contrastive learning for recommendation[J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 36(2): 913-926.
- [50] Imambi S, Prakash K B, Kanagachidambaresan G P T. In Programming with TensorFlow: Solution for Edge Computing Applications[J]. 2021.
- [51] Zhao W X, Mu S, Hou Y, et al. Recbole: Towards a unified, comprehensive and efficient framework for recommendation algorithms[C]//proceedings of the 30th acm international conference on information & knowledge management. 2021: 4653-4664.
- [52] Zhao W X, Hou Y, Pan X, et al. RecBole 2.0: towards a more up-to-date recommendation library[C]//Proceedings of the 31st ACM International Conference on Information & Knowledge Management. 2022: 4722-4726.
- [53] Xue H J, Dai X, Zhang J, et al. Deep matrix factorization models for recommender systems[C]//IJCAI. 2017, 17: 3203-3209.
- [54] Berg R, Kipf T N, Welling M. Graph convolutional matrix completion[J]. arXiv preprint arXiv:1706.02263, 2017.
- [55] Steck H. Embarrassingly shallow autoencoders for sparse data[C]//The World Wide Web Conference. 2019: 3251-3257.
- [56] He X, Deng K, Wang X, et al. Lightgcn: Simplifying and powering graph convolution network for recommendation[C]//Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval. 2020: 639-648.
- [57] Chen C, Zhang M, Zhang Y, et al. Efficient neural matrix factorization without sampling for recommendation[J]. ACM Transactions on Information Systems (TOIS), 2020, 38(2): 1-28.
- [58] Mao K, Zhu J, Wang J, et al. SimpleX: A simple and strong baseline for collaborative filtering[C]//Proceedings of the 30th ACM International Conference on Information & Knowledge Management. 2021: 1243-1252.
- [59] Xia L, Huang C, Xu Y, et al. Hypergraph contrastive collaborative filtering[C]//Proceedings of the 45th International ACM SIGIR conference on research and development in information retrieval. 2022: 70-79.
- [60] 朱志国, 李伟阴, 姜盼, 等. 图神经网络会话推荐系统综述[J]. Journal of Computer Engineering & Applications, 2023, 59(5).
-

- [61] 孟祥福, 霍红锦, 张霄雁, 等. 个性化新闻推荐方法研究综述[J]. *Journal of Frontiers of Computer Science & Technology*, 2023, 17(12).
- [62] Wang, W., Xu, Y., Feng, F., Lin, X., He, X., & Chua, T. S. (2023, July). Diffusion recommender model. In *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval* (pp. 832-841).

附录一 表目录

表 3-1	本章中使用的符号	12
表 3-2	数据集描述	19
表 3-3	ML-100K 数据集上的 Recall@k 和 NDCG@k 比较	21
表 3-4	ModCloth-1000 数据集上的 Recall@k 和 NDCG@k 比较	22
表 4-1	本章使用的符号	31
表 4-2	数据集描述	38
表 4-3	ML-100K 数据集上的 Recall@k 和 NDCG@k 比较	39
表 4-4	ModCloth-1000 数据集上的 Recall@k 和 NDCG@k 比较	39
表 4-5	LastFM 数据集上的 Recall@k 和 NDCG@k 比较	40
表 4-6	隐向量维度在 ML-100K 数据集上的实验结果	41
表 4-7	隐向量维度在 LastFM-1000 数据集上的实验结果	41
表 4-8	ML-100K 数据集上的消融实验	49
表 4-9	LastFM 数据集上的消融实验	50

附录二图目录

图 2-1	基于内容的推荐.....	7
图 2-2	基于结构增强的数据增强.....	9
图 2-3	基于特征增强的数据增强.....	10
图 3-1	DSGCL 的整体架构.....	13
图 3-2	三视图对比学习范式.....	16
图 3-3	隐向量维度对 DSGCL 在 ML-100K 数据集上性能的影响.....	23
图 3-4	噪声比例对 DSGCL 在 ML-100K 数据集上性能的影响	24
图 3-5	网络层数对 DSGCL 在 ML-100K 数据集上性能的影响	25
图 3-6	嵌入维度对 DSGCL 在 ML-100K 数据集上性能的影响	26
图 3-7	两个数据集上损失函数变化.....	27
图 3-8	数据集稀疏度对 DSGCL 性能的影响.....	28
图 3-9	消融实验结果.....	28
图 4-1	HMFGCL 的整体架构	32
图 4-2	ML-100K 数据集上最大奇异值数量的影响.....	42
图 4-3	LastFM 数据集上最大奇异值数量的影响	43
图 4-4	ML-100K 数据集上网络层数的影响.....	44
图 4-5	LastFM 数据集上网络层数的影响	44
图 4-6	ML-100K 数据集上嵌入维度的影响.....	45
图 4-7	LastFM-1000 数据集上嵌入维度的影响	46
图 4-8	两个数据集上损失函数的变化.....	46
图 4-9	ML-100K 数据集上稀疏度影响.....	47
图 4-10	ModCloth-1000 数据集上稀疏度影响	48
图 4-11	LastFM-1000 数据集上稀疏度影响	48